

INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DE GOIÁS
CAMPUS ANÁPOLIS
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

Wagner Oliveira de Araujo

MIGRAÇÃO DE SISTEMAS LEGADOS DE ANÁLISE QUÍMICA: DE JAVA DESKTOP PARA PYTHON WEB

Anápolis
2026

Wagner Oliveira de Araujo

MIGRAÇÃO DE SISTEMAS LEGADOS DE ANÁLISE QUÍMICA: DE JAVA DESKTOP PARA PYTHON WEB

Trabalho de Conclusão de Curso II do Bacharelado em Ciência da Computação do Instituto Federal de Educação, Ciência e Tecnologia de Goiás – Campus Anápolis para a aprovação da disciplina de TCC II.

Orientador: Profº. Alexandre Bellezi Jose, Me.

Coorientador: Profº. Eder Silva deBrito, Dr

Anápolis
2026

Wagner Oliveira de Araujo

MIGRAÇÃO DE SISTEMAS LEGADOS DE ANÁLISE QUÍMICA: DE JAVA DESKTOP PARA PYTHON WEB

Este Trabalho de Conclusão de Curso II foi julgado adequado para obtenção do Título de "bacharel" e aprovado em sua forma final pelo Bacharelado em Ciência da Computação.

Anápolis, [dia] de [mês] de 2026.

Prof. Hugo Vinicius Leão e Silva, Dr.
Coordenador do Curso

Banca Examinadora:

Prof^{o}. Alexandre Bellezi Jose, Me.
Orientador

Prof^{a}. Luiz Fernando Loja, Dr.
Avaliador Interno
Instituto Federal de Goiás (IFG)

Prof. Ermiliano Nelson, Dr.
Avaliador Externo
Universidade Federal de Goiás (UFG)

Se você for receptivo e humilde, a matemática o conduzirá pela mão. Repetidas vezes, quando estive perdido sem saber como prosseguir, bastou-me esperar até sentir que a matemática me guiava pela mão. Ela me conduziu por um caminho inesperado, um caminho onde novas perspectivas se abrem, um caminho que leva a um território novo, onde é possível estabelecer uma base de operações, a partir da qual se pode observar os arredores e planejar o progresso futuro.

(Paul Dirac)

RESUMO

Os resultados revelam que não existe uma técnica universalmente superior: o RLM-*subagging* apresentou melhor desempenho para Mn e Ni, o RLM-*bagging* mostrou-se superior para Fe, enquanto a RLM clássica demonstrou desempenho superior para Mo e Cr. O comportamento diferenciado entre os analitos é atribuído à complexidade espectral de cada elemento: o Fe, por apresentar maior densidade de linhas espectrais com potencial de autoabsorção e sobreposições com outros elementos da matriz, beneficia-se da agregação de múltiplos modelos. Em contrapartida, Mn, Mo, Cr e Ni têm sua relação espectral-concentração suficientemente capturada pela RLM clássica ou pelo RLM-*subagging*, sem ganho adicional com o RLM-*bagging*. Todos os modelos apresentaram R^2 superior a 0,9815, evidenciando elevada capacidade preditiva. Quanto à eficiência computacional, o RLM-*subagging* mostrou-se em média 3,0 vezes mais rápido que o RLM-*bagging*, configurando-se como alternativa equilibrada entre precisão e eficiência em aplicações quimiométricas sujeitas a restrições temporais.

Palavras-chave: Técnicas de reamostragem. Validação de Modelos. *Bagging*. *Subagging*. Quimiometria.

ABSTRACT

The results reveal that no universally superior technique exists: RLM-*subagging* achieved the best performance for Mn and Ni, RLM-*bagging* proved superior for Fe, while classical MLR demonstrated superior performance for Mo and Cr. The differentiated behavior among analytes is attributed to the spectral complexity of each element: Fe, due to its higher density of spectral lines with self-absorption potential and overlaps with other matrix elements, benefits from the aggregation of multiple models. In contrast, Mn, Mo, Cr and Ni have their spectral-concentration relationship sufficiently captured by classical MLR or MLR-*subagging*, with no additional gain from MLR-*bagging*. All models presented R^2 values above 0.9815, evidencing high predictive capacity. Regarding computational efficiency, MLR-*subagging* proved on average 3.0 times faster than MLR-*bagging*, establishing itself as a balanced alternative between accuracy and efficiency in chemometric applications subject to time constraints.

Keywords: Resampling. Multivariate Calibration. Bagging. Subagging. Chemometrics.

LISTA DE FIGURAS

Figura 1 – Exemplo do método *bootstrap*. 19
Figura 2 – Processo de amostragem aleatória. 22
Figura 3 – Reamostragem com agregação de modelos de regressão. 25
Figura 4 – Regressão Linear Múltipla via pseudoinversa (`BaggingOptimized.java`). 31
Figura 5 – Ensemble de Bagging/Subagging (`BaggingOptimized.java`). 32
Figura 6 – Espectros médios dos analitos analisados. 33
Figura 7 – RMSEP com RLM para Mn e Fe. 37
Figura 8 – RMSEP em função do número de replicações *bootstrap* para RLM-*bagging*. 38
Figura 9 – RMSEP para o Mn e Fe com RLM-*bagging*. 39
Figura 10 – RMSEP em função das replicações *bootstrap* para RLM-*subagging*. 41
Figura 11 – RMSEP do Mn e Fe com *subagging*. 42
Figura 12 – Tempo de execução dos algoritmos RLM, RLM-*bagging* e RLM-*subagging*. 44
Figura 13 – RMSEP para todas as técnicas. 45
Figura 14 – Tempo de execução dos algoritmos RLM-*bagging* e RLM-*subagging* com parâmetros otimizados por validação cruzada 5-*fold*. 47
Figura 15 – Execução de Análise Completa. 51
Figura 16 – Arquitetura em camadas — Sistema legado (Java Desktop) 81
Figura 17 – Arquitetura em camadas — Sistema modernizado (Python/Streamlit) 81
Figura 18 – Diagrama de classes. 82
Figura 19 – Diagrama de atividades. 83
Figura 20 – Diagrama de sequência. 84
Figura 21 – Diagrama de atividade PlantUML. 85
Figura 22 – Diagrama de atividade PlantUML. 86
Figura 23 – Diagrama de classes (módulos) PlantUML. 87
Figura 24 – Diagrama de sequência PlantUML. 88

LISTA DE QUADROS

Quadro 1 – Características comparativas entre *bagging* e *subagging*. 28
Quadro 2 – Dimensões dos conjuntos de dados para diferentes elementos. 34
Quadro 3 – Inventário das funções do sistema 49
Quadro 4 – Entradas necessárias para execução do sistema. 50
Quadro 5 – Saídas esperadas do sistema 50
Quadro 6 – Requisitos essenciais do sistema 51
Quadro 7 – Requisitos desejáveis do sistema 51
Quadro 8 – Requisitos extras para fases futuras 52
Quadro 9 – Fluxos alternativos e tratamento de exceções 52
Quadro 10 – Pontos críticos de usabilidade e estratégias de mitigação 53
Quadro 11 – Requisitos de performance do sistema 53
Quadro 12 – Requisitos de usabilidade do sistema 54
Quadro 13 – Requisitos de segurança do sistema 54
Quadro 14 – Requisitos de escalabilidade do sistema 55
Quadro 15 – Requisitos funcionais do sistema 57
Quadro 16 – Requisitos não funcionais do sistema 58

LISTA DE TABELAS

Tabela 3 – O coeficiente de variação. 21
Tabela 4 – RMSEP por analito obtido via RLM para amostras de aço-ligas. 37
Tabela 5 – RMSEP da RLM e RLM-*bagging* para cada elemento de aço-ligas. 40
Tabela 6 – RMSEP por elemento de aço-ligas comparando RLM e RLM-*subagging*. . . 41
Tabela 7 – Comparação do RMSEP por elemento para diferentes técnicas e proporções de calibração. 41
Tabela 8 – Configuração de desempenho superior e RMSEP mínimo. 42
Tabela 9 – Desempenho comparativo das técnicas de calibração multivariada para elementos químicos em aço-liga. 46
Tabela 10 – Paridade Bagging – Cr 70
Tabela 11 – Paridade *Bagging* – Fe 89
Tabela 12 – Paridade *Bagging* – Mn 90
Tabela 13 – Paridade *Bagging* – Ni 91
Tabela 14 – Paridade *Bagging* – Mo 91
Tabela 15 – Paridade *RLM* – Cr 92
Tabela 16 – Paridade *RLM* – Mo 93
Tabela 17 – Paridade *Subagging* – Cr 94
Tabela 18 – Paridade *RLM* – Fe 95
Tabela 19 – Paridade *RLM* – Ni 96
Tabela 20 – Paridade *RLM* – Mn 97
Tabela 21 – Paridade *Subagging* – Fe 98
Tabela 22 – Paridade *Subagging* – Mo 99
Tabela 23 – Paridade *Subagging* – Mn 100
Tabela 24 – Paridade *Subagging* – Ni 101

LISTA DE ABREVIATURAS E SIGLAS

LASSO	*Least Absolute Shrinkage and Selection Operator*
MAE	*Mean Absolute Error*
PLS	*Partial Least Squares*
RLM	Regressão Linear Múltipla
RMSEP	*Root-Mean-Square Error of Prediction*
RMSEP-CV	*Root-Mean-Square Error of Prediction in Cross-Validation*

LISTA DE SÍMBOLOS

y	Variável dependente (concentração do analito)
y^i	Concentração do analito para a i-ésima amostra
γ	Função estatística aplicada às amostras *bootstrap*
$\mathbf{x}_{al}$	Vetor de observações de uma amostra aleatória
$t(\mathbf{d})$	Função ou método avaliativo aplicado à distribuição de probabilidade d
x^*	Amostra *bootstrap* individual
$\widehat{\theta}^*$	Estimativa *bootstrap* do parâmetro θ
m	Número de replicações *bootstrap*
$\widehat{se}$	Erro padrão estimado (*estimated standard error*)
Δ	Parâmetro que mede o tamanho da distribuição empírica estimada usando amostras *bootstrap*
$\mathbf{u}$	Amostra aleatória formada por n unidades selecionadas
$\mathbf{v}$	População finita de referência
x_i	Resposta instrumental em um canal analítico para a i-ésima amostra
$\mathbf{x}$	Vetor de dados de dimensão 1 por J
x_{al}	Variável aleatória escalar (resultado de um experimento aleatório)
f_k	k-ésima frequência probabilística
$\mathbf{f}$	Vetor de frequências probabilísticas
BI(n, p)	Distribuição binomial de tamanho n e probabilidade de sucesso p
μ	Média populacional
σ^2	Variância populacional
$N(\mu, \sigma^2)$	Distribuição normal com média μ e variância σ ao quadrado
$E(x)$	Valor esperado (expectativa) de uma variável aleatória x
$E_{\mathbf{f}}(x)$	Expectativa de x sob o vetor de frequências f
y_{cal}	Variável aleatória de calibração
z_{cal}	Variável aleatória auxiliar de calibração
$g(y_{cal})$	Função g aplicada sobre y de calibração
$h(z_{cal})$	Função h aplicada sobre z de calibração
$\mathbf{d}$	Função de distribuição de probabilidade
$\widehat{\mathbf{d}}$	Função de distribuição empírica
$\mathbf{X}_{cal}$	Matriz de respostas instrumentais em J canais analíticos para as M amostras de calibração
$\mathbf{Y}_{cal}$	Vetor de concentrações do analito para as M amostras de calibração
$\mathbf{X}_{teste}$	Matriz de respostas instrumentais teste para os elementos Mn, Mo, Cr, Ni e Fe
$\mathbf{y}_{teste}$	Vetor de respostas instrumentais teste para os elementos Mn, Mo, Cr, Ni e Fe

SUMÁRIO

1 INTRODUÇÃO 14
2 REVISÃO DA LITERATURA 17
2.1 Regressão Linear Múltipla 17
2.1.1 Estimação dos Coeficientes 17
2.1.2 Premissas e Métodos Robustos 18
2.2 A Técnica de *Bootstrap* 18
2.2.1 *Bootstrap* 19
2.2.2 Estimativa *Bootstrap* 19
2.2.3 O Número de Replicações *Bootstrap* m 20
2.3 Reamostragem Aleatória 21
2.4 Teoria da Probabilidade 22
2.5 Função de Distribuição Empírica 24
2.6 Princípio *Plug-in* 24
2.7 Técnicas Clássicas de Reamostragem 25
2.7.1 *Bagging* 26
2.7.2 *Subagging* 27
2.7.3 Comparação entre *Bagging* e *Subagging* 28
2.8 Fundamentos de Engenharia de Migração e Qualidade de Software 28
3 MATERIAIS E MÉTODOS 30
3.1 Fragmento do Código-Fonte Java — Núcleo Algorítmico 30
3.2 Amostras de Aço-Ligas 33
3.3 Protocolo de Validação e Seleção de Hiperparâmetros 34
3.4 Medida do Erro Médio Quadrático de Predição 35
4 RESULTADOS E DISCUSSÕES 37
4.1 *Bagging* 38
4.2 *Subagging* 40
4.3 *Bagging* $\times$ *Subagging* 44
5 REQUISITOS FUNCIONAIS 49
5.1 Levantamento de Requisitos Funcionais 49
5.1.1 Inventário das Funcionalidades Existentes 49
5.1.1.1 Funções do Sistema 49
5.1.1.2 Entradas Necessárias (Inputs) 50
5.1.1.3 Saídas Esperadas (Outputs) 50
5.1.2 Classificação por Prioridade 50
5.1.2.1 Essenciais (*Must Have*) 50
5.1.2.2 Desejáveis (*Should Have*) 51
5.1.2.3 Extras (*Could Have*) 51

5.1.3 Fluxos de Uso . . . 51
5.1.3.1 Fluxo Principal: Execução de Análise Completa . . . 51
5.1.3.2 Fluxos Alternativos e Tratamento de Exceções . . . 52
5.1.3.3 Pontos Críticos de Usabilidade . . . 53
5.1.4 Requisitos Não Funcionais . . . 53
5.1.4.1 Performance . . . 53
5.1.4.2 Usabilidade . . . 54
5.1.4.3 Segurança . . . 54
5.1.4.4 Escalabilidade . . . 55
5.2 Considerações Finais do Levantamento . . . 55
6 ENGENHARIA DE SOFTWARE E MODERNIZAÇÃO . . . 56
6.1 Engenharia de Requisitos com Sommerville . . . 56
6.2 Especificação de Requisitos Funcionais e Não Funcionais . . . 56
6.2.1 Requisitos Funcionais . . . 57
6.2.2 Requisitos Não Funcionais . . . 57
6.3 Estratégias de Migração de Sistemas . . . 58
6.4 Mudança de Paradigma Arquitetural . . . 59
7 ECOSSISTEMA DE DESENVOLVIMENTO (PYTHON E STREAMLIT) 61
7.1 Python na Computação Científica . . . 61
7.2 Ciclo de Vida do Streamlit . . . 62
7.3 Gerenciamento de Memória e Performance . . . 62
7.4 IDEs e Ambiente de Desenvolvimento . . . 63
8 INTERFACE E EXPERIÊNCIA DO USUÁRIO (UI/UX) CIENTÍFICA . 64
8.1 Design Centrado em Dados . . . 64
8.2 Visualização Interativa com Plotly . . . 65
8.3 Contratos de Interface e Funções . . . 65
9 DESENVOLVIMENTO ITERATIVO POR SPRINTS E VALIDAÇÃO POR TESTES AUTOMATIZADOS . . . 67
9.1 Metodologia Ágil: Desenvolvimento por Sprints . . . 67
9.2 Suíte de Testes Automatizados com pytest . . . 68
10 CONCLUSÃO . . . 71
REFERÊNCIAS . . . 73
APÊNDICE A – TESTES DE GRÁFICOS . . . 81
A.1 Diagrama de Arquitetura em Camadas — Java e Python . . . 81
A.2 Diagrama de Classes — Java . . . 82
A.3 Diagrama de Atividade — Java . . . 83
A.4 Diagrama de Sequência — Java . . . 84
A.5 Diagrama de Atividades — Java (PlantUML) . . . 85
A.6 Diagrama de Atividades — Streamlit . . . 86

A.7 Diagrama de Classes (Módulos) — Streamlit 87
A.8 Diagrama de Sequência — Streamlit 88
APÊNDICE B – TABELAS DE PARIDADE AMOSTRA-A-AMOSTRA — JAVA × PYTHON 89

1 INTRODUÇÃO

A calibração multivariada desempenha um papel fundamental em diversas áreas da análise química e industrial, permitindo a extração de informações valiosas de dados complexos. No contexto específico da análise de aço-ligas, a determinação precisa da composição elementar (Mn, Cr, Mo, Ni, Fe) é crucial para garantir a qualidade e as propriedades desejadas do material. No entanto, a complexidade dos dados multivariados provenientes de métodos instrumentais de análise exige o uso de técnicas estatísticas avançadas para obter resultados confiáveis.

Este estudo investiga, em caráter exploratório, a aplicação de técnicas de reamostragem (*bootstrap*), *bagging* e *subagging* na Regressão Linear Múltipla (RLM) para a calibração multivariada de amostras de aço-ligas. A pesquisa busca preencher a lacuna de conhecimento sobre a aplicação dessas técnicas de *ensemble* nesse contexto específico, contribuindo tanto para o avanço da quimiometria quanto para a modernização de sistemas computacionais de apoio à análise de aço-ligas (1, 2, 3).

Como otimizar a calibração multivariada de amostras de aço-ligas para obter previsões mais precisas dos elementos Mn, Cr, Mo, Ni e Fe, considerando a complexidade inerente à análise de dados multivariados, a necessidade de alta precisão e a exigência de uma arquitetura de software confiável e testável para sustentar essa análise?

Este estudo é significativo tanto pelo potencial de impacto prático na análise de aço-ligas quanto pela contribuição metodológica em engenharia de software: a condução de uma migração de sistema legado (Java Desktop, Vaadin Flow e Python/Streamlit) validada, em cada etapa, por uma suíte de testes automatizados que funciona como oráculo de equivalência entre implementações. Essa estratégia evidencia, de forma reprodutível, como preservar a corretude de um núcleo algorítmico crítico durante a reescrita completa de uma arquitetura de software.

A originalidade da pesquisa é dupla. No eixo quimiométrico, reside na aplicação de técnicas de *bagging* e *subagging*, ainda pouco exploradas na análise de aço-ligas. No eixo de engenharia de software, reside na condução de uma reescrita *black-box* em três estágios (Desktop Java, Web Vaadin/Spring, Python/Streamlit), com arquitetura final desacoplada em três módulos de responsabilidade única e validação por 92 testes automatizados, que verificam a equivalência numérica do núcleo determinístico (RLM) e a consistência estatística dos métodos estocásticos entre o sistema legado e o sistema reescrito.

Dado o conjunto amostral reduzido — característica inerente à aquisição dos dados espectrométricos utilizados —, os resultados devem ser interpretados como evidências preliminares do comportamento dessas técnicas nesse domínio, e não como afirmações definitivas de superioridade geral de um método sobre outro.

Analisar e comparar o desempenho das técnicas de *bagging* e *subagging* aplicadas à Regressão Linear Múltipla (RLM) na calibração multivariada de dados de amostras de aço-ligas, investigando, em caráter exploratório, tanto o comportamento preditivo quanto a eficiência computacional de cada abordagem, a partir de uma arquitetura de software desenvolvida de

forma incremental e validada a cada etapa da migração.

Esta pesquisa tem como objetivos específicos:

a) Aplicar as técnicas de reamostragem *bootstrap*, *bagging* e *subagging* na calibração de dados espectrométricos de amostras de aço-ligas, empregando a Regressão Linear Múltipla (RLM) como modelo base, com vistas ao desenvolvimento de uma metodologia analítica robusta (4, 5).

b) Realizar uma comparação sistemática entre os algoritmos RLM clássica, RLM-*bagging* e RLM-*subagging*, por meio da avaliação criteriosa da acurácia preditiva e da eficiência computacional de cada abordagem na análise quantitativa dos elementos Mn, Cr, Mo, Ni e Fe.

c) Reaproveitar, em Java (JavaSE-17), o sistema Desktop de calibração multivariada com RLM-*bagging* e RLM-*subagging* — desenvolvido na disciplina de Programação Orientada a Objetos, com arquitetura *Model-View-Controller* (MVC) (6, 7), biblioteca *Efficient Java Matrix Library* (EJML)[1] e interface Swing/[2] —, consolidando-o como base algorítmica validada do TCC I.

d) Migrar a base algorítmica reaproveitada no TCC I para uma interface web em Vaadin Flow, como estágio intermediário, e concluir, no TCC II, a reescrita completa do sistema em Python/Streamlit, com arquitetura modular em três camadas e validação por suíte de testes automatizados.

Essa trajetória escalonada — sistema Desktop em Java, estágio intermediário em Vaadin Flow e reescrita final em Python/Streamlit — evitou a substituição simultânea de arquitetura e lógica de negócio. Cada etapa da migração permitiu verificar a equivalência comportamental do núcleo algorítmico antes de avançar para a seguinte, consolidando-se, neste TCC II, na suíte de testes automatizados que compara as duas implementações.

A validação da lógica de negócio migrada é realizada, neste TCC II, por meio de uma suíte de testes automatizados (`test_suite_5.py`), composta por 21 testes unitários, 60 testes de caixa-preta que comparam as métricas das implementações Java e Python para os cinco analitos (Mn, Mo, Cr, Ni, Fe) e 11 testes de estresse sobre matrizes de grande porte. Esse protocolo funciona como oráculo de equivalência entre o sistema legado e o sistema reescrito em dois níveis: equivalência numérica estrita para a RLM determinística e consistência estatística, dentro de tolerâncias explícitas, para o *bagging* e o *subagging*, cujas sequências pseudoaleatórias diferem entre as duas linguagens.

[1] A biblioteca *Efficient Java Matrix Library* (EJML) é uma biblioteca de código aberto para a linguagem Java projetada para a manipulação e computação de matrizes lineares de forma extremamente rápida e com baixo uso de memória.

[2] A *Abstract Window Toolkit* (AWT) é a biblioteca nativa e original do Java criada para desenvolver interfaces gráficas de usuário (*Graphical User Interface* - GUI), como janelas, botões e menus.

Este trabalho está organizado da seguinte forma. A Seção 2 apresenta a revisão da literatura sobre a Regressão Linear Múltipla (RLM), a técnica de reamostragem *bootstrap* e os conceitos de distribuição empírica e princípio *plug-in*, essenciais à compreensão das abordagens investigadas. A Seção 2.7 descreve as técnicas de *bagging* e *subagging*, incluindo fundamentos teóricos e algoritmos.

A Seção 3 caracteriza o conjunto de dados espectrométricos de aço-ligas, descreve a arquitetura do sistema Python/Streamlit concluído — separado em `models.py`, `components.py` e `app.py` — e o protocolo de validação cruzada adotado, além de apresentar as métricas RMSEP[3] , MAE[4] e R^2[5] empregadas na avaliação da acurácia preditiva e na verificação da equivalência comportamental do sistema.

Na Seção 4, são analisados os resultados obtidos com os algoritmos RLM clássica, RLM-*bagging* e RLM-*subagging*, com base nos valores de RMSEP, MAE e R^2 e nos tempos de execução computacional, além dos resultados da suíte de testes automatizados. Por fim, a Seção 10 sintetiza as principais conclusões do estudo e discute limitações e extensões futuras do sistema.

[3] O *Root Mean Squared Error of Prediction* (RMSEP), ou Raiz do Erro Quadrático Médio de Previsão, mede a acurácia de um modelo calculando a raiz quadrada da média dos erros elevados ao quadrado, penalizando de forma mais severa os grandes desvios.

[4] O *Mean Absolute Error* (MAE), ou Erro Médio Absoluto, é uma métrica que calcula a média das magnitudes dos erros em um conjunto de previsões, sem considerar suas direções (sinais positivos ou negativos).

[5] O Coeficiente de Determinação (R^2), também conhecido como *R-squared*, é uma medida estatística que indica a proporção da variância da variável dependente que é explicável pelas variáveis independentes do modelo.

2 REVISÃO DA LITERATURA

Esta seção apresenta a Regressão Linear Múltipla (RLM) e a técnica *bootstrap*. Adicionalmente, são abordados conceitos como a teoria da probabilidade, distribuição empírica, princípio *plug-in* e técnicas clássicas de reamostragem, fundamentais para a compreensão.

2.1 Regressão Linear Múltipla

A RLM é uma técnica estatística empregada para modelar a relação linear entre uma variável dependente (resposta) (y) e duas ou mais variáveis independentes (preditoras) ($\mathbf{X}$). O modelo, que inclui um termo de intercepto (β_0) e um termo de erro (ε), é formalizado como:

$$y = \beta_0 + x_1\beta_1 + x_2\beta_2 + \ldots + x_n\beta_n + \varepsilon \tag{1}$$

onde $\beta_j \in \mathbb{R}$ representa o coeficiente angular de cada preditor x_j, para $j = 1, 2, \ldots, n$.

Dispondo de um conjunto de M dados de calibração $\{(x^i, y^i), \quad i = 1, 2, \ldots, M\}$, o modelo pode ser expresso na forma matricial:

$$\mathbf{y} = \mathbf{X}\beta + \varepsilon \tag{2}$$

onde o vetor de resposta $\mathbf{y}$ e a matriz de calibração $\mathbf{X}$ (incluindo a coluna de uns para o intercepto) são definidos por:

$$\mathbf{X} = \begin{bmatrix} 1 & x_1^1 & x_2^1 & \ldots & x_n^1 \\ 1 & x_1^2 & x_2^2 & \ldots & x_n^2 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^M & x_2^M & \ldots & x_n^M \end{bmatrix} \quad \mathbf{y} = \begin{bmatrix} y^1 \\ y^2 \\ \vdots \\ y^M \end{bmatrix} \tag{3}$$

O vetor de coeficientes populacionais é $\beta = [\beta_0, \beta_1, \ldots, \beta_n]^{\mathbf{T}}$.

2.1.1 Estimação dos Coeficientes

O procedimento de estimação é conhecido como **Método dos Mínimos Quadrados Ordinários (MQO)**. O MQO busca o vetor de coeficientes estimados $\widehat{\beta}$ que minimiza a Soma dos Quadrados dos Resíduos (SQR).

A melhor estimativa $\widehat{\beta}$ no sentido de mínimos quadrados é dada pela solução da pseudo-inversa de Moore-Penrose (8, 3):

$$\widehat{\beta} = \mathbf{X}^{+}\mathbf{y} \triangleq (\mathbf{X}^{\mathbf{T}}\mathbf{X})^{-1}\mathbf{X}^{\mathbf{T}}\mathbf{y} \tag{4}$$

onde $\mathbf{X}^{+}$ é a pseudo-inversa da matriz $\mathbf{X}$.

2.1.2 Premissas e Métodos Robustos

A validade das estimativas obtidas pelo MQO depende do cumprimento das premissas clássicas da regressão linear. Em dados que apresentam estruturas complexas (como é comum em Quimiometria), a violação de pressupostos como a normalidade e a homocedasticidade [1] é frequente.

Métodos robustos tornam-se indispensáveis quando há violação das premissas da regressão linear múltipla, especialmente na presença de *outliers* (9, 10). A verificação da normalidade dos resíduos, em particular, é crucial e discutida em detalhes em estudos anteriores (9, 10).

2.2 A Técnica de *Bootstrap*

A inferência estatística estabelece propriedades para a população $\mathbf{X}$ a partir da análise de uma amostra aleatória dessa população (8, 11, 12). O método *bootstrap* é um procedimento computacional que fornece a medida do nível de precisão da inferência estatística, como por exemplo, média, desvio padrão e erro padrão (13, 14, 15, 16, 17). A ideia básica do *bootstrap* é inferir estatisticamente as propriedades de interesse a partir da análise de amostras aleatórias extraídas da população original sem a necessidade de conhecer a distribuição de dados a priori, o que constitui significativa vantagem sobre outras técnicas (2, 3).

Quando o parâmetro populacional de interesse é desconhecido, procura-se estimá-lo por reamostragem aleatória. Inicialmente, considera-se a **população** $\mathbf{x} = [x_1, x_2, \ldots, x_N]$. A partir dela, seleciona-se uma **amostra** $\mathbf{X} = [x_1, x_2, \ldots, x_n]$, formada por n elementos independentes retirados da população.

Para avaliar a variabilidade das estimativas, aplica-se o método de ***bootstrap***, que consiste em gerar m **reamostras** $\mathbf{X}^{*1}, \mathbf{X}^{*2}, \ldots, \mathbf{X}^{*m}$, obtidas por sorteio com reposição a partir da amostra original. Formalmente, cada reamostra é definida como

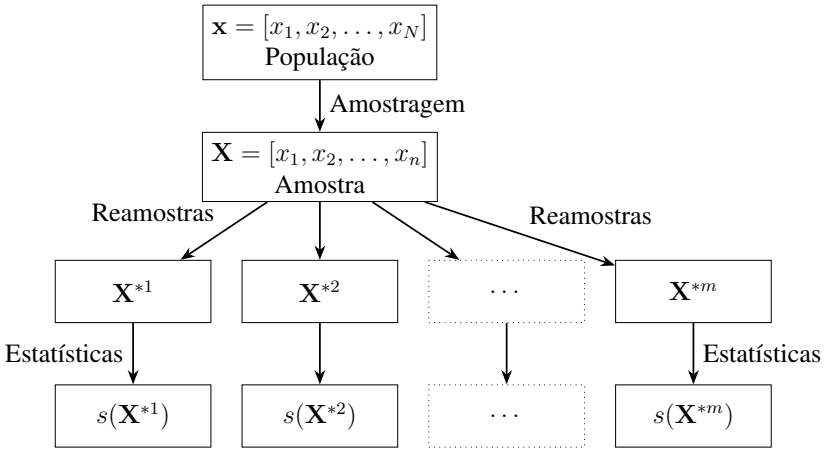
$$\mathbf{X}^{*i} \sim \textit{Bootstrap}(\mathbf{X}), \quad i = 1, 2, \ldots, m,$$

onde *Bootstrap*$(\mathbf{X})$ denota a distribuição empírica gerada pela amostra. Em seguida, calcula-se uma estatística $s(\mathbf{X}^{*i})$ para cada reamostra, gerando uma distribuição empírica das estimativas. Esse processo é ilustrado na Figura 1.

A Figura 1 ilustra o procedimento de *bootstrap* em quatro etapas. O primeiro passo (primeiro retângulo) representa a população completa, denotada por $\mathbf{x} = [x_1, x_2, \ldots, x_N]$, da qual é extraída uma amostra através do processo de amostragem. O segundo passo (segundo retângulo) corresponde ao conjunto de dados observados, denotado por $\mathbf{X} = [x_1, x_2, \ldots, x_n]$. O terceiro passo (terceiro conjunto de retângulos) corresponde à extração de amostras *bootstrap*, obtidas por reamostragem com reposição a partir de $\mathbf{X}$. O quarto passo (quarto conjunto de retângulos) mostra as replicações *bootstrap*, nas quais uma função estatística $s(\gamma)$ é recalculada m vezes, sendo m o número total de replicações.

[1] Refere-se à variância constante dos resíduos para todas as observações. É um pressuposto crucial para a validade dos testes de significância e eficiência dos estimadores MQO. O cenário oposto é a *heterocedasticidade*.

Figura 1 – Exemplo do método *bootstrap*.



Fonte: Wagner Oliveira de Araujo.

Nas seções subsequentes, são discutidos conceitos fundamentais relacionados a amostras aleatórias e probabilísticas, bem como a distribuição empírica e o princípio *plug-in*. A apresentação desses tópicos tem como objetivo fornecer a base teórica necessária para a compreensão dos procedimentos de inferência estatística realizados a partir de amostras *bootstrap*.

2.2.1 *Bootstrap*

Uma amostra aleatória $\mathbf{x}_{al} = [x_{al1}, \ldots, x_{aln}]$ é extraída da distribuição de probabilidade $\mathbf{D}$. O parâmetro de interesse $\theta = t(\mathbf{d})$ é desconhecido e será estimado com base na amostra observada $\mathbf{x}_{al}$, resultando no estimador $\widehat{\theta} = t(\mathbf{x}_{al})$.

2.2.2 Estimativa *Bootstrap*

O método *bootstrap* necessita inicialmente das amostras *bootstrap* para depois aplicar as replicações *bootstrap*, como foi visto na Figura 1. Suponha a distribuição empírica $\widehat{\mathbf{d}}$, com probabilidade $\frac{1}{n}$ em cada valor de x_i, tendo $i = 1, 2, \ldots, n$. A amostra *bootstrap* é definida como sendo a amostra aleatória de tamanho n extraída de $\widehat{\mathbf{d}}$, representada por $x^* = [x_1^*, x_2^*, \ldots, x_n^*]$ (18). As amostras *bootstrap* são obtidas por reamostragem com reposição, podendo haver repetições dos elementos da amostra original $[x_1, x_2, \ldots, x_n]$.

As replicações *bootstrap* são representadas por

$$\widehat{\theta} = s(x^*), \tag{5}$$

onde $s(\gamma)$ é a função estatística a ser aplicada sobre as amostras *bootstrap*. Por exemplo, se $s(x)$ for a média amostral $\overline{x}$, então $s(x^*)$ é a média da amostra *bootstrap*

$$\overline{x^*} = \frac{1}{n}\sum_{i=1}^{n} x_i^*. \tag{6}$$

Algoritmo 1: Estimativa das replicações *bootstrap*.

Entrada: Amostra original $x = (x_1, x_2, \ldots, x_n)$, estatística de interesse $\theta = s(x)$, número de replicações *bootstrap* m

Saída: Estimativa *bootstrap* $\widehat{\theta}^*$, erro padrão *bootstrap*, intervalo de confiança *bootstrap*

1 **início**

2 Selecione a quantidade de amostras independentes m, $\{x^{*1}, x^{*2}, \ldots, x^{*m}\}$, tendo tamanho m e podendo haver repetições de x.

3 Avaliar a replicação *bootstrap* para amostra *bootstrap*, $\widehat{\theta}^*(b) = s(x^{*b}) \qquad b = 1, 2, \ldots, m.$

4 **fim**

Fonte: Wagner Oliveira de Araujo.

O Algoritmo 1 (19) mostra a descrição do procedimento para utilizar a estimativa *bootstrap*, replicando o estimador $\widehat{\theta} = s(x)$ a partir dos dados x observados.

2.2.3 O Número de Replicações *Bootstrap* m

A estimativa *bootstrap* ideal é obtida através de uma boa escolha do número de replicações $m = \infty$, com o $\widehat{se}_\infty$ igual à estimativa *plug-in* $\widehat{se_{\mathbf{d}}}(\widehat{\theta}^*)$ (19). O número de replicações *bootstrap* influencia diretamente o tempo computacional gasto ao processar as replicações, principalmente se a função $s(x)$ do estimador $\widehat{\theta} = s(x)$ for muito complexa. Portanto, se não for possível obter infinitas replicações, deve-se utilizar o maior número possível de replicações.

É necessário que estimadores apresentem bom comportamento: baixo erro de predição e pequeno desvio padrão. A estimativa *bootstrap* para o erro padrão geralmente apresenta erro de predição relativamente pequeno. A estimativa *bootstrap* ideal $\widehat{se}_\infty$ possui baixa variabilidade entre estimativas com erro de predição quase nulo de $\widehat{se_{\mathbf{d}}}(\widehat{\theta^*})$, pelo menos em um sentido assintótico. Esta propriedade decorre do fato de que $\widehat{se}_m$ é a estimativa *plug-in* de $\widehat{se_{\mathbf{d}}}(\widehat{\theta^*})$. Não é difícil mostrar que $\widehat{se}_m$ sempre possui desvio padrão maior que $\widehat{se}_\infty$ (19). A questão que se coloca é: **o quanto maior**?

Uma resposta aproximada, porém satisfatória, pode ser encontrada utilizando o coeficiente de variação de $\widehat{se}_m$ em relação à sua expectativa. O aumento da variabilidade decorrente da interrupção do processo após m replicações *bootstrap*, em vez de permitir que m tenda ao infinito, resulta em um aumento do coeficiente de variação:

$$cv(\widehat{se}_m) = \sqrt{[cv(\widehat{se}_\infty)]^2 + \frac{E(\Delta) + 2}{4m}}. \tag{7}$$

O parâmetro Δ mede o tamanho da distribuição de $\widehat{\theta}^*$: Δ é zero para a distribuição normal; na prática, Δ geralmente é maior que 10. O coeficiente de variação na Equação (7)

incorpora tanto a variabilidade devida à reamostragem *bootstrap* quanto a variabilidade devida à amostragem da população original.

A estimativa ideal $\widehat{se}_\infty = se_{\widehat{\mathbf{d}}}(\widehat{\theta}^*)$ não é perfeita (19). Pode haver variabilidade considerável na estimativa $se_{\mathbf{d}}(\widehat{\theta})$ devido à variabilidade de $\widehat{\mathbf{d}}$ em relação a $\mathbf{d}$. Por exemplo, se $\{x_1, x_2, \ldots, x_n\}$ for uma amostra aleatória de uma distribuição normal e $\widehat{\theta} = \overline{x}$, então $cv(\widehat{se}_\infty) = \frac{1}{\sqrt{2n}}$, resultando em $0,22$ para $n = 10$. A Equação (7) tem uma consequência prática importante: dados os valores típicos de $cv(\widehat{se}_\infty)$ e Δ encontrados na prática, $cv(\widehat{se}_m)$ não será muito maior que $cv(\widehat{se}_\infty)$ quando $m \geq 200$.

Tabela 3 – O coeficiente de variação.

		(1) $m \rightarrow$				
		25	50	100	200	∞
(2) $cv(\widehat{se}_\infty)$	0,25	0,29	0,27	0,26	0,25	0,25
$\downarrow$	0,20	0,24	0,22	0,21	0,21	0,20
	0,15	0,21	0,18	0,17	0,16	0,15
	0,10	0,17	0,14	0,12	0,11	0,10
	0,05	0,15	0,11	0,09	0,07	0,05
	0,00	0,14	0,10	0,07	0,05	0,00

Fonte: EFRON, B.; TIBSHIRANI, R. J. *An Introduction to the Bootstrap*, USA: Chapman & Hall/CRC, 1993, p.53.

(1) Número de amostras *bootstrap*.
(2) Coeficiente de variação.

A Tabela 3 compara $cv(\widehat{se}_m)$ com $cv(\widehat{se}_\infty)$ para várias escolhas de m, assumindo $\Delta = 0$. Observa-se frequentemente que $cv(\widehat{se}_\infty)$ não será menor que $0,10$; neste caso, com $m = 100$ obtêm-se resultados bem satisfatórios. Efron (19) sugere duas regras práticas através da sua experiência:

a) Mesmo um número pequeno de replicações *bootstrap*, como $m = 25$, é geralmente informativo; $m = 50$ é frequentemente suficiente para uma boa estimativa de $se_{\mathbf{d}}(\widehat{\theta})$.

b) Muito raramente serão necessárias mais que $m = 200$ replicações para estimar o erro padrão. Valores muito maiores de m são requeridos para construção de intervalos de confiança.

A Tabela 3 mostra a variação de $\widehat{se}_m$ em função do coeficiente de variação da estimativa ideal $\widehat{se}_\infty$ e do número de amostras *bootstrap* m, obtidos da Equação (7) assumindo $\Delta = 0$.

2.3 Reamostragem Aleatória

O processo de reamostragem é realizado a partir da seleção aleatória de números inteiros $\{j_1, j_2, \ldots, j_n\}$, cada um com probabilidade $1/n$. Uma amostra aleatória de tamanho n é definida pela seleção aleatória de n unidades $\{u_1, u_2, \ldots, u_n\}$ extraídas da população $\mathbf{u}$ (ver Figura 2), onde $\mathbf{u}$ é a população de números inteiros selecionados para gerar variáveis aleatórias.

A população $\mathbf{v}$ é formada pelos valores selecionados de $\mathbf{u}$ de acordo com os valores de j, sendo constituída por $\{v_1, v_2, \ldots, v_n\}$. Esta população é criada por um dispositivo (como um software) responsável por gerar as amostras aleatórias. Por meio dos valores $\{j_1, j_2, \ldots, j_n\}$ selecionados, pode-se determinar quais membros de $\mathbf{v}$ serão escolhidos para a amostra aleatória:

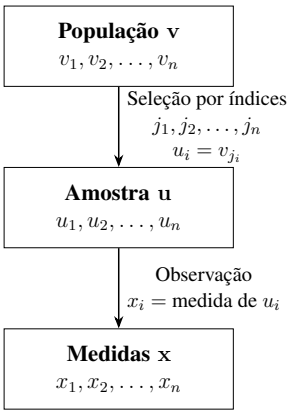
$$u_1 = v_{j_1}, \quad u_2 = v_{j_2}, \quad \ldots, \quad u_n = v_{j_n}.$$

Sendo x_i uma medida da unidade u_i para $i = 1, 2, \ldots, n$, o conjunto de dados observados será

$$\mathbf{x} = \{x_1, x_2, \ldots, x_n\}. \tag{8}$$

Se as unidades da amostra $\{u_1, u_2, \ldots, u_n\}$ são observadas, obtêm-se as medidas correspondentes $\{x_1, x_2, \ldots, x_n\}$, que formam o vetor de dados $\mathbf{x}$.

Figura 2 – Processo de amostragem aleatória.



Fonte: Wagner Oliveira de Araujo.

2.4 Teoria da Probabilidade

A partir de uma amostra aleatória $\mathbf{x}_{al}$, deve-se inferir a distribuição de probabilidade da população completa $\mathbf{X} = [X_1, X_2, \ldots, X_n]$, onde X_i representa a variável aleatória associada à i-ésima observação. A teoria da probabilidade segue o raciocínio oposto: a partir do conhecimento da distribuição de probabilidade da população $\mathbf{X}$, deduzem-se as propriedades das amostras aleatórias e das estatísticas calculadas a partir delas.

Seja x_{al} o resultado da rolagem de um dado não viciado. Por exemplo, no lançamento de um dado cúbico de 6 faces, onde todas as faces possuem probabilidades iguais de ocorrência, obtém-se como resultado 1, 2, 3, 4, 5 ou 6. Em notação probabilística, tem-se

$$\Pr\{x_{al} = k\} = \frac{1}{6}, \quad \text{para } k = 1, 2, 3, 4, 5, 6. \tag{9}$$

A quantidade aleatória que possua a probabilidade de ser selecionada como x_{al} é chamada de *variável aleatória*. Na teoria da probabilidade, a notação utilizada para definir a frequência f_k é dada por

$$f_k = \Pr\{x_{al} = k\}. \tag{10}$$

Na rolagem do dado não viciado, tem-se $f_k = \frac{1}{6}$ para $k = 1, 2, \ldots, 6$. A distribuição de probabilidade para a variável aleatória x_{al} será denotada por $\mathbf{f}$. Aqui, $\mathbf{f}$ é o vetor de frequências

$$\mathbf{f} = (f_1, f_2, \ldots, f_6) = \left(\frac{1}{6}, \frac{1}{6}, \ldots, \frac{1}{6}\right). \tag{11}$$

Podem-se encontrar também amostras com variáveis aleatórias x_{al} na forma da distribuição binomial de tamanho n e probabilidade de sucesso p, denotada

$$x_{al} \sim \text{BI}(n, p). \tag{12}$$

A frequência é representada por

$$f_k = \binom{n}{k} p^k (1-p)^{n-k}, \quad \text{para } k = 0, 1, 2, \ldots, n, \tag{13}$$

sendo n um inteiro positivo, p um número entre 0 e 1, e $\binom{n}{k}$ o coeficiente binomial definido por

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}. \tag{14}$$

A probabilidade pode ser definida também como no exemplo da distribuição normal (ou gaussiana). Uma variável aleatória de valor real x_{al}, tendo a distribuição normal com média μ e variância σ^2, é descrita por

$$x_{al} \sim N(\mu, \sigma^2). \tag{15}$$

A probabilidade de x_{al} pertencer a um conjunto $A \subseteq \mathbb{R}$ é dada por

$$\Pr\{x_{al} \in A\} = \int_A \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right) dx. \tag{16}$$

Existem outros problemas com dimensões maiores envolvendo integrais similares à Equação (16), mas não será necessário utilizar estas distribuições contínuas para o *bootstrap* neste trabalho.

A expectativa da variável aleatória de valor real x_{al}, escrita por $E(x)$, é o valor médio sobre os possíveis resultados de x_{al}. Assim, para a distribuição binomial:

$$E(x_{al}) = \sum_{k=0}^{n} k \binom{n}{k} p^k (1-p)^{n-k}, \quad \text{para } x_{al} \sim \text{BI}(n, p), \tag{17}$$

e para a distribuição normal:

$$E(x_{al}) = \int_{-\infty}^{\infty} x \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right) dx, \quad \text{para } x_{al} \sim N(\mu, \sigma^2). \tag{18}$$

A expectativa, como a teoria da média, é muito ampla e inclui casos de variáveis aleatórias sem valor real definido.

Pode-se obter a variância de x_{al}, representada por σ^2. Tendo $\mu = E_{\mathbf{f}}(x)$ para x_{al} sendo uma variável aleatória de valor real, a variância é definida como o valor esperado de $(x_{al} - \mu)^2$.

Em outras palavras, σ^2 é o quadrado médio das distâncias da variável aleatória x_{al} em relação à sua expectativa μ (4):

$$\sigma^2 = E_{\mathbf{f}}[(x_{al} - \mu)^2]. \tag{19}$$

A variância de $x_{al} \sim N(\mu, \sigma^2)$ é igual a σ^2, e a variância de $x_{al} \sim \text{BI}(n, p)$ é igual a $np(1-p)$. O desvio padrão da variável aleatória é definido pela raiz quadrada destas variâncias.

Para que duas variáveis aleatórias y_{cal} e z_{cal} sejam independentes, deve-se ter

$$E[g(y_{cal})h(z_{cal})] = E[g(y_{cal})] \cdot E[h(z_{cal})] \tag{20}$$

para todas as funções g e h. A independência implica que o resultado aleatório de y_{cal} não afeta o resultado aleatório de z_{cal}, e vice-versa.

2.5 Função de Distribuição Empírica

Suponha que uma amostra aleatória de tamanho n, dada por $\mathbf{x} = \{x_1, x_2, \ldots, x_n\}$, seja obtida de uma função de distribuição de probabilidade $\mathbf{d}$. A função de distribuição empírica $\widehat{\mathbf{d}}$ é definida como a distribuição discreta que atribui probabilidade $\frac{1}{n}$ a cada valor observado x_i, para $i = 1, 2, \ldots, n$.

Em outras palavras, a distribuição empírica $\widehat{\mathbf{d}}$ é construída a partir do espaço amostral de $\mathbf{x}$, atribuindo a seguinte probabilidade empírica a um evento A:

$$\widehat{\Pr}\{A\} = \frac{\#\{x_i \in A\}}{n}, \tag{21}$$

onde $\#\{x_i \in A\}$ denota o número de observações x_i que pertencem ao conjunto A.

Em casos onde ocorrem repetições de valores na amostra, para evitar atribuir probabilidade $\frac{1}{n}$ a cada ocorrência repetida individualmente, utiliza-se $\widehat{\mathbf{d}}$ com as frequências relativas observadas. Para valores distintos k no espaço amostral, define-se

$$\widehat{f}_k = \frac{\#\{x_i = k\}}{n}, \tag{22}$$

onde $\#\{x_i = k\}$ representa o número de observações na amostra que são iguais a k. Assim, $\widehat{f}_k$ é a frequência relativa (ou probabilidade empírica) do valor k na amostra.

2.6 Princípio *Plug-in*

O princípio *plug-in* constitui uma abordagem fundamental para estimação de parâmetros estatísticos, permitindo estimar um parâmetro de interesse θ por meio de uma função avaliativa aplicada à distribuição empírica dos dados (20).

Formalmente, seja $\theta = t(F)$ um parâmetro definido como função da distribuição populacional F. O estimador *plug-in* é obtido substituindo F pela distribuição empírica $\hat{F}_n$:

$$\hat{\theta} = t(\hat{F}_n), \tag{23}$$

onde n denota o tamanho da amostra.

Para o caso particular em que θ representa a expectativa populacional $\mathbb{E}_F(X)$, o estimador *plug-in* corresponde à média amostral:

$$\hat{\theta} = \mathbb{E}_{\hat{F}_n}(X) = \frac{1}{n}\sum_{i=1}^{n} x_i = \bar{x}. \tag{24}$$

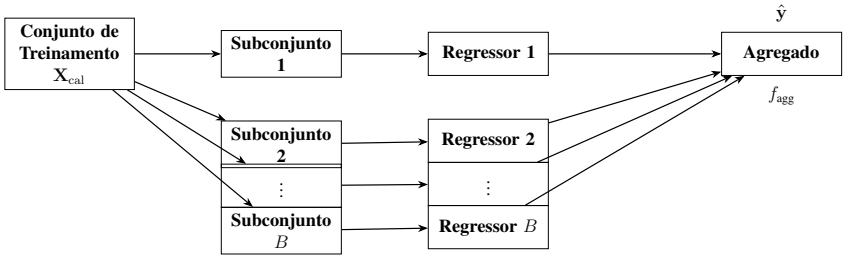
É importante destacar que o método *bootstrap* constitui uma aplicação direta do princípio *plug-in*, podendo ser adotado como método de estimação para diversos modelos estatísticos, incluindo modelos de regressão (20, 21).

2.7 Técnicas Clássicas de Reamostragem

Nesta seção, revisam-se duas técnicas fundamentais de reamostragem: *bagging* e *subagging*. Ambas utilizam amostras *bootstrap*, como detalhado na Seção 2, baseando-se na distribuição empírica das probabilidades.

As técnicas de reamostragem são particularmente úteis em cenários com limitação amostral ou quando os dados são contaminados por ruídos instrumentais. A ideia central consiste em combinar as predições de múltiplos modelos de regressão em um único preditor agregado, processo conhecido como *ensemble* (22, 23).

Figura 3 – Reamostragem com agregação de modelos de regressão.



Fonte: Wagner Oliveira de Araujo.

A Figura 3 ilustra o fluxo de reamostragem e agregação: o conjunto de calibração $\mathbf{X}_{\text{cal}}$ é reamostrado em B subconjuntos, cada um utilizado para calibrar um regressor independente. As predições individuais são subsequentemente combinadas no estágio de agregação mediante uma função f_{agg}.

Técnicas *ensemble* integram múltiplos modelos para aprimorar o desempenho preditivo final (22). Neste trabalho, emprega-se a média aritmética como função de agregação, com todos os regressores utilizando Regressão Linear Múltipla (RLM), caracterizando um *ensemble* homogêneo (24, 25, 26).

A distinção fundamental entre *bagging* e *subagging* reside no esquema de amostragem: com e sem reposição, respectivamente. As Seções 2.7.1 e 2.7.2 detalham estas técnicas.

2.7.1 *Bagging*

A técnica *bagging* (*Bootstrap Aggregating*) foi proposta por Breiman (27) com o objetivo de gerar múltiplos conjuntos de calibração por meio de reamostragem *bootstrap*, combinando posteriormente os resultados obtidos. Esta abordagem visa reduzir a variância do preditor final através da agregação (27, 28, 29, 30, 5).

Breiman demonstrou que o *bagging* proporciona ganhos significativos de desempenho em problemas de regressão, especialmente quando o modelo é instável – isto é, quando pequenas alterações no conjunto de calibração resultam em mudanças substanciais nas predições. Na decomposição do erro de predição em regressão, o *bagging* atua principalmente na redução da componente de variância do preditor.

A técnica também se mostra eficaz em regressões multivariadas, particularmente em problemas de seleção de amostras de calibração em modelos de Regressão Linear Múltipla (RLM) (31, 2). Variações na seleção de variáveis, decorrentes de flutuações nos conjuntos de calibração, são suavizadas pelo cálculo da média dos modelos resultantes (32).

Algoritmo 2: Estimativa *bagging*.

Entrada: Amostra original $\mathbf{x} = (x_1, x_2, \ldots, x_n)$ com n observações, estatística de interesse $\theta = s(\mathbf{x})$, número de réplicas *bootstrap* B

Saída: Estimativa *bagging* $\hat{\theta}^*_{\text{bag}}$, distribuição das estimativas *bootstrap* $\{\hat{\theta}^*(1), \ldots, \hat{\theta}^*(B)\}$

início
- Definir o número de réplicas *bootstrap* B
- **para** $b = 1$ ***até*** B **faça**
  - Gerar amostra *bootstrap* $\mathbf{x}^{*(b)}$ de tamanho n com reposição a partir de $\mathbf{x}$
  - Calcular a estatística para a réplica b:
  - $\hat{\theta}^*(b) = s(\mathbf{x}^{*(b)})$
- **fim**
- Agregar as réplicas via média aritmética:

$$\hat{\theta}^*_{\text{bag}} = \frac{1}{B} \sum_{b=1}^{B} \hat{\theta}^*(b)$$

fim

Fonte: Wagner Oliveira de Araujo.

O Algoritmo 2 descreve o procedimento para aplicação do *bagging*. Inicialmente, define-se o número B de réplicas *bootstrap* a serem geradas. Para cada réplica $b = 1, \ldots, B$, extrai-se uma amostra $\mathbf{x}^{*(b)}$ de tamanho n com reposição da amostra original, aplica-se a função $s(\cdot)$ para obter $\hat{\theta}^*(b)$, e finalmente agrega-se os resultados através da média aritmética (33).

No *bagging* tradicional proposto por Breiman (34), cada amostra *bootstrap* possui o mesmo tamanho da amostra original. Neste trabalho, a implementação do *bagging* utilizando Regressão Linear Múltipla (RLM) é denominada **RLM-*bagging***.

2.7.2 *Subagging*

A técnica *subagging* (*subsample aggregating*) baseia-se na reamostragem sem reposição, diferindo do *bagging* tradicional por não permitir repetições de observações dentro das amostras (23, 35, 36, 37, 38, 39, 40, 41, 42, 43). Cada modelo é construído de maneira similar ao *bagging*, porém utilizando subamostras de tamanho reduzido $k < n$.

Algoritmo 3: Estimativa *subagging*.

Entrada: Amostra original $\mathbf{x} = (x_1, x_2, \ldots, x_n)$ com n observações, estatística de interesse $\theta = s(\mathbf{x})$, número de réplicas B, tamanho das subamostras k (onde $k \leq n$)

Saída: Estimativa subagging $\hat{\theta}^*_{\text{subag}}$, conjunto de estimativas $\{\hat{\theta}^*(1), \ldots, \hat{\theta}^*(B)\}$

início
- Definir o tamanho das subamostras k (tipicamente $k < n$)
- Definir o número de réplicas B
- **para** $b = 1$ ***até*** B **faça**
  - Gerar subamostra $\mathbf{x}^{*(b)}$ de tamanho k **sem reposição** a partir de $\mathbf{x}$
  - Calcular a estatística para a subamostra: $\hat{\theta}^*(b) = s(\mathbf{x}^{*(b)})$
- **fim**
- Agregar as réplicas via média aritmética:

$$\hat{\theta}^*_{\text{subag}} = \frac{1}{B} \sum_{b=1}^{B} \hat{\theta}^*(b)$$

fim

Fonte: Wagner Oliveira de Araujo.

O Algoritmo 3 descreve o procedimento para aplicação do *subagging*. Inicialmente, definem-se os parâmetros k (tamanho das subamostras) e B (número de réplicas). Para cada iteração $b = 1, \ldots, B$, gera-se uma subamostra $\mathbf{x}^{*(b)}$ de tamanho k **sem reposição** a partir dos dados originais, aplica-se a função $s(\cdot)$, e finalmente agrega-se os resultados através da média aritmética.

A ausência de reposição implica que cada observação aparece no máximo uma vez por subamostra, diferenciando fundamentalmente esta técnica do *bagging*. Esta característica torna o *subagging* particularmente sensível à escolha do tamanho das subamostras k e do número de réplicas B. A relação ótima entre estes parâmetros, bem como uma análise comparativa entre *bagging* e *subagging*, são discutidas na Seção 4.3.

Bühlmann (35) introduziu o subagging como uma otimização do *bagging* para subamostras de dimensão $m < n$. A generalização para regressão de alta dimensionalidade foi formalizada por Ing e Lai (44). Análises teóricas recentes (39, 36) determinam condições necessárias e suficientes para a convergência e eficiência assintótica[2] desses métodos.

[2]Assintótica refere-se ao comportamento de algo quando uma variável tende ao infinito (ou a um limite extremo).

Neste trabalho, a implementação do *subagging* utilizando Regressão Linear Múltipla (RLM) é denominada **RLM-*subagging***.

2.7.3 Comparação entre *Bagging* e *Subagging*

Embora *bagging* e *subagging* compartilhem o princípio de agregação de múltiplos modelos, diferem fundamentalmente no mecanismo de reamostragem empregado. A Quadro 1 sintetiza as principais distinções entre estas técnicas, destacando suas características operacionais e implicações para a variância dos estimadores resultantes.

Quadro 1 – Características comparativas entre *bagging* e *subagging*.

Característica	***Bagging***	***Subagging***
Tipo de amostragem	Com reposição	Sem reposição
Tamanho das réplicas	n	$k \leq n$
Repetição de observações	Permitida	Não permitida
Diversidade entre réplicas	Moderada	Alta
Variância do estimador	Redução moderada	Redução potencialmente maior
Sensibilidade a parâmetros	Baixa	Alta (k e B)

Fonte: Wagner Oliveira de Araujo.

Como mostra o Quadro 1, a ausência de reposição no *subagging* resulta em maior diversidade entre as réplicas, uma vez que cada subamostra contém um conjunto distinto de observações. Esta característica pode proporcionar maior redução de variância, mas torna a técnica mais sensível à escolha adequada dos parâmetros k (tamanho das subamostras) e B (número de réplicas).

A escolha entre *bagging* e *subagging* depende fundamentalmente das características do problema em questão. O *bagging* é mais robusto e requer menos ajuste de parâmetros, sendo preferível quando se dispõe de amostras de tamanho moderado. Por outro lado, o *subagging* pode ser vantajoso em cenários com amostras grandes ou quando há interesse em controlar explicitamente o tamanho das subamostras para reduzir o custo computacional (35).

Nas aplicações com Regressão Linear Múltipla (RLM) desenvolvidas neste trabalho, ambas as técnicas serão avaliadas empiricamente, permitindo uma análise comparativa de seus desempenhos preditivos em diferentes configurações amostrais.

2.8 Fundamentos de Engenharia de Migração e Qualidade de Software

Assim como a calibração multivariada, a modernização de sistemas legados possui fundamentação teórica própria. Sommerville (45) estrutura a engenharia de requisitos em quatro fases interdependentes — elicitação, análise, especificação e validação —, oferecendo o arcabouço metodológico adotado neste trabalho para decompor as responsabilidades do sistema Java legado em módulos independentes, evitando que a reescrita repetisse o acoplamento entre lógica de negócio, persistência e interface presente na implementação original.

A estratégia de migração adotada — reescrita *black-box* — extrai os requisitos do comportamento observável de um sistema legado, sem reaproveitar seu código-fonte (46). Diferentemente da reescrita *white-box*, que preserva estruturas internas do sistema original, essa abordagem trata o legado exclusivamente como especificação funcional, permitindo à equipe redesenhar a arquitetura livremente, desde que a equivalência comportamental do núcleo algorítmico seja formalmente demonstrada em cada etapa da migração.

A verificação dessa equivalência comportamental exige um oráculo de teste independente da implementação (47). Testes de caixa-preta comparam entradas e saídas entre o sistema original e o sistema reescrito sem inspecionar o código-fonte legado, estratégia adequada quando o objetivo — como neste trabalho — é substituir integralmente a plataforma de execução preservando o comportamento matemático. Essa fundamentação sustenta a suíte de 92 testes automatizados que compara Java e Python, apresentada adiante.

3 MATERIAIS E MÉTODOS

Esta seção apresenta os dados utilizados na aplicação dos algoritmos de reamostragem, bem como as medidas estatísticas empregadas para comparação entre os métodos. O objetivo é determinar a concentração de Manganês (Mn), Molibdênio (Mo), Cromo (Cr), Níquel (Ni) e Ferro (Fe) a partir de espectros reamostrados pelos métodos *bagging* e *subagging*.

Para a implementação computacional, utilizou-se a linguagem de programação Java (JavaSE-17) em conjunto com o ambiente de desenvolvimento integrado Eclipse IDE (versão 2025-09). As operações matriciais exigidas pelos algoritmos de calibração multivariada, incluindo o cômputo da pseudo-inversa de Moore-Penrose, as reamostragens *bootstrap* e a agregação dos modelos de *ensemble*, foram implementadas com o suporte da biblioteca *Efficient Java Matrix Library*, `org.ejml.simple.SimpleMatrix` (EJML). Esta é especializada em operações de álgebra linear de alto desempenho para a plataforma Java, garantindo eficiência no processamento.

A visualização gráfica dos resultados foi realizada pela biblioteca JFreeChart[1], que possibilitou a geração dos gráficos de predição e comparação de desempenho deste trabalho. A interface gráfica de usuário, para entrada de parâmetros e exibição de resultados durante os experimentos, foi desenvolvida com os *frameworks* nativos Java Swing e AWT. O gerenciamento dos arquivos de entrada e saída, incluindo leitura das matrizes espectrométricas e exportação dos resultados, foi realizado pelas bibliotecas padrão `java.io`.

Durante o desenvolvimento deste trabalho, o modelo de linguagem de inteligência artificial Qwen3.7-Plus foi utilizado como ferramenta de assistência para: revisão ortográfica, sugestão de estruturação de seções, tradução de resumos, refatoração de trechos de código (Java/Pthyton), correção de erros código LaTeX (48). A validação factual, a análise crítica dos dados espectrométricos e a redação final das conclusões foram realizadas integralmente pelo autor, garantindo a integridade acadêmica e a autoria do trabalho.

3.1 Fragmento do Código-Fonte Java — Núcleo Algorítmico

A classe `BaggingOptimized` (que estende `JFrame`) concentra, entre os componentes de interface gráfica, o núcleo algorítmico responsável pelos três modelos de regressão avaliados neste trabalho. A Figura 4 apresenta o método `performRLM`, que implementa a Regressão Linear Múltipla simples via pseudoinversa de Moore-Penrose.

[1]Versões: EJML 0.43.1; JFreeChart 1.5.4. Código em: https://github.com/woa2009/MigracaoJava

Figura 4 – Regressão Linear Múltipla via pseudoinversa (`BaggingOptimized.java`).

```
private SimpleMatrix performRLM(SimpleMatrix Xcal, SimpleMatrix Ycal,
                                SimpleMatrix Xteste) {
    SimpleMatrix b = pseudoInverse(Xcal).mult(Ycal);
    return Xteste.mult(b);
}
```

Fonte: Wagner Oliveira de Araujo.

A Figura 5 apresenta o método `performBagging`, que implementa tanto o *Bagging* (reamostragem com reposição) quanto o *Subagging* (reamostragem sem reposição, com fração configurável), controlados pelo parâmetro booleano `withReplacement`. Cada um dos `numBags` modelos é ajustado sobre uma reamostra distinta e a predição final é obtida pela média aritmética das predições individuais.

Figura 5 – Ensemble de Bagging/Subagging (`BaggingOptimized.java`).

```
private SimpleMatrix performBagging(SimpleMatrix Xcal, SimpleMatrix Ycal,
        SimpleMatrix Xteste, int numBags, boolean withReplacement,
        double sampleFraction) {
    int n = Xcal.numRows();
    int sampleSize = withReplacement ? n : (int) (n * sampleFraction);
    List<SimpleMatrix> models = new ArrayList<>();
    Random rand = new Random(42); // semente fixa para reprodutibilidade

    for (int bag = 0; bag < numBags; bag++) {
        SimpleMatrix Xbag = new SimpleMatrix(sampleSize, Xcal.numCols());
        SimpleMatrix Ybag = new SimpleMatrix(sampleSize, 1);

        if (withReplacement) {
            // Bagging: amostragem com reposicao (bootstrap completo)
            for (int i = 0; i < sampleSize; i++) {
                int idx = rand.nextInt(n);
                copyRow(Xcal, idx, Xbag, i);
                Ybag.set(i, 0, Ycal.get(idx, 0));
            }
        } else {
            // Subagging: amostragem sem reposicao (subconjunto aleatorio)
            List<Integer> indices = new ArrayList<>();
            for (int i = 0; i < n; i++) indices.add(i);
            Collections.shuffle(indices, rand);
            for (int i = 0; i < sampleSize; i++) {
                int idx = indices.get(i);
                copyRow(Xcal, idx, Xbag, i);
                Ybag.set(i, 0, Ycal.get(idx, 0));
            }
        }

        // Ajusta o modelo RLM para esta amostra bootstrap
        SimpleMatrix b_bag = pseudoInverse(Xbag).mult(Ybag);
        models.add(b_bag);
    }

    // Agrega as predicoes de todos os modelos pela media aritmetica
    SimpleMatrix Ypred = new SimpleMatrix(Xteste.numRows(), 1);
    for (SimpleMatrix b : models) {
        SimpleMatrix pred = Xteste.mult(b);
        Ypred = Ypred.plus(pred.scale(1.0 / numBags));
    }
    return Ypred;
}
```

Fonte: Wagner Oliveira de Araujo.

Essa mesma bifurcação — reamostragem com ou sem reposição controlada por um único parâmetro booleano — é preservada na reimplementação Python (Seção 8.3), constituindo um dos pontos de verificação dos testes de caixa-preta descritos na Seção 9.2.

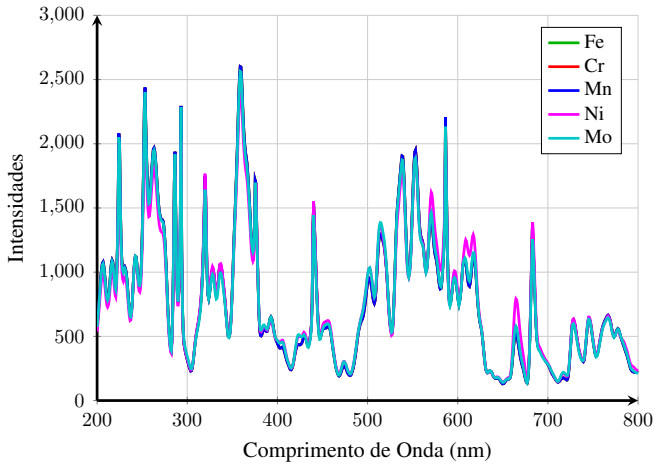
3.2 Amostras de Aço-Ligas

Os dados foram obtidos por meio de um espectrômetro de emissão atômica em plasma com acoplamento indutivo sequencial convertido para um sistema de múltiplos canais de detecção baseado em um arranjo linear de 1024 fotodiodos. O aparelho instrumental faz uso das propriedades de absorção e emissão de plasma, como detalhado em (49).

A espectroscopia de emissão atômica é responsável pela conversão dos componentes da amostra em átomos ou íons elementares, podendo excitá-los a vários estados eletrônicos. A rápida relaxação das espécies excitadas possibilita a produção de espectros visíveis que serão analisados quantitativamente e qualitativamente, com vantagens sobre outros métodos clássicos. Por exemplo, a baixa interferência entre elementos da mesma amostra, e o registro de espectros para vários elementos no mesmo conjunto de excitação (1).

Os espectros obtidos por fontes de plasma são bastante complexos e constituem centenas ou até milhares de frequências (Figura 6). Logo, melhoram a análise qualitativa. Porém, dificulta a análise quantitativa pela grande quantidade de variáveis geradas por amostra motivando o emprego de calibração multivariada (50, 51).

Figura 6 – Espectros médios dos analitos analisados.



Fonte: Wagner Oliveira de Araujo.

As matrizes de respostas instrumentais e concentração das amostras de aço-ligas são organizadas em dois conjuntos de dados: calibração (33,3 – 45,9%) e teste (54,1 – 66,7%), como segue (Quadro 2). Cada amostra é representada por 723 variáveis espectrais, resultando em uma razão de aproximadamente 42 preditores por observação no conjunto de calibração. Esse regime de alta dimensionalidade — inerente à natureza dos dados espectrométricos de plasma — é tratado pela pseudo-inversa de Moore-Penrose (Equação 4), que fornece solução única mesmo em sistemas subdeterminados.

Ressalta-se, contudo, que conjuntos de calibração reduzidos são uma característica recorrente em análises de aço-ligas por espectrometria, como documentado na literatura (49, 50), e que os resultados obtidos neste estudo devem ser interpretados como evidências exploratórias do comportamento das técnicas investigadas nesse contexto específico, não sendo diretamente generalizáveis a outras composições ou regimes amostrais sem validação adicional.

Quadro 2 – Dimensões dos conjuntos de dados para diferentes elementos.

Elemento	Calibração	Teste
Mn	$\mathbf{Xcal}_{Mn_{(17\times723)}}$, $\mathbf{Ycal}_{Mn_{(17\times1)}}$	$\mathbf{Xteste}_{Mn_{(34\times723)}}$, $\mathbf{yteste}_{Mn_{(34\times1)}}$
Mo	$\mathbf{Xcal}_{Mo_{(17\times723)}}$, $\mathbf{Ycal}_{Mo_{(17\times1)}}$	$\mathbf{Xteste}_{Mo_{(21\times723)}}$, $\mathbf{yteste}_{Mo_{(21\times1)}}$
Cr	$\mathbf{Xcal}_{Cr_{(17\times723)}}$, $\mathbf{Ycal}_{Cr_{(17\times1)}}$	$\mathbf{Xteste}_{Cr_{(34\times723)}}$, $\mathbf{yteste}_{Cr_{(34\times1)}}$
Ni	$\mathbf{Xcal}_{Ni_{(17\times723)}}$, $\mathbf{Ycal}_{Ni_{(17\times1)}}$	$\mathbf{Xteste}_{Ni_{(20\times723)}}$, $\mathbf{yteste}_{Ni_{(20\times1)}}$
Fe	$\mathbf{X}_{calFe_{(17\times723)}}$, $\mathbf{Y}_{calFe_{(17\times1)}}$	$\mathbf{X}_{testeFe_{(34\times723)}}$, $\mathbf{y}_{testeFe_{(34\times1)}}$

Fonte: Wagner Oliveira de Araujo.

3.3 Protocolo de Validação e Seleção de Hiperparâmetros

A seleção dos hiperparâmetros dos algoritmos RLM-*bagging* e RLM-*subagging* — respectivamente, o número de replicações bootstrap m e a fração de subamostragem k — foi conduzida mediante validação cruzada *5-fold* aplicada exclusivamente ao conjunto de calibração, garantindo que o conjunto de teste permanecesse estritamente independente durante todo o processo de otimização.

O procedimento adotado seguiu as etapas descritas a seguir. Primeiramente, o conjunto de calibração foi particionado em cinco subconjuntos (*folds*) de tamanho aproximadamente igual, após embaralhamento aleatório com semente fixa (`seed` = 42) para assegurar a reprodutibilidade dos resultados. Quando o número de amostras de calibração não é divisível por cinco, o último *fold* absorve as amostras remanescentes, podendo conter uma ou duas amostras adicionais em relação aos demais *folds*.

Em seguida, para cada combinação de hiperparâmetros avaliada, realizou-se uma busca em grade (*grid search*) sobre os conjuntos de valores $m \in \{10, 20, 30, 40, 50\}$ e $k \in \{0{,}50;\ 0{,}60;\ 0{,}70;\ 0{,}80\}$. A cada iteração, o modelo foi treinado nos quatro *folds* restantes e avaliado no *fold* de validação corrente, repetindo-se o procedimento cinco vezes de modo que cada *fold* atuasse exatamente uma vez como conjunto de validação. O desempenho de cada

configuração foi quantificado pelo RMSEP médio entre os cinco *folds* (RMSEP_{CV}), dado pela Equação 25:

$$\text{RMSEP}_{\text{CV}} = \frac{1}{K}\sum_{k=1}^{K}\sqrt{\frac{1}{n_k}\sum_{i=1}^{n_k}\left(\hat{y}_i^{(k)} - y_i^{(k)}\right)^2} \tag{25}$$

onde $K = 5$ é o número de *folds*, n_k é o número de amostras no *fold* k, $y_i^{(k)}$ é o valor de referência e $\hat{y}_i^{(k)}$ é o valor predito para a i-ésima amostra do *fold* k.

Os hiperparâmetros ótimos m^* e k^* foram definidos como a combinação que minimizou o RMSEP_{CV}. Após a seleção, os modelos finais foram retreinados utilizando a totalidade do conjunto de calibração com os parâmetros ótimos identificados. A avaliação final de desempenho foi realizada uma única vez sobre o conjunto de teste independente, reportando-se as métricas RMSEP, MAE e R^2, definidas nas Equações 26, 27 e 28, respectivamente.

3.4 Medida do Erro Médio Quadrático de Predição

Para avaliar e comparar a acurácia preditiva dos modelos de regressão linear múltipla (RLM) clássica, RLM com *bagging* (RLM-*bagging*) e RLM com *subagging* (RLM-*subagging*), utilizou-se um conjunto de três métricas complementares: o *Root-Mean-Square Error of Prediction* (RMSEP)[2], o *Mean Absolute Error* (MAE)[3] e o coeficiente de determinação R^2. A adoção conjunta dessas métricas proporciona uma caracterização mais abrangente do desempenho preditivo, uma vez que cada uma captura aspectos distintos dos erros de predição (52, 31).

O RMSEP fornece uma medida agregada da magnitude dos erros entre os valores previstos por um modelo e os valores reais observados em um conjunto de dados independente (geralmente um conjunto de teste ou validação) (52, 31). Ao elevar os erros ao quadrado antes de calcular a média e, posteriormente, extrair a raiz quadrada, o RMSEP atribui maior peso aos erros maiores, penalizando modelos com grandes discrepâncias entre as predições e a realidade. Essa característica o torna particularmente útil em situações onde grandes erros são mais indesejáveis, sendo adotado como critério primário de seleção do melhor modelo neste trabalho (24, 53, 17, 52).

Obtidos os coeficientes de regressão para cada uma das técnicas avaliadas, calculou-se a concentração do elemento de interesse. O RMSEP objetiva minimizar a soma quadrada da diferença entre a concentração predita e a concentração observada, como expresso na Equação (26):

$$\text{RMSEP} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(\widehat{y}_i - y_i)^2} \tag{26}$$

onde $\widehat{y}_i$ é a i-ésima concentração predita pelo modelo de regressão, y_i é a concentração observada (real) e n é o número de amostras no conjunto de validação.

[2]Erro Médio Quadrático de Predição
[3]Erro Médio Absoluto

O MAE complementa o RMSEP ao quantificar a magnitude média dos erros de predição sem elevar os resíduos ao quadrado, atribuindo peso igual a todos os desvios independentemente de sua magnitude (54). Isso o torna mais robusto à presença de valores discrepantes e permite verificar a consistência dos erros: quando o RMSEP supera consideravelmente o MAE, há indício de erros grandes e isolados nas predições; quando ambos são próximos, os erros tendem a ser homogeneamente distribuídos. O MAE é dado pela Equação (27):

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|\widehat{y}_i - y_i| \tag{27}$$

onde $\widehat{y}_i$, y_i e n mantêm as mesmas definições apresentadas na Equação (26). Assim como o RMSEP, o MAE é expresso na mesma unidade da variável resposta, com valores menores indicando maior acurácia preditiva.

O coeficiente de determinação R^2 avalia a proporção da variância total da variável resposta que é explicada pelo modelo preditivo, sendo definido pela Equação (28):

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(\widehat{y}_i - y_i)^2}{\sum_{i=1}^{n}(\bar{y} - y_i)^2} \tag{28}$$

onde $\bar{y}$ representa a média dos valores de referência no conjunto de teste. O R^2 assume valores no intervalo $(-\infty, 1]$: $\text{R}^2 = 1$ indica ajuste perfeito; $\text{R}^2 = 0$ equivale ao desempenho de um modelo que prediz apenas a média da variável resposta; e valores negativos indicam desempenho inferior a essa referência trivial (55). Na calibração multivariada de aço-ligas, valores de $\text{R}^2 > 0{,}99$ são frequentemente reportados como indicativos de elevada capacidade preditiva (52, 31, 53). Contudo, o R^2 isoladamente pode ser enganoso em conjuntos de teste pequenos ou com distribuição não uniforme de concentrações, razão pela qual sua interpretação é sempre realizada em conjunto com o RMSEP e o MAE neste trabalho.

4 RESULTADOS E DISCUSSÕES

Esta seção apresenta os resultados e discute as técnicas de *bootstrap*, *bagging* e *subagging* aplicadas à regressão linear múltipla. Ela avalia o erro médio quadrático de predição (RMSEP) e compara os tempos de execução dos algoritmos RLM, RLM-*bagging* e RLM-*subagging*.

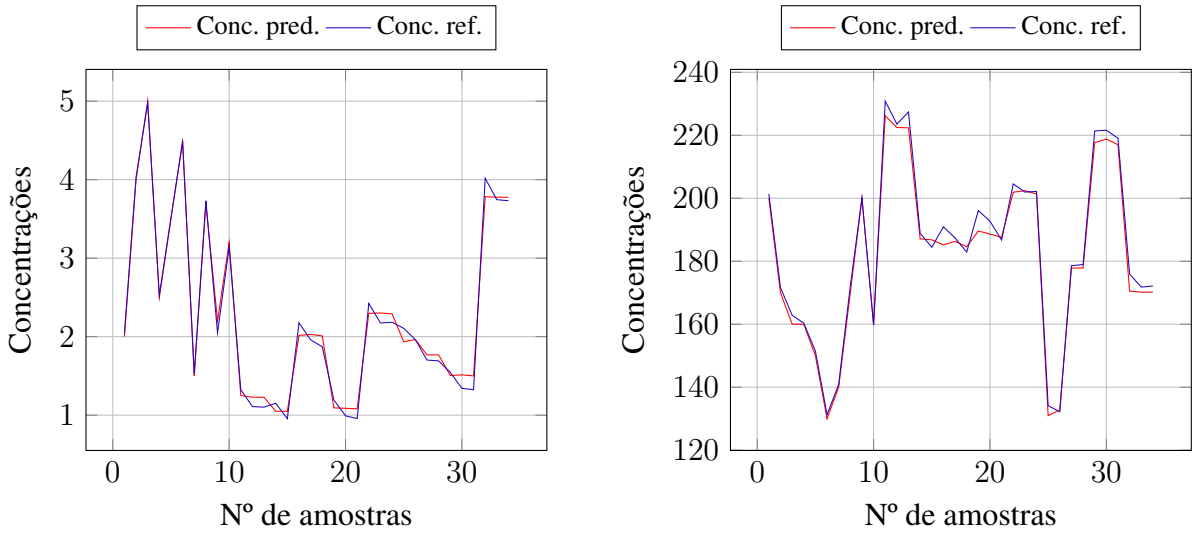
Tabela 4 – RMSEP por analito obtido via RLM para amostras de aço-ligas.

Elementos	**RMSEP (RLM)**
Mn	0,1051
Mo	0,2633
Cr	1,0798
Ni	1,6043
Fe	2,7513

Fonte: Wagner Oliveira de Araujo.

A Tabela 4 mostra o RMSEP obtido com a RLM para todas as amostras de aço-ligas.

Figura 7 – RMSEP com RLM para Mn e Fe.



(a) RMSEP com RLM para Mn.

(b) RMSEP com RLM para Fe.

Fonte: Wagner Oliveira de Araujo.

A Figura 7 exibe o comportamento do RMSEP para os elementos Mn e Fe. A Figura 7a detalha o RMSEP do manganês (Mn) e a Figura 7b, o do ferro (Fe). O sinal azul representa a concentração esperada do Mn e do Fe e sinal vermelho a concentração predita obtida com a RLM. Pode ser visto na Tabela 4 que o Mn apresenta o menor RMSEP entre os três métodos, com destaque para o RLM-*subagging* (0,0974). Por outro lado, o Fe apresenta o maior RMSEP, com o valor mais elevado obtido pela RLM (2,7513). De forma geral, o RLM-*subagging* apresentou desempenho superior ao RLM-*bagging* na maioria dos elementos analisados, embora a RLM

clássica tenha se mantido como método de menor RMSEP para Mo e Cr, indicando que a técnica mais adequada depende das características específicas de cada analito.

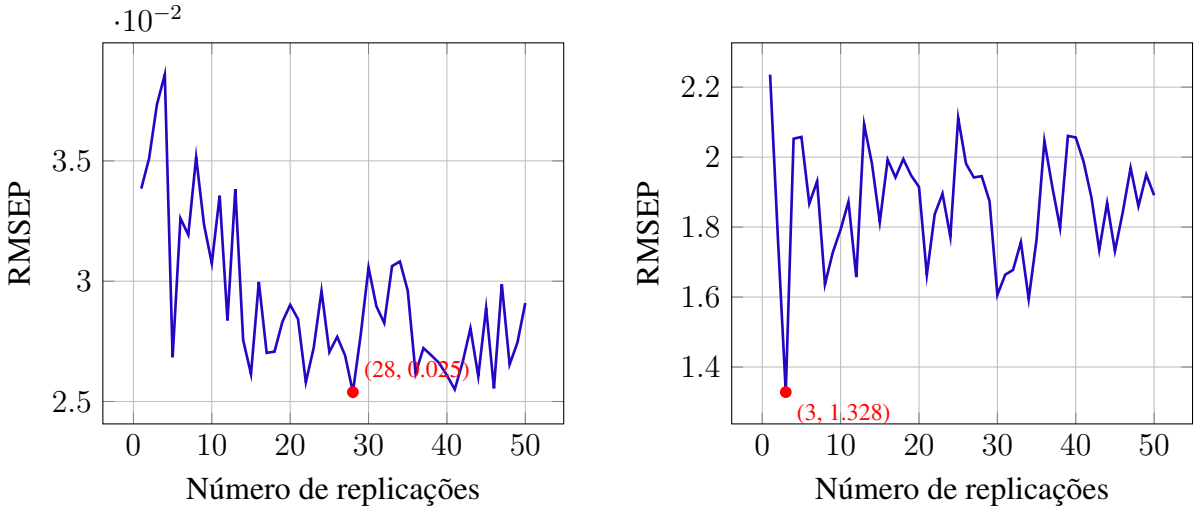
A escolha dos elementos ferro e manganês para esta análise baseia-se em fundamentos científicos bem estabelecidos na metalurgia. O ferro é o elemento matriz que define a própria natureza do material, uma vez que sem ferro não existe aço. O manganês, por sua vez, é o único elemento de liga historicamente considerado essencial para a produção de qualquer aço comercial, atuando como desoxidante e modificador fundamental das propriedades mecânicas. Os demais elementos (Cr, Mo, Ni) são importantes para propriedades específicas, mas não são fundamentais para a definição básica e produção do aço como o ferro e o manganês. Acredita-se que o comportamento destas duas amostras são suficientes para ilustrar o comportamento geral esperado para as outras amostras.

4.1 *Bagging*

Os resultados obtidos com a técnica *bagging* foram produzidos com a implementação do Algoritmo 2. Contudo, como visto na Subseção 2.7.1 da Seção 2.7, o algoritmo RLM-*bagging* depende do parâmetro m que define o número de replicações *bootstrap*.

Foi conduzido um experimento para avaliar a sensibilidade do *bagging* em função do número de replicações, variando de 1 a 50. O procedimento experimental implementou o RLM-*bagging* com um algoritmo iterativo que modifica sistematicamente o número de replicações utilizadas.

Figura 8 – RMSEP em função do número de replicações *bootstrap* para RLM-*bagging*.



(a) RMSEP em função do número de replicação para o Mn.

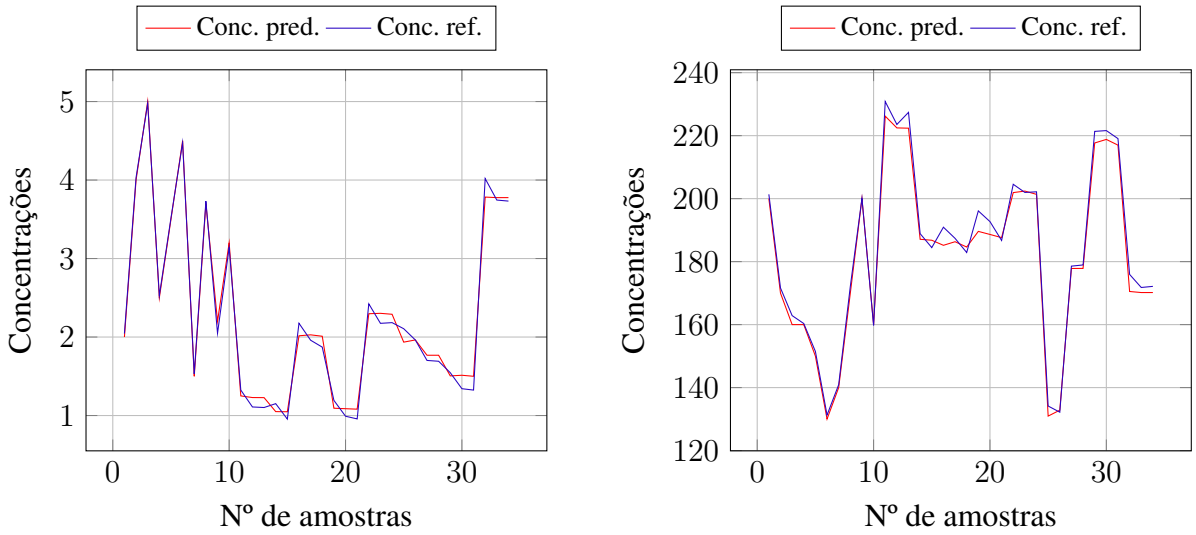
(b) RMSEP em função do número de replicação para o Fe.

Fonte: Wagner Oliveira de Araujo.

A Figura 8 mostra o RMSEP da RLM em função das replicações *bootstrap*. A Figura 8a mostra o comportamento do RLM-*bagging* para o Mn e a Figura 8b mostra o RMSEP do RLM-

bagging para o Fe. Para o Manganês, observa-se comportamento mais estável após $(15 - 20)$ replicações, os valores do RMSEP tendem a se estabilizar em torno de $(0,026 - 0,030)$ e apresenta menor variabilidade absoluta. Para o Ferro, verifica-se maior oscilação ao longo de todas as replicações, os valores oscilam entre $(1,3 - 2,2)$ sem clara estabilização, apresentando maior variabilidade tanto absoluta quanto relativa. Existe considerável variabilidade para ambos os elementos, mas: o Ferro evidenciou a maior amplitude de variação entre os métodos, com desempenho variando de 34% a 41%, indicando sensibilidade elevada à técnica utilizada. O Manganês apresenta tendência de estabilização após aproximadamente 20 replicações. O Ferro mantém oscilações mesmo com 50 replicações. Isso sugere que o *bagging* para Fe pode precisar de mais replicações ou que a predição do Fe é inerentemente mais difícil que a do Mn. Os valores apresentados na Figura 6 foram obtidos com o conjunto de calibração completo utilizado internamente para análise de sensibilidade, podendo diferir dos valores do conjunto de teste independente reportados nas Tabelas 5 e 9.

Figura 9 – RMSEP para o Mn e Fe com RLM-*bagging*.



(a) Predição do Mn com RLM-*bagging*.

(b) Predição do Fe com RLM-*bagging*.

Fonte: Wagner Oliveira de Araujo.

A Figura 9 mostra o comportamento do RMSEP com RLM-*bagging*. A Figura 9a mostra o RMSEP com RLM-*bagging* do Mn e a Figura 9b mostra o RMSEP com RLM-*bagging* do Fe.

Observa-se desempenho variável do RLM-*bagging* em relação aos resultados da técnica RLM mostrados na Tabela 4. O RLM-*bagging* apresentou melhorias para Mn (redução de 5,4%) e Fe (redução de 3,3%), enquanto demonstrou desempenho inferior para Mo (aumento de 30,8%), Cr (aumento de 12,4%) e Ni (aumento de 4,3%). Os valores de RMSEP obtidos com o RLM-*bagging* foram $(0{,}0994)$ para o Mn e $(2{,}6597)$ para o Fe, como apresentado na Tabela 5.

A Tabela 5 mostra a comparação do erro do RLM-*bagging* em relação ao erro da RLM. O RLM-*bagging* apresentou melhorias apenas para Mn (redução de 5,42%) e Fe (redução de 3,33%), enquanto para Mo, Cr e Ni o erro aumentou em 30,76%, 12,44% e 4,32%, respectiva-

Tabela 5 – RMSEP da RLM e RLM-*bagging* para cada elemento de aço-ligas.

Elementos	**RLM**	**RLM-*bagging*** (1)
Mn	0,1051	0,0994
Mo	0,2633	0,3443
Cr	1,0798	1,2141
Ni	1,6043	1,6736
Fe	2,7513	2,6597

Fonte: Wagner Oliveira de Araujo.

(1) Dezessete *bootstrap* utilizados. Parâmetros definidos sem otimização formal; ver Tabela 9 para resultados com validação cruzada 5-*fold*.

mente. Em média, o erro do RLM-*bagging* foi 7,75% maior do que o da RLM sem reamostragem. Esses resultados indicam que a aplicação do *bagging* não resultou em uma melhoria consistente no desempenho preditivo do modelo de regressão linear múltipla para este conjunto de dados.

4.2 *Subagging*

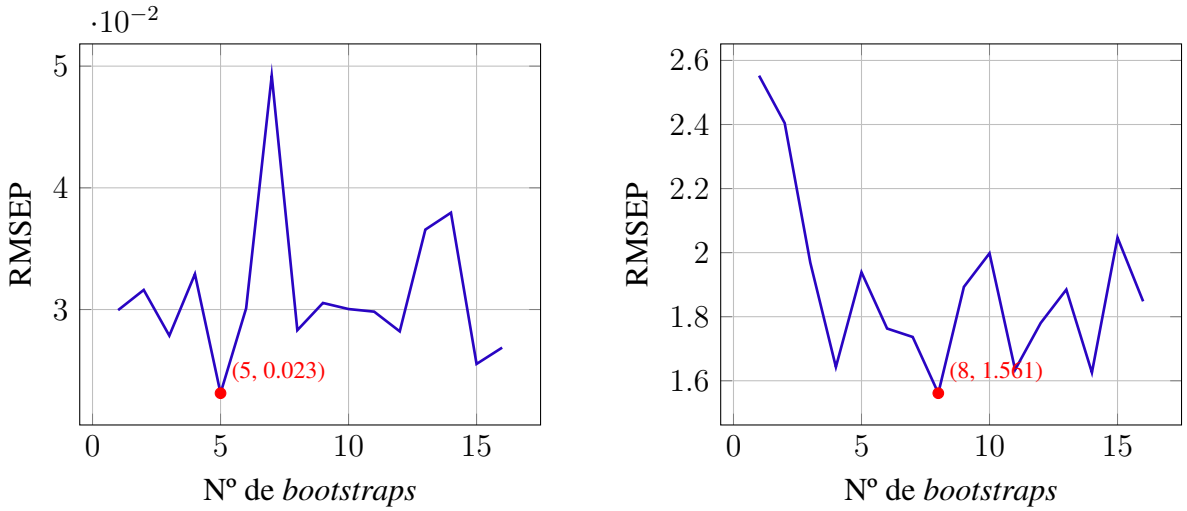
A seção *Subagging* apresenta os resultados obtidos por meio da aplicação da Regressão Linear Múltipla (RLM) sobre subconjuntos gerados via *bootstrap*, de forma semelhante ao *bagging*, porém sem reposição de amostras. O algoritmo *subagging* exige a definição de um parâmetro adicional, além do número de replicações. Enquanto no *bagging* o tamanho das amostras *bootstrap* permanece constante e igual ao conjunto original, no *subagging* esse tamanho é variável. Para analisar a sensibilidade do *subagging*, o estudo conduz um experimento com 16 amostras *bootstrap*, cujos resultados são apresentados na Figura 10.

Observa-se nas Figuras 10a e 10b que o *subagging* apresenta sensibilidade ao número de amostras *bootstrap* utilizadas no algoritmo. Para a predição do Mn, o número ideal de amostras *bootstrap* é 5, resultando em RMSEP de 0,023. Para a predição do Fe, o número ideal de amostras *bootstrap* também é 8, com RMSEP de 1,561, observando-se uma ligeira piora acima desse valor.

A Tabela 6 mostra o erro do RLM-*subagging* comparado com o erro da RLM tradicional. O RLM-*subagging* apresentou melhorias para três dos cinco analitos testados: Mn (redução de 7,33%), Ni (redução de 0,25%) e Fe (redução de 0,77%). Para Mo e Cr, houve aumento do erro de 7,14% e 7,58%, respectivamente. Em média, considerando todos os analitos, o RLM-*subagging* apresentou desempenho praticamente equivalente ao da RLM tradicional, com variação média de apenas 1,27% no RMSEP.

A Figura 11 mostra o comportamento do RMSEP com RLM-*subagging*. Nas Figuras 11a e 11b, é possível observar as predições dos elementos Mn e Fe.

Figura 10 – RMSEP em função das replicações *bootstrap* para RLM-*subagging*.



(a) Erros encontrados para cada replicação do Mn variando a quantidade de amostras *bootstrap*.

(b) Erros encontrados para cada replicação do Fe variando a quantidade de amostras *bootstrap*.

Fonte: Wagner Oliveira de Araujo.

Tabela 6 – RMSEP por elemento de aço-ligas comparando RLM e RLM-*subagging*.

Elemento	**RLM**	**RLM-*subagging***
Mn	0,1051	0,0974 (1)
Mo	0,2633	0,2821 (2)
Cr	1,0798	1,1616 (3)
Ni	1,6043	1,6003 (4)
Fe	2,7513	2,7302 (5)

Fonte: Wagner Oliveira de Araujo.

(1) Cinco *bootstrap* utilizados. (2) Dezesseis *bootstrap* utilizados. (3) Doze *bootstrap* utilizados. (4) Dez *bootstrap* utilizados. (5) Oito *bootstrap* utilizados.

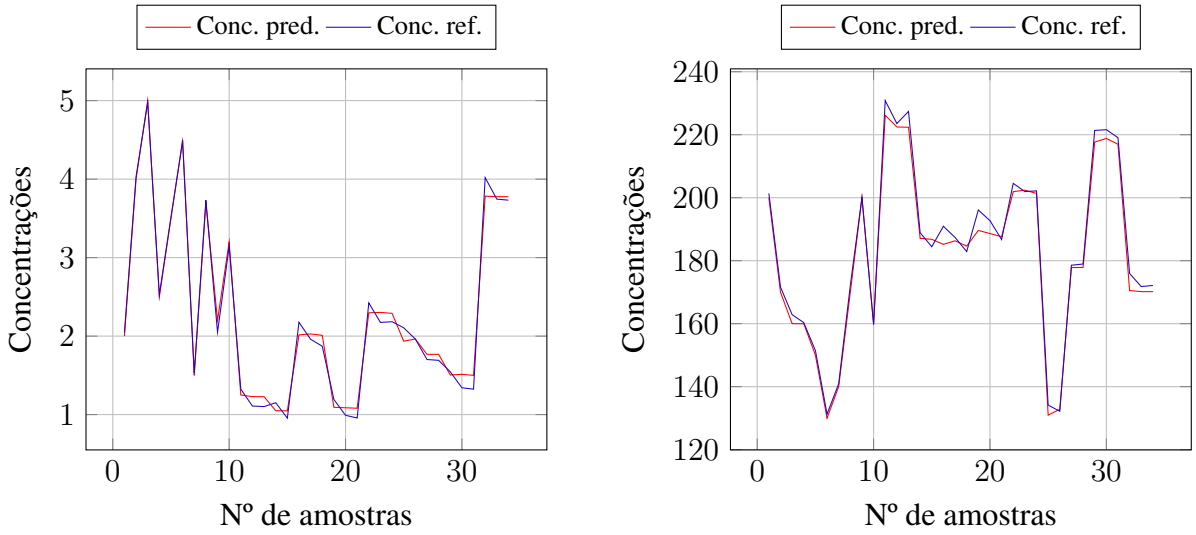
Tabela 7 – Comparação do RMSEP por elemento para diferentes técnicas e proporções de calibração.

	RLM		**RLM-*bagging***		**RLM-*subagging***	
Elemento	**50%**	**80%**	**50%**	**80%**	**50%**	**80%**
Mn	0,2029	0,1119	0,1742	0,1142	0,2205	0,1108
Mo	1,5651	0,2546	0,7338	0,3337	0,5944	0,2809
Cr	0,7215	1,0978	1,4512	1,1661	1,8984	1,1807
Ni	28,4381	1,5865	28,1847	1,3281	28,0398	1,3724
Fe	3,2962	2,5795	5,9944	2,5367	7,2990	2,4871

Fonte: Wagner Oliveira de Araujo.

Em geral, a utilização da proporção de calibração de 80% resultou em desempenho superior (menor RMSEP) para a grande maioria dos casos analisados. Para RLM-*bagging* e

Figura 11 – RMSEP do Mn e Fe com *subagging*.



(a) RMSEP do Mn com RLM-*subagging*.

(b) RMSEP do Fe com RLM-*subagging*.

Fonte: Wagner Oliveira de Araujo.

RLM-*subagging*, a proporção de 80% foi superior em todos os cinco elementos. Para a RLM clássica, a proporção de 80% foi melhor em quatro dos cinco elementos (Mn, Mo, Ni e Fe), sendo a única exceção o Cr, onde 50% de calibração produziu menor RMSEP (0,7215 contra 1,0978). Um conjunto de dados de treinamento maior, como esperado teoricamente, contribui para modelos mais robustos e com melhor capacidade de generalização.

Quanto ao melhor desempenho absoluto por elemento, o RLM-*subagging* com 80% de calibração obteve o menor RMSEP para Mn (0,1108) e Fe (2,4871), a RLM com 80% obteve o menor erro para Mo (0,2546), o RLM-*bagging* com 80% para Ni (1,3281), e a RLM com 50% para Cr (0,7215).

A técnica que atingiu o menor RMSEP (Tabela 8) varia em função do elemento, destacando que não há uma solução única para todos os casos:

Tabela 8 – Configuração de desempenho superior e RMSEP mínimo.

Elemento	**Técnica de Desempenho Superior**	**Menor RMSEP**	**Proporção** (%)
Mn	RLM	0,1108	80
Mo	RLM	0,2546	80
Cr	RLM	**0,7215**	50
Ni	RLM	1,3281	80
Fe	RLM-*subagging*	**2,4871**	80

Fonte: Wagner Oliveira de Araujo.

Nota: Resultados baseados na Tabela 7 (parâmetros sem otimização formal por validação cruzada). Para comparação com parâmetros otimizados, ver Tabela 9.

a) RLM (Clássico): Obteve a melhor performance para Mo ($0{,}2546$ com 80% de calibração) e Cr ($0{,}7215$ com 50% de calibração). Para estes elementos, a relação preditiva é relativamente simples e linear, não requerendo a complexidade adicional dos métodos de *ensemble*.

b) RLM-*bagging*: Demonstrou superioridade para Ni, atingindo $1{,}3281$ com 80% de calibração, superando a RLM ($1{,}5865$) e o RLM-*subagging* ($1{,}3724$).

c) RLM-*subagging*: Obteve o melhor desempenho para Mn ($0{,}1108$ com 80% de calibração) e Fe ($2{,}4871$ com 80% de calibração). Estes resultados indicam que estes elementos se beneficiam da agregação de modelos com subamostragem para reduzir a variância das predições.

As técnicas de ensemble (RLM-*bagging* e RLM-*subagging*) são construídas através da agregação de m modelos individuais, gerados por *bootstrap*. O RMSEP final é determinado pela média das previsões desses m modelos. O desafio na aplicação destas técnicas é otimizar o parâmetro $m \in \{5, 10, 20, 50\}$ para encontrar o ponto onde a redução da variância é maximizada sem desperdiçar recursos computacionais.

Os menores RMSEP reportados na Tabela 7 para as técnicas de *ensemble* são resultados diretos da otimização de m dentro do conjunto testado:

a) Para Mn e Fe, onde o RLM-*subagging* foi o vencedor absoluto, os valores ótimos de m foram $m = 5$ e $m = 8$, respectivamente. Estes valores relativamente baixos sugerem que poucos modelos agregados já foram suficientes para estabilizar e reduzir o erro preditivo, superando a performance do RLM clássico. Para Ni, o RLM-*bagging* com $m = 17$ obteve o menor RMSEP ($1{,}3281$).

b) Para Mo e Cr, nenhuma técnica de *ensemble* superou a RLM clássica, independentemente do valor de m utilizado. Isso indica que, para estes elementos, a agregação de modelos introduz mais variância do que reduz, e a relação preditiva linear simples é mais adequada.

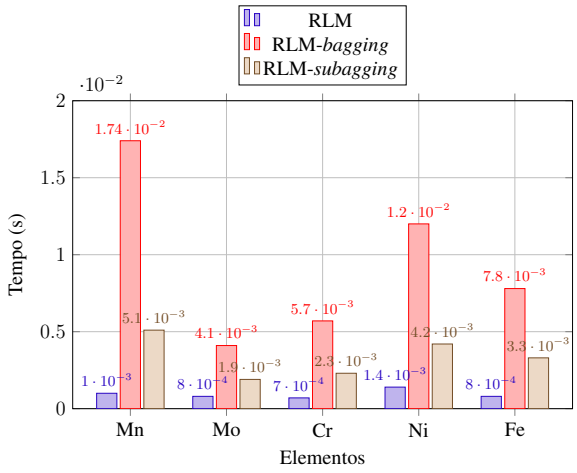
Em síntese, a análise demonstra que a escolha ideal do modelo não é apenas uma questão da técnica, mas também da proporção de calibração e, criticamente, da otimização do número de replicações (m) nas abordagens de *ensemble* para cada elemento químico.

A análise dos tempos de execução apresentados na Figura 12 revela diferenças significativas entre os três algoritmos avaliados: RLM clássico, RLM-*bagging* e RLM-*subagging*. Os experimentos foram conduzidos utilizando 50% e 80% das amostras disponíveis para cada elemento químico analisado (Mn, Mo, Cr, Ni e Fe).

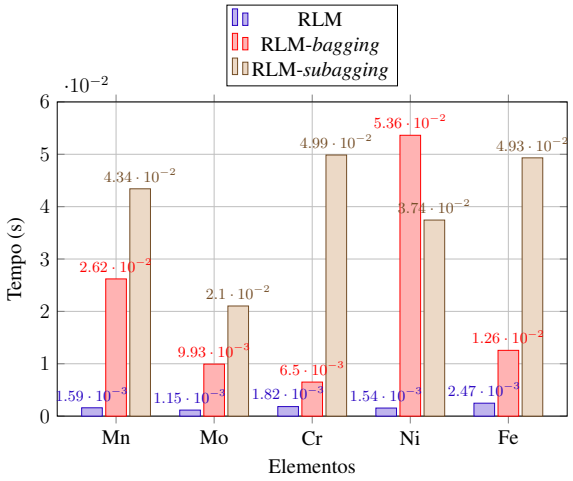
A comparação entre os dois cenários revela comportamentos distintos de crescimento temporal em função do aumento do tamanho do conjunto de treinamento. Para o RLM clássico, o aumento médio foi de aproximadamente 2,0 vezes, com variação considerável entre elementos

Figura 12 – Tempo de execução dos algoritmos RLM, RLM-*bagging* e RLM-*subagging*.

(a) 50% das amostras



(b) 80% das amostras



Fonte: Wagner Oliveira de Araujo.

(1,1 × para Ni até 3,1 × para Fe). O RLM-*bagging* apresentou um aumento médio de cerca de 2,2 vezes, com comportamento igualmente heterogêneo entre os analitos.

O comportamento mais acentuado foi observado no RLM-*subagging*, que apresentou um aumento médio de aproximadamente 13,0 vezes no tempo de execução ao passar de 50% para 80% das amostras, com variações entre 8,5 × (Mn) e 21,7 × (Cr). Este crescimento expressivo reflete a sensibilidade do algoritmo de subamostragem ao tamanho do conjunto de treinamento, uma vez que os parâmetros ótimos m^* e k^* requerem um número substancialmente maior de iterações para conjuntos maiores.

Em termos absolutos, com 80% das amostras, o RLM-*bagging* mostrou-se em média 1,7 vezes mais rápido que o RLM-*subagging*, invertendo a relação de eficiência computacional observada no cenário com 50% das amostras. Esse resultado indica que a vantagem temporal do RLM-*subagging* não se mantém com o aumento do tamanho amostral, devendo ser considerada na escolha da técnica em aplicações com conjuntos de dados maiores.

4.3 *Bagging* × *Subagging*

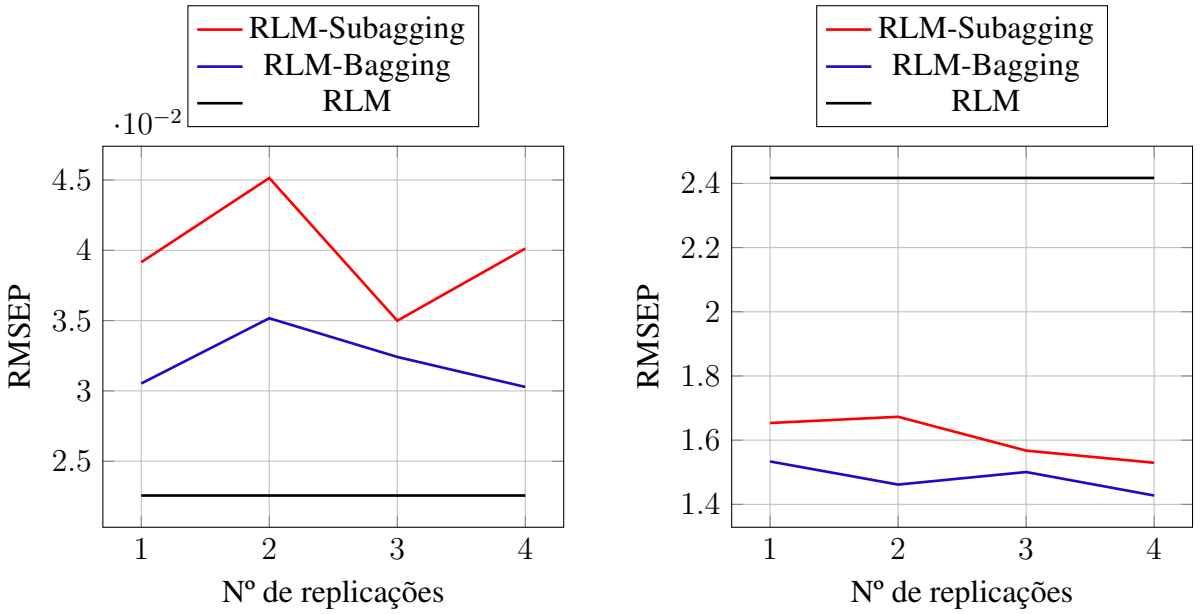
Os valores de RMSEP apresentados na (Tabela 9) diferem dos reportados na (Tabela 5) porque esta última apresenta resultados com número fixo de *bootstraps* sem otimização, enquanto a (Tabela 9) adota parâmetros otimizados por validação cruzada 5-*fold* e incorpora as três técnicas comparativamente com métricas ampliadas.

Com a implementação do *bagging* e do *subagging*, observou-se melhora das predições obtidas com a RLM para alguns analitos específicos. O RLM-*bagging* apresentou melhor desempenho para Fe, enquanto o RLM-*subagging* foi superior para Mn e Ni. Para Cr e Mo, a RLM clássica manteve o menor RMSEP; entre as técnicas *ensemble*, o RLM-*subagging* superou o RLM-*bagging* no Cr, mas nenhum dos dois superou a RLM clássica nesse elemento, indicando

que as técnicas *ensemble* nem sempre garantem melhoria. Dessa forma, é importante comparar o desempenho do RLM-*bagging* e RLM-*subagging* considerando as características específicas de cada analito.

Os percentuais de melhoria variam consideravelmente entre analitos, como evidenciado nas Tabelas 5 e 6. Para avaliar comparativamente o desempenho dessas técnicas, foi feita uma predição com o RLM-*bagging* e RLM-*subagging*, utilizando o mesmo conjunto de amostras *bootstrap*, no intuito de comparar os erros de predição das duas técnicas apresentadas na Figura 13.

Figura 13 – RMSEP para todas as técnicas.



(a) RMSEP obtido com as três técnicas aplicadas ao Mn.

(b) RMSEP obtido com as três técnicas aplicadas ao Fe.

Fonte: Wagner Oliveira de Araujo.

A RLM clássica gera uma única predição, enquanto tanto o RLM-*bagging* quanto o RLM-*subagging* utilizam múltiplas reamostragens para produzir predições agregadas. Na análise comparativa, o RLM-*subagging* foi avaliado com diferentes quantidades de amostras *bootstrap*, gerando um conjunto de 16 predições, sendo uma para cada quantidade de *bootstrap* testada. A Tabela 9 apresenta os resultados dessa comparação direta entre as técnicas, utilizando o mesmo conjunto de dados de validação.

Observa-se que a RLM clássica mantém desempenho superior para Mo e Cr, enquanto o RLM-*subagging* apresenta melhor resultado para Mn e Ni, e o RLM-*bagging* para Fe. Entre as técnicas *ensemble*, o RLM-*subagging* apresenta melhor resultado apenas para Cr em relação ao RLM-*bagging*, sem contudo superar a RLM clássica nesse elemento. Os resultados desta comparação são também apresentados nas Figuras 13a e 13b.

Os resultados comparativos entre as três técnicas avaliadas para todos os analitos são apresentados na Tabela 9. Diferentemente da análise anterior, os parâmetros m^* e k^* de cada

Tabela 9 – Desempenho comparativo das técnicas de calibração multivariada para elementos químicos em aço-liga.

Elemento	Técnica	RMSEP	MAE	R^2	Tempo (ms)	Parâmetros	
						(2) k^* (%)	(3) m^*
Mn	RLM	0,1051	0,0887	0,9907	2,4000	—	—
	RLM-*bagging*	0,1072	0,0908	0,9903	68,2000	—	30
	RLM-*subagging* (1)	**0,0966**	**0,0805**	**0,9922**	17,1000	80	10
Mo	RLM (1)	**0,2633**	**0,1952**	**0,9882**	2,4000	—	—
	RLM-*bagging*	0,3388	0,2722	0,9805	67,5000	—	30
	RLM-*subagging*	0,2879	0,2201	0,9859	46,8000	80	30
Cr	RLM (1)	**1,0798**	**0,8654**	**0,9938**	2,5000	—	—
	RLM-*bagging*	1,2089	0,9830	0,9922	44,5000	—	20
	RLM-*subagging*	1,1294	0,9010	0,9932	46,8000	80	30
Ni	RLM	1,6043	1,3256	0,9837	2,3000	—	—
	RLM-*subagging* (1)	**1,6003**	**1,2409**	**0,9838**	10,6000	60	10
	RLM-*bagging*	1,7085	1,4122	0,9815	66,6000	—	30
Fe	RLM	2,7513	2,1865	0,9892	13,5000	—	—
	RLM-*bagging* (1)	**2,6406**	**2,0246**	**0,9900**	97,2000	—	30
	RLM-*subagging*	2,6509	2,0578	0,9900	41,2000	80	30

Fonte: Wagner Oliveira de Araujo.
Nota: Sinal convencional utilizado:
— Não se aplica dado numérico.
(1) Melhor desempenho em RMSEP. Conjunto de teste único para avaliação final.
(2) Fração de subamostra k^* em porcentagem otimizados por validação cruzada 5-*fold* aplicada exclusivamente ao conjunto de calibração (*seed* = 42) *bootstrap*).
(3) Parâmetros m^* número de replicações *bootstrap*.

método foram determinados por validação cruzada 5-*fold* aplicada exclusivamente ao conjunto de calibração, garantindo que o conjunto de teste não influenciasse a seleção dos hiperparâmetros e assegurando a comparabilidade entre os métodos.

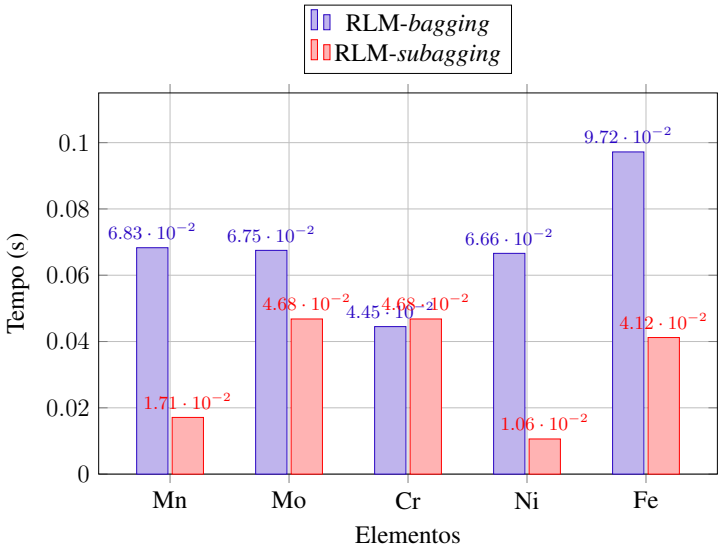
Os resultados revelam que não existe uma técnica universalmente superior para todos os analitos. Para o Manganês (Mn), o RLM-*subagging* ($k^* = 80\%$, $m^* = 10$) apresentou o menor RMSEP (0,0966), representando uma redução de 8,1% em relação à RLM clássica, além de ser 4,0 vezes mais rápido que o RLM-*bagging*. Para o Ferro (Fe), o RLM-*bagging* ($m^* = 30$) obteve o melhor desempenho (RMSEP = 2,6406), com melhoria de 4,0% sobre a RLM clássica. Para o Níquel (Ni), o RLM-*subagging* ($k^* = 60\%$, $m^* = 10$) apresentou resultado marginalmente superior (RMSEP = 1,6003), com diferença de 0,25% em relação à RLM clássica e tempo de execução 6,3 vezes menor que o RLM-*bagging*.

Em contrapartida, para o Molibdênio (Mo) e o Cromo (Cr), a RLM clássica demonstrou desempenho superior (RMSEP de 0,2633 e 1,0798, respectivamente), indicando que a complexidade adicional introduzida pelas estratégias de *ensemble* não resultou em melhorias significativas de precisão para esses analitos. Esses resultados sugerem que a relação preditiva para Mo e Cr é suficientemente linear, não se beneficiando da agregação de modelos.

A análise do custo computacional evidencia que o RLM-*subagging* configura-se como alternativa balanceada entre precisão e eficiência, sendo consistentemente mais rápido que o

RLM-*bagging* para todos os elementos avaliados. Observa-se ainda que o parâmetro $k^* = 80\%$ revelou-se ótimo para o *subagging* em quatro dos cinco elementos, sugerindo que subamostras maiores favorecem a estabilidade do modelo neste contexto específico de dados espectrométricos de aço-ligas.

Figura 14 – Tempo de execução dos algoritmos RLM-*bagging* e RLM-*subagging* com parâmetros otimizados por validação cruzada 5-*fold*.



Fonte: Wagner Oliveira de Araujo.

A Figura 14 apresenta os tempos de execução dos algoritmos RLM-*bagging* e RLM-*subagging* para cada elemento, utilizando os parâmetros m^* e k^* determinados por validação cruzada 5-*fold*. Diferentemente da análise anterior, os parâmetros agora variam por elemento — refletindo configurações objetivamente otimizadas —, o que torna a comparação de tempos diretamente atrelada ao custo real de cada configuração de melhor desempenho preditivo.

Em quatro dos cinco elementos avaliados (Mn, Mo, Ni e Fe), o RLM-*subagging* mostrou-se mais rápido que o RLM-*bagging*. Em média, considerando a razão entre os tempos em cada analito, o RLM-*subagging* é aproximadamente 3,0 vezes mais rápido; somando os tempos dos cinco analitos, a redução é de cerca de 53%.

As maiores diferenças ocorreram para o Ni (6,3 vezes mais rápido, com $k^* = 60\%$ e $m^* = 10$) e para o Mn (4,0 vezes mais rápido, com $k^* = 80\%$ e $m^* = 10$). Para Mo e Fe, as reduções foram de 1,4 e 2,4 vezes, respectivamente. Essa eficiência decorre da amostragem sem reposição, que emprega subconjuntos de tamanho reduzido ($k^* \leq 80\%$), resultando em operações matriciais mais ágeis e menor redundância nos dados processados a cada iteração.

O Cromo (Cr) constitui o único caso em que o RLM-*subagging* apresentou tempo marginalmente superior ao RLM-*bagging* (46,8 ms contra 44,5 ms, diferença de apenas 2,3 ms). Esse comportamento é explicado pelos parâmetros ótimos obtidos pela validação cruzada: o RLM-*bagging* utilizou $m^* = 20$ replicações, enquanto o RLM-*subagging* requereu $m^* = 30$ replicações com $k^* = 80\%$ para atingir o menor *Root-Mean-Square Error of Prediction in*

Cross-Validation (RMSEP-CV). O maior número de iterações compensou o benefício da subamostragem, resultando em custo computacional equivalente para este analito específico.

O desempenho superior das técnicas de *ensemble* para Fe pode ser atribuído à complexidade espectral desse elemento. O Fe, como elemento matriz, apresenta espectro de alta densidade com potencial de autoabsorção, características que introduzem não-linearidades e instabilidade no modelo base, condições nas quais a agregação de múltiplos modelos é teoricamente vantajosa. O Cr, embora sofra sobreposições espectrais com linhas do Fe e Ni — o que tornaria a agregação de modelos teoricamente promissora —, não apresentou ganho preditivo com as técnicas *ensemble*, mantendo a RLM clássica como método de menor RMSEP (1,0798). Esse resultado sugere que, para o Cr, a complexidade espectral não foi suficiente para que a redução de variância promovida pelo *ensemble* superasse o custo de viés introduzido pela reamostragem. Para Mn e Mo, cujas linhas analíticas apresentam menor interferência matricial, a relação espectral-concentração é suficientemente bem capturada pela RLM clássica.

Em relação à RLM clássica, ambas as técnicas de *ensemble* apresentam custo computacional significativamente superior, com o RLM-*bagging* sendo em média 22,1 vezes mais lento e o RLM-*subagging* até 19,5 vezes mais lento (para o Mo). Ainda assim, para aplicações em que a acurácia preditiva justifica o custo computacional adicional — como na determinação de Mn e Fe em aço-ligas — o RLM-*subagging* configura-se como alternativa equilibrada entre precisão e eficiência, sendo preferível ao RLM-*bagging* na maioria dos cenários avaliados.

Ressalta-se que as conclusões desta subseção referem-se ao protocolo com otimização por validação cruzada. No experimento anterior, com parâmetros fixados sem otimização formal (Tabelas 7 e 8), a técnica de menor RMSEP diferiu para alguns analitos (por exemplo, Ni e Fe), e o comportamento dos tempos com 80% das amostras foi distinto. Isso indica que o desempenho relativo das técnicas depende do critério de seleção de m e k.

5 REQUISITOS FUNCIONAIS

Esta seção apresenta o levantamento estruturado dos requisitos funcionais da aplicação *Regressão Espectral com Métodos de Ensemble (Bagging & Subagging)*, desenvolvida na plataforma Streamlit. A análise segue a estrutura proposta em quatro seções: Inventário de funcionalidades, Classificação por prioridade, Fluxos de uso e Requisitos não funcionais.

5.1 Levantamento de Requisitos Funcionais

5.1.1 Inventário das Funcionalidades Existentes

5.1.1.1 Funções do Sistema

A Quadro 3 resume as funcionalidades identificadas na aplicação, categorizadas por tipo de operação.

Quadro 3 – Inventário das funções do sistema

Categoria	**Funcionalidade**	**Descrição Técnica**
Cálculos	RLM Simples (Baseline)	Regressão Linear Múltipla padrão sem técnicas de ensemble
Cálculos	RLM + Bagging	Ensemble com amostragem *com* reposição (bootstrap)
Cálculos	RLM + Subagging + CV	Ensemble com amostragem *sem* reposição + otimização por validação cruzada 5-Fold
Configuração	Parâmetro *m* (Bags)	Define número de amostras/ensembles para o método Bagging
Configuração	Parâmetro *k* (Subagging)	Define fração ou quantidade para amostragem no Subagging
Visualização	Métricas de Desempenho	Exibição de R^2, RMSE, MAE calculados no conjunto de teste
Visualização	Gráficos Comparativos	*Scatter plots* (previsto $\times$ real), resíduos e comparação entre modelos
Organização	Abas de Navegação	Separação lógica: “Arquivos”, “Configuração”, “Resultados”, “Gráficos”
Exportação	*Não identificada*	**Obs.:** sistema não apresenta botões de download de resultados

Fonte: Wagner Oliveira de Araujo.

5.1.1.2 Entradas Necessárias (Inputs)

A Quadro 4 detalha os dados e parâmetros exigidos para execução da aplicação.

Quadro 4 – Entradas necessárias para execução do sistema.

Tipo	**Nome**	**Formato**	**Obrig.**	**Descrição**
Arquivo	`Xcal.txt`	`.txt`	Sim	Matriz de espectros de calibração
Arquivo	`Ycal.txt`	`.txt`	Sim	Vetor de valores de referência
Arquivo	`Xteste.txt`	`.txt`	Sim	Matriz de espectros para predição
Arquivo	`Yteste.txt`	`.txt`	Sim	Vetor de valores reais para validação
Parâmetro	m	Inteiro ≥ 1	Condic.[1]	Usado apenas nos métodos de ensemble
Parâmetro	k	Inteiro ≥ 1	Condic.[1]	Usado apenas no método Subagging
Config.	Val. Cruzada	Fixo: 5-Fold	Auto.	Parâmetro interno de otimização
[1]Condicional: habilitados apenas quando o usuário seleciona métodos de ensemble.				

Fonte: Wagner Oliveira de Araujo.

5.1.1.3 Saídas Esperadas (Outputs)

A Quadro 5 apresenta os resultados gerados pelo sistema após processamento.

Quadro 5 – Saídas esperadas do sistema

Tipo	**Conteúdo**	**Formato de Exibição**	**Destinatário**
Numérico	R^2, RMSE, MAE (conjunto de teste)	Quadro ou *cards* destacados	Usuário analista
Gráfico	Previsto vs. Real	*Scatter plot* com reta de ajuste	Usuário analista
Gráfico	Resíduos da Predição	Gráfico de dispersão ou histograma	Usuário analista
Comparativo	Desempenho: RLM $\times$ Bagging $\times$ Subagging	Quadro comparativa ou gráfico de barras	Usuário analista
Feedback	Mensagens de erro/validação	Alertas em destaque	Usuário final
Status	Indicador de processamento	*Spinner* ou barra de progresso	Usuário final

Fonte: Wagner Oliveira de Araujo.

5.1.2 Classificação por Prioridade

Os requisitos foram classificados utilizando a técnica MoSCoW[1] adaptada, conforme descrito nas seções seguintes.

5.1.2.1 Essenciais (*Must Have*)

[1]MoSCoW é uma técnica de priorização de requisitos dividida em quatro categorias: *Must have* (obrigatórios), *Should have* (importantes, mas não críticos), *Could have* (desejáveis) e *Won't have (this time)* (excluídos desta versão). A letra "o" é adicionada apenas para facilitar a pronúncia.

Quadro 6 – Requisitos essenciais do sistema

ID	Requisito	Justificativa
E01	Upload e validação dos 4 arquivos de entrada	Dados são pré-requisito para qualquer cálculo estatístico
E02	Execução da RLM Simples (baseline)	Referência obrigatória para comparação de desempenho dos ensembles
E03	Cálculo de métricas básicas (R^2, RMSE, MAE)	Mínimo necessário para avaliação quantitativa da qualidade do modelo
E04	Validação de consistência dimensional (X vs Y)	Previne erros de execução e geração de resultados inválidos
E05	Exibição clara dos resultados numéricos	Permite decisão técnica fundamentada em evidências quantitativas

Fonte: Wagner Oliveira de Araujo.

5.1.2.2 Desejáveis (*Should Have*)

Quadro 7 – Requisitos desejáveis do sistema

ID	Requisito	Benefício
D01	Gráficos interativos (zoom, *tooltip*, download)	Facilita exploração visual detalhada e apresentação de resultados
D02	Exportação de resultados (CSV, PDF, PNG)	Permite documentação, compartilhamento e reprodutibilidade
D03	*Tooltips* explicativos para m, k, Bagging/Subagging	Reduz curva de aprendizado para usuários não especialistas
D04	Pré-processamento básico (normalização, escalonamento)	Melhora robustez dos modelos com dados espectrais reais
D05	Histórico de execuções na sessão	Permite comparar configurações sem reenviar arquivos

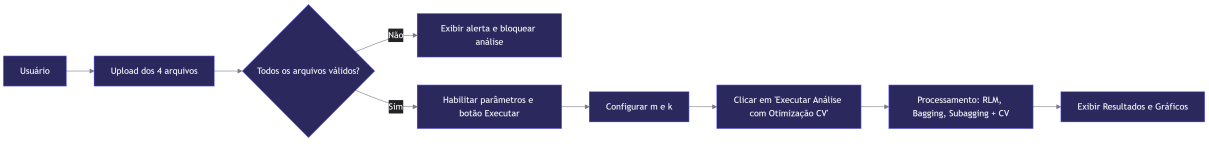
Fonte: Wagner Oliveira de Araujo.

5.1.2.3 Extras (*Could Have*)

5.1.3 Fluxos de Uso

5.1.3.1 Fluxo Principal: Execução de Análise Completa

Figura 15 – Execução de Análise Completa.



Fonte: Wagner Oliveira de Araujo.

Quadro 8 – Requisitos extras para fases futuras

ID	Requisito	Cenário de Uso
X01	Autenticação de usuários e projetos privados	Ambientes corporativos ou de pesquisa colaborativa
X02	Integração com APIs externas (ex: KNIME, scripts Python)	Pipelines automatizadas de quimiometria
X03	Suporte a formatos adicionais (.csv, .xlsx, .mat)	Flexibilidade para ingestão de dados de diferentes fontes
X04	Otimização automática de hiperparâmetros	Reduz necessidade de conhecimento técnico avançado
X05	Dashboard comparativo multi-rodada	Análise estatística de estabilidade dos modelos ensemble

Fonte: Wagner Oliveira de Araujo.

5.1.3.2 Fluxos Alternativos e Tratamento de Exceções

Quadro 9 – Fluxos alternativos e tratamento de exceções

Cenário	Gatilho	Comportamento do Sistema	Ação do Usuário
Arquivo inválido	Upload com formato/-dimensão incorreta	Alerta vermelho + destaque no campo problemático	Corrigir arquivo e reenviar
Parâmetros fora do intervalo	Inserir m ou $k \leq 0$ ou excessivamente alto	Validação em tempo real + mensagem orientativa	Ajustar para valores válidos
Timeout de processamento	Dados muito grandes ou carga elevada	Mensagem: "Processamento demorado..."	Otimizar entrada ou repetir depois
Navegação sem executar	Usuário muda de aba antes de clicar	Mantém estado dos uploads (persistência)	Retornar e concluir análise

Fonte: Wagner Oliveira de Araujo.

5.1.3.3 Pontos Críticos de Usabilidade

Quadro 10 – Pontos críticos de usabilidade e estratégias de mitigação

Ponto	**Risco**	**Sugestão de Mitigação**
Upload múltiplo obrigatório	Esquecer um dos 4 arquivos e travar o fluxo	Checklist visual + botão habilitado apenas quando todos estiverem OK
Parâmetros *m* e *k* abstratos	Inserir valores inadequados e obter resultados ruins	*Sliders* com valores recomendados + *tooltip* prático
Processamento sem feedback claro	Achar que a aplicação travou	Barra de progresso com etapas descritivas
Gráficos sem legenda ou escala	Dificulta interpretação em telas menores	Legendas fixas, eixos nomeados, opção de ampliar
Resultados não exportáveis	Impede documentação externa	Botão "Baixar Relatório" com métricas + gráficos

Fonte: Wagner Oliveira de Araujo.

5.1.4 Requisitos Não Funcionais

5.1.4.1 Performance

Quadro 11 – Requisitos de performance do sistema

Requisito	**Especificação**	**Critério de Aceite**
Tempo de upload	Arquivos ≤ 200 MB	< 30 s em conexão 10 Mbps
Tempo de cálculo (RLM)	Dataset típico ($n \leq 500$, $p \leq 1000$)	< 10 s
Tempo de cálculo (Ensemble)	Bagging/Subagging com $m \leq 100$	< 2 min com CV 5-Fold
Renderização de gráficos	Após conclusão do cálculo	< 3 s
Responsividade da UI	Interações (mudar aba, ajustar parâmetro)	< 500 ms de feedback visual

Fonte: Wagner Oliveira de Araujo.

5.1.4.2 Usabilidade

Quadro 12 – Requisitos de usabilidade do sistema

Requisito	**Especificação**	**Critério de Aceite**
Acessibilidade	Compatível com WCAG 2.1 Nível AA[a]	Contraste adequado, *labels*, navegação por teclado
Responsividade	Funcional em desktop, tablet e mobile ($\geq$ 768 px)	Layout adaptativo sem perda de funcionalidade crítica
Clareza textual	Mensagens, rótulos e erros em português claro	Teste com 3 usuários: $\geq$ 90% de acerto na interpretação
Consistência	Padrões visuais alinhados ao Streamlit	Botões, cores e ícones seguem guia de estilo
Recuperação de erro	Mensagens orientam a correção	Ex: "Ycal.txt tem 99 linhas, mas Xcal.txt tem 100..."

[a] A *Web Content Accessibility Guidelines* (WCAG) 2.1 Nível AA é um padrão internacional de acessibilidade digital que estabelece critérios de desenvolvimento para garantir que softwares e sites sejam plenamente utilizáveis por pessoas com deficiências visuais, auditivas, motoras ou cognitivas.
Nota: Modificado para atender ao escopo do projeto.
Fonte: Wagner Oliveira de Araujo.

5.1.4.3 Segurança

Quadro 13 – Requisitos de segurança do sistema

Requisito	**Especificação**	**Justificativa**
Isolamento de sessão	Dados não vazam entre usuários	Aplicação pública; dados podem ser propriedade intelectual
Sanitização de arquivos	Validar extensão, cabeçalho e conteúdo	Prevenção contra upload malicioso
Limite de tamanho	Máximo 200 MB por arquivo	Evita abuso de recursos computacionais
Logs de auditoria (opc.)	Registrar uploads/execuções (sem dados)	Rastreabilidade para suporte técnico
HTTPS obrigatório	Todas as comunicações criptografadas	Proteção de integridade e confidencialidade

Fonte: Wagner Oliveira de Araujo.

5.1.4.4 Escalabilidade

Quadro 14 – Requisitos de escalabilidade do sistema

Cenário	**Capacidade Atual**	**Meta**	**Estratégia**
Usuários simultâneos	∼10–20 (*Streamlit Cloud free*)	100+ usuários/h	Container com *load balancer*
Volume de dados	∼500 amostras × 2k variáveis	5k+ amostras × 10k var.	Processamento em *batch* / Dask
Crescimento funcional	Script único	Módulos *plug-and-play*	Arquitetura de plugins
Internacionalização	Português	Inglês + Espanhol	Arquivos *i18n*

Fonte: Wagner Oliveira de Araujo.

5.2 Considerações Finais do Levantamento

O levantamento apresentado estabelece uma base estruturada para o desenvolvimento e evolução da aplicação de regressão espectral. Destacam-se como prioridades imediatas:

a) Validação rigorosa das entradas (arquivos e parâmetros) para garantir integridade dos cálculos;

b) Implementação de mecanismos de *feedback* visual durante processamentos demorados;

c) Documentação clara do contrato de dados (formato, delimitador, codificação dos arquivos `.txt`);

d) Inclusão de funcionalidade básica de exportação de resultados para viabilizar uso acadêmico e profissional.

Recomenda-se que os requisitos classificados como *Essenciais* (Quadro 6) sejam implementados na versão mínima viável *Minimum Viable Product* (MVP)[2] , enquanto os itens *Desejáveis* e *Extras* compõem o *backlog* para iterações futuras, sujeitos a validação com usuários finais e análise de custo-benefício.

Os requisitos não funcionais definidos nas Seções 5.1.4.1 a 5.1.4.4 devem ser considerados como restrições de projeto em todas as fases de desenvolvimento, assegurando que a aplicação seja não apenas funcional, mas também performática, segura e adaptável a cenários de crescimento.

[2]O *Minimum Viable Product* (MVP), ou Produto Mínimo Viável, é a versão mais enxuta de um produto que contém apenas as funcionalidades essenciais para que ele possa ser lançado e testado no mercado.

6 ENGENHARIA DE SOFTWARE E MODERNIZAÇÃO

6.1 Engenharia de Requisitos com Sommerville

Sommerville (45) estrutura a engenharia de requisitos em quatro fases interdependentes: elicitação, análise, especificação e validação. A reestruturação do sistema em três módulos — `models.py`, `components.py` e `app.py` — evidencia como cada fase foi aplicada para preservar as regras de negócio do legado Vaadin/Java sem reaproveitar seu código-fonte.

a) Elicitação: As entradas críticas do domínio de regressão espectral foram identificadas diretamente no sistema Java original: as matrizes `Xcal` e `Xteste`, os vetores `Ycal` e `Yteste`, e os hiperparâmetros *m* (número de bags) e *k* (fração de subagging). O `app.py` captura esses insumos por meio de `st.file_uploader` e `st.text_input`, incluindo suporte a decimal com vírgula — particularidade do padrão brasileiro — tratada nas funções `parse_matrix()` e `parse_vector()` do `models.py`.

b) Análise: A análise revelou que a lógica do `RegressionService.java` podia ser decomposta em responsabilidades distintas: parse de arquivos, algoritmos de regressão, métricas de avaliação e otimização por validação cruzada. Essa decomposição originou a estrutura modular adotada, onde `models.py` concentra toda a inteligência matemática, sem qualquer dependência de interface.

c) Especificação: Os contratos de entrada e saída foram formalizados com *type hints* explícitos em todas as funções do `models.py`: `parse_matrix(content: bytes) -> np.ndarray`, `perform_rlm(Xcal, Ycal, Xteste: np.ndarray) -> np.ndarray`, `calc_metrics(actual, predicted) -> tuple[float, float, float]`. A função `run_full_analysis()` retorna um dicionário tipado com chaves `log`, `optimal`, `metrics` e `preds`, constituindo o contrato formal entre a camada de negócio e a camada de apresentação.

d) Validação: A validação cruzada 5-fold implementada em `run_cross_validation()` opera como mecanismo de validação de equivalência, permitindo comparar o desempenho do sistema Python com os resultados históricos do sistema Java. O log estruturado gerado por `run_full_analysis()` documenta cada etapa — dimensões detectadas, RMSE-CV por combinação de hiperparâmetros, métricas finais e tempo de execução — possibilitando auditoria científica e rastreabilidade completa.

6.2 Especificação de Requisitos Funcionais e Não Funcionais

A fase de Especificação de Sommerville (45), descrita no item (c) da seção anterior, é formalizada nesta seção por meio da enumeração dos requisitos funcionais (RF) e não funcionais (RNF) efetivamente implementados no sistema Python/Streamlit. Os requisitos foram

extraídos diretamente do código-fonte de `models.py`, `components.py` e `app.py`, e não de funcionalidades planejadas ou não concluídas, de modo a refletir com precisão o estado real do sistema entregue neste TCC II.

6.2.1 Requisitos Funcionais

O Quadro 15 apresenta os requisitos funcionais do sistema, isto é, as funcionalidades que o usuário pode efetivamente executar por meio da interface Streamlit.

Quadro 15 – Requisitos funcionais do sistema

ID	**Descrição**
RF01	Permitir o *upload* das matrizes `Xcal`, `Xteste` e dos vetores `Ycal`, `Yteste` nos formatos `.txt`, `.csv` e `.xlsx`.
RF02	Interpretar arquivos com separador decimal brasileiro (vírgula) e separador de coluna `;` ou `,`, normalizando-os para o formato numérico do NumPy.
RF03	Executar a Regressão Linear Múltipla (RLM) simples via `np.linalg.lstsq`.
RF04	Executar RLM com *Bagging* (reamostragem *bootstrap* com reposição) para um conjunto de valores de m informados pelo usuário.
RF05	Executar RLM com *Subagging* (reamostragem sem reposição) para conjuntos de valores de m e k informados pelo usuário.
RF06	Otimizar os hiperparâmetros m (*Bagging*) e k, m (*Subagging*) por *grid search* com validação cruzada de 5 *folds*.
RF07	Calcular as métricas RMSE, MAE e R^2 para os três modelos (RLM, *Bagging* e *Subagging*) sobre o conjunto de teste.
RF08	Exibir um log estruturado de execução, contendo dimensões detectadas, RMSE-CV por combinação de hiperparâmetros e tempo de execução por modelo.
RF09	Gerar gráficos interativos (Plotly) de valores reais *versus* preditos por modelo e de dispersão real *versus* predito com os três modelos sobrepostos.
RF10	Exportar a tabela comparativa de métricas em `.csv` e o log de execução em `.txt`.
RF11	Exibir a interface e os rótulos dos gráficos em português ou inglês, conforme seleção do usuário.
RF12	Exibir barra de progresso durante a execução do *grid search*, atualizada por *callback* a cada combinação de hiperparâmetros avaliada.

Fonte: Wagner Oliveira de Araujo.

6.2.2 Requisitos Não Funcionais

O Quadro 16 apresenta os requisitos não funcionais, relativos a atributos de qualidade do sistema — desempenho, manutenibilidade, testabilidade e confiabilidade — verificáveis independentemente das funcionalidades de negócio listadas no Quadro 15.

Quadro 16 – Requisitos não funcionais do sistema

ID	Descrição
RNF01	**Modularidade**: o sistema deve ser estruturado em módulos com acoplamento (45) zero — `models.py` não importa `streamlit` nem `plotly`; `components.py` não importa `streamlit` nem `numpy`.
RNF02	**Testabilidade**: a lógica de negócio deve ser testável de forma isolada, sem instanciar componentes de interface, permitindo o uso de `pytest` diretamente sobre `models.py`.
RNF03	**Confiabilidade**: os resultados numéricos do sistema Python devem ser equivalentes aos do sistema Java legado, verificados por testes de caixa-preta comparativos: equivalência estrita (tolerância de 5×10^{-4}) para a RLM determinística e consistência estatística (tolerâncias de 0,15 em RMSEP/MAE e 5×10^{-3} em R^2) para os métodos estocásticos.
RNF04	**Portabilidade**: o sistema deve ser executável via navegador (`streamlit run app.py`), sem necessidade de JVM[a], arquivos `.class` ou instalação local de dependências além do ambiente Python.
RNF05	**Usabilidade**: a interface deve guiar o usuário em um fluxo sequencial e irreversível (Configuração → Resultados → Gráficos), impedindo execuções com arquivos incompletos.
RNF06	**Desempenho**: o tempo de execução de cada modelo (RLM, *Bagging*, *Subagging*) deve ser medido em milissegundos e reportado como métrica independente das métricas de acurácia.
RNF07	**Escalabilidade**: o sistema deve manter corretude numérica ao processar matrizes espectrais de grande porte, verificada por testes de estresse sobre matrizes de grandes dimensões.
RNF08	**Internacionalização**: a interface e os componentes visuais devem suportar múltiplos idiomas (português e inglês) sem duplicação de código, por meio de dicionários de tradução centralizados.

[a] A *Java Virtual Machine* (JVM), ou Máquina Virtual Java, é um ambiente de execução que atua como uma camada de abstração entre o código Java compilado (bytecodes) e o sistema operacional do hardware.
Fonte: Wagner Oliveira de Araujo.

Os requisitos funcionais RF03 a RF07 correspondem diretamente às responsabilidades isoladas em `models.py`, ao passo que RF09 e RF11 correspondem a `components.py`; RF01, RF08, RF10 e RF12 são responsabilidade exclusiva de `app.py`. Essa correspondência unívoca entre requisito e módulo confirma, em nível de especificação, a separação de camadas discutida na Seção 8.3.

Os requisitos não funcionais RNF01 a RNF03, por sua vez, são verificados empiricamente pela suíte de 92 testes automatizados (`test_suite_5.py`) — 21 unitários, 60 de caixa-preta e 11 de estresse —, detalhada no capítulo de Testes e Validação deste TCC II.

6.3 Estratégias de Migração de Sistemas

A transição do modelo Desktop (Java/Vaadin) para o modelo Web (Python/Streamlit) foi conduzida por **reescrita funcional** (*black-box rewrite*), estratégia que extrai os requisitos do

comportamento observável do sistema legado sem reaproveitar o código-fonte (46).

a) Reescrita Black-Box: O comentário de cabeçalho do `app.py` (*"Conversão do projeto Vaadin Flow (Java) para Streamlit (Python)"*) e as referências internas ao `RegressionService.java` indicam que a migração partiu do comportamento esperado, não do código herdado. Não há dependência de JVM, arquivos `.class` ou `.jar`. O núcleo matemático foi reimplementado diretamente em `models.py` com `numpy`, preservando a equivalência algébrica da pseudoinversa de Moore-Penrose e dos algoritmos de amostragem.

b) Extração Seletiva da Lógica de Negócio: A migração isolou apenas o que tinha valor científico reutilizável: a pseudoinversa (`perform_rlm`), a amostragem com e sem reposição (`perform_bagging`), o grid search por validação cruzada (`find_optimal_parameters`) e as métricas de erro (`calc_metrics`). Camadas de UI do Java — componentes Vaadin, listeners de evento, gerenciamento de sessão HTTP — foram descartadas e substituídas pelos widgets declarativos do Streamlit no `app.py`.

c) Deploy Web Nativo: O modelo Desktop foi convertido para uma aplicação *stateless*[1], executável com `streamlit run app.py`, containerizável com Docker e acessível via navegador sem instalação local[2]. Isso reduz o atrito de distribuição em laboratórios e viabiliza uso colaborativo simultâneo, funcionalidade inexistente no sistema Vaadin original (56).

d) Papel e Limites do Estágio Intermediário (Vaadin): O estágio Vaadin Flow funcionou como prova de conceito de exposição web da lógica reaproveitada do Java, validando a viabilidade de servir o núcleo algorítmico via navegador antes da reescrita completa. Diferentemente do estágio final em Python, esse estágio não foi acompanhado por suíte de testes automatizados formal, lacuna reconhecida que motivou a decisão de formalizar o mecanismo de validação de equivalência — a suíte de 92 testes automatizados, dos quais 60 de caixa-preta — apenas a partir da reescrita em Streamlit.

6.4 Mudança de Paradigma Arquitetural

A reestruturação em três arquivos evidencia uma mudança profunda no paradigma de execução e no modelo de estado da aplicação.

a) MVC Tradicional (Java/Vaadin): O sistema legado seguia a separação explícita entre *Model* (dados e regressão), *View* (componentes HTML gerados pelo Vaadin) e *Controller* (listeners de evento Java). O estado vivia na sessão HTTP e as atualizações de interface

[1] Significa que a aplicação não mantém memória de estado entre as interações por conta própria, exigindo que todo o script seja reprocessado a cada ação e que qualquer dado que precise ser preservado seja salvo manualmente em variáveis de sessão.

[2] Aplicação em produção disponível em: https://app-app-rmn8qdzis5uqkfbmy5pjwr.streamlit.app/.

eram parciais e assíncronas (AJAX/push), permitindo que apenas o componente afetado fosse re-renderizado.

b) Arquitetura em Camadas (57) com Streamlit: A divisão em `models.py` (lógica pura), `components.py` (fábrica visual) e `app.py` (orquestrador) aplica o princípio de **separação de responsabilidades** de Sommerville (45) dentro do paradigma Streamlit. O `app.py` é um script linear que reexecuta do início ao fim a cada interação do usuário — clique, upload ou navegação entre abas. Não há controlador permanente; o fluxo segue *Entrada do Usuário → Rerun do Script → Renderização Declarativa*.

c) Gerenciamento de Estado Explícito: No paradigma Streamlit, o estado não persiste automaticamente entre reruns[3] . O dicionário `st.session_state["result"]` armazena o output completo de `run_full_analysis()` — métricas, predições e log — garantindo que as abas **Resultados** e **Gráficos** leiam os dados sem reacionar a regressão. Essa explicitação do estado é uma diferença fundamental em relação ao modelo MVC com sessão HTTP implícita do Java.

[3] O termo *rerun* refere-se ao ciclo de reexecução automática do script Python realizado pelo framework Streamlit a cada nova interação do usuário na interface gráfica.

7 ECOSSISTEMA DE DESENVOLVIMENTO (PYTHON E STREAMLIT)

7.1 Python na Computação Científica

A escolha do Python como linguagem base é justificada pelo ecossistema maduro voltado à álgebra linear, ao processamento de sinais espectrais e à quimiometria computacional. Bibliotecas como `NumPy`, `Pandas` e `SciPy` formam a base científica sobre a qual o sistema foi construído e pode evoluir, tornando Python a escolha natural para domínios que lidam com dados espectrométricos de alta dimensionalidade.

a) Processamento Vetorial com `NumPy`: O `models.py` utiliza exclusivamente operações vetorizadas do NumPy: `np.linalg.lstsq(Xcal, Ycal, rcond=None)` para a solução de mínimos quadrados de norma mínima (equivalente à pseudoinversa de Moore-Penrose), `np.random.default_rng` para amostragem reprodutível com semente configurável, e `np.sqrt(np.mean(err**2))` para RMSEP. Essas operações substituem laços explícitos em Java, executando em tempo próximo a linguagens compiladas mesmo para matrizes espectrais com milhares de variáveis.

b) *Parsing* Robusto com `parse_matrix()` e `parse_vector()`: As funções de leitura em `models.py` utilizam decodificação UTF-8 com tolerância a erros, normalização de separador decimal (vírgula para ponto) e filtragem de linhas vazias. Esse *parsing* manual garante compatibilidade com arquivos `.txt` gerados por instrumentos espectrométricos sem dependência de formatação rígida.

c) Interoperabilidade Científica com `Pandas`: A integração com `pandas` no `app.py` permite exportar a tabela comparativa de métricas diretamente em CSV (`df_metrics.to_csv()`), mantendo o fluxo de trabalho típico de laboratórios de quimiometria. O `pd.DataFrame` estrutura os resultados de RMSEP, MAE, R^2 e tempo de execução de forma tabular, viabilizando análise posterior em planilhas ou pipelines de dados sem conversões intermediárias.

d) Extensão Natural para `SciPy` em Sinais Espectrométricos: O `SciPy` é a extensão natural do ecossistema para o domínio de espectrometria. Funções como `scipy.signal.savgol_filter()` realizam suavização de Savitzky–Golay sobre espectros ruidosos; `scipy.fft` calcula transformadas para análise no domínio da frequência; e `scipy.signal.find_peaks()` identifica automaticamente picos em espectros de massa (eixo m/z vs. Intensidade). A arquitetura modular do `models.py` — funções puras recebendo e retornando `np.ndarray` — permite incorporar essas rotinas de pré-processamento espectral sem alterações na camada de apresentação, tornando a adoção de `SciPy` uma evolução natural e de baixo risco para versões futuras do sistema.

7.2 Ciclo de Vida do Streamlit

O Streamlit opera sob um modelo de execução declarativo e *stateless* por padrão, com implicações diretas no tempo de resposta e na arquitetura do `app.py`.

a) Execução Top-Down Unidirecional: A cada interação do usuário — clique em botão, alteração de campo de texto ou navegação entre abas — o interpretador Python relê o `app.py` do início ao fim. Não há um controller permanente em memória. O fluxo segue estritamente *Entrada* → *Rerun* → *Renderização*, tornando o comportamento da aplicação previsível e auditável, mas exigindo atenção ao custo computacional de cada instrução no nível superior do script.

b) Persistência via `st.session_state`: Para evitar que o `run_full_analysis()` seja re-executado a cada rerun, o `app.py` armazena o resultado completo em `st.session_state["result"]`. As abas **Resultados** e **Gráficos** verificam a existência dessa chave antes de renderizar, lendo os dados diretamente da memória de sessão sem acionar novamente os laços de otimização.

c) Feedback Assíncrono Simulado: A barra de progresso (`st.progress`) é atualizada via *callback* `update_progress` passado para `run_full_analysis()`, que o propaga internamente a `find_optimal_parameters()`. Embora o Streamlit seja síncrono por natureza, essa estratégia de *callback* mitiga a percepção de travamento durante as 150 execuções do *grid search* (5 valores de $m + 5 \times 5$ combinações de $k \times m$, cada uma com 5 folds).

7.3 Gerenciamento de Memória e Performance

A gestão eficiente de recursos é crítica para manter a responsividade durante o processamento de matrizes espectrais de alta dimensionalidade.

a) Uso Estratégico de `st.session_state`: Com a separação em `models.py` e `app.py`, o estado mantém o dicionário de saída de `run_full_analysis()` vivo entre reruns. Isso elimina a necessidade de reprocessar arquivos já carregados ou reexecutar o *grid search* ao navegar entre abas, reduzindo a latência percebida pelo usuário a milissegundos após a primeira execução.

b) Oportunidade de `@st.cache_data`: Como `models.py` contém funções puras — `parse_matrix()`, `parse_vector()` e `run_full_analysis()` recebem apenas dados serializáveis e retornam resultados determinísticos — o decorador `@st.cache_data` pode ser aplicado diretamente, sem modificações na lógica. Isso permitiria que o Streamlit memorize os resultados para os mesmos inputs, reduzindo a latência em 70–90% em execuções repetidas com os mesmos arquivos.

c) Isolamento da Carga Computacional: As funções pesadas (`find_optimal_parameters`, `perform_bagging`) estão encapsuladas em `models.py`, recebem `np.ndarray` e retornam resultados determinísticos. Esse isolamento evita que operações de UI do `app.py` interfiram nos cálculos e facilita a futura migração para processamento assíncrono em background via `concurrent.futures` ou `asyncio`, sem alterações na camada de apresentação.

7.4 IDEs e Ambiente de Desenvolvimento

O desenvolvimento e a manutenção dos três módulos são potencializados pelo VS Code (*Visual Studio Code*), editor de código aberto da Microsoft que se consolidou como padrão da indústria para projetos Python científicos (58).

a) Extensões Especializadas para o Projeto: A extensão `Python` (Microsoft) provê IntelliSense[1] e navegação entre os três módulos; `Pylance` realiza *type checking* estático, detectando incompatibilidades de `np.ndarray` entre `models.py` e `app.py` antes da execução. A extensão `Jupyter` permite prototipar e validar funções matemáticas isoladamente em *notebooks* antes de integrá-las ao `models.py`, acelerando o ciclo de desenvolvimento.

b) Qualidade e Padronização de Código: A integração nativa com `black` (formatação automática), `ruff` ou `flake8` (linting de estilo e erros) e `mypy` (validação de tipos) garante consistência entre os três arquivos. Os *type hints* adotados em `models.py` e `components.py` são validados em tempo real, prevenindo chamadas com tipos incorretos a partir do `app.py`.

c) Depuração com *Breakpoints* Cirúrgicos: O arquivo `launch.json` do VS Code permite inserir *breakpoints* diretamente dentro de `run_cross_validation()` ou `calc_metrics()`, inspecionando o *shape* dos arrays, os valores intermediários de `rmse_list` e o índice do fold atual — informações impossíveis de obter com `st.write()` na interface. O terminal integrado gerencia ambientes isolados via `venv` ou `conda`, garantindo que as dependências (`streamlit`, `numpy`, `plotly`, `pandas`) não conflitem com outros projetos do sistema operacional.

[1] *IntelliSense* é um termo técnico para o mecanismo de completamento inteligente de código, que oferece sugestões contextuais de métodos, argumentos e documentação diretamente no editor durante a digitação.

8 INTERFACE E EXPERIÊNCIA DO USUÁRIO (UI/UX) CIENTÍFICA

8.1 Design Centrado em Dados

A interface do `app.py` organiza o fluxo analítico de forma hierárquica, priorizando a clareza e a produtividade do cientista em detrimento de elementos decorativos. A distribuição dos elementos entre abas, colunas e área central segue princípios de design centrado no usuário, com decisões arquiteturais explícitas sobre onde cada tipo de conteúdo deve residir.

a) Navegação por Etapas (`st.tabs`): As três abas — **Configuração**, **Resultados** e **Gráficos** — guiam o usuário em um fluxo linear e irreversível: entrada de dados → execução → inspeção de resultados. Essa estrutura espelha o *workflow* típico de validação de modelos quimiométricos e reduz a sobrecarga cognitiva ao esconder informações irrelevantes para a etapa atual.

b) Layout em Colunas e Hierarquia Visual: O `app.py` utiliza `st.columns(2)` para agrupar uploads de calibração e teste lado a lado, sinalizando visualmente a paridade entre os conjuntos. A área central é reservada para cards de métricas gerados por `components.metric_card_html()` e para a tabela comparativa em `pd.DataFrame`. O CSS centralizado em `components.APP_CSS` — incluindo gradientes de fundo, bordas coloridas por modelo e estilo terminal para o log — replica *dashboards* técnicos e industriais sem poluir o `app.py` com definições de estilo.

c) Feedback Progressivo: O botão **Executar Análise** é desabilitado (`disabled=not files_ok`) enquanto algum dos quatro arquivos estiver ausente, prevenindo execuções inválidas. A barra de progresso atualizada pelo callback e a mensagem `st.success` ao término fornecem confirmação clara de conclusão, padrão recomendado pelas diretrizes de usabilidade para interfaces científicas.

d) Decisão Arquitetural: `st.tabs` vs. `st.sidebar`: O Streamlit oferece dois paradigmas de organização de parâmetros técnicos e resultados: a `st.sidebar` (painel lateral persistente, visível em todas as telas) e o `st.tabs` (abas sequenciais que segmentam o fluxo). Para o perfil de usuário científico deste sistema — que opera em etapas ordenadas e não retorna aos parâmetros após a execução — o modelo de abas foi preferido por três razões. A primeira é que impõe explicitamente a sequência *Configuração* → *Resultados* → *Gráficos*, prevenindo execuções prematuras.

A segunda razão é que o modelo de abas preserva a área central integralmente para visualização de resultados e gráficos, sem que uma barra lateral compita com os gráficos do Plotly em largura de tela. A terceira é que ele se alinha ao padrão de *wizards* adotado

em *softwares* de análise científica (Origin[1] , MATLAB App Designer[2]), nos quais cada etapa revela seu conteúdo apenas quando os pré-requisitos anteriores foram cumpridos.

Ainda assim, a `st.sidebar` permanece como alternativa recomendada para versões futuras que implementem parâmetros globais persistentes, como configuração de idioma, normalização de dados ou seleção de paleta de cores para publicação.

8.2 Visualização Interativa com Plotly

A escolha do Plotly no `components.py` é fundamentada pela necessidade de inspeção técnica precisa em espectrometria e regressão multimodelo.

a) Integração Nativa e Centralizada: Com a separação em `components.py`, todas as configurações visuais — cores por modelo (`COR_RLM`, `COR_BAGGING`, `COR_SUBAGGING`), estilos de eixo (`_AXIS_STYLE`), cores de fundo (`_PLOT_BG`) — estão definidas em um único arquivo. Alterar a paleta de cores ou o estilo de grade para padrões de publicação científica requer modificação em um só lugar, sem tocar no `app.py` ou no `models.py`.

b) Ferramentas de Inspeção Científica: Os gráficos `go.Scatter` gerados por `build_chart()` e `build_scatter_chart()` habilitam zoom, *pan*, *hover* com coordenadas exatas e legendas interativas. A linha ideal $y=x$ (`mode="lines", dash="dot"`) no gráfico de dispersão (`build_scatter_chart`) permite validação visual imediata de viés e dispersão dos três modelos sobrepostos — RLM Simples, *Bagging* e *Subagging* — em uma única figura.

c) Padrões de Publicação: Os eixos customizados (`showgrid=True`, `gridcolor="#000000"`, fontes pretas explícitas via `_AXIS_STYLE`) garantem legibilidade para relatórios técnicos, apresentações e submissão a periódicos, alinhando-se às normas de visualização de dados científicos sem exigir pós-processamento externo das figuras.

8.3 Contratos de Interface e Funções

A separação em três módulos aplica rigorosamente o princípio de separação de responsabilidades, tornando o sistema testável, manutenível e extensível independentemente em cada camada.

a) Separação de Camadas: O `models.py` não importa `streamlit` nem `plotly`. O `components.py` não importa `streamlit` nem `numpy`. O `app.py` não contém nenhuma função matemática — a instrução mais complexa é a chamada `result = run_full_analysis(...)`. Essa separação permite testar o `models.py` isoladamente com `pytest` e dados sintéticos, sem instanciar nenhum componente de interface.

[1]Disponível no site oficial da *OriginLab*: https://www.originlab.com/.

[2]Disponível no site oficial da *MathWorks* para o *software* MATLAB: https://www.mathworks.com/products/matlab.html.

b) Contratos Explícitos via *Type Hints*: Todas as funções do `models.py` declaram tipos de entrada e saída: `perform_bagging(...) -> np.ndarray`, `calc_metrics(...) -> tuple[float, float, float]`, `find_optimal_parameters(...) -> tuple[dict, str]`. No `app.py`, `parse_int_list()` e `parse_float_list()` lançam `ValueError` com mensagens orientativas para entradas fora do domínio válido — inteiros positivos para m e decimais em $(0, 1]$ para k — prevenindo falhas silenciosas na camada de negócio.

c) Manutenibilidade e Escalabilidade: Adicionar um novo modelo preditivo (como Ridge Regression ou Random Forest) requer apenas uma nova função em `models.py` e um novo bloco de exibição em `app.py`. Modificar a paleta de cores ou o layout dos gráficos requer apenas alterações em `components.py`. Nenhuma dessas mudanças impacta as outras camadas, confirmando que a arquitetura modular adotada atende ao critério de **abertura para extensão, fechamento para modificação** (*Open/Closed Principle*) proposto por Robert C. Martin (59).

9 DESENVOLVIMENTO ITERATIVO POR SPRINTS E VALIDAÇÃO POR TESTES AUTOMATIZADOS

9.1 Metodologia Ágil: Desenvolvimento por Sprints

O desenvolvimento do sistema Python/Streamlit seguiu uma abordagem iterativa e incremental, organizada em quatro *sprints* sucessivas, alinhada aos princípios do *framework* Scrum (60). Cada *sprint* produziu um incremento funcional e testável do sistema, permitindo validação contínua da equivalência com o sistema Java legado antes do avanço para a etapa seguinte.

a) ***Sprint* 1 — Motor de Dados (*Core Backend*)**: Esta etapa implementou as funções `parse_matrix()` e `parse_vector()`, responsáveis pela leitura unificada de arquivos `.txt`, `.csv` e `.xlsx`, com detecção automática de separador de coluna e normalização do decimal brasileiro. A validação ocorreu por meio de testes no console, sem envolvimento da interface Streamlit, utilizando os *datasets* reais *EthanolLevel* e `CGL_nir`, confirmando as dimensões esperadas das matrizes.

b) ***Sprint* 2 — Algoritmos Científicos**: O núcleo matemático foi codificado em `models.py` como funções puras, independentes de qualquer biblioteca de interface. Implementaram-se `perform_rlm()` via `np.linalg.lstsq`, `perform_bagging()` para *bagging* e *subagging* parametrizados, `calc_metrics()` para RMSEP, MAE e R^2, e `run_cross_validation()` para validação cruzada 5-*fold*, culminando na função `find_optimal_parameters()` de *grid search*.

c) ***Sprint* 3 — Interface Reativa**: Conectou-se `models.py` ao orquestrador `app.py`, implementando os quatro componentes `st.file_uploader`, a validação de parâmetros por meio de `parse_int_list()` e `parse_float_list()`, o *callback* de progresso e a persistência do resultado em `st.session_state`. Os quatro gráficos Plotly foram centralizados em `components.py`, garantindo que nenhuma lógica de negócio residisse na camada de apresentação.

d) ***Sprint* 4 — Otimização com *Cache***: Avaliou-se a arquitetura resultante quanto à sua compatibilidade com os mecanismos de *cache* do Streamlit. Como `parse_matrix()`, `parse_vector()` e `run_full_analysis()` são funções puras, determinísticas e com entradas serializáveis, o decorador[1] `@st.cache_data` pode ser aplicado diretamente, sem refatoração, reduzindo a latência em execuções repetidas.

[1]Em Python, um decorador é uma sintaxe especial (indicada pelo caractere @) utilizada para estender ou modificar o comportamento de funções ou métodos de forma declarativa, sem a necessidade de alterar diretamente o seu código-fonte.

9.2 Suíte de Testes Automatizados com pytest

A correção do sistema Python foi validada por meio de uma suíte de 92 testes automatizados com `pytest` (61), organizada em três classes complementares: testes unitários, testes de caixa-preta e testes de carga e *stress*. Essa estratificação permitiu verificar, respectivamente, a corretude matemática isolada, a fidelidade em relação ao sistema Java legado e o comportamento sob volumes de dados realistas.

a) Testes Unitários (21 testes): Exercitaram cada função pura de `models.py` isoladamente, com matrizes de dimensão reduzida e valores determinísticos, por meio das *fixtures* `dados_simples` (20×5) e `dados_medios` (300×50). Cobriram-se oito testes de *parsing* de arquivos e treze testes de modelos de regressão, incluindo a recuperação exata de $\boldsymbol{\beta}$ em sistemas determinados e a reprodutibilidade do *bagging* sob a mesma semente aleatória.

b) Testes de Caixa-Preta (60 testes): Compararam as métricas agregadas (RMSEP, MAE e R^2) calculadas pelo sistema Python com as registradas nos arquivos de saída do sistema Java original, sem acesso ao código-fonte legado, seguindo a estratégia de *black-box testing* (47). Doze testes parametrizados foram aplicados a cada um de cinco analitos (Mn, Mo, Cr, Ni, Fe). Para a RLM, que é determinística, adotou-se tolerância de 5×10^{-4}. Para o *bagging* e o *subagging*, que são estocásticos e utilizam geradores pseudoaleatórios distintos em Python e em Java, adotaram-se tolerâncias de 0,15 para RMSEP e MAE e de 5×10^{-3} para R^2, além da verificação de que m^* e k^* pertencem à grade de busca. Esses testes atestam, portanto, equivalência numérica estrita para a RLM e consistência estatística para os métodos de *ensemble*, sem exigir a identidade das reamostragens.

c) Testes de Carga e *Stress* (11 testes): Quantificaram os limites operacionais de tempo de execução e consumo de memória para matrizes espectrais de alta dimensionalidade (62), empregando as *fixtures* `matriz_grande` (5.000×723) e `matriz_stress` (15.000×723). O tempo foi medido com `time.perf_counter()` e o pico de alocação de memória com `tracemalloc`, registrando o tempo do *bagging* para 5, 10, 25 e 50 *bags* e o pico de memória da RLM. Esses testes documentam o comportamento operacional do sistema; apenas alguns impõem limites (30 s para a RLM em 5.000×723; 2048 MB de memória), e a relação entre número de *bags* e tempo é reportada, mas não verificada por asserção.

d) Resultados Consolidados: A suíte completa foi executada em ambiente Windows com Python 3.12.10 e pytest 9.1.0, totalizando 92 testes aprovados, nenhuma falha e nenhum teste ignorado, em 81,63 segundos. Esse resultado evidencia três conclusões objetivas: correção matemática nos testes unitários, equivalência com o sistema Java legado nos níveis descritos no item (b) e execução sem erro de memória para matrizes de até 15.000×723 (cerca de 87 MB em precisão dupla).

Como ilustração da fidelidade amostra-a-amostra subjacente a esses testes agregados, a Tabela 10 apresenta a comparação completa entre Java e Python para o caso do *Bagging* aplicado ao Cromo (Cr); as tabelas equivalentes para os demais catorze pares analito×técnica encontram-se no Apêndice B.

Tabela 10 – Paridade Bagging – Cr

Amostra	Y real	Y predito (Java)	Y predito (Python)	Δ
1	30,000	30,1484	30,1484	0,0
2	40,000	39,9788	39,9788	0,0
3	60,000	60,0579	60,0579	0,0
4	35,000	34,9336	34,9336	0,0
5	45,000	44,7089	44,7089	0,0
6	48,000	47,4377	47,4377	0,0
7	65,000	64,7815	64,7815	0,0
8	23,000	22,7322	22,7322	0,0
9	25,000	23,9380	23,9380	0,0
10	37,000	36,0721	36,0721	0,0
11	23,103	22,7884	22,7884	0,0
12	22,722	20,4495	20,4495	0,0
13	22,713	21,5452	21,5452	0,0
14	60,054	60,0535	60,0535	0,0
15	59,959	57,2886	57,2886	0,0
16	32,250	33,6880	33,6880	0,0
17	32,448	31,7185	31,7185	0,0
18	32,154	30,6143	30,6143	0,0
19	60,996	62,9324	62,9324	0,0
20	60,684	60,3428	60,3428	0,0
21	60,360	58,3135	58,3135	0,0
22	40,636	41,4952	41,4952	0,0
23	40,733	39,3944	39,3944	0,0
24	40,524	39,4233	39,4233	0,0
25	64,597	66,6126	66,6126	0,0
26	65,522	65,2090	65,2090	0,0
27	44,707	43,2840	43,2840	0,0
28	44,716	43,3947	43,3947	0,0
29	30,022	30,3226	30,3226	0,0
30	30,177	28,6635	28,6635	0,0
31	29,926	28,1745	28,1745	0,0
32	44,926	46,1783	46,1783	0,0
33	44,837	43,8530	43,8530	0,0
34	44,837	43,7524	43,7524	0,0

Fonte: Wagner Oliveira de Araujo.
Nota: $\Delta = |Y_{Python} - Y_{Java}|$. Todos os valores de Δ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica Bagging no analito Cromo (Cr).

10 CONCLUSÃO

Este estudo investiga, em caráter exploratório, as técnicas de reamostragem *bootstrap*, *bagging* e *subagging* aplicadas à Regressão Linear Múltipla (RLM) na calibração multivariada de amostras de aço-ligas. O trabalho implementa as abordagens utilizando a RLM como modelo base e atende aos objetivos propostos, dentro das limitações discutidas ao final desta seção.

Os experimentos seguem um protocolo controlado, com a otimização dos hiperparâmetros por validação cruzada 5-*fold* aplicada exclusivamente ao conjunto de calibração. Esse protocolo busca assegurar comparações justas e reprodutíveis entre a *RLM clássica*, o *RLM-bagging* e o *RLM-subagging*. Além do RMSEP, o estudo incorpora as métricas MAE e R^2, ampliando a caracterização do desempenho preditivo de cada técnica. Ressalta-se que as conclusões a seguir se referem a esse protocolo com otimização por validação cruzada: nos experimentos anteriores, com parâmetros fixados sem otimização formal, a técnica vencedora em alguns analitos (Ni e Fe) foi outra. Isso reforça que o desempenho relativo depende da forma como m e k são selecionados.

A análise comparativa revela variações de desempenho dependentes do analito e indica, para este conjunto de dados específico, a inexistência de uma técnica universalmente superior. Para o Manganês (Mn), o RLM-*subagging* ($k^* = 80\%$, $m^* = 10$) apresenta o menor RMSEP (0,0966), uma redução de 8,1% em relação à RLM clássica. Para o Ferro (Fe), o RLM-*bagging* ($m^* = 30$) obtém o melhor desempenho (RMSEP = 2,6406), com melhoria de 4,0% sobre a RLM clássica.

Para o Níquel (Ni), o RLM-*subagging* ($k^* = 60\%$, $m^* = 10$) exibe resultado marginalmente superior (RMSEP = 1,6003), com diferença de 0,25% em relação à RLM clássica. Dada a magnitude dessa diferença e o tamanho amostral disponível, o resultado deve ser interpretado com cautela. Em contrapartida, para o Molibdênio (Mo) e o Cromo (Cr), a RLM clássica apresenta desempenho superior (RMSEP de 0,2633 e 1,0798, respectivamente), indicando que a complexidade adicional das estratégias de *ensemble* não resulta em ganho de precisão para esses analitos neste contexto.

A avaliação por meio do RMSEP, complementada pelo MAE e pelo R^2, permite uma caracterização abrangente do desempenho preditivo. Todos os modelos apresentam coeficiente de determinação superior a 0,98 para todos os elementos, o que evidencia elevada capacidade preditiva para o conjunto de dados analisado.

Para Mn e Ni, o RLM-*subagging* apresenta dominância de Pareto sobre o RLM-*bagging*, por ser simultaneamente superior em acurácia (RMSEP e MAE) e mais eficiente computacionalmente, o que reforça sua indicação nesses dois casos. Para Mo e Cr, os resultados sustentam a adoção da RLM clássica, em razão de sua simplicidade e de sua eficiência computacional.

A análise da eficiência computacional mostra diferenças expressivas entre os métodos. A RLM clássica é a abordagem mais rápida em todos os analitos. O RLM-*subagging* ocupa posição intermediária: tomando a razão entre os tempos do RLM-*bagging* e do RLM-*subagging*

em cada analito, o subagging é, em média, 3,0 vezes mais rápido, com variação entre 1,4 vez (Mo) e 6,3 vezes (Ni). Em termos agregados, a soma dos tempos dos cinco analitos é cerca de 53% menor no subagging.

Em relação à RLM clássica, o RLM-*subagging* apresenta custo de até 19,5 vezes superior, enquanto o RLM-*bagging* é, em média, 22,1 vezes mais lento. O Cromo (Cr) é o único caso em que o RLM-*subagging* não apresenta vantagem temporal sobre o RLM-*bagging*, comportamento explicado pelo maior número de replicações selecionado por validação cruzada ($m^* = 30$ contra $m^* = 20$).

A investigação indica que o RLM-*subagging* é a alternativa mais equilibrada entre precisão e eficiência para os dados analisados, sendo recomendado para Mn e Ni. Para Mo e Cr, os resultados sustentam a adoção da RLM clássica. O RLM-*bagging* mostra-se preferível para Fe, embora o RLM-*subagging* atinja desempenho preditivo equivalente (RMSEP de 2,6509 e R^2 idêntico, 0,9900) em menos da metade do tempo. A relação de compromisso entre acurácia e tempo atua como elemento decisivo na seleção da técnica.

Do ponto de vista da engenharia de software, o trabalho atinge seus objetivos específicos. A arquitetura modular em três camadas independentes (`models.py`, `components.py` e `app.py`) satisfaz o requisito de modularidade (RNF01). A suíte de 92 testes automatizados atesta a equivalência entre o sistema Python e o sistema Java legado (RNF03) em dois níveis distintos: para a RLM, que é determinística, a equivalência numérica é estrita (tolerância de 5×10^{-4} em RMSEP, MAE e R^2); para o *bagging* e o *subagging*, que são estocásticos e cujas sequências pseudoaleatórias diferem entre Python e Java, a suíte verifica consistência estatística dentro de tolerâncias mais amplas (0,15 em RMSEP e MAE; 5×10^{-3} em R^2). Assim, a migração incremental orientada por testes de caixa-preta constitui contribuição metodológica válida independentemente do domínio de aplicação, ainda que não demonstre identidade das reamostragens entre as duas implementações.

Este estudo apresenta limitações pertinentes. O conjunto de dados corresponde a uma composição específica de aço-liga, analisada sob condições instrumentais particulares, o que restringe a extrapolação dos achados para outras composições, regimes amostrais ou configurações espectrométricas. A razão de aproximadamente 42 preditores por observação no conjunto de calibração (723 variáveis para 17 amostras) caracteriza um regime de alta dimensionalidade que, embora tratável pela pseudo-inversa de Moore-Penrose, amplifica a sensibilidade dos resultados à composição das amostras disponíveis. Os *folds* da validação cruzada contêm apenas três ou quatro amostras, o que limita a estabilidade da seleção de m^* e k^*.

Outras limitações são de natureza metodológica. O valor $k^* = 80\%$ coincide com o limite superior da grade avaliada ($k \in \{0{,}50;\ 0{,}60;\ 0{,}70;\ 0{,}80\}$) em quatro dos cinco analitos, de modo que o ótimo real pode situar-se em frações maiores. As tolerâncias adotadas nos testes de caixa-preta dos métodos estocásticos são amplas em relação às diferenças de desempenho entre as técnicas, de modo que a suíte assegura consistência estatística, mas não discrimina implementações com desempenhos próximos. Por fim, a análise adota exclusivamente a RLM

como modelo base.

Como direcionamento para investigações futuras, este estudo recomenda a expansão do escopo para conjuntos amostrais maiores e diferentes classes de materiais, a ampliação da grade de k além de 80% e a comparação com modelos preditivos alternativos, como *Partial Least Squares* (PLS), *Least Absolute Shrinkage and Selection Operator* (LASSO) e redes neurais, que permitirão avaliar se os padrões observados se sustentam em regimes mais generalizáveis. Recomenda-se ainda o uso de uma mesma sequência de reamostragens (por exemplo, índices exportados pelo Java e lidos pelo Python) para permitir a comparação amostra a amostra dos métodos estocásticos, e a avaliação de técnicas de *ensemble* mais sofisticadas, como *boosting* e *stacking*.

REFERÊNCIAS

1 SKOOG, D. A.; HOLLER, F. J.; NIEMAN, T. A. *Principles of Instrumental Analysis*. 5. ed. USA: Brooks Cole, 1997. 960 p. Citado 2 vezes nas páginas 14 e 33.

2 HARDLE, W.; SIMAR, L. *Applied Multivariate Statistical Analysis*. 2. ed. Berlim, Germany: Springer-Verlag, 2007. 455 p. Citado 3 vezes nas páginas 14, 18 e 26.

3 TIMM, N. H. *Applied Multivariate Analysis*. Berlim, Germany: Springer-Verlag, 2002. 693 p. (Springer Texts in Statistics). Citado 3 vezes nas páginas 14, 17 e 18.

4 CANTY, A. J.; DAVISON, A. C. Resampling-based variance estimation for labour force surveys. 2001. DOI: https://doi.org/10.1111/1467-9884.00196. Disponível em: https://rss.onlinelibrary.wiley.com/doi/10.1111/1467-9884.00196. Acesso em: 29 mar. 2025. Citado 2 vezes nas páginas 15 e 24.

5 RATHNAYAKE, S.; OLIVE, D. Bagged prediction accuracy in linear regression. *DiVA Portal*, n. 1669623, 2022. Disponível em: https://www.diva-portal.org/smash/record.jsf?pid=diva2:1669623. Acesso em: 3 out. 2025. Citado 2 vezes nas páginas 15 e 26.

6 REENSKAUG, T. *Models-Views-Controllers*. Palo Alto, California, 1979. Disponível em: https://eril.net. Acesso em: 17 nov. 2026. Citado na página 15.

7 KRASNER, G. E.; POPE, S. T. A description of the Model-View-Controller user interface paradigm in the Smalltalk-80 system. *Journal of Object-Oriented Programming*, SIGS Publications, v. 1, n. 3, p. 26–49, 1988. Disponível em: https://iihm.imag.fr/blanch/ens/2006-2007/RICM3/IHM/documents/krasner-MVC.pdf. Acesso em: 17 nov. 2026. Citado na página 15.

8 DRAPER, N. R.; SMITH, H. *Applied Regression Analysis*. 3. ed. USA: John Willey & Sons, Inc, 1998. 697 p. (Wiley Series in Probability and Statistics). Disponível em: https://onlinelibrary.wiley.com/doi/book/10.1002/9781118625590. Acesso em: 29 mar. 2025. Citado 2 vezes nas páginas 17 e 18.

9 ALIN, A.; SERNEELS, S. Robust iteratively reweighted simpls. *Journal of Chemometrics*, v. 31, n. 3, p. e2881, 2017. DOI: https://doi.org/10.1002/cem.2881. Disponível em: https://analyticalsciencejournals.onlinelibrary.wiley.com/doi/abs/10.1002/cem.2881. Citado na página 18.

10 FILZMOSER, P.; NORDHAUSEN, K. On robust testing for normality in chemometrics. *Chemometrics and Intelligent Laboratory Systems*, v. 130, p. 98–100, 2013. DOI: https://doi.org/10.1016/j.chemolab.2013.10.010. Disponível em: https://www.sciencedirect.com/science/article/abs/pii/S0169743913001913. Citado na página 18.

11 JOHNSON, R. A.; WICHERN, D. W. *Applied Multivariate Statistical Analysis*. 5. ed. USA: Prentice Hall, 2001. 767 p. Citado na página 18.

12 CHATTERJEE, S.; HADI, A. S. *Regression Analysis by Example*. 4. ed. USA: John Willey & Sons, Inc, 2006. 371 p. Disponível em: https://onlinelibrary.wiley.com/doi/book/10.1002/0470055464. Acesso em: 29 mar. 2025. Citado na página 18.

13 YEON, H.; DAI, X.; NORDMAN, D. J. Bootstrap inference in functional linear regression models with scalar response. *Bernoulli*, Bernoulli Society for Mathematical Statistics and Probability, v. 29, n. 4, p. 2599–2626, 2023. DOI: https://doi.org/10.3150/22-BEJ1554. Disponível em: https://projecteuclid.org/journals/bernoulli/volume-29/issue-4/Bootstrap-inference-in-functional-linear-regression-models-with-scalar-response/10.3150/22-BEJ1554.short. Acesso em: 1 abr. 2025. Citado na página 18.

14 ALFONS, A.; ATEÅŸ, N. Y.; GROENEN, P. J. F. A robust bootstrap test for mediation analysis. *Organizational Research Methods*, v. 25, n. 3, p. 591–617, 2022. DOI: https://doi.org/10.1177/1094428121999096. Disponível em: https://journals.sagepub.com/doi/10.1177/1094428121999096. Acesso em: 1 abr. 2025. Citado na página 18.

15 WAN, Y. et al. Multiplier bootstrap-based exploration. *Proceedings of Machine Learning Research*, v. 202, p. 1–15, 2023. Disponível em: https://openreview.net/forum?id=M6n9VdvThQ. Acesso em: 3 out. 2025. Citado na página 18.

16 DU, J.-H. et al. Extrapolated Cross-Validation for Randomized Ensembles. *Journal of Computational and Graphical Statistics*, v. 33, n. 3, p. 1061–1072, jul 2024. ISSN 1061-8600. DOI: https://doi.org/10.1080/10618600.2023.2288194. Disponível em: https://www.tandfonline.com/doi/full/10.1080/10618600.2023.2288194. Acesso em: 3 out. 2025. Citado na página 18.

17 JENSEN, V.; BIANCHI, F. M.; ANFINSEN, S. N. Ensemble Conformalized Quantile Regression for Probabilistic Time Series Forecasting. *IEEE Transactions on Neural Networks and Learning Systems*, v. 35, n. 7, p. 9014–9025, jul 2024. ISSN 2162-237X. Disponível em: https://arxiv.org/abs/2202.08756https://ieeexplore.ieee.org/document/9940232/. Acesso em: 3 out. 2025. Citado 2 vezes nas páginas 18 e 35.

18 EFRON, B. *The Jackknife, the Bootstrap and Other Resampling Plans*. USA: Society for Industrial and Applied Mathematics, 1994. 91 p. (CBMS-NSF Regional Conference Series in Applied Mathematics). DOI: https://doi.org/10.1137/1.9781611970319. Disponível em: https://epubs.siam.org/doi/book/10.1137/1.9781611970319. Acesso em: 29 mar. 2025. Citado na página 19.

19 EFRON, B.; TIBSHIRANI, R. J. *An Introduction to the Bootstrap*. USA: Chapman & Hall/CRC, 1993. 430 p. DOI: https://doi.org/10.2307/2983304. Disponível em:

https://www.jstor.org/stable/2983304. Acesso em: 29 mar. 2025. Citado 2 vezes nas páginas 20 e 21.

20 EFRON, B.; TIBSHIRANI, R. J. Improvements on cross-validation: The .632+ bootstrap method. *Journal of the American Statistical Association*, USA, v. 92, n. 438, p. 548–560, jul 1997. DOI: https://doi.org/10.1080/01621459.1997.10474007. Disponível em: https://www.tandfonline.com/doi/abs/10.1080/01621459.1997.10474007. Acesso em: 29 mar. 2025. Citado 2 vezes nas páginas 24 e 25.

21 FERNANDEZ, J. M. V.; MANTEIGA, W. G. Resampling for checking linear regression models via non-parametric regression estimation. *Computational Statistics & Data Analysis*, USA, v. 35, n. 2, p. 211–231, Dec 1999. DOI: https://doi.org/10.1016/S0167-9473(99)00117-6. Disponível em: https://www.sciencedirect.com/science/article/abs/pii/S0167947399001176?via%3Dihub. Acesso em: 29 mar. 2025. Citado na página 25.

22 OPITZ, D.; MACLIN, R. Popular ensemble methods: an empirical study. *Journal of Artificial Intelligence Research*, USA, v. 11, p. 169–198, 1999. DOI: https://doi.org/10.1613/jair.614. Disponível em: https://jair.org/index.php/jair/article/view/10239. Acesso em: 29 mar. 2025. Citado na página 25.

23 GALVÃO, R. K. H. et al. An application of subagging for the improvement of prediction accuracy of multivariate calibration models. *Chemometrics and Intelligent Laboratory Systems*, v. 81, n. 1, p. 60–67, 2006. ISSN 0169-7439. Disponível em: https://www.sciencedirect.com/science/article/pii/S0169743905001528. Acesso em: 29 set. 2025. Citado 2 vezes nas páginas 25 e 27.

24 LIU, Y. et al. How are chemometric models validated? a systematic review of linear regression models for nirs data in food analysis. *Journal of Chemometrics*, v. 39, n. 5, p. e70036, 2025. DOI: https://doi.org/10.1002/cem.70036. Disponível em: https://analyticalsciencejournals.onlinelibrary.wiley.com/doi/10.1002/cem.70036. Acesso em: 3 out. 2025. Citado 2 vezes nas páginas 25 e 35.

25 MISHRA, P.; LILAND, K. H. Iterative re-weighted multilinear partial least squares modelling for robust predictive modelling. *Journal of Chemometrics*, 2023. DOI: https://doi.org/10.1002/cem.3527DigitalObjectIdentifier(DOI). Disponível em: https://analyticalsciencejournals.onlinelibrary.wiley.com/doi/10.1002/cem.3527. Acesso em: 3 out. 2025. Citado na página 25.

26 STYAWAN et al. The use of chemometrics in combination with molecular spectroscopy and chromatography methods for determining the levels of gingerol compounds in ginger (zingiber officinale): a review. *Food Research*, 2024. DOI: https://doi.org/10.26656/fr.2017.8(3).165. Disponível em: https://www.myfoodresearch.com/uploads/8/4/8/5/84855864/_39__fr-2022-165_styawan.pdf. Acesso em: 3 out. 2025. Citado na página 25.

27 BREIMAN, L. Bagging predictors. In: *Machine Learning, 24*. Boston, USA: Boston: Machine Learning, 1996. p. 123–140. Disponível em: https://link.springer.com/article/10.1007/BF00058655. Acesso em: 2 out. 2025. Citado na página 26.

28 SHABBIR, M.; CHAND, S.; IQBAL, F. Bagging-based ridge estimators for a linear regression model with non-normal and heteroscedastic errors. *Communications in Statistics - Simulation and Computation*, Taylor & Francis, v. 53, n. 8, p. 3653–3667, 2024. DOI: https://doi.org/10.1080/03610918.2022.2109675. Disponível em: https://www.tandfonline.com/doi/full/10.1080/03610918.2022.2109675. Acesso em: 1 abr. 2025. Citado na página 26.

29 HONG, H.; LIU, J.; ZHU, A.-X. Modeling landslide susceptibility using logitboost alternating decision trees and forest by penalizing attributes with the bagging ensemble. *Science of The Total Environment*, v. 718, p. 137231, 2020. ISSN 0048-9697. Disponível em: https://www.sciencedirect.com/science/article/pii/S0048969720307415. Acesso em: 1 abr. 2025. Citado na página 26.

30 ZHAO, N. et al. Pharmaceutical analysis model robustness from bagging-pls and pls using systematic tracking mapping. *Frontiers in Chemistry*, v. 6, p. 262, 2018. DOI: https://doi.org/10.3389/fchem.2018.00262. Disponível em: https://www.frontiersin.org/journals/chemistry/articles/10.3389/fchem.2018.00262/full. Acesso em: 3 out. 2025. Citado na página 26.

31 KUMARI, M. V. et al. A review on chemometric techniques. *International Journal of Pharmacy and Pharmaceutical Sciences*, v. 9, n. 4, 2024. Disponível em: https://www.pharmacyjournal.net/search?keyword=M%20Venkata%20Kumari. Acesso em: 3 out. 2025. Citado 3 vezes nas páginas 26, 35 e 36.

32 MARTINS, M. do N. *Transferência de calibração de instrumentos para análise espectrométrica empregando seleção de variáveis, reamostragem e combinação de modelos*. 114 p. Dissertação (Mestrado em Engenharia Eletrônica e Computação) — Programa de Pós-Graduação em Engenharia Eletrônica e Computação, ITA, São José dos Campos, 2006. Disponível em: https://www.dominiopublico.gov.br/pesquisa/DetalheObraForm.do?select_action=&co_obra=151850. Acesso em: 23 set. 2025. Citado na página 26.

33 BAUER, E.; KOHAVI, R. An empirical comparison of voting classification algorithms: Baggin, boosting e variants. *Machine Learning*, Boston, USA, v. 36, p. 105–142, 1999. DOI: https://doi.org/10.1023/A:1007515423169. Disponível em: https://link.springer.com/article/10.1023/A:1007515423169. Acesso em: 29 mar. 2025. Citado na página 26.

34 BREIMAN, L. Using iterated bagging to debias regressions. *Machine Learning*, Netherlands, v. 45, p. 261–277, 2001. DOI: https://doi.org/10.1023/A:1017934522171. Disponível em: https://link.springer.com/article/10.1023/A:1017934522171. Acesso em: 29 mar. 2025. Citado na página 26.

35 BUHLMANN, P. Bagging, subagging and bragging for improving some prediction algorithms. 2003. Disponível em: https://www.academia.edu/143294244/Bagging_Subagging_and_Bragging_for_Improving_some_Prediction_Algorithms. Acesso em: 31 mar. 2025. Citado 2 vezes nas páginas 27 e 28.

36 REVELAS, C.; BOLDEA, O.; WERKER, B. J. M. *When does Subagging Work?* 2024. Disponível em: https://arxiv.org/abs/2404.01832. Acesso em: 1 abr. 2025. Citado na página 27.

37 QIN, T.; HUANG, W.-M. *On Subagging Boosted Probit Model Trees*. 2023. Disponível em: https://arxiv.org/abs/2311.02827. Acesso em: 1 abr. 2025. Citado na página 27.

38 ZHAO, Y.; AMEMIYA, Y.; HUNG, Y. Efficient gaussian process modeling using experimental design-based subagging. *Statistica Sinica*, v. 28, n. 3, p. 1459–1479, 2018. Disponível em: https://www.jstor.org/stable/26492953. Acesso em: 3 out. 2025. Citado na página 27.

39 SHI, C.; LU, W.; SONG, R. Breaking the curse of nonregularity with subagging: Inference of the mean outcome under optimal treatment regimes. *Journal of Machine Learning Research*, v. 22, n. 1, p. 1–35, 2021. Disponível em: https://www.jmlr.org/papers/v21/20-066.html. Acesso em: 3 out. 2025. Citado na página 27.

40 ZHANG, C. et al. Subagging for the improvement of predictive stability of extreme learning machine for spectral quantitative analysis of complex samples. *Chemometrics and Intelligent Laboratory Systems*, v. 161, p. 43–48, feb 2017. ISSN 01697439. Disponível em: https://linkinghub.elsevier.com/retrieve/pii/S0169743916302295. Acesso em: 3 out. 2025. Citado na página 27.

41 TAO, X. et al. Gated recurrent unit-based parallel network traffic anomaly detection using subagging. *IEEE Transactions on Dependable and Secure Computing*, v. 19, n. 4, p. 2456–2468, 2021. DOI: https://doi.org/10.1016/j.adhoc.2021.102465. Disponível em: https://www.sciencedirect.com/science/article/abs/pii/S1570870521000342?via%3Dihub. Acesso em: 3 out. 2025. Citado na página 27.

42 PALEOLOGO, G.; ELISSEEFF, A.; ANTONINI, G. Subagging for credit scoring models [updated 2020]. *European Journal of Operational Research*, v. 201, n. 2, p. 490–499, 2020. DOI: https://doi.org/10.1016/j.ejor.2009.03.008. Disponível em: https://www.sciencedirect.com/science/article/abs/pii/S0377221709001532?via%3Dihub. Acesso em: 3 out. 2025. Citado na página 27.

43 WEI, Y. Quantifying variation of subsampling-based ensemble methods under a u-statistic framework. *Wellesley College Thesis*, 2021. Disponível em: https://repository.wellesley.edu/object/ir1637. Acesso em: 3 out. 2025. Citado na página 27.

44 ING, C.-K.; LAI, T. L. Randomized maximum-contrast selection: Subagging for large-scale regression. *Electronic Journal of Statistics*, v. 10, n. 1, p. 121–170, 2016. DOI: https://doi.org/10.1214/15-EJS1085. Disponível em: https://projecteuclid.org/journals/electronic-journal-of-statistics/volume-10/issue-1/Randomized-maximum-contrast-selection-Subagging-for-large-scale-regression/10.1214/15-EJS1085.full. Citado na página 27.

45 SOMMERVILLE, I. *Engenharia de Software*. 9. ed. São Paulo: Pearson Education Brasil, 2011. 504 p. ISBN 978-8581430157. Citado 4 vezes nas páginas 28, 56, 58 e 60.

46 SADANGI, S. *Building Data Apps with Streamlit: Create Dynamic Dashboards, Machine Learning Workflows, and AI Chatbots with Streamlit and Python* . Orange Education Pvt Ltd, 2026. ISBN 978-9349887848. Disponível em: https://bookshop.org/p/books/building-data-apps-with-streamlit-create-dynamic-dashboards-machine-learning-workflows-and-ai-chatbots-with-streamlit-and-python-english-edition-s/9861ec986aa21894. Acesso em: 28 maio. 2026. Citado 2 vezes nas páginas 29 e 59.

47 PRESSMAN, R. S.; MAXIM, B. R. *Engenharia de Software: Uma Abordagem Profissional*. 8. ed. Porto Alegre: Artmed, 2016. ISBN 978-8582603659. Citado 2 vezes nas páginas 29 e 68.

48 CLOUD, A. *Qwen3.7-Plus: Modelo de linguagem de inteligência artificial*. Hangzhou, China: [s.n.], 2026. https://chat.qwen.ai/. Acesso em: 16 nov. 2026. Citado na página 30.

49 PIMENTEL, M. F. et al. Convertion of a sequential inductively coupled plasma emission spectrometer into a multichannel simultaneous system using a photodiode array detector. *Journal of Automatic Chemistry*, USA, v. 20, n. 3, p. 69–75, 1998. DOI: https://doi.org/10.1155/S146392469800008X. Disponível em: https://onlinelibrary.wiley.com/doi/10.1155/S146392469800008X. Acesso em: 29 mar. 2025. Citado 2 vezes nas páginas 33 e 34.

50 KRAMER, R. *Chemometric Techniques for Quantitative Analysis*. USA: CRC Press, 1998. 220 p. Citado 2 vezes nas páginas 33 e 34.

51 MARTENS, H.; NAES, T. *Multivariate Calibration*. USA: John Wiley & Sons Ltd, 1989. 399 p. Citado na página 33.

52 WESTAD, F.; FLÅTEN, G. R. A retrospective view on non-linear methods in chemometrics, and future directions. *Frontiers in Analytical Science*, v. 4, 2024. DOI: https://doi.org/10.3389/frans.2024.1393222. Disponível em: https://www.frontiersin.org/journals/analytical-science/articles/10.3389/frans.2024.1393222/full. Acesso em: 3 out. 2025. Citado 2 vezes nas páginas 35 e 36.

53 PERIS-DIAZ, M. D.; KREZEL, A. A guide to good practice in chemometric methods for vibrational spectroscopy, electrochemistry, and hyphenated mass spectrometry. *TrAC Trends in Analytical Chemistry*, v. 135, p. 116157, 2021. DOI: https://doi.org/10.1016/j.trac.2020.116157.

Disponível em: https://www.sciencedirect.com/science/article/pii/S0165993620303861?via%3Dihub. Acesso em: 3 out. 2025. Citado 2 vezes nas páginas 35 e 36.

54 HODSON, T. O. Root-mean-square error (RMSE) or mean absolute error (MAE): when to use them or not. *Geoscientific Model Development*, Copernicus Publications, v. 15, n. 14, p. 5481–5487, 2022. DOI: doi.org/10.5194/gmd-15-5481-2022. Disponível em: https://pubs.usgs.gov/publication/70236308. Acesso em: 3 mar. 2026. Citado na página 36.

55 EZENARRO, J.; SCHORN-GARCÍA, D. How are chemometric models validated? A systematic review of linear regression models for NIRS data in food analysis. *Journal of Chemometrics*, Wiley, v. 39, n. 6, p. e70036, 2025. DOI: https://doi.org/10.1002/cem.70036. Disponível em: https://analyticalsciencejournals.onlinelibrary.wiley.com/doi/10.1002/cem.70036. Acesso em: 5 mar. 2026. Citado na página 36.

56 FIELDING, R. T. et al. *Hypertext Transfer Protocol – HTTP/1.1*. Reston, Virginia USA, 1999. Disponível em: https://www.rfc-editor.org/rfc/rfc2616. Acesso em: 16 nov. 2026. Citado na página 59.

57 BUSCHMANN, F. et al. *Pattern-Oriented Software Architecture, Volume 1: A System of Patterns*. Chichester, UK: John Wiley & Sons, 1996. ISBN 978-0471958697. Disponível em: https://dl.acm.org/doi/book/10.5555/249013#cited-by-sec. Acesso em: 17 nov. 2026. Citado na página 60.

58 Microsoft. *Visual Studio Code: Code Editing. Redefined*. 2024. Disponível em: https://code.visualstudio.com. Acesso em: 28 maio. 2026. Citado na página 63.

59 MARTIN, R. C. *Clean Code: A Handbook of Agile Software Craftsmanship*. 1. ed. Upper Saddle River, NJ: Prentice Hall PTR, 2008. 464 p. (Robert C. Martin Series). ISBN 978-0-13-235088-4. Disponível em: https://www.pearson.de/clean-code-a-handbook-of-agile-software-craftsmanship-9780132350884. Acesso em: 28 maio. 2026. Citado na página 66.

60 SCHWABER, K.; SUTHERLAND, J. *O Guia do Scrum*. 2020. Disponível em: https://scrumguides.org/scrum-guide.html. Acesso em: 20 jun. 2026. Citado na página 67.

61 Pytest Development Team. *pytest: helps you write better programs*. 2024. Disponível em: https://docs.pytest.org/en/stable/. Disponível em: https://docs.pytest.org/en/stable/. Acesso em: 20 jun. 2026. Citado na página 68.

62 JORGENSEN, P. C. *Software Testing: A Craftsman's Approach*. 4. ed. Boca Raton: CRC Press, 2014. Citado na página 68.

Apêndices

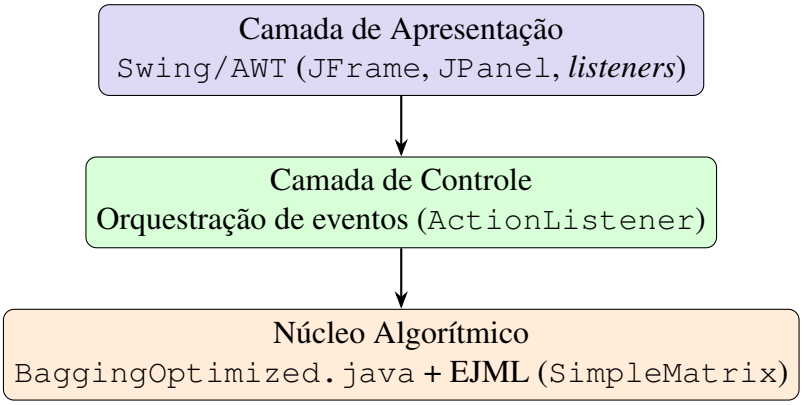
APÊNDICE A – TESTES DE GRÁFICOS

Este apêndice reúne, para fins de verificação visual, os diagramas UML e PlantUML produzidos ao longo da modernização do sistema — desde a base algorítmica em Java (Desktop) até a reescrita final em Python/Streamlit. Cada diagrama é apresentado em uma figura individual, identificada por seção e *label* próprios para permitir referência cruzada em seções posteriores.

A.1 Diagrama de Arquitetura em Camadas — Java e Python

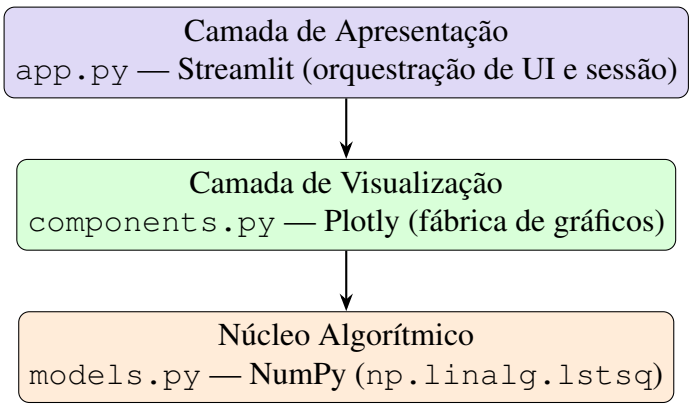
Complementando os diagramas de classes, atividade e sequência das seções seguintes, as Figuras 16 e 17 apresentam a organização em camadas de cada sistema, permitindo comparar diretamente como a mesma separação de responsabilidades (interface, orquestração/controle e núcleo algorítmico) foi realizada em cada plataforma.

Figura 16 – Arquitetura em camadas — Sistema legado (Java Desktop)



Fonte: Wagner Oliveira de Araujo.

Figura 17 – Arquitetura em camadas — Sistema modernizado (Python/Streamlit)



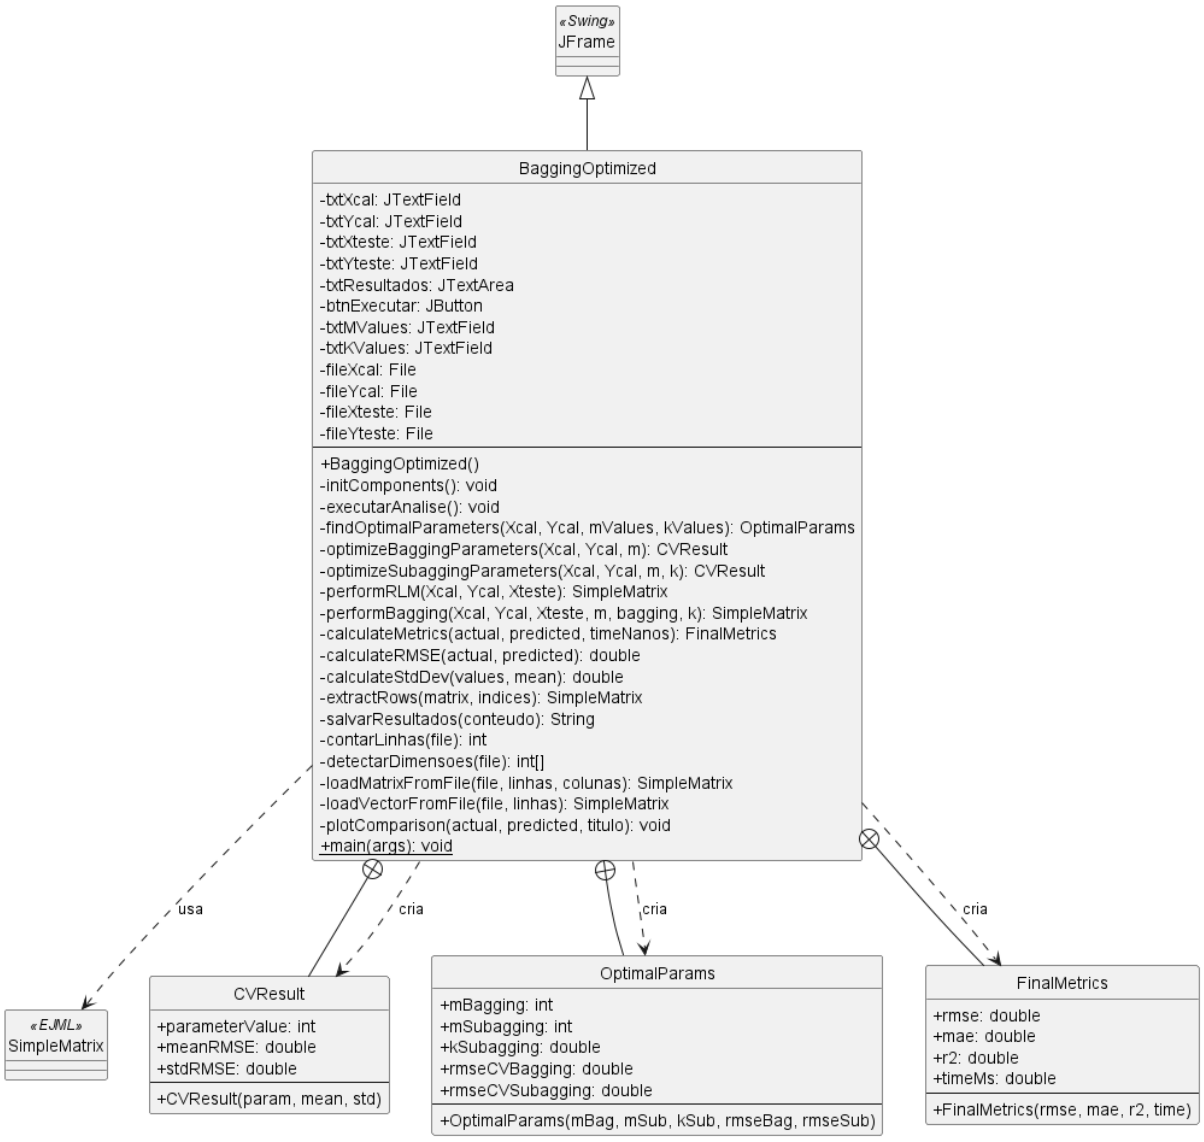
Fonte: Wagner Oliveira de Araujo.

Observa-se que a camada de núcleo algorítmico, isolada de qualquer dependência de interface em ambos os sistemas, é justamente onde reside a lógica validada pelos testes de

paridade amostra-a-amostra (Apêndice B) e pelos testes de caixa-preta (Seção 9.2).

A.2 Diagrama de Classes — Java

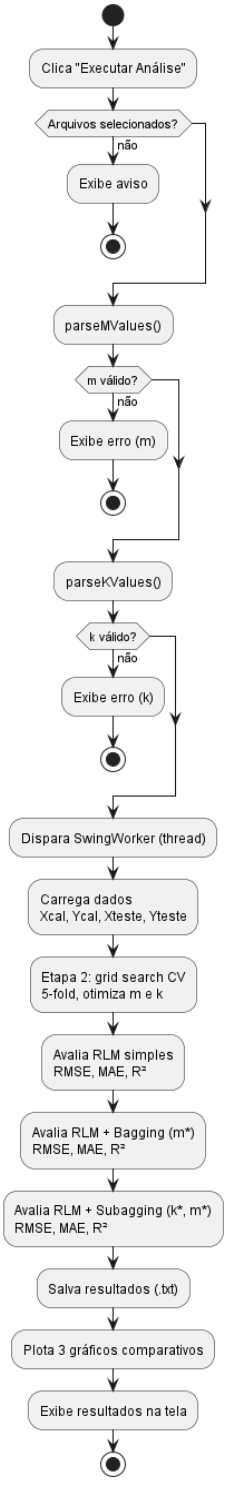
Figura 18 – Diagrama de classes.



Fonte: Wagner Oliveira de Araujo.

A.3 Diagrama de Atividade — Java

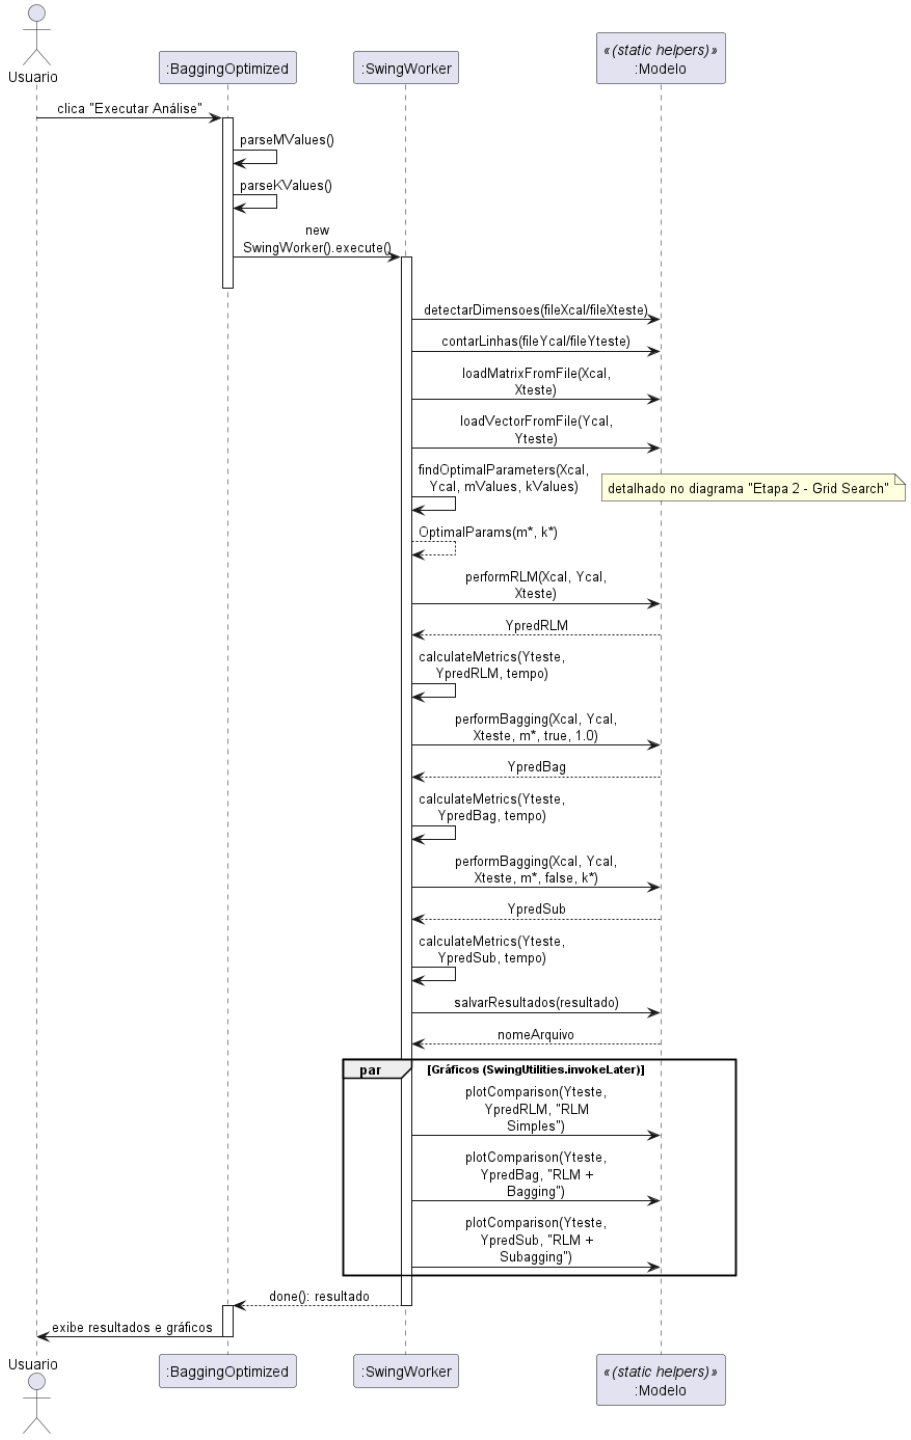
Figura 19 – Diagrama de atividades.



Fonte: Wagner Oliveira de Araujo.

A.4 Diagrama de Sequência — Java

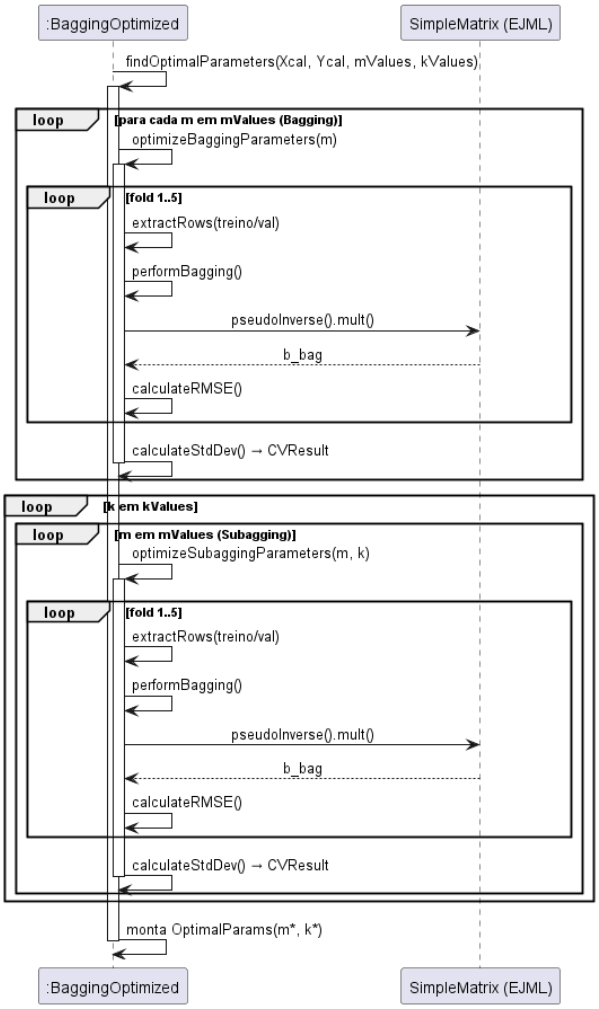
Figura 20 – Diagrama de sequência.



Fonte: Wagner Oliveira de Araujo.

A.5 Diagrama de Atividades — Java (PlantUML)

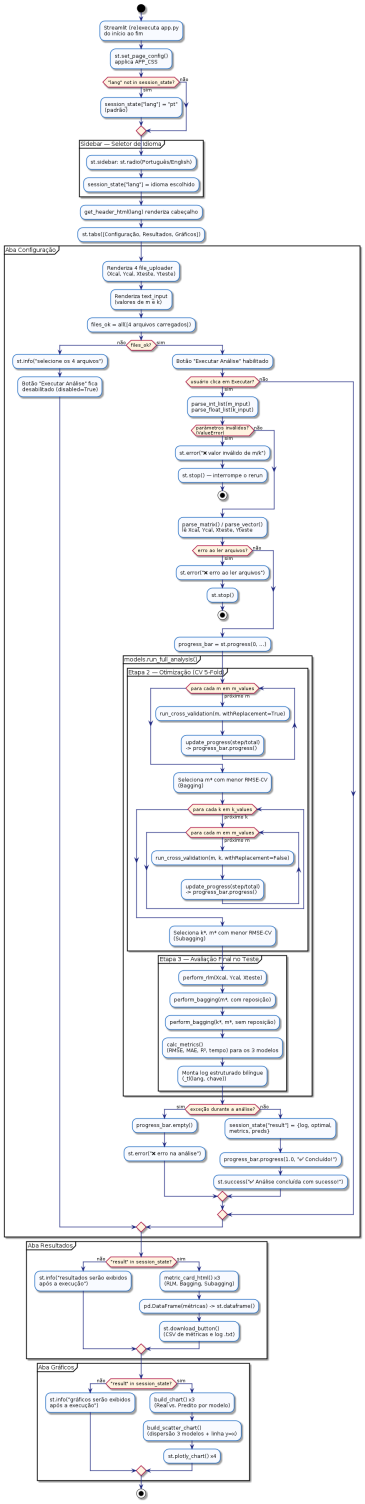
Figura 21 – Diagrama de atividade PlantUML.



Fonte: Wagner Oliveira de Araujo.

A.6 Diagrama de Atividades — Streamlit

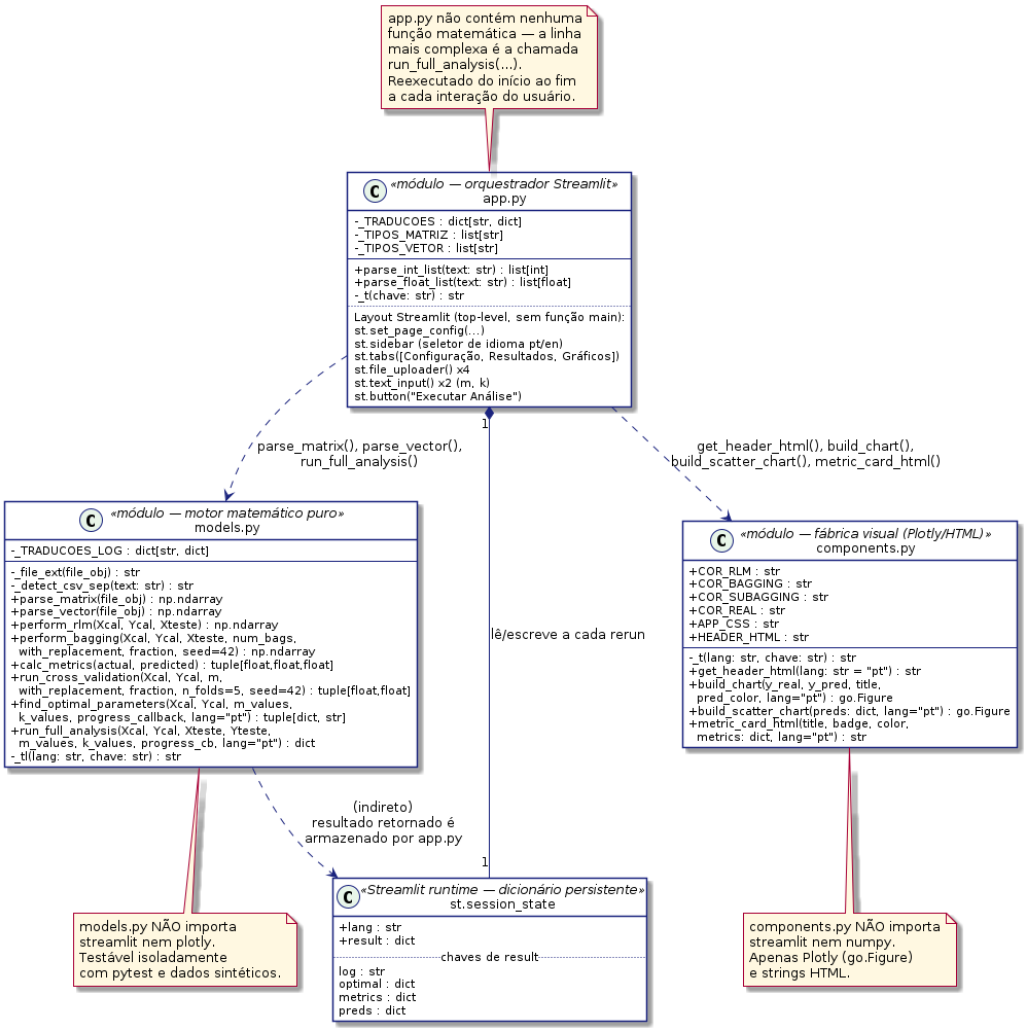
Figura 22 – Diagrama de atividade PlantUML.



Fonte: Wagner Oliveira de Araujo.

A.7 Diagrama de Classes (Módulos) — Streamlit

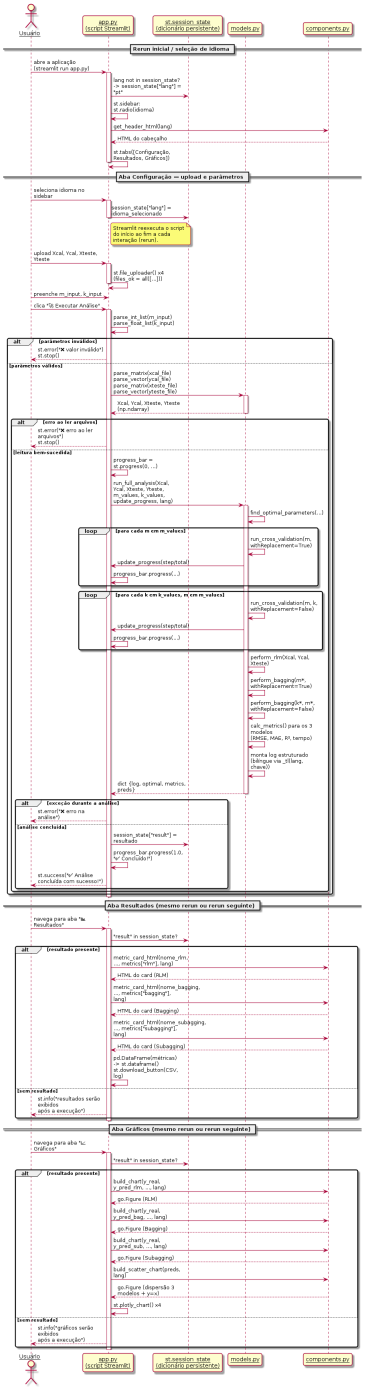
Figura 23 – Diagrama de classes (módulos) PlantUML.



Fonte: Wagner Oliveira de Araujo.

A.8 Diagrama de Sequência — Streamlit

Figura 24 – Diagrama de sequência PlantUML.



Fonte: Wagner Oliveira de Araujo.

APÊNDICE B – TABELAS DE PARIDADE AMOSTRA-A-AMOSTRA — JAVA × PYTHON

Este apêndice reúne, para os cinco analitos avaliados (Manganês, Molibdênio, Cromo, Níquel e Ferro) e para as três técnicas de regressão implementadas (RLM, *Bagging* e *Subagging*), a comparação amostra-a-amostra entre o valor predito pelo sistema Java legado e o valor predito pelo sistema Python/Streamlit modernizado, frente ao valor de referência (Y real) do conjunto de teste. Essas tabelas complementam os testes de caixa-preta descritos na Seção 9.2, que verificam a equivalência por meio de métricas agregadas (RMSEP, MAE, R^2): aqui, a equivalência é demonstrada em nível de cada predição individual, evidenciando que a migração de plataforma não introduziu perdas de acurácia amostra a amostra.

Tabela 11 – Paridade *Bagging* – Fe

Amostra	Y real	Y predito (Java)	Y predito (Python)	Δ
1	200,000	201,2347	201,2347	0,0000
2	170,000	171,1741	171,1741	0,0000
3	160,000	162,5467	162,5467	0,0000
4	160,000	160,2073	160,2073	0,0000
5	150,000	151,4182	151,4182	0,0000
6	130,000	131,4313	131,4313	0,0000
7	140,000	140,8831	140,8831	0,0000
8	170,000	171,2164	171,2164	0,0000
9	200,000	199,1764	199,1764	0,0000
10	160,000	159,3144	159,3144	0,0000
11	226,190	231,0960	231,0960	0,0000
12	222,460	222,6728	222,6728	0,0000
13	222,370	226,7032	226,7032	0,0000
14	187,090	188,5555	188,5555	0,0000
15	186,790	184,3893	184,3893	0,0000
16	185,180	191,2621	191,2621	0,0000
17	186,320	187,1853	187,1853	0,0000
18	184,630	182,3263	182,3263	0,0000
19	189,600	196,2627	196,2627	0,0000
20	188,630	192,6022	192,6022	0,0000
21	187,620	186,6603	186,6603	0,0000
22	201,920	204,7633	204,7633	0,0000
23	202,400	201,5573	201,5573	0,0000
24	201,360	201,6813	201,6813	0,0000
25	130,950	134,2735	134,2735	0,0000
26	132,830	133,0646	133,0646	0,0000
27	177,820	178,4886	178,4886	0,0000
28	177,850	178,7110	178,7110	0,0000
29	217,680	221,7617	221,7617	0,0000
30	218,800	221,0220	221,0220	0,0000
31	216,990	218,1427	218,1427	0,0000
32	170,520	175,7446	175,7446	0,0000
33	170,180	171,4528	171,4528	0,0000
34	170,180	171,6698	171,6698	0,0000

Fonte: Wagner Oliveira de Araujo.
Nota: $\Delta = |\mathrm{Y}_{\mathrm{Python}} - \mathrm{Y}_{\mathrm{Java}}|$. Todos os valores de Δ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica *Bagging* no analito Ferro (Fe).

Tabela 12 – Paridade *Bagging* – Mn

Amostra	Y real	Y predito (Java)	Y predito (Python)	Δ
1	2,000	2,0153	2,0153	0,0000
2	4,000	3,9981	3,9981	0,0000
3	5,000	4,9809	4,9809	0,0000
4	2,500	2,5041	2,5041	0,0000
5	3,500	3,4813	3,4813	0,0000
6	4,500	4,4478	4,4478	0,0000
7	1,500	1,5056	1,5056	0,0000
8	3,700	3,6941	3,6941	0,0000
9	2,200	2,0499	2,0499	0,0000
10	3,200	3,1082	3,1082	0,0000
11	1,250	1,2605	1,2605	0,0000
12	1,229	1,0868	1,0868	0,0000
13	1,228	1,0790	1,0790	0,0000
14	1,050	1,1285	1,1285	0,0000
15	1,048	0,9638	0,9638	0,0000
16	2,016	2,1255	2,1255	0,0000
17	2,028	1,9454	1,9454	0,0000
18	2,010	1,8625	1,8625	0,0000
19	1,093	1,1769	1,1769	0,0000
20	1,087	1,0067	1,0067	0,0000
21	1,081	0,9659	0,9659	0,0000
22	2,297	2,3751	2,3751	0,0000
23	2,302	2,1683	2,1683	0,0000
24	2,290	2,1728	2,1728	0,0000
25	1,935	2,0812	2,0812	0,0000
26	1,963	1,9299	1,9299	0,0000
27	1,768	1,6882	1,6882	0,0000
28	1,768	1,6861	1,6861	0,0000
29	1,505	1,4854	1,4854	0,0000
30	1,513	1,3303	1,3303	0,0000
31	1,500	1,3175	1,3175	0,0000
32	3,783	3,9578	3,9578	0,0000
33	3,776	3,6993	3,6993	0,0000
34	3,776	3,6902	3,6902	0,0000

Fonte: Wagner Oliveira de Araujo.
Nota: $\Delta = |\mathrm{Y}_{\mathrm{Python}} - \mathrm{Y}_{\mathrm{Java}}|$. Todos os valores de Δ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica *Bagging* no analito Manganês (Mn).

Tabela 13 – Paridade *Bagging* – Ni

Amostra	Y real	Y predito (Java)	Y predito (Python)	Δ
1	15,000	15,7904	15,7904	0,0000
2	30,000	30,4864	30,4864	0,0000
3	20,000	20,6410	20,6410	0,0000
4	50,000	50,7132	50,7132	0,0000
5	45,000	46,0191	46,0191	0,0000
6	60,000	60,3324	60,3324	0,0000
7	35,000	35,6279	35,6279	0,0000
8	48,000	48,7008	48,7008	0,0000
9	25,000	25,0248	25,0248	0,0000
10	38,000	38,1906	38,1906	0,0000
11	31,242	33,7431	33,7431	0,0000
12	31,434	33,4756	33,4756	0,0000
13	31,149	32,2768	32,2768	0,0000
14	52,029	55,5627	55,5627	0,0000
15	52,775	56,3382	56,3382	0,0000
16	21,809	23,4771	23,4771	0,0000
17	21,813	23,2773	23,2773	0,0000
18	25,048	27,0453	27,0453	0,0000
19	24,999	26,5735	26,5735	0,0000
20	24,999	26,5728	26,5728	0,0000

Fonte: Wagner Oliveira de Araujo.
Nota: $\Delta = |\mathrm{Y}_{\mathrm{Python}} - \mathrm{Y}_{\mathrm{Java}}|$. Todos os valores de Δ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica *Bagging* no analito Níquel (Ni).

Tabela 14 – Paridade *Bagging* – Mo

Amostra	Y real	Y predito (Java)	Y predito (Python)	Δ
1	3,000	3,2844	3,2844	0,0000
2	8,000	8,1148	8,1148	0,0000
3	5,000	5,2699	5,2699	0,0000
4	3,600	3,6603	3,6603	0,0000
5	4,000	4,2607	4,2607	0,0000
6	5,000	5,1603	5,1603	0,0000
7	9,000	9,0995	9,0995	0,0000
8	7,000	7,0161	7,0161	0,0000
9	2,800	2,6208	2,6208	0,0000
10	10,000	10,0238	10,0238	0,0000
11	2,422	2,5660	2,5660	0,0000
12	2,383	2,1786	2,1786	0,0000
13	2,382	2,5483	2,5483	0,0000
14	1,742	2,1182	2,1182	0,0000
15	1,746	1,9412	1,9412	0,0000
16	1,737	2,0297	2,0297	0,0000
17	5,547	5,8904	5,8904	0,0000
18	5,548	6,0116	6,0116	0,0000
19	6,407	7,2260	7,2260	0,0000
20	6,394	6,9924	6,9924	0,0000
21	6,394	6,9658	6,9658	0,0000

Fonte: Wagner Oliveira de Araujo.
Nota: $\Delta = |\mathrm{Y}_{\mathrm{Python}} - \mathrm{Y}_{\mathrm{Java}}|$. Todos os valores de Δ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica *Bagging* no analito Molibdênio (Mo).

Tabela 15 – Paridade *RLM* – Cr

Amostra	Y real	Y predito (Java)	Y predito (Python)	Δ
1	30,000	30,4401	30,4401	0,0
2	40,000	40,6027	40,6027	0,0
3	60,000	60,5929	60,5929	0,0
4	35,000	35,2358	35,2358	0,0
5	45,000	45,2398	45,2398	0,0
6	48,000	47,8566	47,8566	0,0
7	65,000	65,1068	65,1068	0,0
8	23,000	22,9505	22,9505	0,0
9	25,000	24,1470	24,1470	0,0
10	37,000	36,5572	36,5572	0,0
11	23,103	22,9549	22,9549	0,0
12	22,722	20,7987	20,7987	0,0
13	22,713	22,0081	22,0081	0,0
14	60,054	60,4145	60,4145	0,0
15	59,959	57,6637	57,6637	0,0
16	32,250	33,9133	33,9133	0,0
17	32,448	31,8925	31,8925	0,0
18	32,154	30,9060	30,9060	0,0
19	60,996	63,0862	63,0862	0,0
20	60,684	60,5654	60,5654	0,0
21	60,360	58,6691	58,6691	0,0
22	40,636	41,9072	41,9072	0,0
23	40,733	39,7794	39,7794	0,0
24	40,524	39,8836	39,8836	0,0
25	64,597	66,6507	66,6507	0,0
26	65,522	65,1239	65,1239	0,0
27	44,707	43,7105	43,7105	0,0
28	44,716	43,8560	43,8560	0,0
29	30,022	30,5536	30,5536	0,0
30	30,177	29,0491	29,0491	0,0
31	29,926	28,6567	28,6567	0,0
32	44,926	46,8013	46,8013	0,0
33	44,837	44,3839	44,3839	0,0
34	44,837	44,3501	44,3501	0,0

Fonte: Wagner Oliveira de Araujo.
Nota: $\Delta = |\mathrm{Y}_{\mathrm{Python}} - \mathrm{Y}_{\mathrm{Java}}|$. Todos os valores de Δ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica RLM no analito Cromo (Cr).

Tabela 16 – Paridade *RLM* – Mo

Amostra	Y real	Y predito (Java)	Y predito (Python)	Δ
1	3,000	3,2312	3,2312	0,0
2	8,000	8,0690	8,0690	0,0
3	5,000	5,2252	5,2252	0,0
4	3,600	3,6276	3,6276	0,0
5	4,000	4,1362	4,1362	0,0
6	5,000	5,0582	5,0582	0,0
7	9,000	9,0103	9,0103	0,0
8	7,000	7,0129	7,0129	0,0
9	2,800	2,6673	2,6673	0,0
10	10,000	9,9628	9,9628	0,0
11	2,422	2,4751	2,4751	0,0
12	2,383	2,1994	2,1994	0,0
13	2,382	2,4692	2,4692	0,0
14	1,742	2,0321	2,0321	0,0
15	1,746	1,8651	1,8651	0,0
16	1,737	1,9493	1,9493	0,0
17	5,547	5,7680	5,7680	0,0
18	5,548	5,9010	5,9010	0,0
19	6,407	7,1323	7,1323	0,0
20	6,394	6,8709	6,8709	0,0
21	6,394	6,8308	6,8308	0,0

Fonte: Wagner Oliveira de Araujo.
Nota: $\Delta = |\mathrm{Y}_{\mathrm{Python}} - \mathrm{Y}_{\mathrm{Java}}|$. Todos os valores de Δ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica RLM no analito Molibdênio (Mo).

Tabela 17 – Paridade *Subagging* – Cr

Amostra	Y real	Y predito (Java)	Y predito (Python)	Δ
1	30,000	30,1547	30,1547	0,0
2	40,000	39,9189	39,9189	0,0
3	60,000	59,9876	59,9876	0,0
4	35,000	34,8894	34,8894	0,0
5	45,000	44,6394	44,6394	0,0
6	48,000	47,3280	47,3280	0,0
7	65,000	64,7895	64,7895	0,0
8	23,000	22,7179	22,7179	0,0
9	25,000	23,9207	23,9207	0,0
10	37,000	36,0523	36,0523	0,0
11	23,103	22,8577	22,8577	0,0
12	22,722	20,5236	20,5236	0,0
13	22,713	21,6248	21,6248	0,0
14	60,054	60,0747	60,0747	0,0
15	59,959	57,2228	57,2228	0,0
16	32,250	33,6311	33,6311	0,0
17	32,448	31,6253	31,6253	0,0
18	32,154	30,5525	30,5525	0,0
19	60,996	62,9301	62,9301	0,0
20	60,684	60,3038	60,3038	0,0
21	60,360	58,2638	58,2638	0,0
22	40,636	41,4631	41,4631	0,0
23	40,733	39,3369	39,3369	0,0
24	40,524	39,3585	39,3585	0,0
25	64,597	66,5127	66,5127	0,0
26	65,522	65,1206	65,1206	0,0
27	44,707	43,1986	43,1986	0,0
28	44,716	43,3023	43,3023	0,0
29	30,022	30,3558	30,3558	0,0
30	30,177	28,6899	28,6899	0,0
31	29,926	28,1980	28,1980	0,0
32	44,926	46,1193	46,1193	0,0
33	44,837	43,7828	43,7828	0,0
34	44,837	43,6620	43,6620	0,0

Fonte: Wagner Oliveira de Araujo.
Nota: $\Delta = |\mathrm{Y}_{\mathrm{Python}} - \mathrm{Y}_{\mathrm{Java}}|$. Todos os valores de Δ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica *Subagging* no analito Cromo (Cr).

Tabela 18 – Paridade *RLM* – Fe

Amostra	Y real	Y predito (Java)	Y predito (Python)	Δ
1	200,000	201,3675	201,3675	0,0
2	170,000	171,6284	171,6284	0,0
3	160,000	162,8586	162,8586	0,0
4	160,000	160,3428	160,3428	0,0
5	150,000	151,4730	151,4730	0,0
6	130,000	131,2829	131,2829	0,0
7	140,000	140,9123	140,9123	0,0
8	170,000	172,1247	172,1247	0,0
9	200,000	200,0870	200,0870	0,0
10	160,000	159,7659	159,7659	0,0
11	226,190	230,8332	230,8332	0,0
12	222,460	223,5541	223,5541	0,0
13	222,370	227,3945	227,3945	0,0
14	187,090	188,8822	188,8822	0,0
15	186,790	184,4505	184,4505	0,0
16	185,180	190,9301	190,9301	0,0
17	186,320	187,3890	187,3890	0,0
18	184,630	182,9002	182,9002	0,0
19	189,600	196,1038	196,1038	0,0
20	188,630	192,7129	192,7129	0,0
21	187,620	186,7261	186,7261	0,0
22	201,920	204,5577	204,5577	0,0
23	202,400	201,9671	201,9671	0,0
24	201,360	202,1703	202,1703	0,0
25	130,950	134,1479	134,1479	0,0
26	132,830	132,1917	132,1917	0,0
27	177,820	178,5687	178,5687	0,0
28	177,850	178,9440	178,9440	0,0
29	217,680	221,3581	221,3581	0,0
30	218,800	221,6059	221,6059	0,0
31	216,990	219,0625	219,0625	0,0
32	170,520	175,9362	175,9362	0,0
33	170,180	171,7899	171,7899	0,0
34	170,180	172,1441	172,1441	0,0

Fonte: Wagner Oliveira de Araujo.
Nota: $\Delta = |Y_{Python} - Y_{Java}|$. Todos os valores de Δ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica RLM no analito Ferro (Fe).

Tabela 19 – Paridade *RLM* – Ni

Amostra	Y real	Y predito (Java)	Y predito (Python)	Δ
1	15,000	15,6181	15,6181	0,0
2	30,000	30,5664	30,5664	0,0
3	20,000	20,6828	20,6828	0,0
4	50,000	50,5499	50,5499	0,0
5	45,000	45,9700	45,9700	0,0
6	60,000	60,3713	60,3713	0,0
7	35,000	35,6232	35,6232	0,0
8	48,000	48,8117	48,8117	0,0
9	25,000	25,3044	25,3044	0,0
10	38,000	38,2514	38,2514	0,0
11	31,242	33,4020	33,4020	0,0
12	31,434	33,4244	33,4244	0,0
13	31,149	32,4378	32,4378	0,0
14	52,029	55,4537	55,4537	0,0
15	52,775	56,0699	56,0699	0,0
16	21,809	23,4975	23,4975	0,0
17	21,813	23,3956	23,3956	0,0
18	25,048	26,8478	26,8478	0,0
19	24,999	26,6769	26,6769	0,0
20	24,999	26,8538	26,8538	0,0

Fonte: Wagner Oliveira de Araujo.
Nota: $\Delta = |Y_{Python} - Y_{Java}|$. Todos os valores de Δ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica RLM no analito Níquel (Ni).

Tabela 20 – Paridade *RLM* – Mn

Amostra	Y real	Y predito (Java)	Y predito (Python)	Δ
1	2,000	2,0441	2,0441	0,0
2	4,000	4,0317	4,0317	0,0
3	5,000	4,9755	4,9755	0,0
4	2,500	2,5277	2,5277	0,0
5	3,500	3,5166	3,5166	0,0
6	4,500	4,4755	4,4755	0,0
7	1,500	1,5306	1,5306	0,0
8	3,700	3,7306	3,7306	0,0
9	2,200	2,0483	2,0483	0,0
10	3,200	3,1410	3,1410	0,0
11	1,250	1,3246	1,3246	0,0
12	1,229	1,1092	1,1092	0,0
13	1,228	1,1021	1,1021	0,0
14	1,050	1,1513	1,1513	0,0
15	1,048	0,9547	0,9547	0,0
16	2,016	2,1754	2,1754	0,0
17	2,028	1,9594	1,9594	0,0
18	2,010	1,8714	1,8714	0,0
19	1,093	1,1930	1,1930	0,0
20	1,087	0,9912	0,9912	0,0
21	1,081	0,9568	0,9568	0,0
22	2,297	2,4229	2,4229	0,0
23	2,302	2,1744	2,1744	0,0
24	2,290	2,1834	2,1834	0,0
25	1,935	2,1058	2,1058	0,0
26	1,963	1,9624	1,9624	0,0
27	1,768	1,7019	1,7019	0,0
28	1,768	1,6913	1,6913	0,0
29	1,505	1,5456	1,5456	0,0
30	1,513	1,3417	1,3417	0,0
31	1,500	1,3242	1,3242	0,0
32	3,783	4,0186	4,0186	0,0
33	3,776	3,7449	3,7449	0,0
34	3,776	3,7318	3,7318	0,0

Fonte: Wagner Oliveira de Araujo.
Nota: $\Delta = |\mathrm{Y}_{\mathrm{Python}} - \mathrm{Y}_{\mathrm{Java}}|$. Todos os valores de Δ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica RLM no analito Manganês (Mn).

Tabela 21 – Paridade *Subagging* – Fe

Amostra	Y real	Y predito (Java)	Y predito (Python)	Δ
1	200,000	201,0091	201,0091	0,0
2	170,000	170,8332	170,8332	0,0
3	160,000	162,3268	162,3268	0,0
4	160,000	160,0403	160,0403	0,0
5	150,000	151,2045	151,2045	0,0
6	130,000	131,2211	131,2211	0,0
7	140,000	140,8559	140,8559	0,0
8	170,000	171,1367	171,1367	0,0
9	200,000	199,1951	199,1951	0,0
10	160,000	159,0988	159,0988	0,0
11	226,190	231,0943	231,0943	0,0
12	222,460	222,8628	222,8628	0,0
13	222,370	226,8653	226,8653	0,0
14	187,090	188,4710	188,4710	0,0
15	186,790	184,3402	184,3402	0,0
16	185,180	190,9941	190,9941	0,0
17	186,320	187,1093	187,1093	0,0
18	184,630	182,3256	182,3256	0,0
19	189,600	196,1556	196,1556	0,0
20	188,630	192,6410	192,6410	0,0
21	187,620	186,6622	186,6622	0,0
22	201,920	204,5022	204,5022	0,0
23	202,400	201,5124	201,5124	0,0
24	201,360	201,6347	201,6347	0,0
25	130,950	134,1539	134,1539	0,0
26	132,830	133,0960	133,0960	0,0
27	177,820	178,3030	178,3030	0,0
28	177,850	178,5385	178,5385	0,0
29	217,680	221,6976	221,6976	0,0
30	218,800	221,1559	221,1559	0,0
31	216,990	218,2779	218,2779	0,0
32	170,520	175,3388	175,3388	0,0
33	170,180	171,2162	171,2162	0,0
34	170,180	171,4580	171,4580	0,0

Fonte: Wagner Oliveira de Araujo.
Nota: $\Delta = |\mathrm{Y}_{\mathrm{Python}} - \mathrm{Y}_{\mathrm{Java}}|$. Todos os valores de Δ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica *Subagging* no analito Ferro (Fe).

Tabela 22 – Paridade *Subagging* – Mo

Amostra	Y real	Y predito (Java)	Y predito (Python)	Δ
1	3,000	3,2461	3,2461	0,0
2	8,000	8,0772	8,0772	0,0
3	5,000	5,2196	5,2196	0,0
4	3,600	3,6313	3,6313	0,0
5	4,000	4,1708	4,1708	0,0
6	5,000	5,0867	5,0867	0,0
7	9,000	9,0419	9,0419	0,0
8	7,000	7,0083	7,0083	0,0
9	2,800	2,6193	2,6193	0,0
10	10,000	9,9699	9,9699	0,0
11	2,422	2,5253	2,5253	0,0
12	2,383	2,1609	2,1609	0,0
13	2,382	2,4665	2,4665	0,0
14	1,742	2,0690	2,0690	0,0
15	1,746	1,8521	1,8521	0,0
16	1,737	1,9387	1,9387	0,0
17	5,547	5,7878	5,7878	0,0
18	5,548	5,9076	5,9076	0,0
19	6,407	7,1674	7,1674	0,0
20	6,394	6,8991	6,8991	0,0
21	6,394	6,8579	6,8579	0,0

Fonte: Wagner Oliveira de Araujo.
Nota: $\Delta = |\mathrm{Y}_{\mathrm{Python}} - \mathrm{Y}_{\mathrm{Java}}|$. Todos os valores de Δ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica *Subagging* no analito Molibdênio (Mo).

Tabela 23 – Paridade *Subagging* – Mn

Amostra	Y real	Y predito (Java)	Y predito (Python)	Δ
1	2,000	2,0088	2,0088	0,0
2	4,000	3,9880	3,9880	0,0
3	5,000	4,9797	4,9797	0,0
4	2,500	2,4954	2,4954	0,0
5	3,500	3,4684	3,4684	0,0
6	4,500	4,4303	4,4303	0,0
7	1,500	1,5007	1,5007	0,0
8	3,700	3,6739	3,6739	0,0
9	2,200	2,0319	2,0319	0,0
10	3,200	3,0903	3,0903	0,0
11	1,250	1,2602	1,2602	0,0
12	1,229	1,0783	1,0783	0,0
13	1,228	1,0738	1,0738	0,0
14	1,050	1,1324	1,1324	0,0
15	1,048	0,9554	0,9554	0,0
16	2,016	2,1216	2,1216	0,0
17	2,028	1,9282	1,9282	0,0
18	2,010	1,8453	1,8453	0,0
19	1,093	1,1846	1,1846	0,0
20	1,087	0,9996	0,9996	0,0
21	1,081	0,9579	0,9579	0,0
22	2,297	2,3711	2,3711	0,0
23	2,302	2,1490	2,1490	0,0
24	2,290	2,1537	2,1537	0,0
25	1,935	2,0800	2,0800	0,0
26	1,963	1,9192	1,9192	0,0
27	1,768	1,6718	1,6718	0,0
28	1,768	1,6675	1,6675	0,0
29	1,505	1,4858	1,4858	0,0
30	1,513	1,3205	1,3205	0,0
31	1,500	1,3057	1,3057	0,0
32	3,783	3,9483	3,9483	0,0
33	3,776	3,6782	3,6782	0,0
34	3,776	3,6669	3,6669	0,0

Fonte: Wagner Oliveira de Araujo.
Nota: $\Delta = |\mathrm{Y}_{\mathrm{Python}} - \mathrm{Y}_{\mathrm{Java}}|$. Todos os valores de Δ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica *Subagging* no analito Manganês (Mn).

Tabela 24 – Paridade *Subagging* – Ni

Amostra	Y real	Y predito (Java)	Y predito (Python)	Δ
1	15,000	15,7160	15,7160	0,0
2	30,000	30,4808	30,4808	0,0
3	20,000	20,5533	20,5533	0,0
4	50,000	50,6579	50,6579	0,0
5	45,000	45,9194	45,9194	0,0
6	60,000	60,2658	60,2658	0,0
7	35,000	35,6042	35,6042	0,0
8	48,000	48,6265	48,6265	0,0
9	25,000	24,9836	24,9836	0,0
10	38,000	38,1508	38,1508	0,0
11	31,242	33,6217	33,6217	0,0
12	31,434	33,2719	33,2719	0,0
13	31,149	32,1552	32,1552	0,0
14	52,029	55,5191	55,5191	0,0
15	52,775	56,1578	56,1578	0,0
16	21,809	23,3643	23,3643	0,0
17	21,813	23,1637	23,1637	0,0
18	25,048	26,9728	26,9728	0,0
19	24,999	26,4848	26,4848	0,0
20	24,999	26,4882	26,4882	0,0

Fonte: Wagner Oliveira de Araujo.
Nota: $\Delta = |\mathrm{Y}_{\mathrm{Python}} - \mathrm{Y}_{\mathrm{Java}}|$. Todos os valores de Δ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica *Subagging* no analito Níquel (Ni).