


**INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DE GOIÁS**
**CAMPUS ANÁPOLIS**
**BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO**

Wagner Oliveira de Araujo

# MIGRAÇÃO DE SISTEMAS LEGADOS DE ANÁLISE QUÍMICA: DE JAVA DESKTOP PARA PYTHON WEB

Anápolis
2026

Wagner Oliveira de Araujo

# MIGRAÇÃO DE SISTEMAS LEGADOS DE ANÁLISE QUÍMICA: DE JAVA DESKTOP PARA PYTHON WEB

Trabalho de Conclusão de Curso II do Bacharelado em Ciência da Computação do Instituto Federal de Educação, Ciência e Tecnologia de Goiás – Campus Anápolis para a aprovação da disciplina de TCC II.

Orientador: Profº. Alexandre Bellezi Jose, Me.

Coorientador: Profº. Eder Silva de Brito, Dr

Anápolis
2026

Wagner Oliveira de Araujo

**MIGRAÇÃO DE SISTEMAS LEGADOS DE ANÁLISE QUÍMICA: DE JAVA DESKTOP PARA PYTHON WEB**

Este Trabalho de Conclusão de Curso II foi julgado adequado para obtenção do Título de "bacharel" e aprovado em sua forma final pelo Bacharelado em Ciência da Computação.

Anápolis, [dia] de [mês] de 2026.

---

Prof. Hugo Vinicius Leão e Silva, Dr.
Coordenador do Curso

**Banca Examinadora:**

---

Prof$^{o}$. Alexandre Bellezi Jose, Me.
Orientador

---

Prof$^{a}$. Luiz Fernando Loja, Dr.
Avaliador Interno
Instituto Federal de Goiás (IFG)

---

Prof. Ermiliano Nelson, Dr.
Avaliador Externo
Universidade Federal de Goiás (UFG)

*Se você for receptivo e humilde, a matemática o conduzirá pela mão. Repetidas vezes, quando estive perdido sem saber como prosseguir, bastou-me esperar até sentir que a matemática me guiava pela mão. Ela me conduziu por um caminho inesperado, um caminho onde novas perspectivas se abrem, um caminho que leva a um território novo, onde é possível estabelecer uma base de operações, a partir da qual se pode observar os arredores e planejar o progresso futuro.*

(Paul Dirac)

## RESUMO

Os resultados revelam que não existe uma técnica universalmente superior: o RLM-*subagging* apresentou melhor desempenho para Mn e Ni, o RLM-*bagging* mostrou-se superior para Fe, enquanto a RLM clássica demonstrou desempenho superior para Mo e Cr. O comportamento diferenciado entre os analitos é atribuído à complexidade espectral de cada elemento: o Fe, por apresentar maior densidade de linhas espectrais com potencial de autoabsorção e sobreposições com outros elementos da matriz, beneficia-se da agregação de múltiplos modelos. Em contrapartida, Mn, Mo, Cr e Ni têm sua relação espectral-concentração suficientemente capturada pela RLM clássica ou pelo RLM-*subagging*, sem ganho adicional com o RLM-*bagging*. Todos os modelos apresentaram $R^2$ superior a 0,9815, evidenciando elevada capacidade preditiva. Quanto à eficiência computacional, o RLM-*subagging* mostrou-se em média 3,0 vezes mais rápido que o RLM-*bagging*, configurando-se como alternativa equilibrada entre precisão e eficiência em aplicações quimiométricas sujeitas a restrições temporais.



**Palavras-chave**: Técnicas de reamostragem. Validação de Modelos. *Bagging*. *Subagging*. Quimiometria.

## ABSTRACT

The results reveal that no universally superior technique exists: RLM-*subagging* achieved the best performance for Mn and Ni, RLM-*bagging* proved superior for Fe, while classical MLR demonstrated superior performance for Mo and Cr. The differentiated behavior among analytes is attributed to the spectral complexity of each element: Fe, due to its higher density of spectral lines with self-absorption potential and overlaps with other matrix elements, benefits from the aggregation of multiple models. In contrast, Mn, Mo, Cr and Ni have their spectral-concentration relationship sufficiently captured by classical MLR or MLR-*subagging*, with no additional gain from MLR-*bagging*. All models presented $R^2$ values above 0.9815, evidencing high predictive capacity. Regarding computational efficiency, MLR-*subagging* proved on average 3.0 times faster than MLR-*bagging*, establishing itself as a balanced alternative between accuracy and efficiency in chemometric applications subject to time constraints.



**Keywords**: Resampling. Multivariate Calibration. Bagging. Subagging. Chemometrics.

## LISTA DE FIGURAS


Figura 1 – Exemplo do método *bootstrap*. . . . . 20
Figura 2 – Processo de amostragem aleatória. . . . . 23
Figura 3 – Reamostragem com agregação de modelos de regressão. . . . . 26
Figura 4 – Regressão Linear Múltipla via pseudoinversa (`BaggingOptimized.java`). 32
Figura 5 – Ensemble de Bagging/Subagging (`BaggingOptimized.java`). . . . . 33
Figura 6 – Espectros médios dos analitos analisados. . . . . 34
Figura 7 – RMSEP com RLM para Mn e Fe. . . . . 38
Figura 8 – RMSEP em função do número de replicações *bootstrap* para RLM-*bagging*. 39
Figura 9 – RMSEP para o Mn e Fe com RLM-*bagging*. . . . . 40
Figura 10 – RMSEP em função das replicações *bootstrap* para RLM-*subagging*. . . . . 41
Figura 11 – RMSEP do Mn e Fe com *subagging*. . . . . 42
Figura 12 – Tempo de execução dos algoritmos RLM, RLM-*bagging* e RLM-*subagging*. 45
Figura 13 – RMSEP para todas as técnicas. . . . . 46
Figura 14 – Tempo de execução dos algoritmos RLM-*bagging* e RLM-*subagging* com parâmetros otimizados por validação cruzada 5-*fold*. . . . . 48
Figura 15 – Fluxograma do processo de execução da análise. . . . . 54
Figura 16 – Arquitetura em camadas — Sistema legado (Java Desktop) . . . . . 86
Figura 17 – Arquitetura em camadas — Sistema modernizado (Python/Streamlit) . . . . 86
Figura 18 – Diagrama de classes. . . . . 87
Figura 19 – Diagrama de atividades. . . . . 88
Figura 20 – Diagrama de sequência. . . . . 89
Figura 21 – Diagrama de atividade PlantUML. . . . . 90
Figura 22 – Diagrama de atividade PlantUML. . . . . 91
Figura 23 – Diagrama de classes (módulos) PlantUML. . . . . 92
Figura 24 – Diagrama de sequência PlantUML. . . . . 93

## LISTA DE QUADROS

Quadro 1 – Características comparativas entre *bagging* e *subagging*. . . . . 29
Quadro 2 – Dimensões dos conjuntos de dados para diferentes elementos. . . . . 35
Quadro 3 – Inventário das funções do sistema. . . . . 50
Quadro 4 – Entradas necessárias para execução do sistema. . . . . 51
Quadro 5 – Saídas esperadas do sistema. . . . . 51
Quadro 6 – Requisitos essenciais do sistema. . . . . 52
Quadro 7 – Requisitos desejáveis do sistema. . . . . 52
Quadro 8 – Requisitos extras para fases futuras. . . . . 53
Quadro 9 – Fluxos alternativos e tratamento de exceções. . . . . 55
Quadro 10 – Pontos críticos de usabilidade e estratégias de mitigação. . . . . 55
Quadro 11 – Requisitos de performance do sistema. . . . . 56
Quadro 12 – Requisitos de usabilidade do sistema. . . . . 56
Quadro 13 – Requisitos de segurança do sistema. . . . . 57
Quadro 14 – Requisitos de escalabilidade do sistema. . . . . 57
Quadro 15 – Requisitos funcionais do sistema. . . . . 60
Quadro 16 – Requisitos não funcionais do sistema. . . . . 61

## LISTA DE TABELAS


Tabela 3 – O coeficiente de variação. . . . . 22
Tabela 4 – RMSEP por analito obtido via RLM para amostras de aço-ligas. . . . . 38
Tabela 5 – RMSEP da RLM e RLM-*bagging* para cada elemento de aço-ligas. . . . . 40
Tabela 6 – RMSEP por elemento de aço-ligas comparando RLM e RLM-*subagging*. . . 42
Tabela 7 – Comparação do RMSEP por elemento para diferentes técnicas e proporções de calibração. . . . . 43
Tabela 8 – Configuração de desempenho superior e RMSEP mínimo. . . . . 43
Tabela 9 – Desempenho comparativo das técnicas de calibração multivariada para elementos químicos em aço-liga. . . . . 47
Tabela 10 – Paridade Bagging – Cr. . . . . 73
Tabela 11 – Paridade *Bagging* – Fe. . . . . 94
Tabela 12 – Paridade *Bagging* – Mn. . . . . 95
Tabela 13 – Paridade *Bagging* – Ni. . . . . 96
Tabela 14 – Paridade *Bagging* – Mo. . . . . 97
Tabela 15 – Paridade *RLM* – Cr. . . . . 98
Tabela 16 – Paridade *RLM* – Mo. . . . . 99
Tabela 17 – Paridade *Subagging* – Cr. . . . . 100
Tabela 18 – Paridade *RLM* – Fe. . . . . 101
Tabela 19 – Paridade *RLM* – Ni. . . . . 102
Tabela 20 – Paridade *RLM* – Mn. . . . . 103
Tabela 21 – Paridade *Subagging* – Fe. . . . . 104
Tabela 22 – Paridade *Subagging* – Mo. . . . . 105
Tabela 23 – Paridade *Subagging* – Mn. . . . . 106
Tabela 24 – Paridade *Subagging* – Ni. . . . . 107

## LISTA DE ABREVIATURAS E SIGLAS

| | |
|---|---|
| AJAX | *Asynchronous JavaScript and XML* |
| AWT | *Abstract Window Toolkit* |
| EJML | *Efficient Java Matrix Library* |
| IDE | *Integrated Development Environment* |
| JVM | *Java Virtual Machine* |
| LASSO | *Least Absolute Shrinkage and Selection Operator* |
| MAE | *Mean Absolute Error* |
| MoSCoW | *Must, Should, Could, Won't have* |
| MVC | *Model-View-Controller* |
| MVP | *Minimum Viable Product* |
| PLS | *Partial Least Squares* |
| RLM | Regressão Linear Múltipla |
| RMSEP | *Root-Mean-Square Error of Prediction* |
| RMSEP-CV | *Root-Mean-Square Error of Prediction in Cross-Validation* |
| WCAG | *Web Content Accessibility Guidelines* |

## LISTA DE SÍMBOLOS

| | |
|---|---|
| $y$ | Variável dependente (concentração do analito) |
| $y^i$ | Concentração do analito para a i-ésima amostra |
| $\gamma$ | Função estatística aplicada às amostras *bootstrap* |
| $\mathbf{x}_{al}$ | Vetor de observações de uma amostra aleatória |
| $t(\mathbf{d})$ | Função ou método avaliativo aplicado à distribuição de probabilidade d |
| $x^*$ | Amostra *bootstrap* individual |
| $\widehat{\theta}^*$ | Estimativa *bootstrap* do parâmetro $\theta$ |
| $m$ | Número de replicações *bootstrap* |
| $\widehat{se}$ | Erro padrão estimado (*estimated standard error*) |
| $\Delta$ | Parâmetro que mede o tamanho da distribuição empírica estimada usando amostras *bootstrap* |
| $\mathbf{u}$ | Amostra aleatória formada por n unidades selecionadas |
| $\mathbf{v}$ | População finita de referência |
| $x_i$ | Resposta instrumental em um canal analítico para a i-ésima amostra |
| $\mathbf{x}$ | Vetor de dados de dimensão 1 por J |
| $x_{al}$ | Variável aleatória escalar (resultado de um experimento aleatório) |
| $f_k$ | k-ésima frequência probabilística |
| $\mathbf{f}$ | Vetor de frequências probabilísticas |
| BI$(n, p)$ | Distribuição binomial de tamanho n e probabilidade de sucesso p |
| $\mu$ | Média populacional |
| $\sigma^2$ | Variância populacional |
| $N(\mu, \sigma^2)$ | Distribuição normal com média $\mu$ e variância $\sigma$ ao quadrado |
| $E(x)$ | Valor esperado (expectativa) de uma variável aleatória x |
| $E_{\mathbf{f}}(x)$ | Expectativa de x sob o vetor de frequências f |
| $y_{cal}$ | Variável aleatória de calibração |
| $z_{cal}$ | Variável aleatória auxiliar de calibração |
| $g(y_{cal})$ | Função g aplicada sobre y de calibração |
| $h(z_{cal})$ | Função h aplicada sobre z de calibração |
| $\mathbf{d}$ | Função de distribuição de probabilidade |
| $\widehat{\mathbf{d}}$ | Função de distribuição empírica |
| $\mathbf{X}_{cal}$ | Matriz de respostas instrumentais em J canais analíticos para as M amostras de calibração |
| $\mathbf{Y}_{cal}$ | Vetor de concentrações do analito para as M amostras de calibração |
| $\mathbf{X}_{teste}$ | Matriz de respostas instrumentais teste para os elementos Mn, Mo, Cr, Ni e Fe |
| $\mathbf{y}_{teste}$ | Vetor de respostas instrumentais teste para os elementos Mn, Mo, Cr, Ni e Fe |

**SUMÁRIO**


**1 INTRODUÇÃO . . . . . 15**
**2 REVISÃO DA LITERATURA . . . . . 18**
**2.1 Regressão Linear Múltipla . . . . . 18**
2.1.1 Estimação dos Coeficientes . . . . . 18
2.1.2 Premissas e Métodos Robustos . . . . . 19
**2.2 A Técnica de *Bootstrap* . . . . . 19**
2.2.1 *Bootstrap* . . . . . 20
2.2.2 Estimativa *Bootstrap* . . . . . 20
2.2.3 O Número de Replicações *Bootstrap* $m$ . . . . . 21
**2.3 Reamostragem Aleatória . . . . . 22**
**2.4 Teoria da Probabilidade . . . . . 23**
**2.5 Função de Distribuição Empírica . . . . . 25**
**2.6 Princípio *Plug-in* . . . . . 25**
**2.7 Técnicas Clássicas de Reamostragem . . . . . 26**
2.7.1 *Bagging* . . . . . 27
2.7.2 *Subagging* . . . . . 28
2.7.3 Comparação entre *Bagging* e *Subagging* . . . . . 29
**2.8 Fundamentos de Engenharia de Migração e Qualidade de Software 30**
**3 MATERIAIS E MÉTODOS . . . . . 31**
**3.1 Fragmento do Código-Fonte Java — Núcleo Algorítmico . . . . . 31**
**3.2 Amostras de Aço-Ligas . . . . . 34**
**3.3 Protocolo de Validação e Seleção de Hiperparâmetros . . . . . 35**
**3.4 Medida do Erro Médio Quadrático de Predição . . . . . 36**
**4 RESULTADOS E DISCUSSÕES . . . . . 38**
**4.1 *Bagging* . . . . . 39**
**4.2 *Subagging* . . . . . 41**
**4.3 *Bagging* $\times$ *Subagging* . . . . . 45**
**5 REQUISITOS FUNCIONAIS . . . . . 50**
**5.1 Levantamento de Requisitos Funcionais . . . . . 50**
5.1.1 Inventário das Funcionalidades Existentes . . . . . 50
5.1.1.1 Funções do Sistema . . . . . 50
5.1.1.2 Entradas Necessárias (Inputs) . . . . . 51
5.1.1.3 Saídas Esperadas (Outputs) . . . . . 51
5.1.2 Classificação por Prioridade . . . . . 51
5.1.2.1 Essenciais (*Must Have*) . . . . . 51
5.1.2.2 Desejáveis (*Should Have*) . . . . . 52
5.1.2.3 Extras (*Could Have*) . . . . . 53

5.1.3 Fluxos de Uso . . . 54
5.1.3.1 Fluxo Principal: Execução de Análise Completa . . . 54
5.1.3.2 Fluxos Alternativos e Tratamento de Exceções . . . 55
5.1.3.3 Pontos Críticos de Usabilidade . . . 55
5.1.4 Requisitos Não Funcionais . . . 56
5.1.4.1 Performance . . . 56
5.1.4.2 Usabilidade . . . 56
5.1.4.3 Segurança . . . 57
5.1.4.4 Escalabilidade . . . 57
**5.2 Considerações Finais do Levantamento . . . 57**
**6 ENGENHARIA DE SOFTWARE E MODERNIZAÇÃO . . . 59**
**6.1 Engenharia de Requisitos com Sommerville . . . 59**
6.1.1 Elicitação . . . 59
6.1.2 Análise . . . 59
6.1.3 Especificação . . . 59
6.1.4 Validação . . . 59
**6.2 Especificação de Requisitos Funcionais e Não Funcionais . . . 60**
6.2.1 Requisitos Funcionais . . . 60
6.2.2 Requisitos Não Funcionais . . . 61
**6.3 Estratégias de Migração de Sistemas . . . 62**
6.3.1 Reescrita Black-Box . . . 62
6.3.2 Extração Seletiva da Lógica de Negócio . . . 62
6.3.3 Deploy Web Nativo . . . 62
6.3.4 Papel e Limites do Estágio Intermediário (Vaadin) . . . 62
**6.4 Mudança de Paradigma Arquitetural . . . 63**
6.4.1 MVC Tradicional (Java/Vaadin) . . . 63
6.4.2 Arquitetura em Camadas com Streamlit . . . 63
6.4.3 Gerenciamento de Estado Explícito . . . 63
**7 ECOSSISTEMA DE DESENVOLVIMENTO (PYTHON E STREAMLIT) 64**
**7.1 Python na Computação Científica . . . 64**
7.1.1 Processamento Vetorial com `NumPy` . . . 64
7.1.2 *Parsing* Robusto com `parse_matrix()` e `parse_vector()` . . . 64
7.1.3 Interoperabilidade Científica com `Pandas` . . . 64
7.1.4 Extensão Natural para `SciPy` em Sinais Espectrométricos . . . 64
**7.2 Ciclo de Vida do Streamlit . . . 65**
7.2.1 Execução Top-Down Unidirecional . . . 65
7.2.2 Persistência via `st.session_state` . . . 65
7.2.3 Feedback Assíncrono Simulado . . . 65
**7.3 Gerenciamento de Memória e Performance . . . 65**

7.3.1 Uso Estratégico de `st.session_state` . . . 65
7.3.2 Oportunidade de `@st.cache_data` . . . 66
7.3.3 Isolamento da Carga Computacional . . . 66
**7.4 IDEs e Ambiente de Desenvolvimento . . . 66**
7.4.1 Extensões Especializadas para o Projeto . . . 66
7.4.2 Qualidade e Padronização de Código . . . 66
7.4.3 Depuração com *Breakpoints* . . . 67
**8 INTERFACE E EXPERIÊNCIA DO USUÁRIO (UI/UX) CIENTÍFICA . 68**
**8.1 Design Centrado em Dados . . . 68**
8.1.1 Navegação por Etapas (`st.tabs`) . . . 68
8.1.2 Layout em Colunas e Hierarquia Visual . . . 68
8.1.3 Feedback Progressivo . . . 68
8.1.4 Decisão Arquitetural: `st.tabs` vs. `st.sidebar` . . . 68
**8.2 Visualização Interativa com Plotly . . . 69**
8.2.1 Integração Nativa e Centralizada . . . 69
8.2.2 Ferramentas de Inspeção Científica . . . 69
8.2.3 Padrões de Publicação . . . 69
**8.3 Contratos de Interface e Funções . . . 69**
8.3.1 Separação de Camadas . . . 70
8.3.2 Contratos Explícitos via *Type Hints* . . . 70
8.3.3 Manutenibilidade e Escalabilidade . . . 70
**9 DESENVOLVIMENTO ITERATIVO POR SPRINTS E VALIDAÇÃO POR TESTES AUTOMATIZADOS . . . 71**
**9.1 Metodologia Ágil: Desenvolvimento por Sprints . . . 71**
9.1.1 *Sprint* 1 — Motor de Dados (*Core Backend*) . . . 71
9.1.2 *Sprint* 2 — Algoritmos Científicos . . . 71
9.1.3 *Sprint* 3 — Interface Reativa . . . 71
9.1.4 *Sprint* 4 — Otimização com *Cache* . . . 71
**9.2 Suíte de Testes Automatizados com pytest . . . 72**
9.2.1 Testes Unitários (21 testes) . . . 72
9.2.2 Testes de Caixa-Preta (60 testes) . . . 72
9.2.3 Testes de Carga e *Stress* (11 testes) . . . 72
9.2.4 Resultados Consolidados . . . 73
**10 CONCLUSÃO . . . 74**
**REFERÊNCIAS . . . 77**
**APÊNDICE A – TESTES DE GRÁFICOS . . . 86**
**A.1 Diagrama de Arquitetura em Camadas — Java e Python . . . 86**
**A.2 Diagrama de Classes — Java . . . 87**
**A.3 Diagrama de Atividade — Java . . . 88**

**A.4 Diagrama de Sequência — Java . . . . . 89**
**A.5 Diagrama de Atividades — Java (PlantUML) . . . . . 90**
**A.6 Diagrama de Atividades — Streamlit . . . . . 91**
**A.7 Diagrama de Classes (Módulos) — Streamlit . . . . . 92**
**A.8 Diagrama de Sequência — Streamlit . . . . . 93**
**APÊNDICE B – TABELAS DE PARIDADE AMOSTRA-A-AMOSTRA — JAVA × PYTHON . . . . . 94**
**APÊNDICE C – RESULTADO DOS TESTES . . . . . 108**

# 1 INTRODUÇÃO

A calibração multivariada viabiliza a interpretação de dados analíticos complexos na indústria. No contexto das ligações de aço, o controle quantitativo de Mn, Cr, Mo, Ni e Fe assegura as especificações técnicas do produto. Contudo, devido à sobreposição de sinais e ao ruído de métodos instrumentais, faz-se necessário o emprego de métodos quimiométricos para a estimação precisa das concentrações.

Este estudo investiga, em caráter exploratório, a aplicação de técnicas de reamostragem (*bootstrap*), *bagging* e *subagging* na Regressão Linear Múltipla (RLM) para a calibração multivariada de amostras de aço-ligas. A pesquisa busca preencher a lacuna de conhecimento sobre a aplicação dessas técnicas de *ensemble* nesse contexto específico, contribuindo tanto para o avanço da quimiometria quanto para a modernização de sistemas computacionais de apoio à análise de aço-ligas (1, 2, 3).

Como otimizar a calibração multivariada de amostras de aço-ligas para obter previsões mais precisas dos elementos Mn, Cr, Mo, Ni e Fe, considerando a complexidade inerente à análise de dados multivariados, a necessidade de alta precisão e a exigência de uma arquitetura de software confiável e testável para sustentar essa análise?

Este estudo é significativo tanto pelo potencial de impacto prático na análise de aço-ligas quanto pela contribuição metodológica em engenharia de software: a condução de uma migração de sistema legado (Java Desktop, Vaadin Flow e Python/Streamlit) validada, em cada etapa, por uma suíte de testes automatizados que funciona como validador de equivalência entre implementações. Essa estratégia evidencia, de forma reprodutível, como preservar a corretude de um núcleo algorítmico crítico durante a reescrita completa de uma arquitetura de software.

A originalidade da pesquisa é dupla. No eixo quimiométrico, reside na aplicação de técnicas de *bagging* e *subagging*, ainda pouco exploradas na análise de aço-ligas.

No eixo de engenharia de software, reside na condução de uma reescrita *black-box* em três estágios (Desktop Java, Web Vaadin/Spring, Python/Streamlit), com arquitetura final desacoplada em três módulos de responsabilidade única e validação por 92 testes automatizados, que verificam a equivalência numérica do núcleo determinístico (RLM) e a consistência estatística dos métodos estocásticos entre o sistema legado e o sistema reescrito.

Dado o conjunto amostral reduzido — característica inerente à aquisição dos dados espectrométricos utilizados —, os resultados devem ser interpretados como evidências preliminares do comportamento dessas técnicas nesse domínio, e não como afirmações definitivas de superioridade geral de um método sobre outro.

Analisar e comparar o desempenho das técnicas de *bagging* e *subagging* aplicadas à Regressão Linear Múltipla (RLM) na calibração multivariada de dados de amostras de aço-ligas, investigando, em caráter exploratório, tanto o comportamento preditivo quanto a eficiência computacional de cada abordagem, a partir de uma arquitetura de software desenvolvida de forma incremental e validada a cada etapa da migração.

Esta pesquisa tem como objetivos específicos:

**a)** Aplicar as técnicas de reamostragem *bootstrap*, *bagging* e *subagging* na calibração de dados espectrométricos de amostras de aço-ligas, empregando a Regressão Linear Múltipla (RLM) como modelo base, com vistas ao desenvolvimento de uma metodologia analítica robusta (4, 5).

**b)** Realizar uma comparação sistemática entre os algoritmos RLM clássica, RLM-*bagging* e RLM-*subagging*, por meio da avaliação criteriosa da acurácia preditiva e da eficiência computacional de cada abordagem na análise quantitativa dos elementos Mn, Cr, Mo, Ni e Fe.

**c)** Reaproveitar, em Java (JavaSE-17), o sistema Desktop de calibração multivariada com RLM-*bagging* e RLM-*subagging* — desenvolvido na disciplina de Programação Orientada a Objetos, com arquitetura (*Model-View-Controller* (MVC)) (6, 7), biblioteca *Efficient Java Matrix Library* (EJML)[1] e interface Swing *Abstract Window Toolkit* (AWT)[2] —, consolidando-o como base algorítmica validada do TCC I.

**d)** Migrar a base algorítmica reaproveitada no TCC I para uma interface web em Vaadin Flow, como estágio intermediário, e concluir, no TCC II, a reescrita completa do sistema em Python/Streamlit, com arquitetura modular em três camadas e validação por suíte de testes automatizados.

Essa trajetória escalonada — sistema Desktop em Java, estágio intermediário em Vaadin Flow e reescrita final em Python/Streamlit — evitou a substituição simultânea de arquitetura e lógica de negócio. Cada etapa da migração permitiu verificar a equivalência comportamental da lógica matemática antes de avançar para a seguinte, consolidando-se, neste TCC II, na suíte de testes automatizados que compara as duas implementações.

A validação da lógica de negócio migrada é realizada, neste TCC II, por meio de uma suíte de testes automatizados (`test_suite_5.py`), composta por 21 testes unitários, 60 testes de caixa-preta que comparam as métricas das implementações Java e Python para os cinco analitos (Mn, Mo, Cr, Ni, Fe) e 11 testes de estresse sobre matrizes de grande porte.

Esse protocolo funciona como validador de equivalência entre o sistema legado e o sistema reescrito em dois níveis: equivalência numérica estrita para a RLM determinística e consistência estatística, dentro de tolerâncias explícitas, para o *bagging* e o *subagging*, cujas sequências pseudoaleatórias diferem entre as duas linguagens.

Este trabalho está organizado da seguinte forma. A Seção 2 apresenta a revisão da literatura sobre a Regressão Linear Múltipla (RLM), a técnica de reamostragem *bootstrap* e os

[1] A biblioteca *Efficient Java Matrix Library* (EJML) é uma biblioteca de código aberto para a linguagem Java projetada para a manipulação e computação de matrizes lineares de forma extremamente rápida e com baixo uso de memória.

[2] A *Abstract Window Toolkit* é a biblioteca nativa e original do Java criada para desenvolver interfaces gráficas de usuário (*Graphical User Interface* - GUI), como janelas, botões e menus.

conceitos de distribuição empírica e princípio *plug-in*, essenciais à compreensão das abordagens investigadas. A Seção 2.7 descreve as técnicas de *bagging* e *subagging*, incluindo fundamentos teóricos e algoritmos.

A Seção 3 caracteriza o conjunto de dados espectrométricos de aço-ligas, descreve a arquitetura do sistema Python/Streamlit concluído — separado em `models.py`, `components.py` e `app.py` — e o protocolo de validação cruzada adotado, além de apresentar as métricas RMSEP[3] , MAE[4] e $R^2$[5] empregadas na avaliação da acurácia preditiva e na verificação da equivalência comportamental do sistema.

Na Seção 4, são analisados os resultados obtidos com os algoritmos RLM clássica, RLM-*bagging* e RLM-*subagging*, com base nos valores de RMSEP, MAE e $R^2$ e nos tempos de execução computacional, além dos resultados da suíte de testes automatizados. Por fim, a Seção 10 sintetiza as principais conclusões do estudo e discute limitações e extensões futuras do sistema.

[3]O *Root Mean Squared Error of Prediction* (RMSEP), ou Raiz do Erro Quadrático Médio de Previsão, mede a acurácia de um modelo calculando a raiz quadrada da média dos erros elevados ao quadrado, penalizando de forma mais severa os grandes desvios.

[4]O *Mean Absolute Error* (MAE), ou Erro Médio Absoluto, é uma métrica que calcula a média das magnitudes dos erros em um conjunto de previsões, sem considerar suas direções (sinais positivos ou negativos).

[5]O Coeficiente de Determinação ($R^2$), também conhecido como *R-squared*, é uma medida estatística que indica a proporção da variância da variável dependente que é explicável pelas variáveis independentes do modelo.

# 2 REVISÃO DA LITERATURA

Esta seção apresenta a Regressão Linear Múltipla (RLM) e a técnica *bootstrap*. Adicionalmente, são abordados conceitos como a teoria da probabilidade, distribuição empírica, princípio *plug-in* e técnicas clássicas de reamostragem, fundamentais para a compreensão.

## 2.1 Regressão Linear Múltipla

A RLM é uma técnica estatística empregada para modelar a relação linear entre uma variável dependente (resposta) ($y$) e duas ou mais variáveis independentes (preditoras) ($\mathbf{X}$). O modelo, que inclui um termo de intercepto ($\beta_0$) e um termo de erro ($\varepsilon$), é formalizado como:

$$y = \beta_0 + x_1\beta_1 + x_2\beta_2 + \ldots + x_n\beta_n + \varepsilon \tag{1}$$

onde $\beta_j \in \mathbb{R}$ representa o coeficiente angular de cada preditor $x_j$, para $j = 1, 2, \ldots, n$.

Dispondo de um conjunto de $M$ dados de calibração $\{(x^i, y^i), \quad i = 1, 2, \ldots, M\}$, o modelo pode ser expresso na forma matricial:

$$\mathbf{y} = \mathbf{X}\beta + \varepsilon \tag{2}$$

onde o vetor de resposta $\mathbf{y}$ e a matriz de calibração $\mathbf{X}$ (incluindo a coluna de uns para o intercepto) são definidos por:

$$\mathbf{X} = \begin{bmatrix} 1 & x_1^1 & x_2^1 & \ldots & x_n^1 \\ 1 & x_1^2 & x_2^2 & \ldots & x_n^2 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^M & x_2^M & \ldots & x_n^M \end{bmatrix} \quad \mathbf{y} = \begin{bmatrix} y^1 \\ y^2 \\ \vdots \\ y^M \end{bmatrix} \tag{3}$$

O vetor de coeficientes populacionais é $\beta = [\beta_0, \beta_1, \ldots, \beta_n]^{\mathbf{T}}$.

### 2.1.1 Estimação dos Coeficientes

O procedimento de estimação é conhecido como **Método dos Mínimos Quadrados Ordinários (MQO)**. O MQO busca o vetor de coeficientes estimados $\widehat{\beta}$ que minimiza a Soma dos Quadrados dos Resíduos (SQR).

A melhor estimativa $\widehat{\beta}$ no sentido de mínimos quadrados é dada pela solução da pseudo-inversa de Moore-Penrose (8, 3):

$$\widehat{\beta} = \mathbf{X}^{+}\mathbf{y} \triangleq (\mathbf{X}^{\mathbf{T}}\mathbf{X})^{-1}\mathbf{X}^{\mathbf{T}}\mathbf{y} \tag{4}$$

onde $\mathbf{X}^{+}$ é a pseudo-inversa da matriz $\mathbf{X}$.

### 2.1.2 Premissas e Métodos Robustos

A validade das estimativas obtidas pelo MQO depende do cumprimento das premissas clássicas da regressão linear. Em dados que apresentam estruturas complexas (como é comum em Quimiometria), a violação de pressupostos como a normalidade e a homocedasticidade [1] é frequente.

Métodos robustos tornam-se indispensáveis quando há violação das premissas da regressão linear múltipla, especialmente na presença de *outliers* (9, 10). A verificação da normalidade dos resíduos, em particular, é crucial e discutida em detalhes em estudos anteriores (9, 10).

## 2.2 A Técnica de *Bootstrap*

A inferência estatística estabelece propriedades para a população $\mathbf{X}$ a partir da análise de uma amostra aleatória dessa população (8, 11, 12). O método *bootstrap* é um procedimento computacional que fornece a medida do nível de precisão da inferência estatística, como por exemplo, média, desvio padrão e erro padrão (13, 14, 15, 16, 17).

A ideia básica do *bootstrap* é inferir estatisticamente as propriedades de interesse a partir da análise de amostras aleatórias extraídas da população original sem a necessidade de conhecer a distribuição de dados a priori, o que constitui significativa vantagem sobre outras técnicas (2, 3).

Quando o parâmetro populacional de interesse é desconhecido, procura-se estimá-lo por reamostragem aleatória. Inicialmente, considera-se a **população** $\mathbf{x} = [x_1, x_2, \ldots, x_N]$. A partir dela, seleciona-se uma **amostra** $\mathbf{X} = [x_1, x_2, \ldots, x_n]$, formada por $n$ elementos independentes retirados da população.

Para avaliar a variabilidade das estimativas, aplica-se o método de ***bootstrap***, que consiste em gerar $m$ **reamostras** $\mathbf{X}^{*1}, \mathbf{X}^{*2}, \ldots, \mathbf{X}^{*m}$, obtidas por sorteio com reposição a partir da amostra original. Formalmente, cada reamostra é definida como

$$\mathbf{X}^{*i} \sim \textit{Bootstrap}(\mathbf{X}), \quad i = 1, 2, \ldots, m,$$

onde $\textit{Bootstrap}(\mathbf{X})$ denota a distribuição empírica gerada pela amostra.

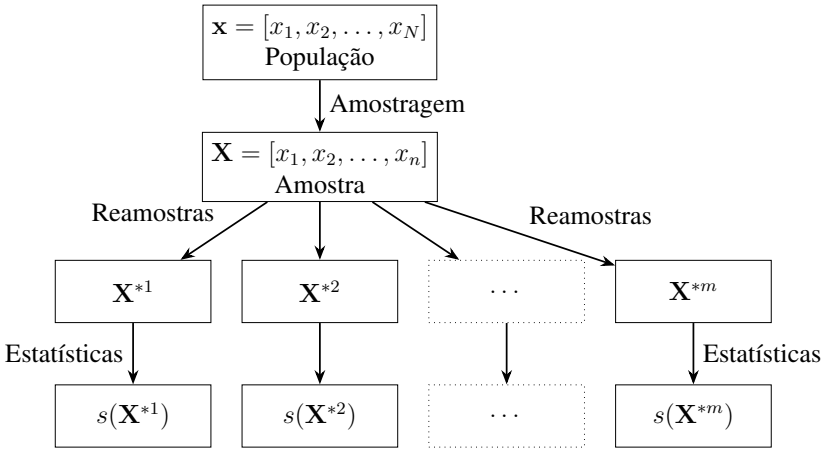
Em seguida, calcula-se uma estatística $s(\mathbf{X}^{*i})$ para cada reamostra, gerando uma distribuição empírica das estimativas. Esse processo é ilustrado na Figura 1.

A Figura 1 ilustra o procedimento de *bootstrap* em quatro etapas. O primeiro passo (primeiro retângulo) representa a população completa, denotada por $\mathbf{x} = [x_1, x_2, \ldots, x_N]$, da qual é extraída uma amostra através do processo de amostragem. O segundo passo (segundo retângulo) corresponde ao conjunto de dados observados, denotado por $\mathbf{X} = [x_1, x_2, \ldots, x_n]$.

O terceiro passo (terceiro conjunto de retângulos) corresponde à extração de amostras *bootstrap*, obtidas por reamostragem com reposição a partir de $\mathbf{X}$. O quarto passo (quarto

[1] Refere-se à variância constante dos resíduos para todas as observações. É um pressuposto crucial para a validade dos testes de significância e eficiência dos estimadores MQO. O cenário oposto é a *heterocedasticidade*.

Figura 1 – Exemplo do método *bootstrap*.




Fonte: Wagner Oliveira de Araujo.

conjunto de retângulos) mostra as replicações *bootstrap*, nas quais uma função estatística $s(\gamma)$ é recalculada $m$ vezes, sendo $m$ o número total de replicações.

Nas seções subsequentes, são discutidos conceitos fundamentais relacionados a amostras aleatórias e probabilísticas, bem como a distribuição empírica e o princípio *plug-in*. A apresentação desses tópicos tem como objetivo fornecer a base teórica necessária para a compreensão dos procedimentos de inferência estatística realizados a partir de amostras *bootstrap*.

### 2.2.1 *Bootstrap*

Uma amostra aleatória $\mathbf{x}_{al} = [x_{al1}, \ldots, x_{aln}]$ é extraída da distribuição de probabilidade $\mathbf{D}$. O parâmetro de interesse $\theta = t(\mathbf{d})$ é desconhecido e será estimado com base na amostra observada $\mathbf{x}_{al}$, resultando no estimador $\widehat{\theta} = t(\mathbf{x}_{al})$.

### 2.2.2 Estimativa *Bootstrap*

O método *bootstrap* necessita inicialmente das amostras *bootstrap* para depois aplicar as replicações *bootstrap*, como foi visto na Figura 1. Suponha a distribuição empírica $\widehat{\mathbf{d}}$, com probabilidade $\frac{1}{n}$ em cada valor de $x_i$, tendo $i = 1, 2, \ldots, n$. A amostra *bootstrap* é definida como sendo a amostra aleatória de tamanho $n$ extraída de $\widehat{\mathbf{d}}$, representada por $x^* = [x_1^*, x_2^*, \ldots, x_n^*]$ (18). As amostras *bootstrap* são obtidas por reamostragem com reposição, podendo haver repetições dos elementos da amostra original $[x_1, x_2, \ldots, x_n]$.

As replicações *bootstrap* são representadas por

$$\widehat{\theta} = s(x^*), \tag{5}$$

onde $s(\gamma)$ é a função estatística a ser aplicada sobre as amostras *bootstrap*. Por exemplo, se $s(x)$ for a média amostral $\overline{x}$, então $s(x^*)$ é a média da amostra *bootstrap*

$$\overline{x^*} = \frac{1}{n}\sum_{i=1}^{n} x_i^*. \tag{6}$$

**Algoritmo 1**: Estimativa das replicações *bootstrap*.

**Entrada**: Amostra original $x = (x_1, x_2, \ldots, x_n)$, estatística de interesse $\theta = s(x)$, número de replicações *bootstrap* $m$

**Saída**: Estimativa *bootstrap* $\widehat{\theta}^*$, erro padrão *bootstrap*, intervalo de confiança *bootstrap*

1 **início**

2 Selecione a quantidade de amostras independentes $m$, $\{x^{*1}, x^{*2}, \ldots, x^{*m}\}$, tendo tamanho $m$ e podendo haver repetições de $x$.

3 Avaliar a replicação *bootstrap* para amostra *bootstrap*, $\widehat{\theta}^*(b) = s(x^{*b}) \qquad b = 1, 2, \ldots, m.$

4 **fim**

Fonte: Wagner Oliveira de Araujo.

O Algoritmo 1 (19) mostra a descrição do procedimento para utilizar a estimativa *bootstrap*, replicando o estimador $\widehat{\theta} = s(x)$ a partir dos dados $x$ observados.

### 2.2.3 O Número de Replicações *Bootstrap* $m$

A estimativa *bootstrap* ideal é obtida através de uma boa escolha do número de replicações $m = \infty$, com o $\widehat{se}_\infty$ igual à estimativa *plug-in* $se_{\widehat{\mathbf{d}}}(\widehat{\theta}^*)$ (19). O número de replicações *bootstrap* influencia diretamente o tempo computacional gasto ao processar as replicações, principalmente se a função $s(x)$ do estimador $\widehat{\theta} = s(x)$ for muito complexa. Portanto, se não for possível obter infinitas replicações, deve-se utilizar o maior número possível de replicações.

É necessário que estimadores apresentem bom comportamento: baixo erro de predição e pequeno desvio padrão. A estimativa *bootstrap* para o erro padrão geralmente apresenta erro de predição relativamente pequeno. A estimativa *bootstrap* ideal $\widehat{se}_\infty$ possui baixa variabilidade entre estimativas com erro de predição quase nulo de $se_{\widehat{\mathbf{d}}}(\widehat{\theta^*})$, pelo menos em um sentido assintótico.

Esta propriedade decorre do fato de que $\widehat{se}_m$ é a estimativa *plug-in* de $se_{\widehat{\mathbf{d}}}(\widehat{\theta^*})$. Não é difícil mostrar que $\widehat{se}_m$ sempre possui desvio padrão maior que $\widehat{se}_\infty$ (19). A questão que se coloca é: **o quanto maior**?

Uma resposta aproximada, porém satisfatória, pode ser encontrada utilizando o coeficiente de variação de $\widehat{se}_m$ em relação à sua expectativa. O aumento da variabilidade decorrente da interrupção do processo após $m$ replicações *bootstrap*, em vez de permitir que $m$ tenda ao infinito, resulta em um aumento do coeficiente de variação:

$$cv(\widehat{se}_m) = \sqrt{[cv(\widehat{se}_\infty)]^2 + \frac{E(\Delta) + 2}{4m}}. \tag{7}$$

O parâmetro $\Delta$ mede o tamanho da distribuição de $\widehat{\theta}^*$: $\Delta$ é zero para a distribuição normal; na prática, $\Delta$ geralmente é maior que 10. O coeficiente de variação na Equação (7)

incorpora tanto a variabilidade devida à reamostragem *bootstrap* quanto a variabilidade devida à amostragem da população original.

A estimativa ideal $\widehat{se}_\infty = se_{\widehat{\mathbf{d}}}(\widehat{\theta}^*)$ não é perfeita (19). Pode haver variabilidade considerável na estimativa $se_{\mathbf{d}}(\widehat{\theta})$ devido à variabilidade de $\hat{\mathbf{d}}$ em relação a $\mathbf{d}$. Por exemplo, se $\{x_1, x_2, \ldots, x_n\}$ for uma amostra aleatória de uma distribuição normal e $\widehat{\theta} = \overline{x}$, então $cv(\widehat{se}_\infty) = \frac{1}{\sqrt{2n}}$, resultando em $0,22$ para $n = 10$.

A Equação (7) tem uma consequência prática importante: dados os valores típicos de $cv(\widehat{se}_\infty)$ e $\Delta$ encontrados na prática, $cv(\widehat{se}_m)$ não será muito maior que $cv(\widehat{se}_\infty)$ quando $m \geq 200$.

Tabela 3 – O coeficiente de variação.

| | | m[a]→ | | | | |
|---|---|---|---|---|---|---|
| | | 25 | 50 | 100 | 200 | $\infty$ |
| $cv(\widehat{se}_\infty)$[b] | 0,25 | 0,29 | 0,27 | 0,26 | 0,25 | 0,25 |
| ↓ | 0,20 | 0,24 | 0,22 | 0,21 | 0,21 | 0,20 |
| | 0,15 | 0,21 | 0,18 | 0,17 | 0,16 | 0,15 |
| | 0,10 | 0,17 | 0,14 | 0,12 | 0,11 | 0,10 |
| | 0,05 | 0,15 | 0,11 | 0,09 | 0,07 | 0,05 |
| | 0,00 | 0,14 | 0,10 | 0,07 | 0,05 | 0,00 |

Fonte: EFRON, B.; TIBSHIRANI, R. J. *An Introduction to the Bootstrap*, USA: Chapman & Hall/CRC, 1993, p.53.
[a] Número de amostras *bootstrap*.
[b] Coeficiente de variação.

A Tabela 3 compara $cv(\widehat{se}_m)$ com $cv(\widehat{se}_\infty)$ para várias escolhas de $m$, assumindo $\Delta = 0$. Observa-se frequentemente que $cv(\widehat{se}_\infty)$ não será menor que $0,10$; neste caso, com $m = 100$ obtêm-se resultados bem satisfatórios. Efron (19) sugere duas regras práticas através da sua experiência:

a) Mesmo um número pequeno de replicações *bootstrap*, como $m = 25$, é geralmente informativo; $m = 50$ é frequentemente suficiente para uma boa estimativa de $se_{\mathbf{d}}(\widehat{\theta})$.

b) Muito raramente serão necessárias mais que $m = 200$ replicações para estimar o erro padrão. Valores muito maiores de $m$ são requeridos para construção de intervalos de confiança.

A Tabela 3 mostra a variação de $\widehat{se}_m$ em função do coeficiente de variação da estimativa ideal $\widehat{se}_\infty$ e do número de amostras *bootstrap* $m$, obtidos da Equação (7) assumindo $\Delta = 0$.

## 2.3 Reamostragem Aleatória

O processo de reamostragem é realizado a partir da seleção aleatória de números inteiros $\{j_1, j_2, \ldots, j_n\}$, cada um com probabilidade $1/n$. Uma amostra aleatória de tamanho $n$ é definida

pela seleção aleatória de $n$ unidades $\{u_1, u_2, \ldots, u_n\}$ extraídas da população $\mathbf{u}$ (ver Figura 2), onde $\mathbf{u}$ é a população de números inteiros selecionados para gerar variáveis aleatórias.

A população $\mathbf{v}$ é formada pelos valores selecionados de $\mathbf{u}$ de acordo com os valores de $j$, sendo constituída por $\{v_1, v_2, \ldots, v_n\}$. Esta população é criada por um dispositivo (como um software) responsável por gerar as amostras aleatórias. Por meio dos valores $\{j_1, j_2, \ldots, j_n\}$ selecionados, pode-se determinar quais membros de $\mathbf{v}$ serão escolhidos para a amostra aleatória:

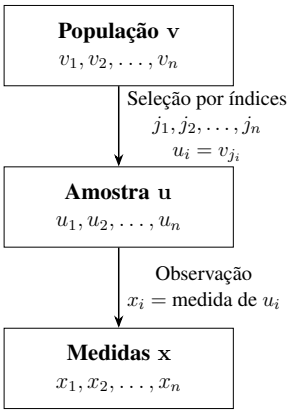
$$u_1 = v_{j_1}, \quad u_2 = v_{j_2}, \quad \ldots, \quad u_n = v_{j_n}.$$

Sendo $x_i$ uma medida da unidade $u_i$ para $i = 1, 2, \ldots, n$, o conjunto de dados observados será

$$\mathbf{x} = \{x_1, x_2, \ldots, x_n\}. \tag{8}$$

Se as unidades da amostra $\{u_1, u_2, \ldots, u_n\}$ são observadas, obtêm-se as medidas correspondentes $\{x_1, x_2, \ldots, x_n\}$, que formam o vetor de dados $\mathbf{x}$.

Figura 2 – Processo de amostragem aleatória.




Fonte: Wagner Oliveira de Araujo.

## 2.4 Teoria da Probabilidade

A partir de uma amostra aleatória $\mathbf{x}_{al}$, deve-se inferir a distribuição de probabilidade da população completa $\mathbf{X} = [X_1, X_2, \ldots, X_n]$, onde $X_i$ representa a variável aleatória associada à $i$-ésima observação. A teoria da probabilidade segue o raciocínio oposto: a partir do conhecimento da distribuição de probabilidade da população $\mathbf{X}$, deduzem-se as propriedades das amostras aleatórias e das estatísticas calculadas a partir delas.

Seja $x_{al}$ o resultado da rolagem de um dado não viciado. Por exemplo, no lançamento de um dado cúbico de 6 faces, onde todas as faces possuem probabilidades iguais de ocorrência, obtém-se como resultado 1, 2, 3, 4, 5 ou 6. Em notação probabilística, tem-se

$$\Pr\{x_{al} = k\} = \frac{1}{6}, \quad \text{para } k = 1, 2, 3, 4, 5, 6. \tag{9}$$

A quantidade aleatória que possua a probabilidade de ser selecionada como $x_{al}$ é chamada de *variável aleatória*. Na teoria da probabilidade, a notação utilizada para definir a frequência $f_k$ é dada por

$$f_k = \Pr\{x_{al} = k\}. \tag{10}$$

Na rolagem do dado não viciado, tem-se $f_k = \frac{1}{6}$ para $k = 1, 2, \ldots, 6$. A distribuição de probabilidade para a variável aleatória $x_{al}$ será denotada por $\mathbf{f}$. Aqui, $\mathbf{f}$ é o vetor de frequências

$$\mathbf{f} = (f_1, f_2, \ldots, f_6) = \left(\frac{1}{6}, \frac{1}{6}, \ldots, \frac{1}{6}\right). \tag{11}$$

Podem-se encontrar também amostras com variáveis aleatórias $x_{al}$ na forma da distribuição binomial de tamanho $n$ e probabilidade de sucesso $p$, denotada

$$x_{al} \sim \text{BI}(n, p). \tag{12}$$

A frequência é representada por

$$f_k = \binom{n}{k} p^k (1-p)^{n-k}, \quad \text{para } k = 0, 1, 2, \ldots, n, \tag{13}$$

sendo $n$ um inteiro positivo, $p$ um número entre 0 e 1, e $\binom{n}{k}$ o coeficiente binomial definido por

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}. \tag{14}$$

A probabilidade pode ser definida também como no exemplo da distribuição normal (ou gaussiana). Uma variável aleatória de valor real $x_{al}$, tendo a distribuição normal com média $\mu$ e variância $\sigma^2$, é descrita por

$$x_{al} \sim N(\mu, \sigma^2). \tag{15}$$

A probabilidade de $x_{al}$ pertencer a um conjunto $A \subseteq \mathbb{R}$ é dada por

$$\Pr\{x_{al} \in A\} = \int_A \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right) dx. \tag{16}$$

Existem outros problemas com dimensões maiores envolvendo integrais similares à Equação (16), mas não será necessário utilizar estas distribuições contínuas para o *bootstrap* neste trabalho.

A expectativa da variável aleatória de valor real $x_{al}$, escrita por $E(x)$, é o valor médio sobre os possíveis resultados de $x_{al}$. Assim, para a distribuição binomial:

$$E(x_{al}) = \sum_{k=0}^{n} k \binom{n}{k} p^k (1-p)^{n-k}, \quad \text{para } x_{al} \sim \text{BI}(n, p), \tag{17}$$

e para a distribuição normal:

$$E(x_{al}) = \int_{-\infty}^{\infty} x \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right) dx, \quad \text{para } x_{al} \sim N(\mu, \sigma^2). \tag{18}$$

A expectativa, como a teoria da média, é muito ampla e inclui casos de variáveis aleatórias sem valor real definido.

Pode-se obter a variância de $x_{al}$, representada por $\sigma^2$. Tendo $\mu = E_{\mathbf{f}}(x)$ para $x_{al}$ sendo uma variável aleatória de valor real, a variância é definida como o valor esperado de $(x_{al} - \mu)^2$. Em outras palavras, $\sigma^2$ é o quadrado médio das distâncias da variável aleatória $x_{al}$ em relação à sua expectativa $\mu$ (4):

$$\sigma^2 = E_{\mathbf{f}}[(x_{al} - \mu)^2]. \tag{19}$$

A variância de $x_{al} \sim N(\mu, \sigma^2)$ é igual a $\sigma^2$, e a variância de $x_{al} \sim \text{BI}(n, p)$ é igual a $np(1-p)$. O desvio padrão da variável aleatória é definido pela raiz quadrada destas variâncias.

Para que duas variáveis aleatórias $y_{cal}$ e $z_{cal}$ sejam independentes, deve-se ter

$$E[g(y_{cal})h(z_{cal})] = E[g(y_{cal})] \cdot E[h(z_{cal})] \tag{20}$$

para todas as funções $g$ e $h$. A independência implica que o resultado aleatório de $y_{cal}$ não afeta o resultado aleatório de $z_{cal}$, e vice-versa.

## 2.5 Função de Distribuição Empírica

Suponha que uma amostra aleatória de tamanho $n$, dada por $\mathbf{x} = \{x_1, x_2, \ldots, x_n\}$, seja obtida de uma função de distribuição de probabilidade $\mathbf{d}$. A função de distribuição empírica $\widehat{\mathbf{d}}$ é definida como a distribuição discreta que atribui probabilidade $\frac{1}{n}$ a cada valor observado $x_i$, para $i = 1, 2, \ldots, n$.

Em outras palavras, a distribuição empírica $\widehat{\mathbf{d}}$ é construída a partir do espaço amostral de $\mathbf{x}$, atribuindo a seguinte probabilidade empírica a um evento $A$:

$$\widehat{\Pr}\{A\} = \frac{\#\{x_i \in A\}}{n}, \tag{21}$$

onde $\#\{x_i \in A\}$ denota o número de observações $x_i$ que pertencem ao conjunto $A$.

Em casos onde ocorrem repetições de valores na amostra, para evitar atribuir probabilidade $\frac{1}{n}$ a cada ocorrência repetida individualmente, utiliza-se $\widehat{\mathbf{d}}$ com as frequências relativas observadas. Para valores distintos $k$ no espaço amostral, define-se

$$\widehat{f}_k = \frac{\#\{x_i = k\}}{n}, \tag{22}$$

onde $\#\{x_i = k\}$ representa o número de observações na amostra que são iguais a $k$. Assim, $\widehat{f}_k$ é a frequência relativa (ou probabilidade empírica) do valor $k$ na amostra.

## 2.6 Princípio *Plug-in*

O princípio *plug-in* constitui uma abordagem fundamental para estimação de parâmetros estatísticos, permitindo estimar um parâmetro de interesse $\theta$ por meio de uma função avaliativa aplicada à distribuição empírica dos dados (20).

Formalmente, seja $\theta = t(F)$ um parâmetro definido como função da distribuição populacional $F$. O estimador *plug-in* é obtido substituindo $F$ pela distribuição empírica $\hat{F}_n$:

$$\hat{\theta} = t(\hat{F}_n), \tag{23}$$

onde $n$ denota o tamanho da amostra.

Para o caso particular em que $\theta$ representa a expectativa populacional $\mathbb{E}_F(X)$, o estimador *plug-in* corresponde à média amostral:

$$\hat{\theta} = \mathbb{E}_{\hat{F}_n}(X) = \frac{1}{n}\sum_{i=1}^{n} x_i = \bar{x}. \tag{24}$$

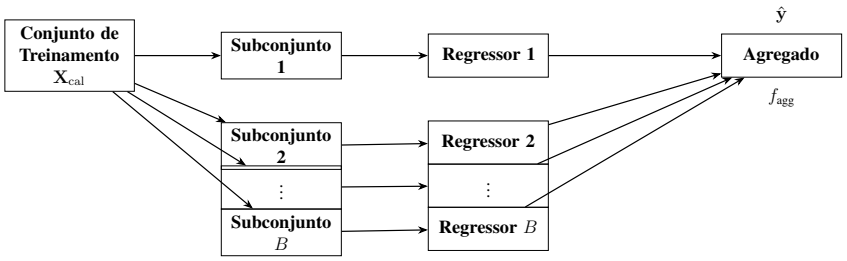
É importante destacar que o método *bootstrap* constitui uma aplicação direta do princípio *plug-in*, podendo ser adotado como método de estimação para diversos modelos estatísticos, incluindo modelos de regressão (20, 21).

## 2.7 Técnicas Clássicas de Reamostragem

Nesta seção, revisam-se duas técnicas fundamentais de reamostragem: *bagging* e *subbagging*. Ambas utilizam amostras *bootstrap*, como detalhado na Seção 2, baseando-se na distribuição empírica das probabilidades.

As técnicas de reamostragem são particularmente úteis em cenários com limitação amostral ou quando os dados são contaminados por ruídos instrumentais. A ideia central consiste em combinar as predições de múltiplos modelos de regressão em um único preditor agregado, processo conhecido como *ensemble* (22, 23).

Figura 3 – Reamostragem com agregação de modelos de regressão.




Fonte: Wagner Oliveira de Araujo.

A Figura 3 ilustra o fluxo de reamostragem e agregação: o conjunto de calibração $\mathbf{X}_{\text{cal}}$ é reamostrado em $B$ subconjuntos, cada um utilizado para calibrar um regressor independente. As predições individuais são subsequentemente combinadas no estágio de agregação mediante uma função $f_{\text{agg}}$.

Técnicas *ensemble* integram múltiplos modelos para aprimorar o desempenho preditivo final (22). Neste trabalho, emprega-se a média aritmética como função de agregação, com todos os regressores utilizando Regressão Linear Múltipla (RLM), caracterizando um *ensemble* homogêneo (24, 25, 26).

A distinção fundamental entre *bagging* e *subagging* reside no esquema de amostragem: com e sem reposição, respectivamente. As Seções 2.7.1 e 2.7.2 detalham estas técnicas.

### 2.7.1 *Bagging*

A técnica *bagging* (*Bootstrap Aggregating*) foi proposta por Breiman (27) com o objetivo de gerar múltiplos conjuntos de calibração por meio de reamostragem *bootstrap*, combinando posteriormente os resultados obtidos. Esta abordagem visa reduzir a variância do preditor final através da agregação (27, 28, 29, 30, 5).

Breiman demonstrou que o *bagging* proporciona ganhos significativos de desempenho em problemas de regressão, especialmente quando o modelo é instável – isto é, quando pequenas alterações no conjunto de calibração resultam em mudanças substanciais nas predições. Na decomposição do erro de predição em regressão, o *bagging* atua principalmente na redução da componente de variância do preditor.

A técnica também se mostra eficaz em regressões multivariadas, particularmente em problemas de seleção de amostras de calibração em modelos de Regressão Linear Múltipla (RLM) (31, 2). Variações na seleção de variáveis, decorrentes de flutuações nos conjuntos de calibração, são suavizadas pelo cálculo da média dos modelos resultantes (32).

**Algoritmo 2**: Estimativa *bagging*.

**Entrada**: Amostra original $\mathbf{x} = (x_1, x_2, \ldots, x_n)$ com $n$ observações, estatística de interesse $\theta = s(\mathbf{x})$, número de réplicas *bootstrap* $B$

**Saída**: Estimativa *bagging* $\hat{\theta}^*_{\text{bag}}$, distribuição das estimativas *bootstrap* $\{\hat{\theta}^*(1), \ldots, \hat{\theta}^*(B)\}$

**início**
- Definir o número de réplicas *bootstrap* $B$
- **para** $b = 1$ ***até*** $B$ **faça**
  - Gerar amostra *bootstrap* $\mathbf{x}^{*(b)}$ de tamanho $n$ com reposição a partir de $\mathbf{x}$
  - Calcular a estatística para a réplica $b$:
  - $\hat{\theta}^*(b) = s(\mathbf{x}^{*(b)})$
- **fim**
- Agregar as réplicas via média aritmética:

$$\hat{\theta}^*_{\text{bag}} = \frac{1}{B} \sum_{b=1}^{B} \hat{\theta}^*(b)$$

**fim**

Fonte: Wagner Oliveira de Araujo.

O Algoritmo 2 descreve o procedimento para aplicação do *bagging*. Inicialmente, define-se o número $B$ de réplicas *bootstrap* a serem geradas. Para cada réplica $b = 1, \ldots, B$, extrai-se uma amostra $\mathbf{x}^{*(b)}$ de tamanho $n$ com reposição da amostra original, aplica-se a função $s(\cdot)$ para obter $\hat{\theta}^*(b)$, e finalmente agrega-se os resultados através da média aritmética (33).

No *bagging* tradicional proposto por Breiman (34), cada amostra *bootstrap* possui o mesmo tamanho da amostra original. Neste trabalho, a implementação do *bagging* utilizando Regressão Linear Múltipla (RLM) é denominada **RLM-*bagging***.

### 2.7.2 *Subagging*

A técnica *subagging* (*subsample aggregating*) baseia-se na reamostragem sem reposição, diferindo do *bagging* tradicional por não permitir repetições de observações dentro das amostras (23, 35, 36, 37, 38, 39, 40, 41, 42, 43). Cada modelo é construído de maneira similar ao *bagging*, porém utilizando subamostras de tamanho reduzido $k < n$.

**Algoritmo 3**: Estimativa *subagging*.

**Entrada**: Amostra original $\mathbf{x} = (x_1, x_2, \ldots, x_n)$ com $n$ observações, estatística de interesse $\theta = s(\mathbf{x})$, número de réplicas $B$, tamanho das subamostras $k$ (onde $k \leq n$)

**Saída**: Estimativa subagging $\hat{\theta}^*_{\text{subag}}$, conjunto de estimativas $\{\hat{\theta}^*(1), \ldots, \hat{\theta}^*(B)\}$

**início**
- Definir o tamanho das subamostras $k$ (tipicamente $k < n$)
- Definir o número de réplicas $B$
- **para** $b = 1$ ***até*** $B$ **faça**
  - Gerar subamostra $\mathbf{x}^{*(b)}$ de tamanho $k$ **sem reposição** a partir de $\mathbf{x}$
  - Calcular a estatística para a subamostra: $\hat{\theta}^*(b) = s(\mathbf{x}^{*(b)})$
- **fim**
- Agregar as réplicas via média aritmética:

$$\hat{\theta}^*_{\text{subag}} = \frac{1}{B} \sum_{b=1}^{B} \hat{\theta}^*(b)$$

**fim**

Fonte: Wagner Oliveira de Araujo.

O Algoritmo 3 descreve o procedimento para aplicação do *subagging*. Inicialmente, definem-se os parâmetros $k$ (tamanho das subamostras) e $B$ (número de réplicas). Para cada iteração $b = 1, \ldots, B$, gera-se uma subamostra $\mathbf{x}^{*(b)}$ de tamanho $k$ **sem reposição** a partir dos dados originais, aplica-se a função $s(\cdot)$, e finalmente agrega-se os resultados através da média aritmética.

A ausência de reposição implica que cada observação aparece no máximo uma vez por subamostra, diferenciando fundamentalmente esta técnica do *bagging*. Esta característica torna o *subagging* particularmente sensível à escolha do tamanho das subamostras $k$ e do número de réplicas $B$. A relação ótima entre estes parâmetros, bem como uma análise comparativa entre *bagging* e *subagging*, são discutidas na Seção 4.3.

Bühlmann (35) introduziu o subagging como uma otimização do *bagging* para subamostras de dimensão $m < n$. A generalização para regressão de alta dimensionalidade foi formalizada por Ing e Lai (44). Análises teóricas recentes (39, 36) determinam condições necessárias e suficientes para a convergência e eficiência assintótica[2] desses métodos.

Neste trabalho, a implementação do *subagging* utilizando Regressão Linear Múltipla (RLM) é denominada **RLM-*subagging***.

### 2.7.3 Comparação entre *Bagging* e *Subagging*

Embora *bagging* e *subagging* compartilhem o princípio de agregação de múltiplos modelos, diferem fundamentalmente no mecanismo de reamostragem empregado. A Quadro 1 sintetiza as principais distinções entre estas técnicas, destacando suas características operacionais e implicações para a variância dos estimadores resultantes.

Quadro 1 – Características comparativas entre *bagging* e *subagging*.

| **Característica** | ***Bagging*** | ***Subagging*** |
|---|---|---|
| Tipo de amostragem | Com reposição | Sem reposição |
| Tamanho das réplicas | $n$ | $k \leq n$ |
| Repetição de observações | Permitida | Não permitida |
| Diversidade entre réplicas | Moderada | Alta |
| Variância do estimador | Redução moderada | Redução potencialmente maior |
| Sensibilidade a parâmetros | Baixa | Alta ($k$ e $B$) |

Fonte: Wagner Oliveira de Araujo.

Como mostra o Quadro 1, a ausência de reposição no *subagging* resulta em maior diversidade entre as réplicas, uma vez que cada subamostra contém um conjunto distinto de observações. Esta característica pode proporcionar maior redução de variância, mas torna a técnica mais sensível à escolha adequada dos parâmetros $k$ (tamanho das subamostras) e $B$ (número de réplicas).

A escolha entre *bagging* e *subagging* depende fundamentalmente das características do problema em questão. O *bagging* é mais robusto e requer menos ajuste de parâmetros, sendo preferível quando se dispõe de amostras de tamanho moderado. Por outro lado, o *subagging* pode ser vantajoso em cenários com amostras grandes ou quando há interesse em controlar explicitamente o tamanho das subamostras para reduzir o custo computacional (35).

Nas aplicações com Regressão Linear Múltipla (RLM) desenvolvidas neste trabalho, ambas as técnicas serão avaliadas empiricamente, permitindo uma análise comparativa de seus desempenhos preditivos em diferentes configurações amostrais.

[2]Assintótica refere-se ao comportamento de algo quando uma variável tende ao infinito (ou a um limite extremo).

## 2.8 Fundamentos de Engenharia de Migração e Qualidade de Software

Assim como a calibração multivariada, a modernização de sistemas legados possui fundamentação teórica própria. Sommerville (45) estrutura a engenharia de requisitos em quatro fases interdependentes — elicitação, análise, especificação e validação —, oferecendo o arcabouço metodológico adotado neste trabalho para decompor as responsabilidades do sistema Java legado em módulos independentes, evitando que a reescrita repetisse o acoplamento entre lógica de negócio, persistência e interface presente na implementação original.

A estratégia de migração adotada — reescrita *black-box* — extrai os requisitos do comportamento observável de um sistema legado, sem reaproveitar seu código-fonte (46). Diferentemente da reescrita *white-box*, que preserva estruturas internas do sistema original, essa abordagem trata o legado exclusivamente como especificação funcional, permitindo à equipe redesenhar a arquitetura livremente, desde que a equivalência comportamental do núcleo algorítmico seja formalmente demonstrada em cada etapa da migração.

A verificação dessa equivalência comportamental exige um critério de avaliação independente da implementação (47). Testes de caixa-preta comparam entradas e saídas entre o sistema original e o sistema reescrito sem inspecionar o código-fonte legado, estratégia adequada quando o objetivo — como neste trabalho — é substituir integralmente a plataforma de execução preservando o comportamento matemático. Essa fundamentação sustenta a suíte de 92 testes automatizados que compara Java e Python, apresentada adiante.

# 3 MATERIAIS E MÉTODOS

Esta seção apresenta os dados utilizados na aplicação dos algoritmos de reamostragem, bem como as medidas estatísticas empregadas para comparação entre os métodos. O objetivo é determinar a concentração de Manganês (Mn), Molibdênio (Mo), Cromo (Cr), Níquel (Ni) e Ferro (Fe) a partir de espectros reamostrados pelos métodos *bagging* e *subagging*.

Para a implementação computacional, utilizou-se a linguagem de programação Java (JavaSE-17) em conjunto com o ambiente de desenvolvimento integrado Eclipse *Integrated Development Environment* (IDE) (versão 2025-09). As operações matriciais exigidas pelos algoritmos de calibração multivariada, incluindo o cômputo da pseudo-inversa de Moore-Penrose, as reamostragens *bootstrap* e a agregação dos modelos de *ensemble*, foram implementadas com o suporte da biblioteca *Efficient Java Matrix Library*, `org.ejml.simple.SimpleMatrix` (EJML). Esta é especializada em operações de álgebra linear de alto desempenho para a plataforma Java, garantindo eficiência no processamento.

A visualização gráfica dos resultados foi realizada pela biblioteca JFreeChart[1], que possibilitou a geração dos gráficos de predição e comparação de desempenho deste trabalho. A interface gráfica de usuário, para entrada de parâmetros e exibição de resultados durante os experimentos, foi desenvolvida com os *frameworks* nativos Java Swing e AWT. O gerenciamento dos arquivos de entrada e saída, incluindo leitura das matrizes espectrométricas e exportação dos resultados, foi realizado pelas bibliotecas padrão `java.io`.

Durante o desenvolvimento deste trabalho, o modelo de linguagem de inteligência artificial Qwen3.7-Plus foi utilizado como ferramenta de assistência para: revisão ortográfica, sugestão de estruturação de seções, tradução de resumos, refatoração de trechos de código (Java/Pthyton), correção de erros código LaTeX (48). A validação factual, a análise crítica dos dados espectrométricos e a redação final das conclusões foram realizadas integralmente pelo autor, garantindo a integridade acadêmica e a autoria do trabalho.

## 3.1 Fragmento do Código-Fonte Java — Núcleo Algorítmico

A classe `BaggingOptimized` (que estende `JFrame`) concentra, entre os componentes de interface gráfica, o núcleo algorítmico responsável pelos três modelos de regressão avaliados neste trabalho. A Figura 4 apresenta o método `performRLM`, que implementa a Regressão Linear Múltipla simples via pseudoinversa de Moore-Penrose.

[1] Versões: EJML 0.43.1; JFreeChart 1.5.4. Código em: https://github.com/woa2009/MigracaoJava

Figura 4 – Regressão Linear Múltipla via pseudoinversa (`BaggingOptimized.java`).

```
private SimpleMatrix performRLM(SimpleMatrix Xcal, SimpleMatrix Ycal,
                                SimpleMatrix Xteste) {
    SimpleMatrix b = pseudoInverse(Xcal).mult(Ycal);
    return Xteste.mult(b);
}
```

Fonte: Wagner Oliveira de Araujo.

A Figura 5 apresenta o método `performBagging`, que implementa tanto o *Bagging* (reamostragem com reposição) quanto o *Subagging* (reamostragem sem reposição, com fração configurável), controlados pelo parâmetro booleano `withReplacement`. Cada um dos `numBags` modelos é ajustado sobre uma reamostra distinta e a predição final é obtida pela média aritmética das predições individuais.

Figura 5 – Ensemble de Bagging/Subagging (`BaggingOptimized.java`).

```
private SimpleMatrix performBagging(SimpleMatrix Xcal, SimpleMatrix Ycal,
        SimpleMatrix Xteste, int numBags, boolean withReplacement,
        double sampleFraction) {
    int n = Xcal.numRows();
    int sampleSize = withReplacement ? n : (int) (n * sampleFraction);
    List<SimpleMatrix> models = new ArrayList<>();
    Random rand = new Random(42); // semente fixa para reprodutibilidade

    for (int bag = 0; bag < numBags; bag++) {
        SimpleMatrix Xbag = new SimpleMatrix(sampleSize, Xcal.numCols());
        SimpleMatrix Ybag = new SimpleMatrix(sampleSize, 1);

        if (withReplacement) {
            // Bagging: amostragem com reposicao (bootstrap completo)
            for (int i = 0; i < sampleSize; i++) {
                int idx = rand.nextInt(n);
                copyRow(Xcal, idx, Xbag, i);
                Ybag.set(i, 0, Ycal.get(idx, 0));
            }
        } else {
            // Subagging: amostragem sem reposicao (subconjunto aleatorio)
            List<Integer> indices = new ArrayList<>();
            for (int i = 0; i < n; i++) indices.add(i);
            Collections.shuffle(indices, rand);
            for (int i = 0; i < sampleSize; i++) {
                int idx = indices.get(i);
                copyRow(Xcal, idx, Xbag, i);
                Ybag.set(i, 0, Ycal.get(idx, 0));
            }
        }

        // Ajusta o modelo RLM para esta amostra bootstrap
        SimpleMatrix b_bag = pseudoInverse(Xbag).mult(Ybag);
        models.add(b_bag);
    }

    // Agrega as predicoes de todos os modelos pela media aritmetica
    SimpleMatrix Ypred = new SimpleMatrix(Xteste.numRows(), 1);
    for (SimpleMatrix b : models) {
        SimpleMatrix pred = Xteste.mult(b);
        Ypred = Ypred.plus(pred.scale(1.0 / numBags));
    }
    return Ypred;
}
```

Fonte: Wagner Oliveira de Araujo.

Essa mesma bifurcação — reamostragem com ou sem reposição controlada por um único parâmetro booleano — é preservada na reimplementação Python (Seção 8.3), constituindo um dos pontos de verificação dos testes de caixa-preta descritos na Seção 9.2.

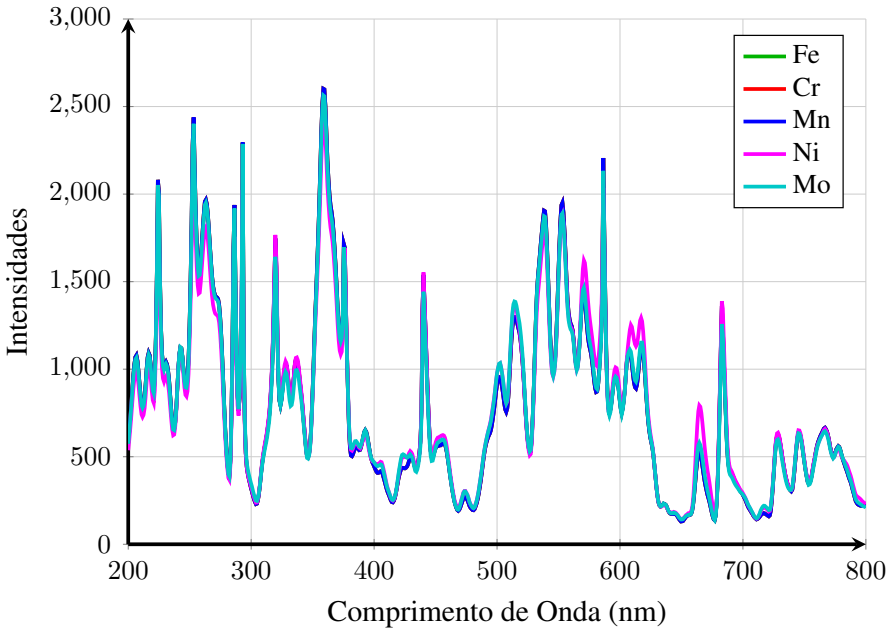
## 3.2 Amostras de Aço-Ligas

Os dados foram obtidos por meio de um espectrômetro de emissão atômica em plasma com acoplamento indutivo sequencial convertido para um sistema de múltiplos canais de detecção baseado em um arranjo linear de 1024 fotodiodos. O aparelho instrumental faz uso das propriedades de absorção e emissão de plasma, como detalhado em (49).

A espectroscopia de emissão atômica é responsável pela conversão dos componentes da amostra em átomos ou íons elementares, podendo excitá-los a vários estados eletrônicos. A rápida relaxação das espécies excitadas possibilita a produção de espectros visíveis que serão analisados quantitativamente e qualitativamente, com vantagens sobre outros métodos clássicos. Por exemplo, a baixa interferência entre elementos da mesma amostra, e o registro de espectros para vários elementos no mesmo conjunto de excitação (1).

Os espectros obtidos por fontes de plasma são bastante complexos e constituem centenas ou até milhares de frequências (Figura 6). Logo, melhoram a análise qualitativa. Porém, dificulta a análise quantitativa pela grande quantidade de variáveis geradas por amostra motivando o emprego de calibração multivariada (50, 51).

Figura 6 – Espectros médios dos analitos analisados.




Fonte: Wagner Oliveira de Araujo.

As matrizes de respostas instrumentais e concentração das amostras de aço-ligas são organizadas em dois conjuntos de dados: calibração (33,3 – 45,9%) e teste (54,1 – 66,7%), como segue (Quadro 2). Cada amostra é representada por 723 variáveis espectrais, resultando em uma razão de aproximadamente 42 preditores por observação no conjunto de calibração. Esse regime de alta dimensionalidade — inerente à natureza dos dados espectrométricos de plasma — é tratado pela pseudo-inversa de Moore-Penrose (Equação 4), que fornece solução única mesmo em sistemas subdeterminados.

Ressalta-se, contudo, que conjuntos de calibração reduzidos são uma característica recorrente em análises de aço-ligas por espectrometria, como documentado na literatura (49, 50), e que os resultados obtidos neste estudo devem ser interpretados como evidências exploratórias do comportamento das técnicas investigadas nesse contexto específico, não sendo diretamente generalizáveis a outras composições ou regimes amostrais sem validação adicional.

Quadro 2 – Dimensões dos conjuntos de dados para diferentes elementos.

| Elemento | Calibração | Teste |
|---|---|---|
| Mn | $\mathbf{Xcal}_{Mn_{(17\times723)}}$, $\mathbf{Ycal}_{Mn_{(17\times1)}}$ | $\mathbf{Xteste}_{Mn_{(34\times723)}}$, $\mathbf{yteste}_{Mn_{(34\times1)}}$ |
| Mo | $\mathbf{Xcal}_{Mo_{(17\times723)}}$, $\mathbf{Ycal}_{Mo_{(17\times1)}}$ | $\mathbf{Xteste}_{Mo_{(21\times723)}}$, $\mathbf{yteste}_{Mo_{(21\times1)}}$ |
| Cr | $\mathbf{Xcal}_{Cr_{(17\times723)}}$, $\mathbf{Ycal}_{Cr_{(17\times1)}}$ | $\mathbf{Xteste}_{Cr_{(34\times723)}}$, $\mathbf{yteste}_{Cr_{(34\times1)}}$ |
| Ni | $\mathbf{Xcal}_{Ni_{(17\times723)}}$, $\mathbf{Ycal}_{Ni_{(17\times1)}}$ | $\mathbf{Xteste}_{Ni_{(20\times723)}}$, $\mathbf{yteste}_{Ni_{(20\times1)}}$ |
| Fe | $\mathbf{X}_{calFe_{(17\times723)}}$, $\mathbf{Y}_{calFe_{(17\times1)}}$ | $\mathbf{X}_{testeFe_{(34\times723)}}$, $\mathbf{y}_{testeFe_{(34\times1)}}$ |

Fonte: Wagner Oliveira de Araujo.

## 3.3 Protocolo de Validação e Seleção de Hiperparâmetros

A seleção dos hiperparâmetros dos algoritmos RLM-*bagging* e RLM-*subagging* — respectivamente, o número de replicações bootstrap $m$ e a fração de subamostragem $k$ — foi conduzida mediante validação cruzada *5-fold* aplicada exclusivamente ao conjunto de calibração, garantindo que o conjunto de teste permanecesse estritamente independente durante todo o processo de otimização.

O procedimento adotado seguiu as etapas descritas a seguir. Primeiramente, o conjunto de calibração foi particionado em cinco subconjuntos (*folds*) de tamanho aproximadamente igual, após embaralhamento aleatório com semente fixa (`seed` = 42) para assegurar a reprodutibilidade dos resultados. Quando o número de amostras de calibração não é divisível por cinco, o último *fold* absorve as amostras remanescentes, podendo conter uma ou duas amostras adicionais em relação aos demais *folds*.

Em seguida, para cada combinação de hiperparâmetros avaliada, realizou-se uma busca em grade (*grid search*) sobre os conjuntos de valores $m \in \{10, 20, 30, 40, 50\}$ e $k \in \{0{,}50;\ 0{,}60;\ 0{,}70;\ 0{,}80\}$.

A cada iteração, o modelo foi treinado nos quatro *folds* restantes e avaliado no *fold* de validação corrente, repetindo-se o procedimento cinco vezes de modo que cada *fold* atuasse

exatamente uma vez como conjunto de validação. O desempenho de cada configuração foi quantificado pelo RMSEP médio entre os cinco *folds* ($\text{RMSEP}_{\text{CV}}$), dado pela Equação 25:

$$\text{RMSEP}_{\text{CV}} = \frac{1}{K}\sum_{k=1}^{K}\sqrt{\frac{1}{n_k}\sum_{i=1}^{n_k}\left(\hat{y}_i^{(k)} - y_i^{(k)}\right)^2} \tag{25}$$

onde $K = 5$ é o número de *folds*, $n_k$ é o número de amostras no *fold* $k$, $y_i^{(k)}$ é o valor de referência e $\hat{y}_i^{(k)}$ é o valor predito para a $i$-ésima amostra do *fold* $k$.

Os hiperparâmetros ótimos $m^*$ e $k^*$ foram definidos como a combinação que minimizou o $\text{RMSEP}_{\text{CV}}$. Após a seleção, os modelos finais foram retreinados utilizando a totalidade do conjunto de calibração com os parâmetros ótimos identificados. A avaliação final de desempenho foi realizada uma única vez sobre o conjunto de teste independente, reportando-se as métricas RMSEP, MAE e $R^2$, definidas nas Equações 26, 27 e 28, respectivamente.

## 3.4 Medida do Erro Médio Quadrático de Predição

Para avaliar e comparar a acurácia preditiva dos modelos de regressão linear múltipla (RLM) clássica, RLM com *bagging* (RLM-*bagging*) e RLM com *subagging* (RLM-*subagging*), utilizou-se um conjunto de três métricas complementares: o *Root-Mean-Square Error of Prediction* (RMSEP)[2], o *Mean Absolute Error* (MAE)[3] e o coeficiente de determinação $\text{R}^2$. A adoção conjunta dessas métricas proporciona uma caracterização mais abrangente do desempenho preditivo, uma vez que cada uma captura aspectos distintos dos erros de predição (52, 31).

O RMSEP fornece uma medida agregada da magnitude dos erros entre os valores previstos por um modelo e os valores reais observados em um conjunto de dados independente (geralmente um conjunto de teste ou validação) (52, 31). Ao elevar os erros ao quadrado antes de calcular a média e, posteriormente, extrair a raiz quadrada, o RMSEP atribui maior peso aos erros maiores, penalizando modelos com grandes discrepâncias entre as predições e a realidade.

Essa característica o torna particularmente útil em situações onde grandes erros são mais indesejáveis, sendo adotado como critério primário de seleção do melhor modelo neste trabalho (24, 53, 17, 52).

Obtidos os coeficientes de regressão para cada uma das técnicas avaliadas, calculou-se a concentração do elemento de interesse. O RMSEP objetiva minimizar a soma quadrada da diferença entre a concentração predita e a concentração observada, como expresso na Equação (26):

$$\text{RMSEP} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(\widehat{y}_i - y_i)^2} \tag{26}$$

onde $\widehat{y}_i$ é a $i$-ésima concentração predita pelo modelo de regressão, $y_i$ é a concentração observada (real) e $n$ é o número de amostras no conjunto de validação.

[2]Erro Médio Quadrático de Predição
[3]Erro Médio Absoluto

O MAE complementa o RMSEP ao quantificar a magnitude média dos erros de predição sem elevar os resíduos ao quadrado, atribuindo peso igual a todos os desvios independentemente de sua magnitude (54). Isso o torna mais robusto à presença de valores discrepantes e permite verificar a consistência dos erros: quando o RMSEP supera consideravelmente o MAE, há indício de erros grandes e isolados nas predições; quando ambos são próximos, os erros tendem a ser homogeneamente distribuídos. O MAE é dado pela Equação (27):

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|\widehat{y}_i - y_i| \tag{27}$$

onde $\widehat{y}_i$, $y_i$ e $n$ mantêm as mesmas definições apresentadas na Equação (26). Assim como o RMSEP, o MAE é expresso na mesma unidade da variável resposta, com valores menores indicando maior acurácia preditiva.

O coeficiente de determinação $\text{R}^2$ avalia a proporção da variância total da variável resposta que é explicada pelo modelo preditivo, sendo definido pela Equação (28):

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(\widehat{y}_i - y_i)^2}{\sum_{i=1}^{n}(\bar{y} - y_i)^2} \tag{28}$$

onde $\bar{y}$ representa a média dos valores de referência no conjunto de teste. O $\text{R}^2$ assume valores no intervalo $(-\infty, 1]$: $\text{R}^2 = 1$ indica ajuste perfeito; $\text{R}^2 = 0$ equivale ao desempenho de um modelo que prediz apenas a média da variável resposta; e valores negativos indicam desempenho inferior a essa referência trivial (55).

Na calibração multivariada de aço-ligas, valores de $\text{R}^2 > 0{,}99$ são frequentemente reportados como indicativos de elevada capacidade preditiva (52, 31, 53). Contudo, o $\text{R}^2$ isoladamente pode ser enganoso em conjuntos de teste pequenos ou com distribuição não uniforme de concentrações, razão pela qual sua interpretação é sempre realizada em conjunto com o RMSEP e o MAE neste trabalho.

# 4 RESULTADOS E DISCUSSÕES

Esta seção apresenta os resultados e discute as técnicas de *bootstrap*, *bagging* e *subagging* aplicadas à regressão linear múltipla. Ela avalia o erro médio quadrático de predição (RMSEP) e compara os tempos de execução dos algoritmos RLM, RLM-*bagging* e RLM-*subagging*.

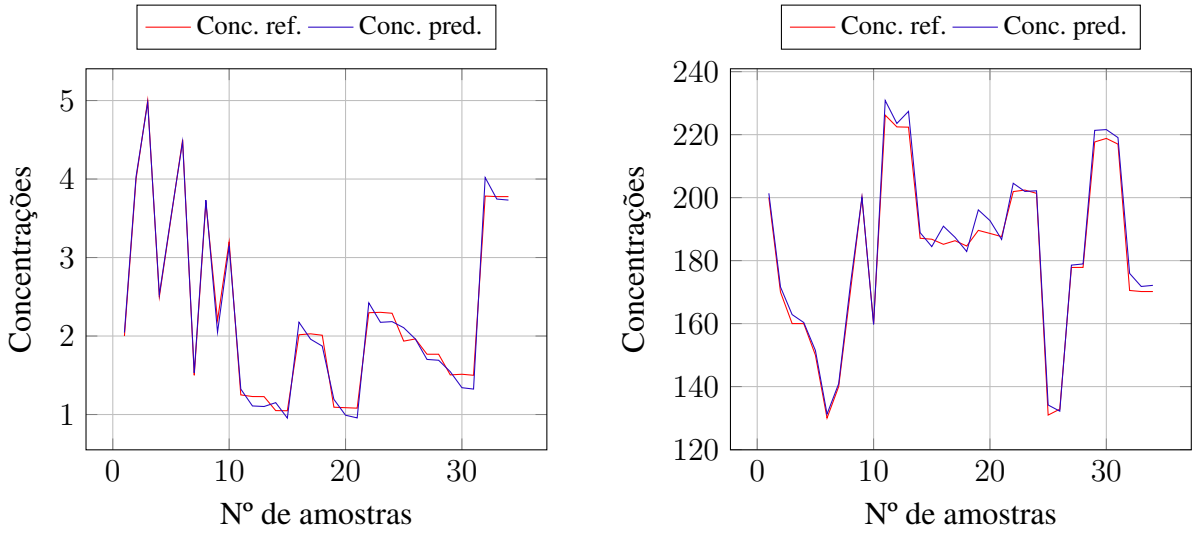
Tabela 4 – RMSEP por analito obtido via RLM para amostras de aço-ligas.

| **Elementos** | **RMSEP (RLM)** |
|---|---|
| Mn | 0,1051 |
| Mo | 0,2633 |
| Cr | 1,0798 |
| Ni | 1,6043 |
| Fe | 2,7513 |

Fonte: Wagner Oliveira de Araujo.

A Tabela 4 mostra o RMSEP obtido com a RLM para todas as amostras de aço-ligas.

Figura 7 – RMSEP com RLM para Mn e Fe.




(a) RMSEP com RLM para Mn.

(b) RMSEP com RLM para Fe.

Fonte: Wagner Oliveira de Araujo.

A Figura 7 exibe o comportamento do RMSEP para os elementos Mn e Fe. A Figura 7a detalha o RMSEP do manganês (Mn) e a Figura 7b, o do ferro (Fe). O sinal vermelho representa a concentração de referência do Mn e do Fe e o sinal azul a concentração predita obtida com a RLM. A Tabela 4 mostra que, para a RLM, o Mn apresenta o menor RMSEP (0,1051) e o Fe o maior (2,7513). Na comparação com parâmetros otimizados (Tabela 9), o RLM-*subagging* obteve RMSEP menor que o RLM-*bagging* em quatro dos cinco analitos (Mn, Mo, Cr e Ni), e a RLM clássica obteve o menor RMSEP entre as três técnicas em dois analitos (Mo e Cr). Isso indica que a técnica mais adequada depende do analito.

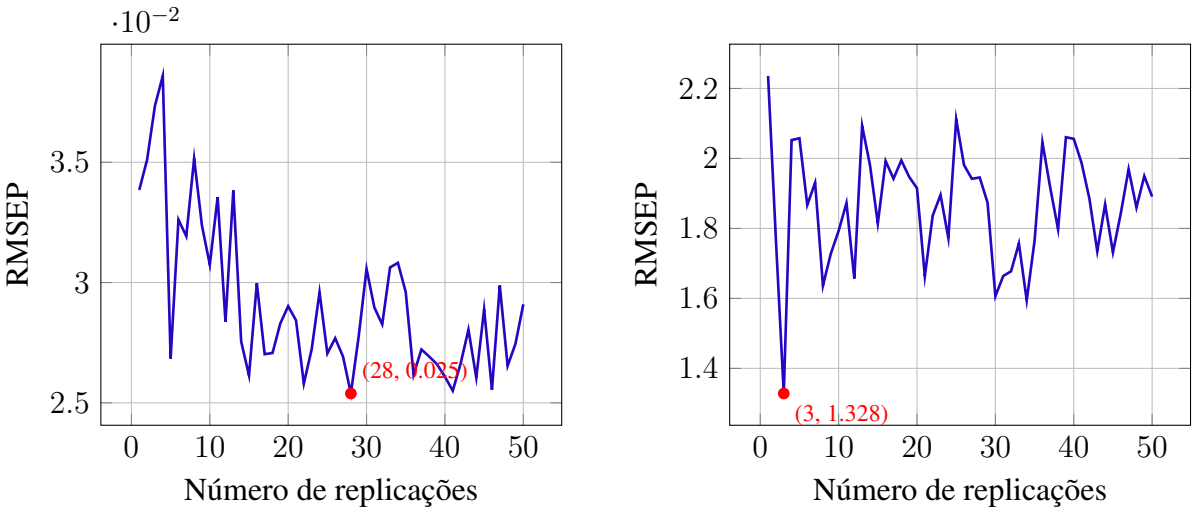
A escolha dos elementos ferro e manganês para esta análise baseia-se em fundamentos científicos bem estabelecidos na metalurgia. O ferro é o elemento matriz que define a própria natureza do material, uma vez que sem ferro não existe aço. O manganês, por sua vez, é o único elemento de liga historicamente considerado essencial para a produção de qualquer aço comercial, atuando como desoxidante e modificador fundamental das propriedades mecânicas. Os demais elementos (Cr, Mo, Ni) são importantes para propriedades específicas, mas não são fundamentais para a definição básica e produção do aço como o ferro e o manganês. Mn e Fe foram escolhidos como analitos ilustrativos nas figuras desta seção; os resultados dos cinco analitos são apresentados na Tabela 9.

## 4.1 *Bagging*

Os resultados obtidos com a técnica *bagging* foram produzidos com a implementação do Algoritmo 2. Contudo, como visto na Subseção 2.7.1 da Seção 2.7, o algoritmo RLM-*bagging* depende do parâmetro $m$ que define o número de replicações *bootstrap*.

Foi conduzido um experimento para avaliar a sensibilidade do *bagging* em função do número de replicações, variando de 1 a 50. O procedimento experimental implementou o RLM-*bagging* com um algoritmo iterativo que modifica sistematicamente o número de replicações utilizadas.

Figura 8 – RMSEP em função do número de replicações *bootstrap* para RLM-*bagging*.




(a) RMSEP em função do número de replicação para o Mn.

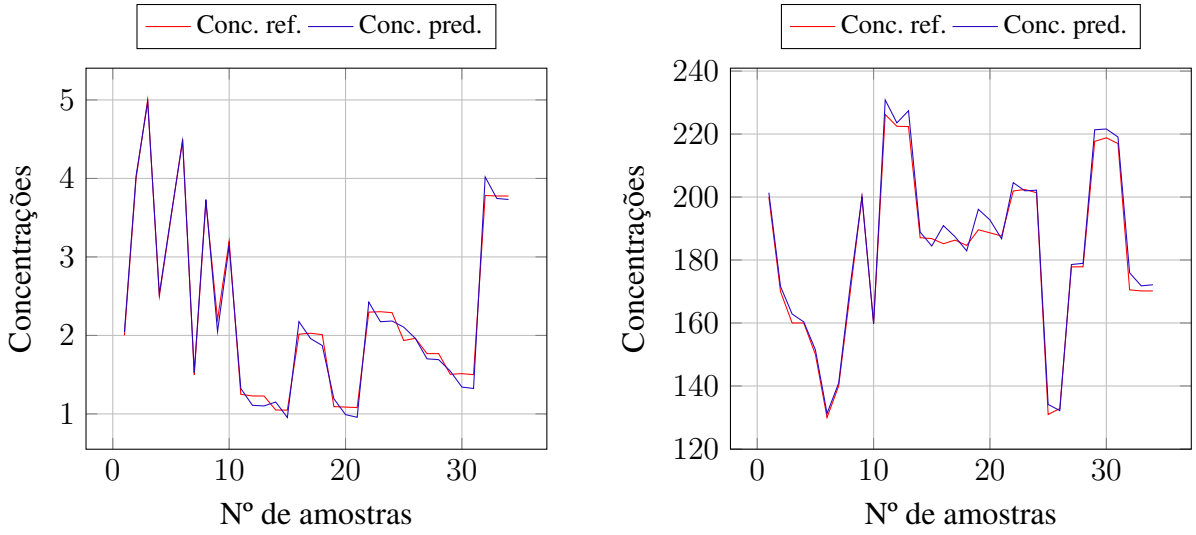
(b) RMSEP em função do número de replicação para o Fe.

Fonte: Wagner Oliveira de Araujo.

A Figura 8 mostra o RMSEP da RLM em função das replicações *bootstrap*. A Figura 8a mostra o comportamento do RLM-*bagging* para o Mn e a Figura 8b mostra o RMSEP do RLM-*bagging* para o Fe. Para o Mn, o RMSEP tende a se estabilizar entre $0{,}026$ e $0{,}030$ a partir de 15–20 replicações. Para o Fe, o RMSEP oscila entre $1{,}3$ e $2{,}2$ em todo o intervalo

de 1 a 50 replicações, sem estabilização observável. Duas hipóteses são compatíveis com esse comportamento: o Fe pode exigir mais de 50 replicações, ou sua predição pode ser mais difícil que a do Mn; o experimento não permite distingui-las. Os valores da Figura 8 foram obtidos com o conjunto de calibração completo, em análise de sensibilidade interna, e podem diferir dos valores do conjunto de teste independente reportados nas Tabelas 5 e 9.

Figura 9 – RMSEP para o Mn e Fe com RLM-*bagging*.




(a) Predição do Mn com RLM-*bagging*.

(b) Predição do Fe com RLM-*bagging*.

Fonte: Wagner Oliveira de Araujo.

A Figura 9 mostra o comportamento do RMSEP com RLM-*bagging*. A Figura 9a mostra o RMSEP com RLM-*bagging* do Mn e a Figura 9b mostra o RMSEP com RLM-*bagging* do Fe.

Observa-se desempenho variável do RLM-*bagging* em relação aos resultados da técnica RLM mostrados na Tabela 4. O RLM-*bagging* apresentou melhorias para Mn (redução de 5,4%) e Fe (redução de 3,3%), enquanto demonstrou desempenho inferior para Mo (aumento de 30,8%), Cr (aumento de 12,4%) e Ni (aumento de 4,3%). Os valores de RMSEP obtidos com o RLM-*bagging* foram (0,0994) para o Mn e (2,6597) para o Fe, como apresentado na Tabela 5.

Tabela 5 – RMSEP da RLM e RLM-*bagging* para cada elemento de aço-ligas.

| **Elementos** | **RLM** | **RLM-*bagging*** (1) |
|---|---|---|
| Mn | 0,1051 | 0,0994 |
| Mo | 0,2633 | 0,3443 |
| Cr | 1,0798 | 1,2141 |
| Ni | 1,6043 | 1,6736 |
| Fe | 2,7513 | 2,6597 |

Fonte: Wagner Oliveira de Araujo.

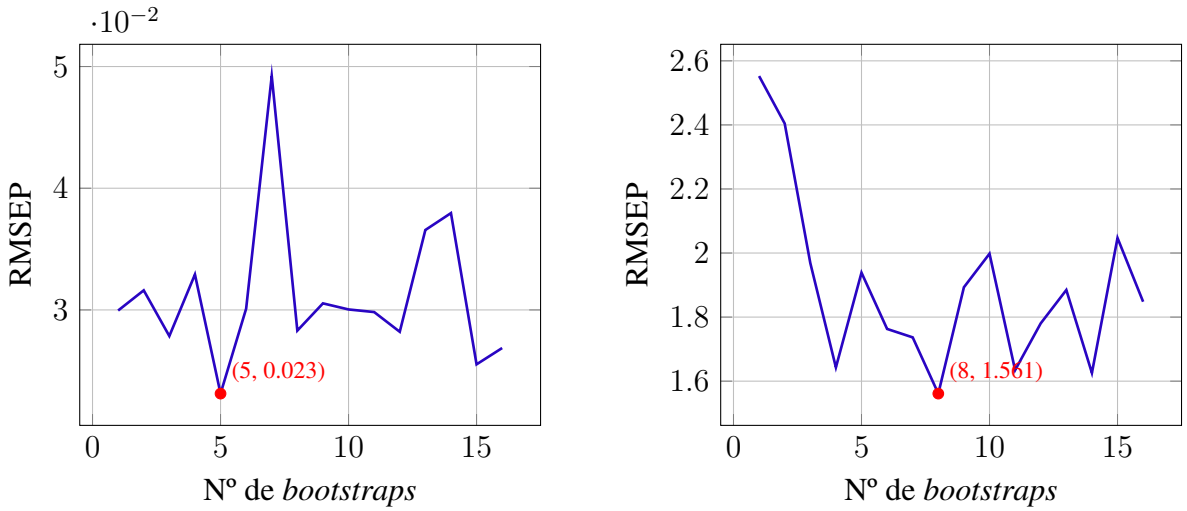
(1) Dezessete *bootstrap* utilizados. Parâmetros definidos sem otimização formal; ver Tabela 9 para resultados com validação cruzada 5-*fold*.

A Tabela 5 mostra a comparação do erro do RLM-*bagging* em relação ao erro da RLM. O RLM-*bagging* apresentou melhorias apenas para Mn (redução de 5,42%) e Fe (redução de 3,33%), enquanto para Mo, Cr e Ni o erro aumentou em 30,76%, 12,44% e 4,32%, respectivamente. Em média, o erro do RLM-*bagging* foi 7,75% maior do que o da RLM sem reamostragem. Esses resultados indicam que a aplicação do *bagging* não resultou em uma melhoria consistente no desempenho preditivo do modelo de regressão linear múltipla para este conjunto de dados.

## 4.2 *Subagging*

A seção *Subagging* apresenta os resultados obtidos por meio da aplicação da Regressão Linear Múltipla (RLM) sobre subconjuntos gerados via *bootstrap*, de forma semelhante ao *bagging*, porém sem reposição de amostras. O algoritmo *subagging* exige a definição de um parâmetro adicional, além do número de replicações. Enquanto no *bagging* o tamanho das amostras *bootstrap* permanece constante e igual ao conjunto original, no *subagging* esse tamanho é variável. Para analisar a sensibilidade do *subagging*, o estudo conduz um experimento com 16 amostras *bootstrap*, cujos resultados são apresentados na Figura 10.

Figura 10 – RMSEP em função das replicações *bootstrap* para RLM-*subagging*.




(a) Erros encontrados para cada replicação do Mn variando a quantidade de amostras *bootstrap*.

(b) Erros encontrados para cada replicação do Fe variando a quantidade de amostras *bootstrap*.

Fonte: Wagner Oliveira de Araujo.

Observa-se nas Figuras 10a e 10b que o *subagging* apresenta sensibilidade ao número de amostras *bootstrap* utilizadas no algoritmo. Para a predição do Mn, o número ideal de amostras *bootstrap* é 5, resultando em RMSEP de 0,023. Para a predição do Fe, o número ideal de amostras *bootstrap* também é 8, com RMSEP de 1,561, observando-se uma ligeira piora acima desse valor.

A Tabela 6 mostra o erro do RLM-*subagging* comparado com o erro da RLM tradicional. O RLM-*subagging* apresentou melhorias para três dos cinco analitos testados: Mn (redução de

Tabela 6 – RMSEP por elemento de aço-ligas comparando RLM e RLM-*subagging*.

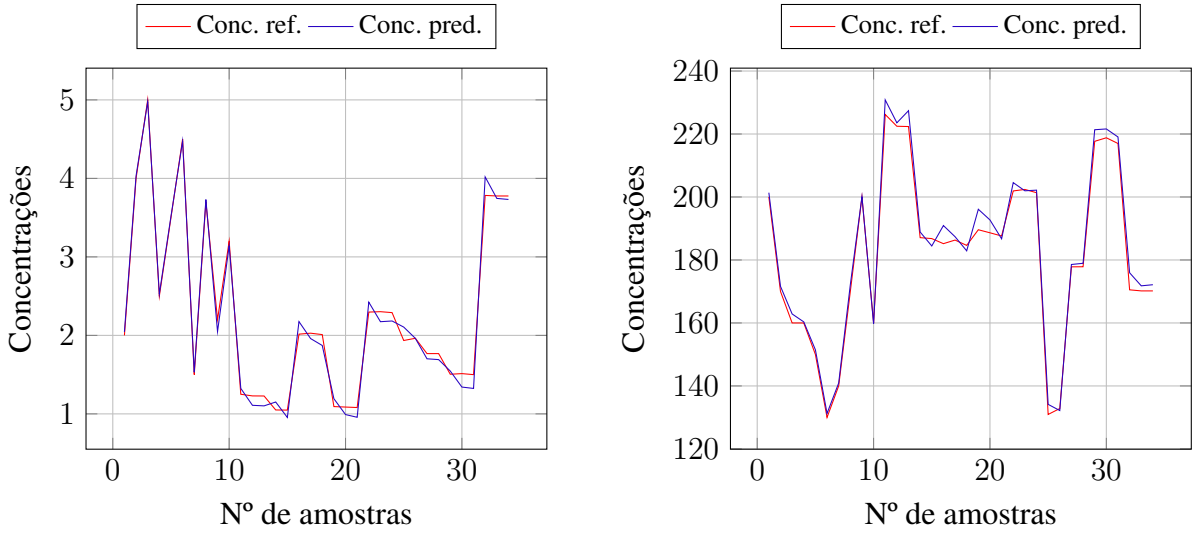
| **Elemento** | **RLM** | **RLM-*subagging*** |
|---|---|---|
| Mn | 0,1051 | 0,0974 (1) |
| Mo | 0,2633 | 0,2821 (2) |
| Cr | 1,0798 | 1,1616 (3) |
| Ni | 1,6043 | 1,6003 (4) |
| Fe | 2,7513 | 2,7302 (5) |

Fonte: Wagner Oliveira de Araujo.

(1) Cinco *bootstrap* utilizados. (2) Dezesseis *bootstrap* utilizados. (3) Doze *bootstrap* utilizados. (4) Dez *bootstrap* utilizados. (5) Oito *bootstrap* utilizados.

7,33%), Ni (redução de 0,25%) e Fe (redução de 0,77%). Para Mo e Cr, houve aumento do erro de 7,14% e 7,58%, respectivamente. Em média, considerando todos os analitos, o RLM-*subagging* apresentou desempenho praticamente equivalente ao da RLM tradicional, com variação média de apenas 1,27% no RMSEP.

Figura 11 – RMSEP do Mn e Fe com *subagging*.




(a) RMSEP do Mn com RLM-*subagging*.

(b) RMSEP do Fe com RLM-*subagging*.

Fonte: Wagner Oliveira de Araujo.

A Figura 11 mostra o comportamento do RMSEP com RLM-*subagging*. Nas Figuras 11a e 11b, é possível observar as predições dos elementos Mn e Fe.

Tabela 7 – Comparação do RMSEP por elemento para diferentes técnicas e proporções de calibração.

| | **RLM** | | **RLM-*bagging*** | | **RLM-*subagging*** | |
|---|---|---|---|---|---|---|
| **Elemento** | **50%** | **80%** | **50%** | **80%** | **50%** | **80%** |
| Mn | 0,2029 | 0,1119 | 0,1742 | 0,1142 | 0,2205 | 0,1108 |
| Mo | 1,5651 | 0,2546 | 0,7338 | 0,3337 | 0,5944 | 0,2809 |
| Cr | 0,7215 | 1,0978 | 1,4512 | 1,1661 | 1,8984 | 1,1807 |
| Ni | 28,4381 | 1,5865 | 28,1847 | 1,3281 | 28,0398 | 1,3724 |
| Fe | 3,2962 | 2,5795 | 5,9944 | 2,5367 | 7,2990 | 2,4871 |

Fonte: Wagner Oliveira de Araujo.

Em geral, a utilização da proporção de calibração de 80% resultou em menor RMSEP em 14 das 15 combinações analito $\times$ técnica. Para RLM-*bagging* e RLM-*subagging*, a proporção de 80% foi superior em todos os cinco elementos. Para a RLM clássica, a proporção de 80% foi melhor em quatro dos cinco elementos (Mn, Mo, Ni e Fe), sendo a única exceção o Cr, onde 50% de calibração produziu menor RMSEP ($0{,}7215$ contra $1{,}0978$). Um conjunto de dados de treinamento maior, como esperado teoricamente, é compatível com a expectativa teórica de que conjuntos de calibração maiores favoreçam a generalização do modelo.

Quanto ao melhor desempenho absoluto por elemento, o RLM-*subagging* com 80% de calibração obteve o menor RMSEP para Mn ($0{,}1108$) e Fe ($2{,}4871$), a RLM com 80% obteve o menor erro para Mo ($0{,}2546$), o RLM-*bagging* com 80% para Ni ($1{,}3281$), e a RLM com 50% para Cr ($0{,}7215$).

A técnica que atingiu o menor RMSEP (Tabela 8) varia em função do elemento, destacando que não há uma solução única para todos os casos:

Tabela 8 – Configuração de desempenho superior e RMSEP mínimo.

| **Elemento** | **Técnica de Desempenho Superior** | **Menor RMSEP** | **Proporção** (%) |
|---|---|---|---|
| Mn | RLM | 0,1108 | 80 |
| Mo | RLM | 0,2546 | 80 |
| Cr | RLM | **0,7215** | 50 |
| Ni | RLM | 1,3281 | 80 |
| Fe | RLM-*subagging* | **2,4871** | 80 |

Fonte: Wagner Oliveira de Araujo.

Nota: Resultados baseados na Tabela 7 (parâmetros sem otimização formal por validação cruzada). Para comparação com parâmetros otimizados, ver Tabela 9.

**a) RLM (Clássico):** Obteve a melhor performance para Mo ($0{,}2546$ com 80% de calibração) e Cr ($0{,}7215$ com 50% de calibração). Para estes elementos, a relação preditiva é relativamente simples e linear, não requerendo a complexidade adicional dos métodos de *ensemble*.

**b) RLM-*bagging*:** Demonstrou superioridade para Ni, atingindo $1{,}3281$ com 80% de calibração, superando a RLM ($1{,}5865$) e o RLM-*subagging* ($1{,}3724$).

**c) RLM-*subagging*:** Obteve o melhor desempenho para Mn ($0{,}1108$ com 80% de calibração) e Fe ($2{,}4871$ com 80% de calibração). Estes resultados indicam que estes elementos se beneficiam da agregação de modelos com subamostragem para reduzir a variância das predições.

As técnicas de ensemble (RLM-*bagging* e RLM-*subagging*) são construídas através da agregação de $m$ modelos individuais, gerados por *bootstrap*. O RMSEP final é determinado pela média das previsões desses $m$ modelos. O desafio na aplicação destas técnicas é otimizar o parâmetro $m \in \{5, 10, 20, 50\}$ para encontrar o ponto onde a redução da variância é maximizada sem desperdiçar recursos computacionais.

Os menores RMSEP reportados na Tabela 7 para as técnicas de *ensemble* são resultados diretos da otimização de $m$ dentro do conjunto testado:

**a)** Para Mn e Fe, onde o RLM-*subagging* foi o vencedor absoluto, os valores ótimos de $m$ foram $m = 5$ e $m = 8$, respectivamente. Estes valores relativamente baixos sugerem que poucos modelos agregados já foram suficientes para estabilizar e reduzir o erro preditivo, superando a performance do RLM clássico. Para Ni, o RLM-*bagging* com $m = 17$ obteve o menor RMSEP ($1{,}3281$).

**b)** Para Mo e Cr, nenhuma técnica de *ensemble* superou a RLM clássica, independentemente do valor de $m$ utilizado. Isso indica que, para estes elementos, a agregação de modelos introduz mais variância do que reduz, e a relação preditiva linear simples é mais adequada.

Em síntese, a análise demonstra que a escolha ideal do modelo não é apenas uma questão da técnica, mas também da proporção de calibração e, criticamente, da otimização do número de replicações ($m$) nas abordagens de *ensemble* para cada elemento químico.

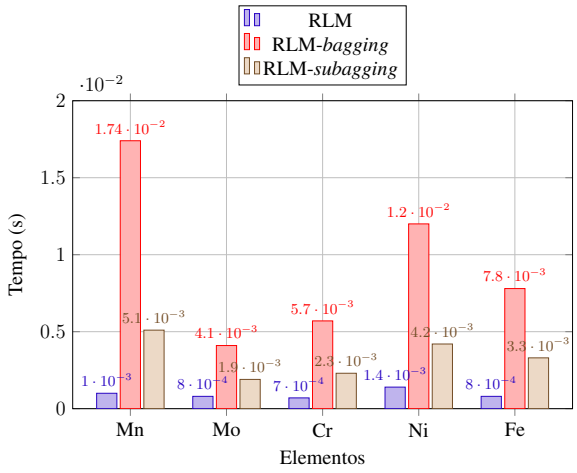
A Figura 12 apresenta os tempos de execução dos três algoritmos avaliados — RLM clássica, RLM-*bagging* e RLM-*subagging* — para cada elemento químico (Mn, Mo, Cr, Ni e Fe), com 50% e 80% das amostras disponíveis.

A comparação entre os dois cenários mostra o crescimento do tempo de execução com o aumento do conjunto de treinamento. Para a RLM clássica, o aumento médio foi de aproximadamente 2,0 vezes, variando de 1,1 $\times$ (Ni) a 3,1 $\times$ (Fe). O RLM-*bagging* apresentou aumento médio de cerca de 2,2 vezes, variando de 1,1 $\times$ (Cr) a 4,5 $\times$ (Ni).

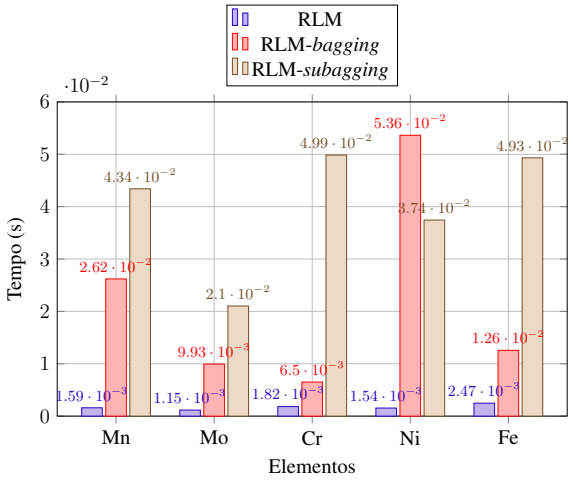
O maior aumento foi observado no RLM-*subagging*, com média de aproximadamente 13,0 vezes ao passar de 50% para 80% das amostras, variando de 8,5 $\times$ (Mn) a 21,7 $\times$ (Cr). Esse aumento é compatível com a sensibilidade do algoritmo de subamostragem ao tamanho do conjunto de treinamento e com a possível seleção de valores maiores de $m^*$ e $k^*$ nos conjuntos maiores; os valores selecionados em cada cenário não são reportados nesta seção.

Figura 12 – Tempo de execução dos algoritmos RLM, RLM-*bagging* e RLM-*subagging*.

(a) 50% das amostras




(b) 80% das amostras




Fonte: Wagner Oliveira de Araujo.

Em termos absolutos, com 80% das amostras, o RLM-*bagging* foi mais rápido que o RLM-*subagging* em quatro dos cinco elementos (Mn, Mo, Cr e Fe); a soma dos tempos do RLM-*subagging* (0,201 s) é 1,85 vez a do RLM-*bagging* (0,109 s). Com 50% das amostras, o RLM-*subagging* foi mais rápido nos cinco elementos. Esse resultado indica que, neste conjunto de dados, a vantagem temporal do RLM-*subagging* não se manteve com o aumento do tamanho amostral, o que deve ser considerado na escolha da técnica em aplicações com conjuntos de dados maiores.

## 4.3 *Bagging* × *Subagging*

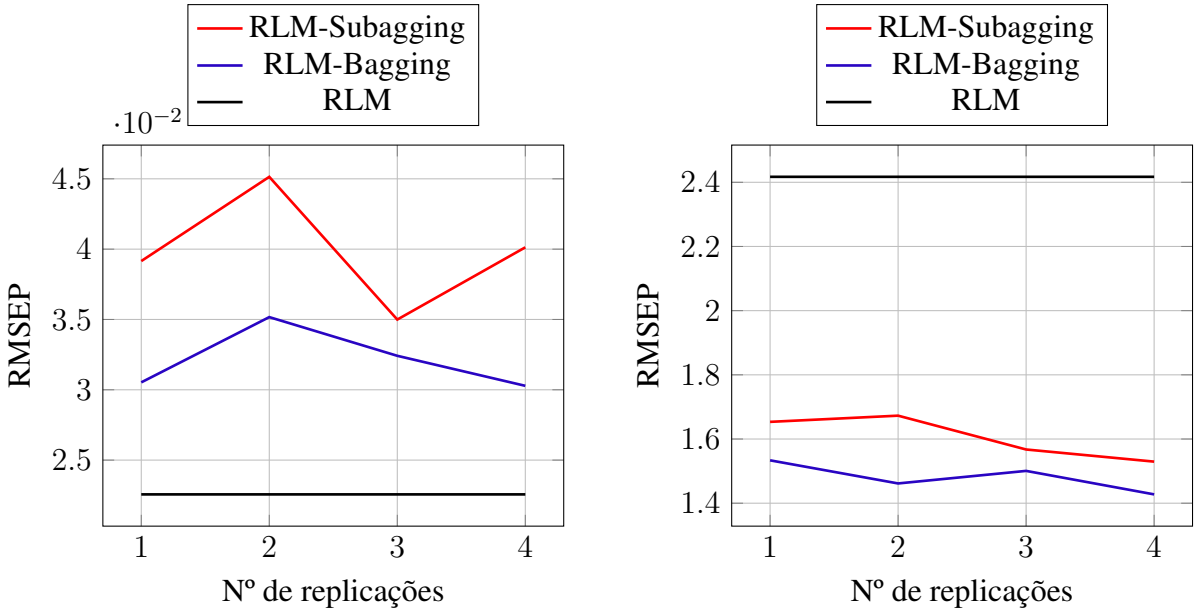
Os valores de RMSEP apresentados na (Tabela 9) diferem dos reportados na (Tabela 5) porque esta última apresenta resultados com número fixo de *bootstraps* sem otimização, enquanto a (Tabela 9) adota parâmetros otimizados por validação cruzada 5-*fold* e incorpora as três técnicas comparativamente com métricas ampliadas.

Com a implementação do *bagging* e do *subagging*, observou-se melhora das predições obtidas com a RLM para alguns analitos específicos. O RLM-*bagging* apresentou melhor desempenho para Fe, enquanto o RLM-*subagging* foi superior para Mn e Ni. Para Cr e Mo, a RLM clássica manteve o menor RMSEP; entre as técnicas *ensemble*, o RLM-*subagging* superou o RLM-*bagging* no Cr, mas nenhum dos dois superou a RLM clássica nesse elemento, indicando que as técnicas *ensemble* nem sempre garantem melhoria. Dessa forma, é importante comparar o desempenho do RLM-*bagging* e RLM-*subagging* considerando as características específicas de cada analito.

A variação do RMSEP em relação à RLM difere entre os analitos: de $-5{,}4\%$ (Mn) a $+30{,}8\%$ (Mo) para o RLM-*bagging* (Tabela 5) e de $-7{,}3\%$ (Mn) a $+7{,}6\%$ (Cr) para o RLM-*subagging* (Tabela 6). Para avaliar comparativamente o desempenho dessas técnicas, foi feita

uma predição com o RLM-*bagging* e RLM-*subagging*, utilizando o mesmo conjunto de amostras *bootstrap*, no intuito de comparar os erros de predição das duas técnicas apresentadas na Figura 13.

Figura 13 – RMSEP para todas as técnicas.




(a) RMSEP obtido com as três técnicas aplicadas ao Mn.

(b) RMSEP obtido com as três técnicas aplicadas ao Fe.

Fonte: Wagner Oliveira de Araujo.

A RLM clássica gera uma única predição, enquanto tanto o RLM-*bagging* quanto o RLM-*subagging* utilizam múltiplas reamostragens para produzir predições agregadas. Na análise comparativa, o RLM-*subagging* foi avaliado com diferentes quantidades de amostras *bootstrap*, gerando um conjunto de 16 predições, sendo uma para cada quantidade de *bootstrap* testada. A Tabela 9 apresenta os resultados dessa comparação direta entre as técnicas, utilizando o mesmo conjunto de dados de validação.

Observa-se que a RLM clássica mantém desempenho superior para Mo e Cr, enquanto o RLM-*subagging* apresenta melhor resultado para Mn e Ni, e o RLM-*bagging* para Fe. Entre as técnicas *ensemble*, o RLM-*subagging* apresenta melhor resultado apenas para Cr em relação ao RLM-*bagging*, sem contudo superar a RLM clássica nesse elemento. Os resultados desta comparação são também apresentados nas Figuras 13a e 13b.

Os resultados comparativos entre as três técnicas avaliadas para todos os analitos são apresentados na Tabela 9. Diferentemente da análise anterior, os parâmetros $m^*$ e $k^*$ de cada método foram determinados por validação cruzada 5-*fold* aplicada exclusivamente ao conjunto de calibração, garantindo que o conjunto de teste não influenciasse a seleção dos hiperparâmetros e assegurando a comparabilidade entre os métodos.

Os resultados revelam que não existe uma técnica universalmente superior para todos os analitos. Para o Manganês (Mn), o RLM-*subagging* ($k^* = 80\%$, $m^* = 10$) apresentou o menor

Tabela 9 – Desempenho comparativo das técnicas de calibração multivariada para elementos químicos em aço-liga.

| Elemento | Técnica | RMSEP | MAE | $R^2$ | Tempo (ms) | Parâmetros | |
|---|---|---|---|---|---|---|---|
| | | | | | | (2) $k^*$ (%) | (3) $m^*$ |
| Mn | RLM | 0,1051 | 0,0887 | 0,9907 | 2,4000 | — | — |
| | RLM-*bagging* | 0,1072 | 0,0908 | 0,9903 | 68,2000 | — | 30 |
| | RLM-*subagging* (1) | **0,0966** | **0,0805** | **0,9922** | 17,1000 | 80 | 10 |
| Mo | RLM (1) | **0,2633** | **0,1952** | **0,9882** | 2,4000 | — | — |
| | RLM-*bagging* | 0,3388 | 0,2722 | 0,9805 | 67,5000 | — | 30 |
| | RLM-*subagging* | 0,2879 | 0,2201 | 0,9859 | 46,8000 | 80 | 30 |
| Cr | RLM (1) | **1,0798** | **0,8654** | **0,9938** | 2,5000 | — | — |
| | RLM-*bagging* | 1,2089 | 0,9830 | 0,9922 | 44,5000 | — | 20 |
| | RLM-*subagging* | 1,1294 | 0,9010 | 0,9932 | 46,8000 | 80 | 30 |
| Ni | RLM | 1,6043 | 1,3256 | 0,9837 | 2,3000 | — | — |
| | RLM-*subagging* (1) | **1,6003** | **1,2409** | **0,9838** | 10,6000 | 60 | 10 |
| | RLM-*bagging* | 1,7085 | 1,4122 | 0,9815 | 66,6000 | — | 30 |
| Fe | RLM | 2,7513 | 2,1865 | 0,9892 | 13,5000 | — | — |
| | RLM-*bagging* (1) | **2,6406** | **2,0246** | **0,9900** | 97,2000 | — | 30 |
| | RLM-*subagging* | 2,6509 | 2,0578 | 0,9900 | 41,2000 | 80 | 30 |

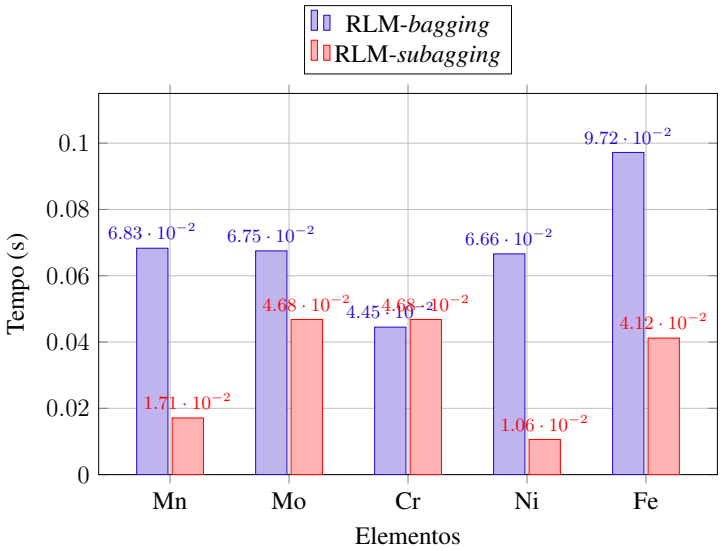
Fonte: Wagner Oliveira de Araujo.
Nota: Sinal convencional utilizado:
— Não se aplica dado numérico.
(1) Melhor desempenho em RMSEP. Conjunto de teste único para avaliação final.
(2) Fração de subamostra $k^*$ em porcentagem otimizados por validação cruzada 5-*fold* aplicada exclusivamente ao conjunto de calibração (*seed* = 42) *bootstrap*).
(3) Parâmetros $m^*$ número de replicações *bootstrap*.

RMSEP (0,0966), representando uma redução de 8,1% em relação à RLM clássica, além de ser 4,0 vezes mais rápido que o RLM-*bagging*. Para o Ferro (Fe), o RLM-*bagging* ($m^* = 30$) obteve o melhor desempenho (RMSEP = 2,6406), com melhoria de 4,0% sobre a RLM clássica. Para o Níquel (Ni), o RLM-*subagging* ($k^* = 60\%$, $m^* = 10$) apresentou resultado marginalmente superior (RMSEP = 1,6003), com diferença de 0,25% em relação à RLM clássica e tempo de execução 6,3 vezes menor que o RLM-*bagging*.

Em contrapartida, para o Molibdênio (Mo) e o Cromo (Cr), a RLM clássica demonstrou desempenho superior (RMSEP de 0,2633 e 1,0798, respectivamente), indicando que a complexidade adicional introduzida pelas estratégias de *ensemble* não resultou em menor RMSEP para esses analitos. Esses resultados são compatíveis com uma relação preditiva aproximadamente linear para Mo e Cr, hipótese não testada diretamente neste trabalho, em que a agregação de modelos não trouxe ganho de RMSEP.

A análise do custo computacional evidencia que o RLM-*subagging* configura-se como alternativa balanceada entre precisão e eficiência, sendo consistentemente mais rápido que o RLM-*bagging* para todos os elementos avaliados. Observa-se ainda que o parâmetro $k^* = 80\%$ revelou-se ótimo para o *subagging* em quatro dos cinco elementos, sugerindo que subamostras maiores favorecem a estabilidade do modelo neste contexto específico de dados espectrométricos de aço-ligas.

Figura 14 – Tempo de execução dos algoritmos RLM-*bagging* e RLM-*subagging* com parâmetros otimizados por validação cruzada 5-*fold*.




Fonte: Wagner Oliveira de Araujo.

A Figura 14 apresenta os tempos de execução dos algoritmos RLM-*bagging* e RLM-*subagging* para cada elemento, utilizando os parâmetros $m^*$ e $k^*$ determinados por validação cruzada 5-*fold*. Diferentemente da análise anterior, os parâmetros agora variam por elemento — refletindo configurações otimizadas por validação cruzada —, o que torna a comparação de tempos diretamente atrelada ao custo real de cada configuração de melhor desempenho preditivo.

Em quatro dos cinco elementos avaliados (Mn, Mo, Ni e Fe), o RLM-*subagging* foi mais rápido que o RLM-*bagging*. A razão média entre os tempos (*bagging*/*subagging*) foi 3,0, variando de 0,95 (Cr) a 6,3 (Ni); a soma dos tempos dos cinco elementos é 52,8% menor no *subagging* (162,5 ms contra 344,0 ms). As maiores diferenças ocorreram para o Ni (6,3 vezes mais rápido, com $k^* = 60\%$ e $m^* = 10$) e para o Mn (4,0 vezes mais rápido, com $k^* = 80\%$ e $m^* = 10$). Para Mo e Fe, as razões foram de 1,4 e 2,4, respectivamente. A menor duração do *subagging* é compatível com o uso de subconjuntos menores ($k^* \leq 80\%$ das amostras), que reduzem a dimensão de cada problema de mínimos quadrados; este trabalho não isolou esse efeito experimentalmente.

O Cromo (Cr) é o único elemento em que o RLM-*subagging* foi mais lento que o RLM-*bagging* (46,8 ms contra 44,5 ms; diferença de 2,3 ms, ou 5,2%). Esse resultado é consistente com os parâmetros selecionados por validação cruzada (menor *Root-Mean-Square Error of Prediction in Cross-Validation* (RMSEP-CV)): $m^* = 20$ para o *bagging* e $m^* = 30$ com $k^* = 80\%$ para o *subagging*.

Para o Fe, o RLM-*bagging* obteve o menor RMSEP (2,6406). Uma hipótese para esse resultado é que o Fe, por ser o elemento matriz, apresente espectro de alta densidade e possível autoabsorção, o que tornaria o modelo base mais instável e favoreceria a agregação; este trabalho não testou essa hipótese (56). Para o Cr, apesar da sobreposição espectral com linhas do Fe

e do Ni, nenhuma técnica de *ensemble* superou a RLM clássica (RMSEP = $1{,}0798$). Uma interpretação possível é que, com 17 amostras de calibração, a redução de variância do *ensemble* não compensou o viés introduzido pela reamostragem; essa interpretação também carece de verificação direta (por exemplo, decomposição viés–variância). Para o Mo, a RLM clássica obteve o menor RMSEP ($0{,}2633$); para o Mn, o RLM-*subagging* obteve o menor RMSEP ($0{,}0966$), 8,1% abaixo da RLM.

Em relação à RLM clássica, o custo computacional dos *ensembles* é maior: o RLM-*bagging* foi, em média, 22,1 vezes mais lento e o RLM-*subagging* até 19,5 vezes mais lento (Mo). Comparado ao RLM-*bagging*, o RLM-*subagging* obteve menor RMSEP em quatro elementos (Mn, Mo, Cr e Ni) e menor tempo em quatro (Mn, Mo, Ni e Fe), superando-o simultaneamente nos dois critérios em Mn, Mo e Ni.

# 5 REQUISITOS FUNCIONAIS

Esta seção apresenta o levantamento estruturado dos requisitos funcionais da aplicação *Regressão Espectral com Métodos de Ensemble (Bagging & Subagging)*, desenvolvida na plataforma Streamlit. A análise segue a estrutura proposta em quatro seções: Inventário de funcionalidades, Classificação por prioridade, Fluxos de uso e Requisitos não funcionais.

## 5.1 Levantamento de Requisitos Funcionais

### 5.1.1 Inventário das Funcionalidades Existentes

#### 5.1.1.1 Funções do Sistema

A Quadro 3 resume as funcionalidades identificadas na aplicação, categorizadas por tipo de operação.

Quadro 3 – Inventário das funções do sistema.

| **Categoria** | **Funcionalidade** | **Descrição Técnica** |
|---|---|---|
| Cálculos | RLM Simples (Baseline) | Regressão Linear Múltipla padrão sem técnicas de ensemble |
| Cálculos | RLM + Bagging | Ensemble com amostragem *com* reposição (bootstrap) |
| Cálculos | RLM + Subagging + CV | Ensemble com amostragem *sem* reposição + otimização por validação cruzada 5-Fold |
| Configuração | Parâmetro $m$ (Bags) | Define número de amostras/ensembles para o método Bagging |
| Configuração | Parâmetro $k$ (Subagging) | Define fração ou quantidade para amostragem no Subagging |
| Visualização | Métricas de Desempenho | Exibição de $R^2$, RMSE, MAE calculados no conjunto de teste |
| Visualização | Gráficos Comparativos | *Scatter plots* (previsto $\times$ real), resíduos e comparação entre modelos |
| Organização | Abas de Navegação | Separação lógica: “Arquivos”, “Configuração”, “Resultados”, “Gráficos” |
| Exportação | *Não identificada* | **Obs.:** sistema não apresenta botões de download de resultados |

Fonte: Wagner Oliveira de Araujo.

#### 5.1.1.2 Entradas Necessárias (Inputs)

A Quadro 4 detalha os dados e parâmetros exigidos para execução da aplicação.

Quadro 4 – Entradas necessárias para execução do sistema.

| **Tipo** | **Nome** | **Formato** | **Obrig.** | **Descrição** |
|---|---|---|---|---|
| Arquivo | `Xcal.txt` | `.txt` | Sim | Matriz de espectros de calibração |
| Arquivo | `Ycal.txt` | `.txt` | Sim | Vetor de valores de referência |
| Arquivo | `Xteste.txt` | `.txt` | Sim | Matriz de espectros para predição |
| Arquivo | `Yteste.txt` | `.txt` | Sim | Vetor de valores reais para validação |
| Parâmetro | $m$ | Inteiro $\geq 1$ | Condic.[a] | Usado apenas nos métodos de ensemble |
| Parâmetro | $k$ | Inteiro $\geq 1$ | Condic.[a] | Usado apenas no método Subagging |
| Config. | Val. Cruzada | Fixo: 5-Fold | Auto. | Parâmetro interno de otimização |

[a] Condicional: habilitados apenas quando o usuário seleciona métodos de ensemble.
Fonte: Wagner Oliveira de Araujo.

#### 5.1.1.3 Saídas Esperadas (Outputs)

A Quadro 5 apresenta os resultados gerados pelo sistema após processamento.

Quadro 5 – Saídas esperadas do sistema.

| **Tipo** | **Conteúdo** | **Formato de Exibição** | **Destinatário** |
|---|---|---|---|
| Numérico | $R^2$, RMSE, MAE (conjunto de teste) | Quadro ou *cards* destacados | Usuário analista |
| Gráfico | Previsto vs. Real | *Scatter plot* com reta de ajuste | Usuário analista |
| Gráfico | Resíduos da Predição | Gráfico de dispersão ou histograma | Usuário analista |
| Comparativo | Desempenho: RLM $\times$ Bagging $\times$ Subagging | Quadro comparativa ou gráfico de barras | Usuário analista |
| Feedback | Mensagens de erro/validação | Alertas em destaque | Usuário final |
| Status | Indicador de processamento | *Spinner* ou barra de progresso | Usuário final |

Fonte: Wagner Oliveira de Araujo.

### 5.1.2 Classificação por Prioridade

Os requisitos foram classificados utilizando a técnica *Must, Should, Could, Won't have* (MoSCoW)[1] adaptada, conforme descrito nas seções seguintes.

#### 5.1.2.1 Essenciais (*Must Have*)

[1] MoSCoW é uma técnica de priorização de requisitos dividida em quatro categorias: *Must have* (obrigatórios), *Should have* (importantes, mas não críticos), *Could have* (desejáveis) e *Won't have (this time)* (excluídos desta versão). A letra "o" é adicionada apenas para facilitar a pronúncia.

Quadro 6 – Requisitos essenciais do sistema.

| ID | Requisito | Justificativa |
|---|---|---|
| E01 | Upload e validação dos 4 arquivos de entrada | Dados são pré-requisito para qualquer cálculo estatístico |
| E02 | Execução da RLM Simples (baseline) | Referência obrigatória para comparação de desempenho dos ensembles |
| E03 | Cálculo de métricas básicas ($R^2$, RMSE, MAE) | Mínimo necessário para avaliação quantitativa da qualidade do modelo |
| E04 | Validação de consistência dimensional (X vs Y) | Previne erros de execução e geração de resultados inválidos |
| E05 | Exibição clara dos resultados numéricos | Permite decisão técnica fundamentada em evidências quantitativas |

Fonte: Wagner Oliveira de Araujo.

#### 5.1.2.2 Desejáveis (*Should Have*)

Quadro 7 – Requisitos desejáveis do sistema.

| ID | Requisito | Benefício |
|---|---|---|
| D01 | Gráficos interativos (zoom, *tooltip*, download) | Facilita exploração visual detalhada e apresentação de resultados |
| D02 | Exportação de resultados (CSV, PDF, PNG) | Permite documentação, compartilhamento e reprodutibilidade |
| D03 | *Tooltips* explicativos para $m$, $k$, Bagging/Subagging | Reduz curva de aprendizado para usuários não especialistas |
| D04 | Pré-processamento básico (normalização, escalonamento) | Melhora robustez dos modelos com dados espectrais reais |
| D05 | Histórico de execuções na sessão | Permite comparar configurações sem reenviar arquivos |

Fonte: Wagner Oliveira de Araujo.

#### 5.1.2.3 Extras (*Could Have*)

Quadro 8 – Requisitos extras para fases futuras.

| ID | Requisito | Cenário de Uso |
|---|---|---|
| X01 | Autenticação de usuários e projetos privados | Ambientes corporativos ou de pesquisa colaborativa |
| X02 | Integração com APIs externas (ex: KNIME, scripts Python) | Pipelines automatizadas de quimiometria |
| X03 | Suporte a formatos adicionais (.csv, .xlsx, .mat) | Flexibilidade para ingestão de dados de diferentes fontes |
| X04 | Otimização automática de hiperparâmetros | Reduz necessidade de conhecimento técnico avançado |
| X05 | Dashboard comparativo multi-rodada | Análise estatística de estabilidade dos modelos ensemble |

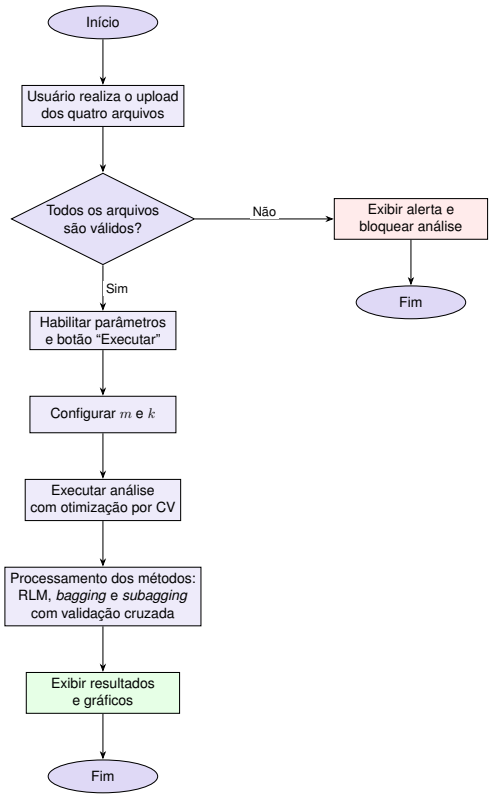
Fonte: Wagner Oliveira de Araujo.

### 5.1.3 Fluxos de Uso

#### 5.1.3.1 Fluxo Principal: Execução de Análise Completa

A Figura 15 apresenta o fluxograma do fluxo principal de interação do usuário com o sistema, ilustrando as etapas percorridas desde o acesso à aplicação Streamlit até a obtenção dos resultados finais. O fluxo tem início com o *upload* dos quatro arquivos de entrada — as matrizes `Xcal` e `Xteste` e os vetores `Ycal` e `Yteste` —, seguido pela configuração dos hiperparâmetros $m$ (número de *bags*) e $k$ (fração de subamostragem) na aba **Configuração**. Uma vez validados os arquivos e os parâmetros informados, o usuário aciona o botão de execução, que dispara o processamento em `models.py`: primeiro a otimização por validação cruzada 5-*fold* (`find_optimal_parameters()`) e, em seguida, a avaliação final dos três modelos — RLM Simples, RLM + Bagging e RLM + Subagging — sobre o conjunto de teste independente (`run_full_analysis()`). Ao término do processamento, os resultados numéricos (RMSE, MAE, R² e tempo de execução) tornam-se disponíveis na aba **Resultados**, enquanto os gráficos comparativos de valores reais *versus* preditos e o gráfico de dispersão são renderizados na aba **Gráficos**, encerrando o ciclo de interação representado no fluxograma.

Figura 15 – Fluxograma do processo de execução da análise.




Fonte: Wagner Oliveira de Araujo.

#### 5.1.3.2 Fluxos Alternativos e Tratamento de Exceções

Quadro 9 – Fluxos alternativos e tratamento de exceções.

| **Cenário** | **Gatilho** | **Comportamento do Sistema** | **Ação do Usuário** |
|---|---|---|---|
| Arquivo inválido | Upload com formato/-dimensão incorreta | Alerta vermelho + destaque no campo problemático | Corrigir arquivo e reenviar |
| Parâmetros fora do intervalo | Inserir $m$ ou $k \leq 0$ ou excessivamente alto | Validação em tempo real + mensagem orientativa | Ajustar para valores válidos |
| *Timeout* de processamento | Dados muito grandes ou carga elevada | Mensagem: "Processamento demorado..." | Otimizar entrada ou repetir depois |
| Navegação sem executar | Usuário muda de aba antes de clicar | Mantém estado dos uploads (persistência) | Retornar e concluir análise |

Fonte: Wagner Oliveira de Araujo.

#### 5.1.3.3 Pontos Críticos de Usabilidade

Quadro 10 – Pontos críticos de usabilidade e estratégias de mitigação.

| **Ponto** | **Risco** | **Sugestão de Mitigação** |
|---|---|---|
| Upload múltiplo obrigatório | Esquecer um dos 4 arquivos e travar o fluxo | Checklist visual + botão habilitado apenas quando todos estiverem OK |
| Parâmetros $m$ e $k$ abstratos | Inserir valores inadequados e obter resultados ruins | *Sliders* com valores recomendados + *tooltip* prático |
| Processamento sem feedback claro | Achar que a aplicação travou | Barra de progresso com etapas descritivas |
| Gráficos sem legenda ou escala | Dificulta interpretação em telas menores | Legendas fixas, eixos nomeados, opção de ampliar |
| Resultados não exportáveis | Impede documentação externa | Botão "Baixar Relatório" com métricas + gráficos |

Fonte: Wagner Oliveira de Araujo.

### 5.1.4 Requisitos Não Funcionais

#### 5.1.4.1 Performance

Quadro 11 – Requisitos de performance do sistema.

| **Requisito** | **Especificação** | **Critério de Aceite** |
|---|---|---|
| Tempo de upload | Arquivos $\leq$ 200 MB | $<$ 30 s em conexão 10 Mbps |
| Tempo de cálculo (RLM) | Dataset típico ($n \leq 500$, $p \leq 1000$) | $<$ 10 s |
| Tempo de cálculo (Ensemble) | Bagging/Subagging com $m \leq 100$ | $<$ 2 min com CV 5-Fold |
| Renderização de gráficos | Após conclusão do cálculo | $<$ 3 s |
| Responsividade da UI | Interações (mudar aba, ajustar parâmetro) | $<$ 500 ms de feedback visual |

Fonte: Wagner Oliveira de Araujo.

#### 5.1.4.2 Usabilidade

Quadro 12 – Requisitos de usabilidade do sistema.

| **Requisito** | **Especificação** | **Critério de Aceite** |
|---|---|---|
| Acessibilidade | Compatível com WCAG 2.1 Nível AA[a] | Contraste adequado, *labels*, navegação por teclado |
| Responsividade | Funcional em desktop, tablet e mobile ($\geq$ 768 px) | Layout adaptativo sem perda de funcionalidade crítica |
| Clareza textual | Mensagens, rótulos e erros em português claro | Teste com 3 usuários: $\geq$ 90% de acerto na interpretação |
| Consistência | Padrões visuais alinhados ao Streamlit | Botões, cores e ícones seguem guia de estilo |
| Recuperação de erro | Mensagens orientam a correção | Ex: "Ycal.txt tem 99 linhas, mas Xcal.txt tem 100..." |

[a] A *Web Content Accessibility Guidelines* (WCAG) 2.1 Nível AA é um padrão internacional de acessibilidade digital que estabelece critérios de desenvolvimento para garantir que softwares e sites sejam plenamente utilizáveis por pessoas com deficiências visuais, auditivas, motoras ou cognitivas.
*Nota:* Modificado para atender ao escopo do projeto.
Fonte: Wagner Oliveira de Araujo.

#### 5.1.4.3 Segurança

Quadro 13 – Requisitos de segurança do sistema.

| **Requisito** | **Especificação** | **Justificativa** |
|---|---|---|
| Isolamento de sessão | Dados não vazam entre usuários | Aplicação pública; dados podem ser propriedade intelectual |
| Sanitização de arquivos | Validar extensão, cabeçalho e conteúdo | Prevenção contra upload malicioso |
| Limite de tamanho | Máximo 200 MB por arquivo | Evita abuso de recursos computacionais |
| Logs de auditoria (opc.) | Registrar uploads/execuções (sem dados) | Rastreabilidade para suporte técnico |
| HTTPS obrigatório | Todas as comunicações criptografadas | Proteção de integridade e confidencialidade |

Fonte: Wagner Oliveira de Araujo.

#### 5.1.4.4 Escalabilidade

Quadro 14 – Requisitos de escalabilidade do sistema.

| **Cenário** | **Capacidade Atual** | **Meta** | **Estratégia** |
|---|---|---|---|
| Usuários simultâneos | ∼10–20 (*Streamlit Cloud free*) | 100+ usuários/h | Container com *load balancer* |
| Volume de dados | ∼500 amostras × 2k variáveis | 5k+ amostras × 10k var. | Processamento em *batch* / Dask |
| Crescimento funcional | Script único | Módulos *plug-and-play* | Arquitetura de plugins |
| Internacionalização | Português | Inglês + Espanhol | Arquivos *i18n* |

Fonte: Wagner Oliveira de Araujo.

## 5.2 Considerações Finais do Levantamento

O levantamento apresentado estabelece uma base estruturada para o desenvolvimento e evolução da aplicação de regressão espectral. Destacam-se como prioridades imediatas:

**a)** Validação rigorosa das entradas (arquivos e parâmetros) para garantir integridade dos cálculos;

**b)** Implementação de mecanismos de *feedback* visual durante processamentos demorados;

**c)** Documentação clara do contrato de dados (formato, delimitador, codificação dos arquivos `.txt`);

**d)** Inclusão de funcionalidade básica de exportação de resultados para viabilizar uso acadêmico e profissional.

Recomenda-se que os requisitos classificados como *Essenciais* (Quadro 6) sejam implementados na versão mínima viável *Minimum Viable Product* (MVP)[2] , enquanto os itens *Desejáveis* e *Extras* compõem o *backlog* para iterações futuras, sujeitos a validação com usuários finais e análise de custo-benefício.

Os requisitos não funcionais definidos nas Seções 5.1.4.1 a 5.1.4.4 devem ser considerados como restrições de projeto em todas as fases de desenvolvimento, assegurando que a aplicação seja não apenas funcional, mas também performática, segura e adaptável a cenários de crescimento.

[2]O *Minimum Viable Product* (MVP), ou Produto Mínimo Viável, é a versão mais enxuta de um produto que contém apenas as funcionalidades essenciais para que ele possa ser lançado e testado no mercado.

# 6 ENGENHARIA DE SOFTWARE E MODERNIZAÇÃO

## 6.1 Engenharia de Requisitos com Sommerville

Sommerville (45) estrutura a engenharia de requisitos em quatro fases interdependentes: elicitação, análise, especificação e validação. A reestruturação do sistema em três módulos — `models.py`, `components.py` e `app.py` — evidencia como cada fase foi aplicada para preservar as regras de negócio do legado Vaadin/Java sem reaproveitar seu código-fonte.

### 6.1.1 Elicitação

As entradas críticas do domínio de regressão espectral foram identificadas diretamente no sistema Java original: as matrizes `Xcal` e `Xteste`, os vetores `Ycal` e `Yteste`, e os hiperparâmetros *m* (número de bags) e *k* (fração de subagging). O `app.py` captura esses insumos por meio de `st.file_uploader` e `st.text_input`, incluindo suporte a decimal com vírgula — particularidade do padrão brasileiro — tratada nas funções `parse_matrix()` e `parse_vector()` do `models.py`.

### 6.1.2 Análise

A análise revelou que a lógica do `RegressionService.java` podia ser decomposta em responsabilidades distintas: parse de arquivos, algoritmos de regressão, métricas de avaliação e otimização por validação cruzada. Essa decomposição originou a estrutura modular adotada, onde `models.py` concentra toda a inteligência matemática, sem qualquer dependência de interface.

### 6.1.3 Especificação

Os contratos de entrada e saída foram formalizados com *type hints* explícitos em todas as funções do `models.py`: `parse_matrix(content: bytes) -> np.ndarray`, `perform_rlm(Xcal, Ycal, Xteste: np.ndarray) -> np.ndarray`, `calc_metrics(actual, predicted) -> tuple[float, float, float]`. A função `run_full_analysis()` retorna um dicionário tipado com chaves `log`, `optimal`, `metrics` e `preds`, constituindo o contrato formal entre a camada de negócio e a camada de apresentação.

### 6.1.4 Validação

A validação cruzada 5-fold implementada em `run_cross_validation()` opera como mecanismo de validação de equivalência, permitindo comparar o desempenho do sistema Python com os resultados históricos do sistema Java. O log estruturado gerado por `run_full_analysis()` documenta cada etapa — dimensões detectadas, RMSE-CV por combinação de

hiperparâmetros, métricas finais e tempo de execução — possibilitando auditoria científica e rastreabilidade completa.

## 6.2 Especificação de Requisitos Funcionais e Não Funcionais

A fase de Especificação de Sommerville (45), descrita no item (c) da seção anterior, é formalizada nesta seção por meio da enumeração dos requisitos funcionais (RF) e não funcionais (RNF) efetivamente implementados no sistema Python/Streamlit. Os requisitos foram extraídos diretamente do código-fonte de `models.py`, `components.py` e `app.py`, e não de funcionalidades planejadas ou não concluídas, de modo a refletir com precisão o estado real do sistema entregue neste TCC II.

### 6.2.1 Requisitos Funcionais

O Quadro 15 apresenta os requisitos funcionais do sistema, isto é, as funcionalidades que o usuário pode efetivamente executar por meio da interface Streamlit.

Quadro 15 – Requisitos funcionais do sistema.

| ID | Descrição |
|---|---|
| RF01 | Permitir o *upload* das matrizes `Xcal`, `Xteste` e dos vetores `Ycal`, `Yteste` nos formatos `.txt`, `.csv` e `.xlsx`. |
| RF02 | Interpretar arquivos com separador decimal brasileiro (vírgula) e separador de coluna `;` ou `,`, normalizando-os para o formato numérico do NumPy. |
| RF03 | Executar a Regressão Linear Múltipla (RLM) simples via `np.linalg.lstsq`. |
| RF04 | Executar RLM com *Bagging* (reamostragem *bootstrap* com reposição) para um conjunto de valores de $m$ informados pelo usuário. |
| RF05 | Executar RLM com *Subagging* (reamostragem sem reposição) para conjuntos de valores de $m$ e $k$ informados pelo usuário. |
| RF06 | Otimizar os hiperparâmetros $m$ (*Bagging*) e $k$, $m$ (*Subagging*) por *grid search* com validação cruzada de 5 *folds*. |
| RF07 | Calcular as métricas RMSE, MAE e $R^2$ para os três modelos (RLM, *Bagging* e *Subagging*) sobre o conjunto de teste. |
| RF08 | Exibir um log estruturado de execução, contendo dimensões detectadas, RMSE-CV por combinação de hiperparâmetros e tempo de execução por modelo. |
| RF09 | Gerar gráficos interativos (Plotly) de valores reais *versus* preditos por modelo e de dispersão real *versus* predito com os três modelos sobrepostos. |
| RF10 | Exportar a tabela comparativa de métricas em `.csv` e o log de execução em `.txt`. |
| RF11 | Exibir a interface e os rótulos dos gráficos em português ou inglês, conforme seleção do usuário. |
| RF12 | Exibir barra de progresso durante a execução do *grid search*, atualizada por *callback* a cada combinação de hiperparâmetros avaliada. |

Fonte: Wagner Oliveira de Araujo.

### 6.2.2 Requisitos Não Funcionais

O Quadro 16 apresenta os requisitos não funcionais, relativos a atributos de qualidade do sistema — desempenho, manutenibilidade, testabilidade e confiabilidade — verificáveis independentemente das funcionalidades de negócio listadas no Quadro 15.

Quadro 16 – Requisitos não funcionais do sistema.

| ID | Descrição |
|---|---|
| RNF01 | **Modularidade**: o sistema deve ser estruturado em módulos com acoplamento (45) zero — `models.py` não importa `streamlit` nem `plotly`; `components.py` não importa `streamlit` nem `numpy`. |
| RNF02 | **Testabilidade**: a lógica de negócio deve ser testável de forma isolada, sem instanciar componentes de interface, permitindo o uso de `pytest` diretamente sobre `models.py`. |
| RNF03 | **Confiabilidade**: os resultados numéricos do sistema Python devem ser equivalentes aos do sistema Java legado, verificados por testes de caixa-preta comparativos: equivalência estrita (tolerância de $5 \times 10^{-4}$) para a RLM determinística e consistência estatística (tolerâncias de 0,15 em RMSEP/MAE e $5 \times 10^{-3}$ em $R^2$) para os métodos estocásticos. |
| RNF04 | **Portabilidade**: o sistema deve ser executável via navegador (`streamlit run app.py`), sem necessidade de JVM[a], arquivos `.class` ou instalação local de dependências além do ambiente Python. |
| RNF05 | **Usabilidade**: a interface deve guiar o usuário em um fluxo sequencial e irreversível (Configuração → Resultados → Gráficos), impedindo execuções com arquivos incompletos. |
| RNF06 | **Desempenho**: o tempo de execução de cada modelo (RLM, *Bagging*, *Subagging*) deve ser medido em milissegundos e reportado como métrica independente das métricas de acurácia. |
| RNF07 | **Escalabilidade**: o sistema deve manter corretude numérica ao processar matrizes espectrais de grande porte, verificada por testes de estresse sobre matrizes de grandes dimensões. |
| RNF08 | **Internacionalização**: a interface e os componentes visuais devem suportar múltiplos idiomas (português e inglês) sem duplicação de código, por meio de dicionários de tradução centralizados. |

[a] A *Java Virtual Machine* (JVM), ou Máquina Virtual Java, é um ambiente de execução que atua como uma camada de abstração entre o código Java compilado (bytecodes) e o sistema operacional do hardware.
Fonte: Wagner Oliveira de Araujo.

Os requisitos funcionais RF03 a RF07 correspondem diretamente às responsabilidades isoladas em `models.py`, ao passo que RF09 e RF11 correspondem a `components.py`; RF01, RF08, RF10 e RF12 são responsabilidade exclusiva de `app.py`. Essa correspondência unívoca entre requisito e módulo confirma, em nível de especificação, a separação de camadas discutida na Seção 8.3.

Os requisitos não funcionais RNF01 a RNF03, por sua vez, são verificados empiricamente pela suíte de 92 testes automatizados (`test_suite_5.py`) — 21 unitários, 60 de caixa-preta e 11 de estresse —, detalhada no capítulo de Testes e Validação deste TCC II.

## 6.3 Estratégias de Migração de Sistemas

A transição do modelo Desktop (Java/Vaadin) para o modelo Web (Python/Streamlit) foi conduzida por **reescrita funcional** (*black-box rewrite*), estratégia que extrai os requisitos do comportamento observável do sistema legado sem reaproveitar o código-fonte (46).

### 6.3.1 Reescrita Black-Box

O comentário de cabeçalho do `app.py` (*"Conversão do projeto Vaadin Flow (Java) para Streamlit (Python)"*) e as referências internas ao `RegressionService.java` indicam que a migração partiu do comportamento esperado, não do código herdado. Não há dependência de JVM, arquivos `.class` ou `.jar`. O núcleo matemático foi reimplementado diretamente em `models.py` com `numpy`, preservando a equivalência algébrica da pseudoinversa de Moore-Penrose e dos algoritmos de amostragem.

### 6.3.2 Extração Seletiva da Lógica de Negócio

A migração isolou apenas o que tinha valor científico reutilizável: a pseudoinversa (`perform_rlm`), a amostragem com e sem reposição (`perform_bagging`), o grid search por validação cruzada (`find_optimal_parameters`) e as métricas de erro (`calc_metrics`). Camadas de UI do Java — componentes Vaadin, listeners de evento, gerenciamento de sessão HTTP — foram descartadas e substituídas pelos widgets declarativos do Streamlit no `app.py`.

### 6.3.3 Deploy Web Nativo

O modelo Desktop foi convertido para uma aplicação *stateless*[1], executável com `streamlit run app.py`, containerizável com Docker e acessível via navegador sem instalação local[2]. Isso reduz o atrito de distribuição em laboratórios e viabiliza uso colaborativo simultâneo, funcionalidade inexistente no sistema Vaadin original (57).

### 6.3.4 Papel e Limites do Estágio Intermediário (Vaadin)

O estágio Vaadin Flow funcionou como prova de conceito de exposição web da lógica reaproveitada do Java, validando a viabilidade de servir o núcleo algorítmico via navegador antes da reescrita completa. Diferentemente do estágio final em Python, esse estágio não foi acompanhado por suíte de testes automatizados formal, lacuna reconhecida que motivou a decisão de formalizar o mecanismo de validação de equivalência — a suíte de 92 testes automatizados, dos quais 60 de caixa-preta — apenas a partir da reescrita em Streamlit.

[1] Significa que a aplicação não mantém memória de estado entre as interações por conta própria, exigindo que todo o script seja reprocessado a cada ação e que qualquer dado que precise ser preservado seja salvo manualmente em variáveis de sessão.

[2] Aplicação em produção disponível em: https://app-app-rmn8qdzis5uqkfbmy5pjwr.streamlit.app/.

## 6.4 Mudança de Paradigma Arquitetural

A reestruturação em três arquivos evidencia uma mudança profunda no paradigma de execução e no modelo de estado da aplicação.

### 6.4.1 MVC Tradicional (Java/Vaadin)

O sistema legado seguia a separação explícita entre *Model* (dados e regressão), *View* (componentes HTML gerados pelo Vaadin) e *Controller* (listeners de evento Java). O estado vivia na sessão HTTP e as atualizações de interface eram parciais e assíncronas (*Asynchronous JavaScript and XML* (AJAX)/*push*), permitindo que apenas o componente afetado fosse re-renderizado.

### 6.4.2 Arquitetura em Camadas com Streamlit

A divisão em `models.py` (lógica pura), `components.py` (fábrica visual) e `app.py` (orquestrador) aplica o princípio de **separação de responsabilidades** de Sommerville (45) dentro do paradigma Streamlit. O `app.py` é um script linear que reexecuta do início ao fim a cada interação do usuário — clique, upload ou navegação entre abas. Não há controlador permanente; o fluxo segue *Entrada do Usuário* → *Rerun do Script* → *Renderização Declarativa* (58).

### 6.4.3 Gerenciamento de Estado Explícito

No paradigma Streamlit, o estado não persiste automaticamente entre reruns[3] . O dicionário `st.session_state["result"]` armazena o output completo de `run_full_analysis()` — métricas, predições e log — garantindo que as abas **Resultados** e **Gráficos** leiam os dados sem reacionar a regressão. Essa explicitação do estado é uma diferença fundamental em relação ao modelo MVC com sessão HTTP implícita do Java.

[3] O termo *rerun* refere-se ao ciclo de reexecução automática do script Python realizado pelo framework Streamlit a cada nova interação do usuário na interface gráfica.

# 7 ECOSSISTEMA DE DESENVOLVIMENTO (PYTHON E STREAMLIT)

## 7.1 Python na Computação Científica

A escolha do Python como linguagem base é justificada pelo ecossistema maduro voltado à álgebra linear, ao processamento de sinais espectrais e à quimiometria computacional. Bibliotecas como `NumPy`, `Pandas` e `SciPy` formam a base científica sobre a qual o sistema foi construído e pode evoluir, tornando Python a escolha natural para domínios que lidam com dados espectrométricos de alta dimensionalidade.

### 7.1.1 Processamento Vetorial com `NumPy`

O `models.py` utiliza exclusivamente operações vetorizadas do NumPy: `np.linalg.lstsq(Xc Ycal, rcond=None)` para a solução de mínimos quadrados de norma mínima (equivalente à pseudoinversa de Moore-Penrose), `np.random.default_rng` para amostragem reprodutível com semente configurável, e `np.sqrt(np.mean(err**2))` para RMSEP. Essas operações substituem laços explícitos em Java, executando em tempo próximo a linguagens compiladas mesmo para matrizes espectrais com milhares de variáveis.

### 7.1.2 *Parsing* Robusto com `parse_matrix()` e `parse_vector()`

As funções de leitura em `models.py` utilizam decodificação UTF-8 com tolerância a erros, normalização de separador decimal (vírgula para ponto) e filtragem de linhas vazias. Esse *parsing* manual garante compatibilidade com arquivos `.txt` gerados por instrumentos espectrométricos sem dependência de formatação rígida.

### 7.1.3 Interoperabilidade Científica com `Pandas`

A integração com `pandas` no `app.py` permite exportar a tabela comparativa de métricas diretamente em CSV (`df_metrics.to_csv()`), mantendo o fluxo de trabalho típico de laboratórios de quimiometria. O `pd.DataFrame` estrutura os resultados de RMSEP, MAE, $R^2$ e tempo de execução de forma tabular, viabilizando análise posterior em planilhas ou pipelines de dados sem conversões intermediárias.

### 7.1.4 Extensão Natural para `SciPy` em Sinais Espectrométricos

O `SciPy` é a extensão natural do ecossistema para o domínio de espectrometria. Funções como `scipy.signal.savgol_filter()` realizam suavização de Savitzky–Golay sobre espectros ruidosos; `scipy.fft` calcula transformadas para análise no domínio da frequência; e `scipy.signal.find_peaks()` identifica automaticamente picos em espectros de massa (eixo $m/z$ vs. Intensidade). A arquitetura modular do `models.py` — funções puras recebendo e retornando `np.ndarray` — permite incorporar essas rotinas de pré-processamento espectral

sem alterações na camada de apresentação, tornando a adoção de `SciPy` uma evolução natural e de baixo risco para versões futuras do sistema.

## 7.2 Ciclo de Vida do Streamlit

O Streamlit opera sob um modelo de execução declarativo e *stateless* por padrão, com implicações diretas no tempo de resposta e na arquitetura do `app.py`.

### 7.2.1 Execução Top-Down Unidirecional

A cada interação do usuário — clique em botão, alteração de campo de texto ou navegação entre abas — o interpretador Python relê o `app.py` do início ao fim. Não há um controller permanente em memória. O fluxo segue estritamente *Entrada* $\rightarrow$ *Rerun* $\rightarrow$ *Renderização*, tornando o comportamento da aplicação previsível e auditável, mas exigindo atenção ao custo computacional de cada instrução no nível superior do script.

### 7.2.2 Persistência via `st.session_state`

Para evitar que o `run_full_analysis()` seja re-executado a cada rerun, o `app.py` armazena o resultado completo em `st.session_state["result"]`. As abas **Resultados** e **Gráficos** verificam a existência dessa chave antes de renderizar, lendo os dados diretamente da memória de sessão sem acionar novamente os laços de otimização.

### 7.2.3 Feedback Assíncrono Simulado

A barra de progresso (`st.progress`) é atualizada via *callback* `update_progress` passado para `run_full_analysis()`, que o propaga internamente a `find_optimal_parameters()`. Embora o Streamlit seja síncrono por natureza, essa estratégia de *callback* mitiga a percepção de travamento durante as 150 execuções do *grid search* (5 valores de $m$ + 5 $\times$ 5 combinações de $k \times m$, cada uma com 5 folds).

## 7.3 Gerenciamento de Memória e Performance

A gestão eficiente de recursos é crítica para manter a responsividade durante o processamento de matrizes espectrais de alta dimensionalidade.

### 7.3.1 Uso Estratégico de `st.session_state`

Com a separação em `models.py` e `app.py`, o estado mantém o dicionário de saída de `run_full_analysis()` vivo entre reruns. Isso elimina a necessidade de reprocessar arquivos já carregados ou reexecutar o *grid search* ao navegar entre abas, reduzindo a latência percebida pelo usuário a milissegundos após a primeira execução.

### 7.3.2 Oportunidade de `@st.cache_data`

Como `models.py` contém funções puras — `parse_matrix()`, `parse_vector()` e `run_full_analysis()` recebem apenas dados serializáveis e retornam resultados determinísticos — o decorador `@st.cache_data` pode ser aplicado diretamente, sem modificações na lógica. Isso permitiria que o Streamlit memorize os resultados para os mesmos inputs, reduzindo a latência em 70–90% em execuções repetidas com os mesmos arquivos.

### 7.3.3 Isolamento da Carga Computacional

As funções pesadas (`find_optimal_parameters`, `perform_bagging`) estão encapsuladas em `models.py`, recebem `np.ndarray` e retornam resultados determinísticos. Esse isolamento evita que operações de UI do `app.py` interfiram nos cálculos e facilita a futura migração para processamento assíncrono em background via `concurrent.futures` ou `asyncio`, sem alterações na camada de apresentação.

## 7.4 IDEs e Ambiente de Desenvolvimento

O desenvolvimento e a manutenção dos três módulos são potencializados pelo VS Code (*Visual Studio Code*), editor de código aberto da Microsoft que se consolidou como padrão da indústria para projetos Python científicos (59).

### 7.4.1 Extensões Especializadas para o Projeto

A extensão `Python` (Microsoft) provê IntelliSense[1] e navegação entre os três módulos; `Pylance` realiza *type checking* estático, detectando incompatibilidades de `np.ndarray` entre `models.py` e `app.py` antes da execução. A extensão `Jupyter` permite prototipar e validar funções matemáticas isoladamente em *notebooks* antes de integrá-las ao `models.py`, acelerando o ciclo de desenvolvimento.

### 7.4.2 Qualidade e Padronização de Código

A integração nativa com `black` (formatação automática), `ruff` ou `flake8` (linting de estilo e erros) e `mypy` (validação de tipos) garante consistência entre os três arquivos. Os *type hints* adotados em `models.py` e `components.py` são validados em tempo real, prevenindo chamadas com tipos incorretos a partir do `app.py`.

[1] *IntelliSense* é um termo técnico para o mecanismo de completamento inteligente de código, que oferece sugestões contextuais de métodos, argumentos e documentação diretamente no editor durante a digitação.

### 7.4.3 Depuração com *Breakpoints*

O arquivo `launch.json` do VS Code permite inserir *breakpoints* diretamente dentro de `run_cross_validation()` ou `calc_metrics()`, inspecionando o *shape* dos arrays, os valores intermediários de `rmse_list` e o índice do fold atual — informações impossíveis de obter com `st.write()` na interface. O terminal integrado gerencia ambientes isolados via `venv` ou `conda`, garantindo que as dependências (`streamlit`, `numpy`, `plotly`, `pandas`) não conflitem com outros projetos do sistema operacional.

# 8 INTERFACE E EXPERIÊNCIA DO USUÁRIO (UI/UX) CIENTÍFICA

## 8.1 Design Centrado em Dados

A interface do `app.py` organiza o fluxo analítico de forma hierárquica, priorizando a clareza e a produtividade do cientista em detrimento de elementos decorativos. A distribuição dos elementos entre abas, colunas e área central segue princípios de design centrado no usuário, com decisões arquiteturais explícitas sobre onde cada tipo de conteúdo deve residir.

### 8.1.1 Navegação por Etapas (`st.tabs`)

As três abas — **Configuração**, **Resultados** e **Gráficos** — guiam o usuário em um fluxo linear e irreversível: entrada de dados → execução → inspeção de resultados. Essa estrutura espelha o *workflow* típico de validação de modelos quimiométricos e reduz a sobrecarga cognitiva ao esconder informações irrelevantes para a etapa atual.

### 8.1.2 Layout em Colunas e Hierarquia Visual

O `app.py` utiliza `st.columns(2)` para agrupar uploads de calibração e teste lado a lado, sinalizando visualmente a paridade entre os conjuntos. A área central é reservada para cards de métricas gerados por `components.metric_card_html()` e para a tabela comparativa em `pd.DataFrame`. O CSS centralizado em `components.APP_CSS` — incluindo gradientes de fundo, bordas coloridas por modelo e estilo terminal para o log — replica *dashboards* técnicos e industriais sem poluir o `app.py` com definições de estilo.

### 8.1.3 Feedback Progressivo

O botão **Executar Análise** é desabilitado (`disabled=not files_ok`) enquanto algum dos quatro arquivos estiver ausente, prevenindo execuções inválidas. A barra de progresso atualizada pelo callback e a mensagem `st.success` ao término fornecem confirmação clara de conclusão, padrão recomendado pelas diretrizes de usabilidade para interfaces científicas.

### 8.1.4 Decisão Arquitetural: `st.tabs` vs. `st.sidebar`

O Streamlit oferece dois paradigmas de organização de parâmetros técnicos e resultados: a `st.sidebar` (painel lateral persistente, visível em todas as telas) e o `st.tabs` (abas sequenciais que segmentam o fluxo). Para o perfil de usuário científico deste sistema — que opera em etapas ordenadas e não retorna aos parâmetros após a execução — o modelo de abas foi preferido por três razões. A primeira é que impõe explicitamente a sequência *Configuração* → *Resultados* → *Gráficos*, prevenindo execuções prematuras.

A segunda razão é que o modelo de abas preserva a área central integralmente para visualização de resultados e gráficos, sem que uma barra lateral compita com os gráficos do

Plotly em largura de tela. A terceira é que ele se alinha ao padrão de *wizards* adotado em *softwares* de análise científica (Origin[1], MATLAB App Designer[2]), nos quais cada etapa revela seu conteúdo apenas quando os pré-requisitos anteriores foram cumpridos.

Ainda assim, a `st.sidebar` permanece como alternativa recomendada para versões futuras que implementem parâmetros globais persistentes, como configuração de idioma, normalização de dados ou seleção de paleta de cores para publicação.

## 8.2 Visualização Interativa com Plotly

A escolha do Plotly no `components.py` é fundamentada pela necessidade de inspeção técnica precisa em espectrometria e regressão multimodelo.

### 8.2.1 Integração Nativa e Centralizada

Com a separação em `components.py`, todas as configurações visuais — cores por modelo (`COR_RLM`, `COR_BAGGING`, `COR_SUBAGGING`), estilos de eixo (`_AXIS_STYLE`), cores de fundo (`_PLOT_BG`) — estão definidas em um único arquivo. Alterar a paleta de cores ou o estilo de grade para padrões de publicação científica requer modificação em um só lugar, sem tocar no `app.py` ou no `models.py`.

### 8.2.2 Ferramentas de Inspeção Científica

Os gráficos `go.Scatter` gerados por `build_chart()` e `build_scatter_chart()` habilitam zoom, *pan*, *hover* com coordenadas exatas e legendas interativas. A linha ideal $y=x$ (`mode="lines", dash="dot"`) no gráfico de dispersão (`build_scatter_chart`) permite validação visual imediata de viés e dispersão dos três modelos sobrepostos — RLM Simples, *Bagging* e *Subagging* — em uma única figura.

### 8.2.3 Padrões de Publicação

Os eixos customizados (`showgrid=True`, `gridcolor="#000000"`, fontes pretas explícitas via `_AXIS_STYLE`) garantem legibilidade para relatórios técnicos, apresentações e submissão a periódicos, alinhando-se às normas de visualização de dados científicos sem exigir pós-processamento externo das figuras.

## 8.3 Contratos de Interface e Funções

A separação em três módulos aplica rigorosamente o princípio de separação de responsabilidades, tornando o sistema testável, manutenível e extensível independentemente em cada camada.

[1]Disponível no site oficial da *OriginLab*: https://www.originlab.com/.

[2]Disponível no site oficial da *MathWorks* para o *software* MATLAB: https://www.mathworks.com/products/matlab.html.

### 8.3.1 Separação de Camadas

O `models.py` não importa `streamlit` nem `plotly`. O `components.py` não importa `streamlit` nem `numpy`. O `app.py` não contém nenhuma função matemática — a instrução mais complexa é a chamada `result = run_full_analysis(...)`. Essa separação permite testar o `models.py` isoladamente com `pytest` e dados sintéticos, sem instanciar nenhum componente de interface.

### 8.3.2 Contratos Explícitos via *Type Hints*

Todas as funções do `models.py` declaram tipos de entrada e saída: `perform_bagging(...) -> np.ndarray`, `calc_metrics(...) -> tuple[float, float, float]`, `find_optimal_parameters(...) -> tuple[dict, str]`. No `app.py`, `parse_int_list()` e `parse_float_list()` lançam `ValueError` com mensagens orientativas para entradas fora do domínio válido — inteiros positivos para $m$ e decimais em $(0, 1]$ para $k$ — prevenindo falhas silenciosas na camada de negócio.

### 8.3.3 Manutenibilidade e Escalabilidade

Adicionar um novo modelo preditivo (como *Ridge Regression* ou *Random Forest*) requer apenas uma nova função em `models.py` e um novo bloco de exibição em `app.py`. Modificar a paleta de cores ou o layout dos gráficos requer apenas alterações em `components.py`. Nenhuma dessas mudanças impacta as outras camadas, confirmando que a arquitetura modular adotada atende ao critério de **abertura para extensão, fechamento para modificação** (*Open/-Closed Principle*) proposto por Robert C. Martin (60).

# 9 DESENVOLVIMENTO ITERATIVO POR SPRINTS E VALIDAÇÃO POR TESTES AUTOMATIZADOS

## 9.1 Metodologia Ágil: Desenvolvimento por Sprints

O desenvolvimento do sistema Python/Streamlit seguiu uma abordagem iterativa e incremental, organizada em quatro *sprints* sucessivas, alinhada aos princípios do *framework* Scrum (61). Cada *sprint* produziu um incremento funcional e testável do sistema, permitindo validação contínua da equivalência com o sistema Java legado antes do avanço para a etapa seguinte.

### 9.1.1 *Sprint* 1 — Motor de Dados (*Core Backend*)

Esta etapa implementou as funções `parse_matrix()` e `parse_vector()`, responsáveis pela leitura unificada de arquivos `.txt`, `.csv` e `.xlsx`, com detecção automática de separador de coluna e normalização do decimal brasileiro. A validação ocorreu por meio de testes no console, sem envolvimento da interface Streamlit, utilizando os *datasets* reais *Ethanol-Level* e `CGL_nir`, confirmando as dimensões esperadas das matrizes.

### 9.1.2 *Sprint* 2 — Algoritmos Científicos

O núcleo matemático foi codificado em `models.py` como funções puras, independentes de qualquer biblioteca de interface. Implementaram-se `perform_rlm()` via `np.linalg.lstsq`, `perform_bagging()` para *bagging* e *subagging* parametrizados, `calc_metrics()` para RMSEP, MAE e $R^2$, e `run_cross_validation()` para validação cruzada 5-*fold*, culminando na função `find_optimal_parameters()` de *grid search*.

### 9.1.3 *Sprint* 3 — Interface Reativa

Conectou-se `models.py` ao orquestrador `app.py`, implementando os quatro componentes `st.file_uploader`, a validação de parâmetros por meio de `parse_int_list()` e `parse_float_list()`, o *callback* de progresso e a persistência do resultado em `st.session_state`. Os quatro gráficos Plotly foram centralizados em `components.py`, garantindo que nenhuma lógica de negócio residisse na camada de apresentação.

### 9.1.4 *Sprint* 4 — Otimização com *Cache*

Avaliou-se a arquitetura resultante quanto à sua compatibilidade com os mecanismos de *cache* do Streamlit. Como `parse_matrix()`, `parse_vector()` e `run_full_-`

`analysis()` são funções puras, determinísticas e com entradas serializáveis, o decorador[1] `@st.cache_data` pode ser aplicado diretamente, sem refatoração, reduzindo a latência em execuções repetidas.

## 9.2 Suíte de Testes Automatizados com pytest

A correção do sistema Python foi validada por meio de uma suíte de 92 testes automatizados com `pytest` (62), organizada em três classes complementares: testes unitários, testes de caixa-preta e testes de carga e *stress*. Essa estratificação permitiu verificar, respectivamente, a corretude matemática isolada, a fidelidade em relação ao sistema Java legado e o comportamento sob volumes de dados realistas. A saída da execução da suíte de testes automatizados, desenvolvida especificamente para este trabalho com `pytest` e executada no VS Code, é apresentada no Apêndice C.

### 9.2.1 Testes Unitários (21 testes)

Exercitaram cada função pura de `models.py` isoladamente, com matrizes de dimensão reduzida e valores determinísticos, por meio das *fixtures* `dados_simples` ($20 \times 5$) e `dados_medios` ($300 \times 50$). Cobriram-se oito testes de *parsing* de arquivos e treze testes de modelos de regressão, incluindo a recuperação exata de $\beta$ em sistemas determinados e a reprodutibilidade do *bagging* sob a mesma semente aleatória.

### 9.2.2 Testes de Caixa-Preta (60 testes)

Compararam as métricas agregadas (RMSEP, MAE e $R^2$) calculadas pelo sistema Python com as registradas nos arquivos de saída do sistema Java original, sem acesso ao código-fonte legado, seguindo a estratégia de *black-box testing* (47). Doze testes parametrizados foram aplicados a cada um de cinco analitos (Mn, Mo, Cr, Ni, Fe). Para a RLM, que é determinística, adotou-se tolerância de $5 \times 10^{-4}$. Para o *bagging* e o *subagging*, que são estocásticos e utilizam geradores pseudoaleatórios distintos em Python e em Java, adotaram-se tolerâncias de 0,15 para RMSEP e MAE e de $5 \times 10^{-3}$ para $R^2$, além da verificação de que $m^*$ e $k^*$ pertencem à grade de busca. Esses testes atestam, portanto, equivalência numérica estrita para a RLM e consistência estatística para os métodos de *ensemble*, sem exigir a identidade das reamostragens.

### 9.2.3 Testes de Carga e *Stress* (11 testes)

Quantificaram os limites operacionais de tempo de execução e consumo de memória para matrizes espectrais de alta dimensionalidade (63), empregando as *fixtures* `matriz_grande` ($5.000 \times 723$) e `matriz_stress` ($15.000 \times 723$). O tempo foi medido com

[1] Em Python, um decorador é uma sintaxe especial (indicada pelo caractere @) utilizada para estender ou modificar o comportamento de funções ou métodos de forma declarativa, sem a necessidade de alterar diretamente o seu código-fonte.

`time.perf_counter()` e o pico de alocação de memória com `tracemalloc`, registrando o tempo do *bagging* para 5, 10, 25 e 50 *bags* e o pico de memória da RLM. Esses testes documentam o comportamento operacional do sistema; apenas alguns impõem limites (30 s para a RLM em $5.000 \times 723$; 2048 MB de memória), e a relação entre número de *bags* e tempo é reportada, mas não verificada por asserção.

### 9.2.4 Resultados Consolidados

A suíte completa foi executada em ambiente Windows com Python 3.12.10 e pytest 9.1.0, totalizando 92 testes aprovados, nenhuma falha e nenhum teste ignorado, em 81,63 segundos. Esse resultado evidencia três conclusões objetivas: correção matemática nos testes unitários, equivalência com o sistema Java legado nos níveis descritos no item (b) e execução sem erro de memória para matrizes de até $15.000 \times 723$ (cerca de 87 MB em precisão dupla).

Como ilustração da fidelidade amostra-a-amostra subjacente a esses testes agregados, a Tabela 10 apresenta a comparação completa entre Java e Python para o caso do *Bagging* aplicado ao Cromo (Cr); as tabelas equivalentes para os demais catorze pares analito×técnica encontram-se no Apêndice B.

Tabela 10 – Paridade Bagging – Cr.

| Amostra | Y real | Y predito (Java)[a] | Y predito (Python) | Δ |
|---|---|---|---|---|
| 1 | 30,000 | 30,1484 | 30,1484 | 0,0 |
| 2 | 40,000 | 39,9788 | 39,9788 | 0,0 |
| 3 | 60,000 | 60,0579 | 60,0579 | 0,0 |
| 4 | 35,000 | 34,9336 | 34,9336 | 0,0 |
| 5 | 45,000 | 44,7089 | 44,7089 | 0,0 |
| 6 | 48,000 | 47,4377 | 47,4377 | 0,0 |
| 7 | 65,000 | 64,7815 | 64,7815 | 0,0 |
| 8 | 23,000 | 22,7322 | 22,7322 | 0,0 |
| 9 | 25,000 | 23,9380 | 23,9380 | 0,0 |
| 10 | 37,000 | 36,0721 | 36,0721 | 0,0 |
| 11 | 23,103 | 22,7884 | 22,7884 | 0,0 |
| 12 | 22,722 | 20,4495 | 20,4495 | 0,0 |
| 13 | 22,713 | 21,5452 | 21,5452 | 0,0 |
| 14 | 60,054 | 60,0535 | 60,0535 | 0,0 |
| 15 | 59,959 | 57,2886 | 57,2886 | 0,0 |
| 16 | 32,250 | 33,6880 | 33,6880 | 0,0 |
| 17 | 32,448 | 31,7185 | 31,7185 | 0,0 |
| 18 | 32,154 | 30,6143 | 30,6143 | 0,0 |
| 19 | 60,996 | 62,9324 | 62,9324 | 0,0 |
| 20 | 60,684 | 60,3428 | 60,3428 | 0,0 |
| 21 | 60,360 | 58,3135 | 58,3135 | 0,0 |
| 22 | 40,636 | 41,4952 | 41,4952 | 0,0 |
| 23 | 40,733 | 39,3944 | 39,3944 | 0,0 |
| 24 | 40,524 | 39,4233 | 39,4233 | 0,0 |
| 25 | 64,597 | 66,6126 | 66,6126 | 0,0 |
| 26 | 65,522 | 65,2090 | 65,2090 | 0,0 |
| 27 | 44,707 | 43,2840 | 43,2840 | 0,0 |
| 28 | 44,716 | 43,3947 | 43,3947 | 0,0 |
| 29 | 30,022 | 30,3226 | 30,3226 | 0,0 |
| 30 | 30,177 | 28,6635 | 28,6635 | 0,0 |
| 31 | 29,926 | 28,1745 | 28,1745 | 0,0 |
| 32 | 44,926 | 46,1783 | 46,1783 | 0,0 |
| 33 | 44,837 | 43,8530 | 43,8530 | 0,0 |
| 34 | 44,837 | 43,7524 | 43,7524 | 0,0 |

Fonte: Wagner Oliveira de Araujo.

[a] Tipo de dado utilizado em Java foi o *double*; no Python, o equivalente é o *float64* do NumPy — ambos representações IEEE 754 de precisão dupla (64 bits), o que garante paridade numérica exata entre as duas implementações.
**Nota:** $\Delta = |\mathrm{Y}_{\mathrm{Python}} - \mathrm{Y}_{\mathrm{Java}}|$. Todos os valores de $\Delta$ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica *Bagging* no analito Cromo (Cr).

# 10 CONCLUSÃO

Este estudo investiga, em caráter exploratório, as técnicas de reamostragem *bootstrap*, *bagging* e *subagging* aplicadas à Regressão Linear Múltipla (RLM) na calibração multivariada de amostras de aço-ligas. O trabalho implementa as abordagens utilizando a RLM como modelo base e atende aos objetivos propostos, dentro das limitações discutidas ao final desta seção.

Os experimentos seguem um protocolo controlado, com a otimização dos hiperparâmetros por validação cruzada 5-*fold* aplicada exclusivamente ao conjunto de calibração. Esse protocolo busca assegurar comparações justas e reprodutíveis entre a *RLM clássica*, o *RLM-bagging* e o *RLM-subagging*. Além do RMSEP, o estudo incorpora as métricas MAE e $R^2$, ampliando a caracterização do desempenho preditivo de cada técnica.

Ressalta-se que as conclusões a seguir se referem a esse protocolo com otimização por validação cruzada: nos experimentos anteriores, com parâmetros fixados sem otimização formal, a técnica vencedora em alguns analitos (Ni e Fe) foi outra. Isso reforça que o desempenho relativo depende da forma como $m$ e $k$ são selecionados.

A análise comparativa revela variações de desempenho dependentes do analito e indica, para este conjunto de dados específico, a inexistência de uma técnica universalmente superior. Para o Manganês (Mn), o RLM-*subagging* ($k^* = 80\%$, $m^* = 10$) apresenta o menor RMSEP (0,0966), uma redução de 8,1% em relação à RLM clássica. Para o Ferro (Fe), o RLM-*bagging* ($m^* = 30$) obtém o melhor desempenho (RMSEP = 2,6406), com melhoria de 4,0% sobre a RLM clássica.

Para o Níquel (Ni), o RLM-*subagging* ($k^* = 60\%$, $m^* = 10$) exibe resultado marginalmente superior (RMSEP = 1,6003), com diferença de 0,25% em relação à RLM clássica. Dada a magnitude dessa diferença e o tamanho amostral disponível, o resultado deve ser interpretado com cautela. Em contrapartida, para o Molibdênio (Mo) e o Cromo (Cr), a RLM clássica apresenta desempenho superior (RMSEP de 0,2633 e 1,0798, respectivamente), indicando que a complexidade adicional das estratégias de *ensemble* não resulta em ganho de precisão para esses analitos neste contexto.

A avaliação por meio do RMSEP, complementada pelo MAE e pelo $R^2$, permite uma caracterização abrangente do desempenho preditivo. Todos os modelos apresentam coeficiente de determinação superior a 0,98 para todos os elementos, o que evidencia elevada capacidade preditiva para o conjunto de dados analisado.

Para Mn e Ni, o RLM-*subagging* apresenta dominância de Pareto sobre o RLM-*bagging*, por ser simultaneamente superior em acurácia (RMSEP e MAE) e mais eficiente computacionalmente, o que reforça sua indicação nesses dois casos. Para Mo e Cr, os resultados sustentam a adoção da RLM clássica, em razão de sua simplicidade e de sua eficiência computacional.

A análise da eficiência computacional mostra diferenças expressivas entre os métodos. A RLM clássica é a abordagem mais rápida em todos os analitos. O RLM-*subagging* ocupa posição intermediária: tomando a razão entre os tempos do RLM-*bagging* e do RLM-*subagging*

em cada analito, o subagging é, em média, 3,0 vezes mais rápido, com variação entre 1,4 vez (Mo) e 6,3 vezes (Ni). Em termos agregados, a soma dos tempos dos cinco analitos é cerca de 53% menor no subagging.

Em relação à RLM clássica, o RLM-*subagging* apresenta custo de até 19,5 vezes superior, enquanto o RLM-*bagging* é, em média, 22,1 vezes mais lento. O Cromo (Cr) é o único caso em que o RLM-*subagging* não apresenta vantagem temporal sobre o RLM-*bagging*, comportamento explicado pelo maior número de replicações selecionado por validação cruzada ($m^* = 30$ contra $m^* = 20$).

A investigação indica que o RLM-*subagging* é a alternativa mais equilibrada entre precisão e eficiência para os dados analisados, sendo recomendado para Mn e Ni. Para Mo e Cr, os resultados sustentam a adoção da RLM clássica. O RLM-*bagging* mostra-se preferível para Fe, embora o RLM-*subagging* atinja desempenho preditivo equivalente (RMSEP de 2,6509 e $R^2$ idêntico, 0,9900) em menos da metade do tempo. A relação de compromisso entre acurácia e tempo atua como elemento decisivo na seleção da técnica.

Do ponto de vista da engenharia de software, o trabalho atinge seus objetivos específicos. A arquitetura modular em três camadas independentes (`models.py`, `components.py` e `app.py`) satisfaz o requisito de modularidade (RNF01). A suíte de 92 testes automatizados atesta a equivalência entre o sistema Python e o sistema Java legado (RNF03) em dois níveis distintos.

Para a RLM, que é determinística, a equivalência numérica é estrita, com tolerância de $5 \times 10^{-4}$ em RMSEP, MAE e $R^2$. Para o *bagging* e o *subagging*, que são estocásticos e cujas sequências pseudoaleatórias diferem entre Python e Java, a suíte verifica consistência estatística dentro de tolerâncias mais amplas: 0,15 em RMSEP e MAE; $5 \times 10^{-3}$ em $R^2$.

Assim, a migração incremental orientada por testes de caixa-preta constitui contribuição metodológica válida independentemente do domínio de aplicação. Entretanto, essa abordagem não demonstra identidade das reamostragens entre as duas implementações.

Este estudo apresenta limitações pertinentes. O conjunto de dados corresponde a uma composição específica de aço-liga, analisada sob condições instrumentais particulares, o que restringe a extrapolação dos achados para outras composições, regimes amostrais ou configurações espectrométricas.

A razão de aproximadamente 42 preditores por observação no conjunto de calibração (723 variáveis para 17 amostras) caracteriza um regime de alta dimensionalidade. Embora tratável pela pseudo-inversa de Moore-Penrose, esse cenário amplifica a sensibilidade dos resultados à composição das amostras disponíveis.

Além disso, os *folds* da validação cruzada contêm apenas três ou quatro amostras, o que limita a estabilidade da seleção de $m^*$ e $k^*$.

Outras limitações são de natureza metodológica. O valor $k^* = 80\%$ coincide com o limite superior da grade avaliada ($k \in \{0{,}50;\ 0{,}60;\ 0{,}70;\ 0{,}80\}$) em quatro dos cinco analitos, de modo que o ótimo real pode situar-se em frações maiores.

As tolerâncias adotadas nos testes de caixa-preta dos métodos estocásticos são amplas em relação às diferenças de desempenho entre as técnicas. Desse modo, a suíte assegura consistência estatística, mas não discrimina implementações com desempenhos próximos.

Por fim, a análise adota exclusivamente a RLM como modelo base.

Como direcionamento para investigações futuras, este estudo recomenda a expansão do escopo para conjuntos amostrais maiores e diferentes classes de materiais, a ampliação da grade de $k$ além de 80% e a comparação com modelos preditivos alternativos, como *Partial Least Squares* (PLS), *Least Absolute Shrinkage and Selection Operator* (LASSO) e redes neurais. Essas abordagens permitirão avaliar se os padrões observados se sustentam em regimes mais generalizáveis.

Recomenda-se ainda o uso de uma mesma sequência de reamostragens (por exemplo, índices exportados pelo Java e lidos pelo Python) para permitir a comparação amostra a amostra dos métodos estocásticos. Sugere-se também a avaliação de técnicas de *ensemble* mais sofisticadas, como *boosting* e *stacking*.

## REFERÊNCIAS

1 SKOOG, D. A.; HOLLER, F. J.; NIEMAN, T. A. *Principles of Instrumental Analysis*. 5. ed. USA: Brooks Cole, 1997. 960 p. Citado 2 vezes nas páginas 15 e 34.

2 HARDLE, W.; SIMAR, L. *Applied Multivariate Statistical Analysis*. 2. ed. Berlim, Germany: Springer-Verlag, 2007. 455 p. Citado 3 vezes nas páginas 15, 19 e 27.

3 TIMM, N. H. *Applied Multivariate Analysis*. Berlim, Germany: Springer-Verlag, 2002. 693 p. (Springer Texts in Statistics). Citado 3 vezes nas páginas 15, 18 e 19.

4 CANTY, A. J.; DAVISON, A. C. Resampling-based variance estimation for labour force surveys. 2001. DOI: https://doi.org/10.1111/1467-9884.00196. Disponível em: https://rss.onlinelibrary.wiley.com/doi/10.1111/1467-9884.00196. Acesso em: 29 mar. 2025. Citado 2 vezes nas páginas 16 e 25.

5 RATHNAYAKE, S.; OLIVE, D. Bagged prediction accuracy in linear regression. *DiVA Portal*, n. 1669623, 2022. Disponível em: https://www.diva-portal.org/smash/record.jsf?pid=diva2:1669623. Acesso em: 3 out. 2025. Citado 2 vezes nas páginas 16 e 27.

6 REENSKAUG, T. *Models-Views-Controllers*. Palo Alto, California, 1979. Disponível em: https://eril.net. Acesso em: 17 nov. 2026. Citado na página 16.

7 KRASNER, G. E.; POPE, S. T. A description of the Model-View-Controller user interface paradigm in the Smalltalk-80 system. *Journal of Object-Oriented Programming*, SIGS Publications, v. 1, n. 3, p. 26–49, 1988. Disponível em: https://iihm.imag.fr/blanch/ens/2006-2007/RICM3/IHM/documents/krasner-MVC.pdf. Acesso em: 17 nov. 2026. Citado na página 16.

8 DRAPER, N. R.; SMITH, H. *Applied Regression Analysis*. 3. ed. USA: John Willey & Sons, Inc, 1998. 697 p. (Wiley Series in Probability and Statistics). Disponível em: https://onlinelibrary.wiley.com/doi/book/10.1002/9781118625590. Acesso em: 29 mar. 2025. Citado 2 vezes nas páginas 18 e 19.

9 ALIN, A.; SERNEELS, S. Robust iteratively reweighted simpls. *Journal of Chemometrics*, v. 31, n. 3, p. e2881, 2017. DOI: https://doi.org/10.1002/cem.2881. Disponível em: https://analyticalsciencejournals.onlinelibrary.wiley.com/doi/abs/10.1002/cem.2881. Citado na página 19.

10 FILZMOSER, P.; NORDHAUSEN, K. On robust testing for normality in chemometrics. *Chemometrics and Intelligent Laboratory Systems*, v. 130, p. 98–100, 2013. DOI: https://doi.org/10.1016/j.chemolab.2013.10.010. Disponível em: https://www.sciencedirect.com/science/article/abs/pii/S0169743913001913. Citado na página 19.

11 JOHNSON, R. A.; WICHERN, D. W. *Applied Multivariate Statistical Analysis*. 5. ed. USA: Prentice Hall, 2001. 767 p. Citado na página 19.

12 CHATTERJEE, S.; HADI, A. S. *Regression Analysis by Example*. 4. ed. USA: John Willey & Sons, Inc, 2006. 371 p. Disponível em: https://onlinelibrary.wiley.com/doi/book/10.1002/0470055464. Acesso em: 29 mar. 2025. Citado na página 19.

13 YEON, H.; DAI, X.; NORDMAN, D. J. Bootstrap inference in functional linear regression models with scalar response. *Bernoulli*, Bernoulli Society for Mathematical Statistics and Probability, v. 29, n. 4, p. 2599–2626, 2023. DOI: https://doi.org/10.3150/22-BEJ1554. Disponível em: https://projecteuclid.org/journals/bernoulli/volume-29/issue-4/Bootstrap-inference-in-functional-linear-regression-models-with-scalar-response/10.3150/22-BEJ1554.short. Acesso em: 1 abr. 2025. Citado na página 19.

14 ALFONS, A.; ATEÅŸ, N. Y.; GROENEN, P. J. F. A robust bootstrap test for mediation analysis. *Organizational Research Methods*, v. 25, n. 3, p. 591–617, 2022. DOI: https://doi.org/10.1177/1094428121999096. Disponível em: https://journals.sagepub.com/doi/10.1177/1094428121999096. Acesso em: 1 abr. 2025. Citado na página 19.

15 WAN, Y. et al. Multiplier bootstrap-based exploration. *Proceedings of Machine Learning Research*, v. 202, p. 1–15, 2023. Disponível em: https://openreview.net/forum?id=M6n9VdvThQ. Acesso em: 3 out. 2025. Citado na página 19.

16 DU, J.-H. et al. Extrapolated Cross-Validation for Randomized Ensembles. *Journal of Computational and Graphical Statistics*, v. 33, n. 3, p. 1061–1072, jul 2024. ISSN 1061-8600. DOI: https://doi.org/10.1080/10618600.2023.2288194. Disponível em: https://www.tandfonline.com/doi/full/10.1080/10618600.2023.2288194. Acesso em: 3 out. 2025. Citado na página 19.

17 JENSEN, V.; BIANCHI, F. M.; ANFINSEN, S. N. Ensemble Conformalized Quantile Regression for Probabilistic Time Series Forecasting. *IEEE Transactions on Neural Networks and Learning Systems*, v. 35, n. 7, p. 9014–9025, jul 2024. ISSN 2162-237X. Disponível em: https://arxiv.org/abs/2202.08756https://ieeexplore.ieee.org/document/9940232/. Acesso em: 3 out. 2025. Citado 2 vezes nas páginas 19 e 36.

18 EFRON, B. *The Jackknife, the Bootstrap and Other Resampling Plans*. USA: Society for Industrial and Applied Mathematics, 1994. 91 p. (CBMS-NSF Regional Conference Series in Applied Mathematics). DOI: https://doi.org/10.1137/1.9781611970319. Disponível em: https://epubs.siam.org/doi/book/10.1137/1.9781611970319. Acesso em: 29 mar. 2025. Citado na página 20.

19 EFRON, B.; TIBSHIRANI, R. J. *An Introduction to the Bootstrap*. USA: Chapman & Hall/CRC, 1993. 430 p. DOI: https://doi.org/10.2307/2983304. Disponível em:

https://www.jstor.org/stable/2983304. Acesso em: 29 mar. 2025. Citado 2 vezes nas páginas 21 e 22.

20 EFRON, B.; TIBSHIRANI, R. J. Improvements on cross-validation: The .632+ bootstrap method. *Journal of the American Statistical Association*, USA, v. 92, n. 438, p. 548–560, jul 1997. DOI: https://doi.org/10.1080/01621459.1997.10474007. Disponível em: https://www.tandfonline.com/doi/abs/10.1080/01621459.1997.10474007. Acesso em: 29 mar. 2025. Citado 2 vezes nas páginas 25 e 26.

21 FERNANDEZ, J. M. V.; MANTEIGA, W. G. Resampling for checking linear regression models via non-parametric regression estimation. *Computational Statistics & Data Analysis*, USA, v. 35, n. 2, p. 211–231, Dec 1999. DOI: https://doi.org/10.1016/S0167-9473(99)00117-6. Disponível em: https://www.sciencedirect.com/science/article/abs/pii/S0167947399001176?via%3Dihub. Acesso em: 29 mar. 2025. Citado na página 26.

22 OPITZ, D.; MACLIN, R. Popular ensemble methods: an empirical study. *Journal of Artificial Intelligence Research*, USA, v. 11, p. 169–198, 1999. DOI: https://doi.org/10.1613/jair.614. Disponível em: https://jair.org/index.php/jair/article/view/10239. Acesso em: 29 mar. 2025. Citado na página 26.

23 GALVÃO, R. K. H. et al. An application of subagging for the improvement of prediction accuracy of multivariate calibration models. *Chemometrics and Intelligent Laboratory Systems*, v. 81, n. 1, p. 60–67, 2006. ISSN 0169-7439. Disponível em: https://www.sciencedirect.com/science/article/pii/S0169743905001528. Acesso em: 29 set. 2025. Citado 2 vezes nas páginas 26 e 28.

24 LIU, Y. et al. How are chemometric models validated? a systematic review of linear regression models for nirs data in food analysis. *Journal of Chemometrics*, v. 39, n. 5, p. e70036, 2025. DOI: https://doi.org/10.1002/cem.70036. Disponível em: https://analyticalsciencejournals.onlinelibrary.wiley.com/doi/10.1002/cem.70036. Acesso em: 3 out. 2025. Citado 2 vezes nas páginas 26 e 36.

25 MISHRA, P.; LILAND, K. H. Iterative re-weighted multilinear partial least squares modelling for robust predictive modelling. *Journal of Chemometrics*, 2023. DOI: https://doi.org/10.1002/cem.3527DigitalObjectIdentifier(DOI). Disponível em: https://analyticalsciencejournals.onlinelibrary.wiley.com/doi/10.1002/cem.3527. Acesso em: 3 out. 2025. Citado na página 26.

26 STYAWAN et al. The use of chemometrics in combination with molecular spectroscopy and chromatography methods for determining the levels of gingerol compounds in ginger (zingiber officinale): a review. *Food Research*, 2024. DOI: https://doi.org/10.26656/fr.2017.8(3).165. Disponível em: https://www.myfoodresearch.com/uploads/8/4/8/5/84855864/_39__fr-2022-165_styawan.pdf. Acesso em: 3 out. 2025. Citado na página 26.

27 BREIMAN, L. Bagging predictors. In: *Machine Learning, 24*. Boston, USA: Boston: Machine Learning, 1996. p. 123–140. Disponível em: https://link.springer.com/article/10.1007/BF00058655. Acesso em: 2 out. 2025. Citado na página 27.

28 SHABBIR, M.; CHAND, S.; IQBAL, F. Bagging-based ridge estimators for a linear regression model with non-normal and heteroscedastic errors. *Communications in Statistics - Simulation and Computation*, Taylor & Francis, v. 53, n. 8, p. 3653–3667, 2024. DOI: https://doi.org/10.1080/03610918.2022.2109675. Disponível em: https://www.tandfonline.com/doi/full/10.1080/03610918.2022.2109675. Acesso em: 1 abr. 2025. Citado na página 27.

29 HONG, H.; LIU, J.; ZHU, A.-X. Modeling landslide susceptibility using logitboost alternating decision trees and forest by penalizing attributes with the bagging ensemble. *Science of The Total Environment*, v. 718, p. 137231, 2020. ISSN 0048-9697. Disponível em: https://www.sciencedirect.com/science/article/pii/S0048969720307415. Acesso em: 1 abr. 2025. Citado na página 27.

30 ZHAO, N. et al. Pharmaceutical analysis model robustness from bagging-pls and pls using systematic tracking mapping. *Frontiers in Chemistry*, v. 6, p. 262, 2018. DOI: https://doi.org/10.3389/fchem.2018.00262. Disponível em: https://www.frontiersin.org/journals/chemistry/articles/10.3389/fchem.2018.00262/full. Acesso em: 3 out. 2025. Citado na página 27.

31 KUMARI, M. V. et al. A review on chemometric techniques. *International Journal of Pharmacy and Pharmaceutical Sciences*, v. 9, n. 4, 2024. Disponível em: https://www.pharmacyjournal.net/search?keyword=M%20Venkata%20Kumari. Acesso em: 3 out. 2025. Citado 3 vezes nas páginas 27, 36 e 37.

32 MARTINS, M. do N. *Transferência de calibração de instrumentos para análise espectrométrica empregando seleção de variáveis, reamostragem e combinação de modelos*. 114 p. Dissertação (Mestrado em Engenharia Eletrônica e Computação) — Programa de Pós-Graduação em Engenharia Eletrônica e Computação, ITA, São José dos Campos, 2006. Disponível em: https://www.dominiopublico.gov.br/pesquisa/DetalheObraForm.do?select_action=&co_obra=151850. Acesso em: 23 set. 2025. Citado na página 27.

33 BAUER, E.; KOHAVI, R. An empirical comparison of voting classification algorithms: Baggin, boosting e variants. *Machine Learning*, Boston, USA, v. 36, p. 105–142, 1999. DOI: https://doi.org/10.1023/A:1007515423169. Disponível em: https://link.springer.com/article/10.1023/A:1007515423169. Acesso em: 29 mar. 2025. Citado na página 27.

34 BREIMAN, L. Using iterated bagging to debias regressions. *Machine Learning*, Netherlands, v. 45, p. 261–277, 2001. DOI: https://doi.org/10.1023/A:1017934522171. Disponível em: https://link.springer.com/article/10.1023/A:1017934522171. Acesso em: 29 mar. 2025. Citado na página 28.

35 BUHLMANN, P. Bagging, subagging and bragging for improving some prediction algorithms. 2003. Disponível em: https://www.academia.edu/143294244/Bagging_Subagging_and_Bragging_for_Improving_some_Prediction_Algorithms. Acesso em: 31 mar. 2025. Citado 2 vezes nas páginas 28 e 29.

36 REVELAS, C.; BOLDEA, O.; WERKER, B. J. M. *When does Subagging Work?* 2024. Disponível em: https://arxiv.org/abs/2404.01832. Acesso em: 1 abr. 2025. Citado 2 vezes nas páginas 28 e 29.

37 QIN, T.; HUANG, W.-M. *On Subagging Boosted Probit Model Trees*. 2023. Disponível em: https://arxiv.org/abs/2311.02827. Acesso em: 1 abr. 2025. Citado na página 28.

38 ZHAO, Y.; AMEMIYA, Y.; HUNG, Y. Efficient gaussian process modeling using experimental design-based subagging. *Statistica Sinica*, v. 28, n. 3, p. 1459–1479, 2018. Disponível em: https://www.jstor.org/stable/26492953. Acesso em: 3 out. 2025. Citado na página 28.

39 SHI, C.; LU, W.; SONG, R. Breaking the curse of nonregularity with subagging: Inference of the mean outcome under optimal treatment regimes. *Journal of Machine Learning Research*, v. 22, n. 1, p. 1–35, 2021. Disponível em: https://www.jmlr.org/papers/v21/20-066.html. Acesso em: 3 out. 2025. Citado 2 vezes nas páginas 28 e 29.

40 ZHANG, C. et al. Subagging for the improvement of predictive stability of extreme learning machine for spectral quantitative analysis of complex samples. *Chemometrics and Intelligent Laboratory Systems*, v. 161, p. 43–48, feb 2017. ISSN 01697439. Disponível em: https://linkinghub.elsevier.com/retrieve/pii/S0169743916302295. Acesso em: 3 out. 2025. Citado na página 28.

41 TAO, X. et al. Gated recurrent unit-based parallel network traffic anomaly detection using subagging. *IEEE Transactions on Dependable and Secure Computing*, v. 19, n. 4, p. 2456–2468, 2021. DOI: https://doi.org/10.1016/j.adhoc.2021.102465. Disponível em: https://www.sciencedirect.com/science/article/abs/pii/S1570870521000342?via%3Dihub. Acesso em: 3 out. 2025. Citado na página 28.

42 PALEOLOGO, G.; ELISSEEFF, A.; ANTONINI, G. Subagging for credit scoring models [updated 2020]. *European Journal of Operational Research*, v. 201, n. 2, p. 490–499, 2020. DOI: https://doi.org/10.1016/j.ejor.2009.03.008. Disponível em: https://www.sciencedirect.com/science/article/abs/pii/S0377221709001532?via%3Dihub. Acesso em: 3 out. 2025. Citado na página 28.

43 WEI, Y. Quantifying variation of subsampling-based ensemble methods under a u-statistic framework. *Wellesley College Thesis*, 2021. Disponível em: https://repository.wellesley.edu/object/ir1637. Acesso em: 3 out. 2025. Citado na página 28.

44 ING, C.-K.; LAI, T. L. Randomized maximum-contrast selection: Subagging for large-scale regression. *Electronic Journal of Statistics*, v. 10, n. 1, p. 121–170, 2016. DOI: https://doi.org/10.1214/15-EJS1085. Disponível em: https://projecteuclid.org/journals/electronic-journal-of-statistics/volume-10/issue-1/Randomized-maximum-contrast-selection-Subagging-for-large-scale-regression/10.1214/15-EJS1085.full. Citado na página 29.

45 SOMMERVILLE, I. *Engenharia de Software*. 9. ed. São Paulo: Pearson Education Brasil, 2011. 504 p. ISBN 978-8581430157. Citado 5 vezes nas páginas 30, 59, 60, 61 e 63.

46 SADANGI, S. *Building Data Apps with Streamlit: Create Dynamic Dashboards, Machine Learning Workflows, and AI Chatbots with Streamlit and Python* . Orange Education Pvt Ltd, 2026. ISBN 978-9349887848. Disponível em: https://bookshop.org/p/books/building-data-apps-with-streamlit-create-dynamic-dashboards-machine-learning-workflows-and-ai-chatbots-with-streamlit-and-python-english-edition-s/9861ec986aa21894. Acesso em: 28 maio. 2026. Citado 2 vezes nas páginas 30 e 62.

47 PRESSMAN, R. S.; MAXIM, B. R. *Engenharia de Software: Uma Abordagem Profissional*. 8. ed. Porto Alegre: Artmed, 2016. ISBN 978-8582603659. Citado 2 vezes nas páginas 30 e 72.

48 CLOUD, A. *Qwen3.7-Plus: Modelo de linguagem de inteligência artificial*. Hangzhou, China: [s.n.], 2026. https://chat.qwen.ai/. Acesso em: 16 nov. 2026. Citado na página 31.

49 PIMENTEL, M. F. et al. Convertion of a sequential inductively coupled plasma emission spectrometer into a multichannel simultaneous system using a photodiode array detector. *Journal of Automatic Chemistry*, USA, v. 20, n. 3, p. 69–75, 1998. DOI: https://doi.org/10.1155/S146392469800008X. Disponível em: https://onlinelibrary.wiley.com/doi/10.1155/S146392469800008X. Acesso em: 29 mar. 2025. Citado 2 vezes nas páginas 34 e 35.

50 KRAMER, R. *Chemometric Techniques for Quantitative Analysis*. USA: CRC Press, 1998. 220 p. Citado 2 vezes nas páginas 34 e 35.

51 MARTENS, H.; NAES, T. *Multivariate Calibration*. USA: John Wiley & Sons Ltd, 1989. 399 p. Citado na página 34.

52 WESTAD, F.; FLÅTEN, G. R. A retrospective view on non-linear methods in chemometrics, and future directions. *Frontiers in Analytical Science*, v. 4, 2024. DOI: https://doi.org/10.3389/frans.2024.1393222. Disponível em: https://www.frontiersin.org/journals/analytical-science/articles/10.3389/frans.2024.1393222/full. Acesso em: 3 out. 2025. Citado 2 vezes nas páginas 36 e 37.

53 PERIS-DIAZ, M. D.; KREZEL, A. A guide to good practice in chemometric methods for vibrational spectroscopy, electrochemistry, and hyphenated mass spectrometry. *TrAC Trends in Analytical Chemistry*, v. 135, p. 116157, 2021. DOI: https://doi.org/10.1016/j.trac.2020.116157.

Disponível em: https://www.sciencedirect.com/science/article/pii/S0165993620303861?via%3Dihub. Acesso em: 3 out. 2025. Citado 2 vezes nas páginas 36 e 37.

54 HODSON, T. O. Root-mean-square error (RMSE) or mean absolute error (MAE): when to use them or not. *Geoscientific Model Development*, Copernicus Publications, v. 15, n. 14, p. 5481–5487, 2022. DOI: doi.org/10.5194/gmd-15-5481-2022. Disponível em: https://pubs.usgs.gov/publication/70236308. Acesso em: 3 mar. 2026. Citado na página 37.

55 EZENARRO, J.; SCHORN-GARCÍA, D. How are chemometric models validated? A systematic review of linear regression models for NIRS data in food analysis. *Journal of Chemometrics*, Wiley, v. 39, n. 6, p. e70036, 2025. DOI: https://doi.org/10.1002/cem.70036. Disponível em: https://analyticalsciencejournals.onlinelibrary.wiley.com/doi/10.1002/cem.70036. Acesso em: 5 mar. 2026. Citado na página 37.

56 TAKAHASHI, T.; THORNTON, B. Quantitative methods for compensation of matrix effects and self-absorption in laser induced breakdown spectroscopy signals of solids. *Spectrochimica Acta Part B: Atomic Spectroscopy*, v. 138, p. 31–42, 2017. ISSN 0584-8547. Disponível em: https://www.sciencedirect.com/science/article/pii/S0584854716303299. Acesso em: 27 set. 2026. Citado na página 48.

57 FIELDING, R. T. et al. *Hypertext Transfer Protocol – HTTP/1.1*. Reston, Virginia USA, 1999. Disponível em: https://www.rfc-editor.org/rfc/rfc2616. Acesso em: 16 nov. 2026. Citado na página 62.

58 BUSCHMANN, F. et al. *Pattern-Oriented Software Architecture, Volume 1: A System of Patterns*. Chichester, UK: John Wiley & Sons, 1996. ISBN 978-0471958697. Disponível em: https://dl.acm.org/doi/book/10.5555/249013#cited-by-sec. Acesso em: 17 nov. 2026. Citado na página 63.

59 Microsoft. *Visual Studio Code: Code Editing. Redefined*. 2024. Disponível em: https://code.visualstudio.com. Acesso em: 28 maio. 2026. Citado na página 66.

60 MARTIN, R. C. *Clean Code: A Handbook of Agile Software Craftsmanship*. 1. ed. Upper Saddle River, NJ: Prentice Hall PTR, 2008. 464 p. (Robert C. Martin Series). ISBN 978-0-13-235088-4. Disponível em: https://www.pearson.de/clean-code-a-handbook-of-agile-software-craftsmanship-9780132350884. Acesso em: 28 maio. 2026. Citado na página 70.

61 SCHWABER, K.; SUTHERLAND, J. *O Guia do Scrum*. 2020. Disponível em: https://scrumguides.org/scrum-guide.html. Acesso em: 20 jun. 2026. Citado na página 71.

62 Pytest Development Team. *pytest: helps you write better programs*. 2024. Disponível em: https://docs.pytest.org/en/stable/. Disponível em: https://docs.pytest.org/en/stable/. Acesso em: 20 jun. 2026. Citado na página 72.

63 JORGENSEN, P. C. *Software Testing: A Craftsman's Approach*. 4. ed. Boca Raton: CRC Press, 2014. Citado na página 72.

# Apêndices

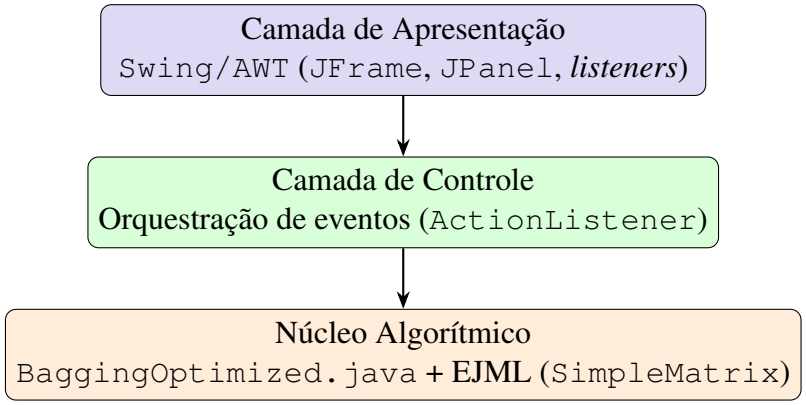
# APÊNDICE A – TESTES DE GRÁFICOS

Este apêndice reúne, para fins de verificação visual, os diagramas UML e PlantUML produzidos ao longo da modernização do sistema — desde a base algorítmica em Java (Desktop) até a reescrita final em Python/Streamlit. Cada diagrama é apresentado em uma figura individual, identificada por seção e *label* próprios para permitir referência cruzada em seções posteriores.

## A.1 Diagrama de Arquitetura em Camadas — Java e Python

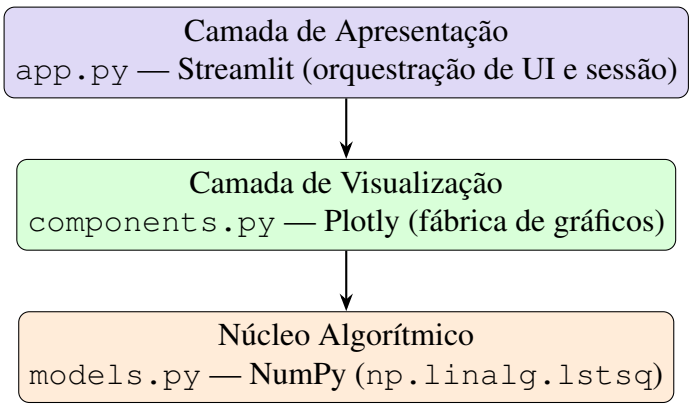
Complementando os diagramas de classes, atividade e sequência das seções seguintes, as Figuras 16 e 17 apresentam a organização em camadas de cada sistema, permitindo comparar diretamente como a mesma separação de responsabilidades (interface, orquestração/controle e núcleo algorítmico) foi realizada em cada plataforma.

Figura 16 – Arquitetura em camadas — Sistema legado (Java Desktop)




Fonte: Wagner Oliveira de Araujo.

Figura 17 – Arquitetura em camadas — Sistema modernizado (Python/Streamlit)



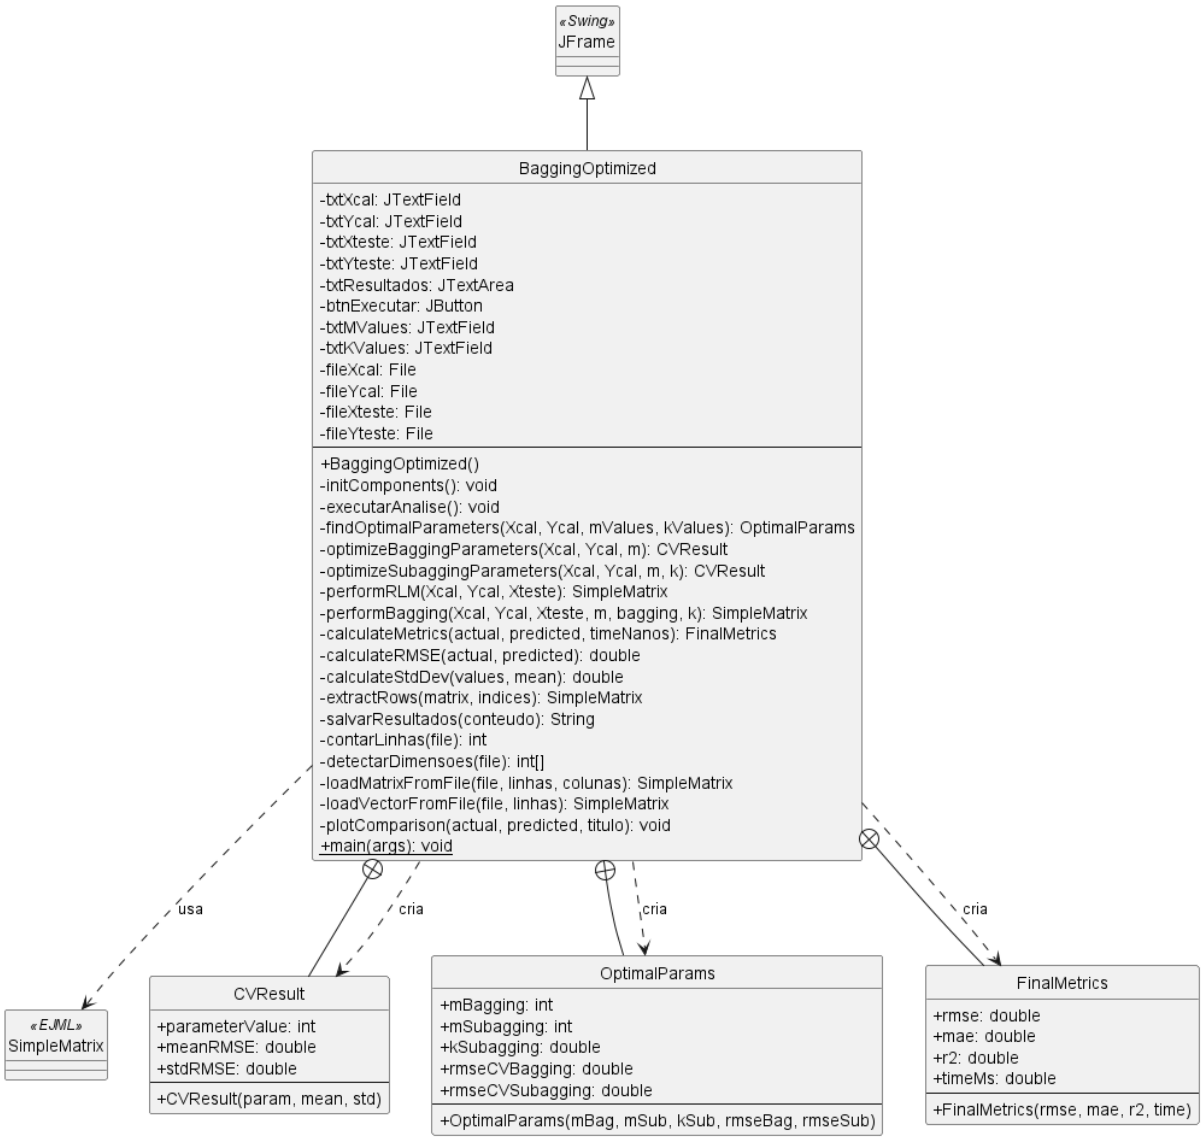

Fonte: Wagner Oliveira de Araujo.

Observa-se que a camada de núcleo algorítmico, isolada de qualquer dependência de interface em ambos os sistemas, é justamente onde reside a lógica validada pelos testes de

paridade amostra-a-amostra (Apêndice B) e pelos testes de caixa-preta (Seção 9.2).

## A.2 Diagrama de Classes — Java

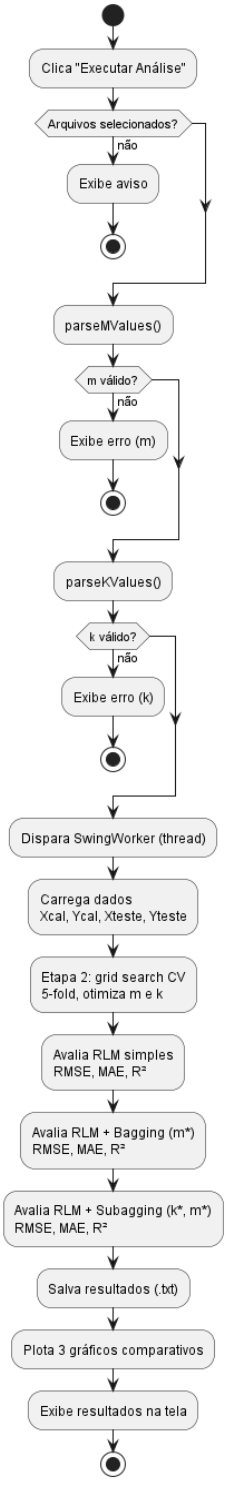
Figura 18 – Diagrama de classes.




Fonte: Wagner Oliveira de Araujo.

## A.3 Diagrama de Atividade — Java

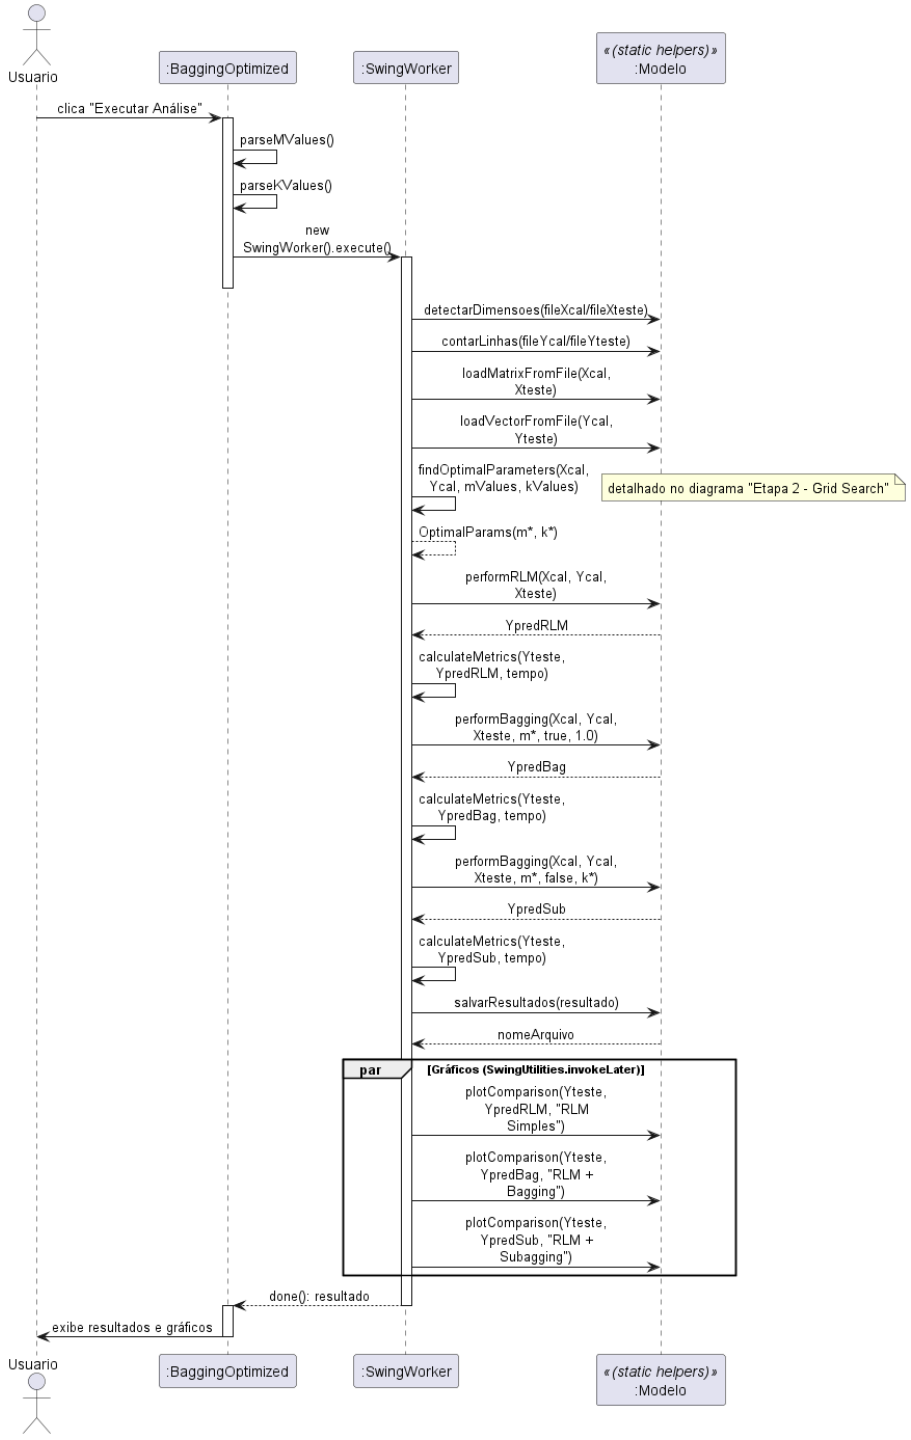
Figura 19 – Diagrama de atividades.




Fonte: Wagner Oliveira de Araujo.

## A.4 Diagrama de Sequência — Java

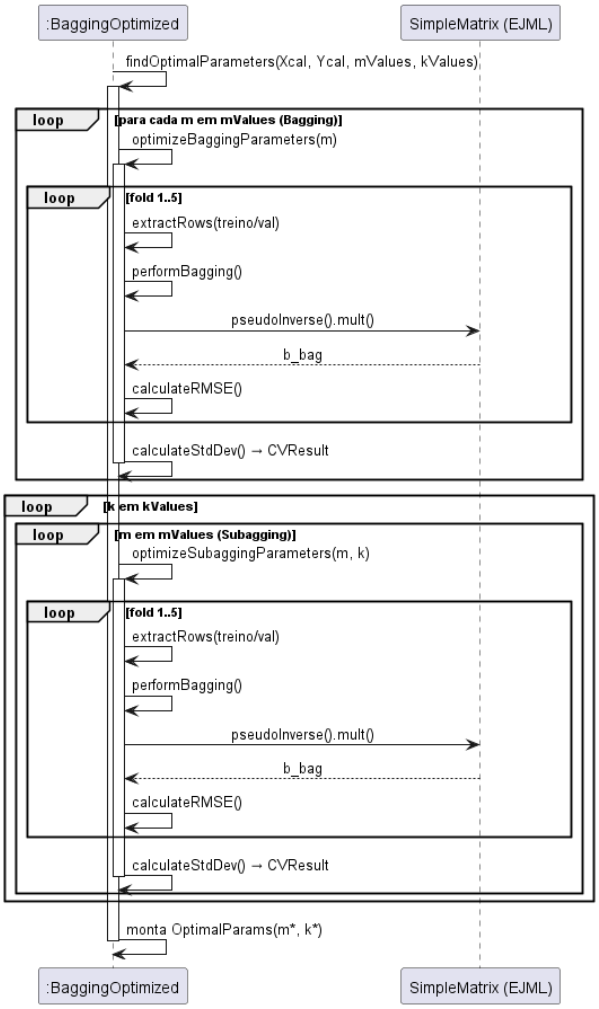
Figura 20 – Diagrama de sequência.




Fonte: Wagner Oliveira de Araujo.

## A.5 Diagrama de Atividades — Java (PlantUML)

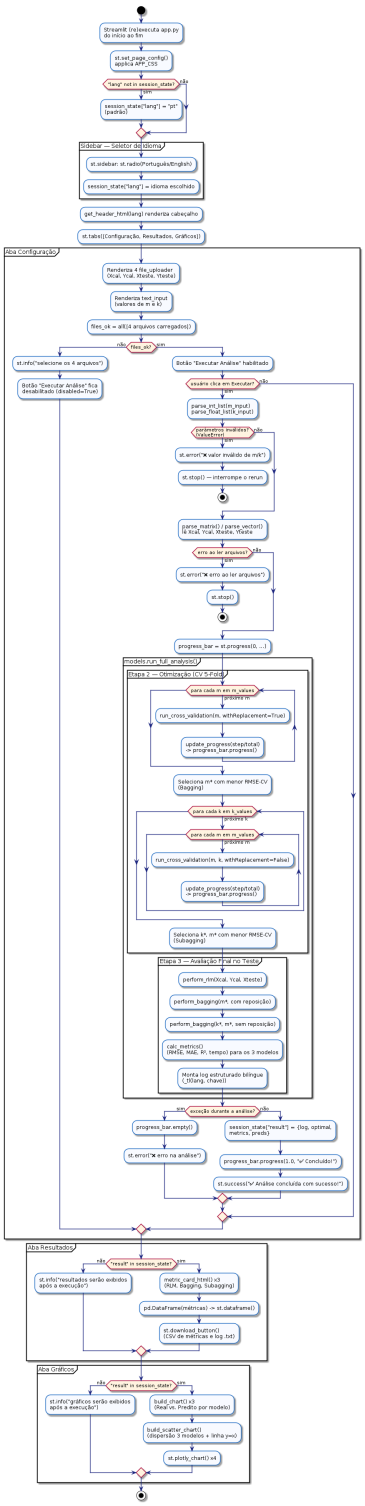
Figura 21 – Diagrama de atividade PlantUML.




Fonte: Wagner Oliveira de Araujo.

## A.6 Diagrama de Atividades — Streamlit

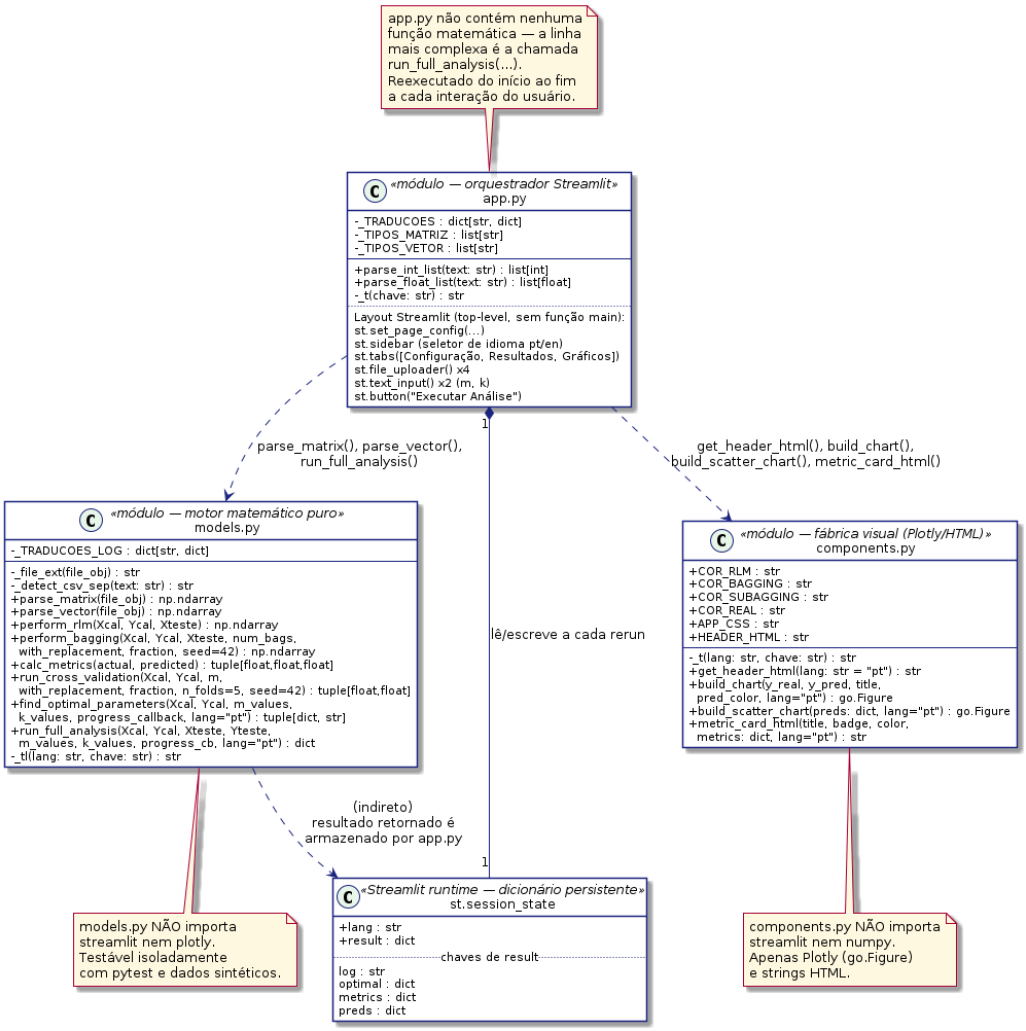
Figura 22 – Diagrama de atividade PlantUML.




Fonte: Wagner Oliveira de Araujo.

## A.7 Diagrama de Classes (Módulos) — Streamlit

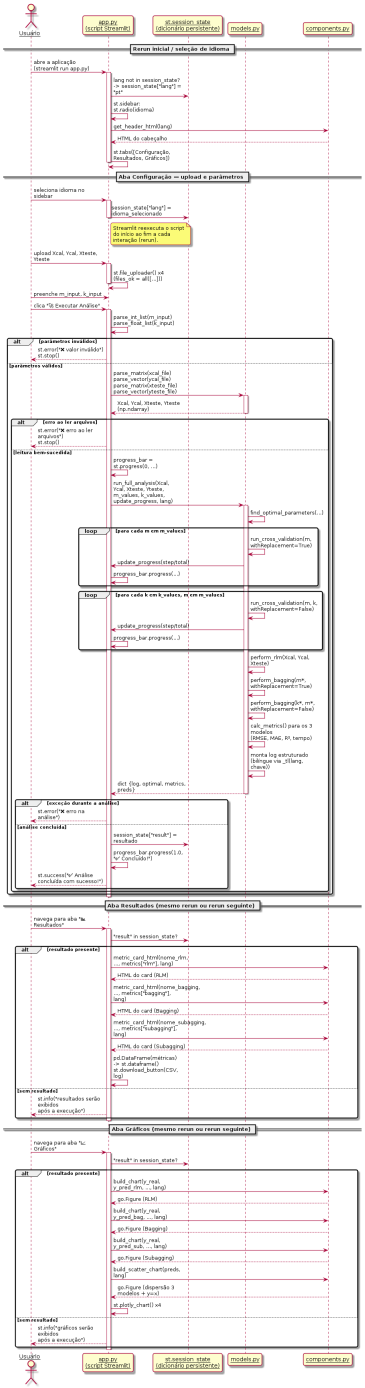
Figura 23 – Diagrama de classes (módulos) PlantUML.




Fonte: Wagner Oliveira de Araujo.

## A.8 Diagrama de Sequência — Streamlit

Figura 24 – Diagrama de sequência PlantUML.




Fonte: Wagner Oliveira de Araujo.

# APÊNDICE B – TABELAS DE PARIDADE AMOSTRA-A-AMOSTRA — JAVA × PYTHON

Este apêndice reúne, para os cinco analitos avaliados (Manganês, Molibdênio, Cromo, Níquel e Ferro) e para as três técnicas de regressão implementadas (RLM, *Bagging* e *Subagging*), a comparação amostra-a-amostra entre o valor predito pelo sistema Java legado e o valor predito pelo sistema Python/Streamlit modernizado, frente ao valor de referência (Y real) do conjunto de teste. Essas tabelas complementam os testes de caixa-preta descritos na Seção 9.2, que verificam a equivalência por meio de métricas agregadas (RMSEP, MAE, $R^2$): aqui, a equivalência é demonstrada em nível de cada predição individual, evidenciando que a migração de plataforma não introduziu perdas de acurácia amostra a amostra.

Tabela 11 – Paridade *Bagging* – Fe.

| Amostra | Y real | Y predito (Java)[a] | Y predito (Python) | Δ |
|---|---|---|---|---|
| 1 | 200,000 | 201,2347 | 201,2347 | 0,0000 |
| 2 | 170,000 | 171,1741 | 171,1741 | 0,0000 |
| 3 | 160,000 | 162,5467 | 162,5467 | 0,0000 |
| 4 | 160,000 | 160,2073 | 160,2073 | 0,0000 |
| 5 | 150,000 | 151,4182 | 151,4182 | 0,0000 |
| 6 | 130,000 | 131,4313 | 131,4313 | 0,0000 |
| 7 | 140,000 | 140,8831 | 140,8831 | 0,0000 |
| 8 | 170,000 | 171,2164 | 171,2164 | 0,0000 |
| 9 | 200,000 | 199,1764 | 199,1764 | 0,0000 |
| 10 | 160,000 | 159,3144 | 159,3144 | 0,0000 |
| 11 | 226,190 | 231,0960 | 231,0960 | 0,0000 |
| 12 | 222,460 | 222,6728 | 222,6728 | 0,0000 |
| 13 | 222,370 | 226,7032 | 226,7032 | 0,0000 |
| 14 | 187,090 | 188,5555 | 188,5555 | 0,0000 |
| 15 | 186,790 | 184,3893 | 184,3893 | 0,0000 |
| 16 | 185,180 | 191,2621 | 191,2621 | 0,0000 |
| 17 | 186,320 | 187,1853 | 187,1853 | 0,0000 |
| 18 | 184,630 | 182,3263 | 182,3263 | 0,0000 |
| 19 | 189,600 | 196,2627 | 196,2627 | 0,0000 |
| 20 | 188,630 | 192,6022 | 192,6022 | 0,0000 |
| 21 | 187,620 | 186,6603 | 186,6603 | 0,0000 |
| 22 | 201,920 | 204,7633 | 204,7633 | 0,0000 |
| 23 | 202,400 | 201,5573 | 201,5573 | 0,0000 |
| 24 | 201,360 | 201,6813 | 201,6813 | 0,0000 |
| 25 | 130,950 | 134,2735 | 134,2735 | 0,0000 |
| 26 | 132,830 | 133,0646 | 133,0646 | 0,0000 |
| 27 | 177,820 | 178,4886 | 178,4886 | 0,0000 |
| 28 | 177,850 | 178,7110 | 178,7110 | 0,0000 |
| 29 | 217,680 | 221,7617 | 221,7617 | 0,0000 |
| 30 | 218,800 | 221,0220 | 221,0220 | 0,0000 |
| 31 | 216,990 | 218,1427 | 218,1427 | 0,0000 |
| 32 | 170,520 | 175,7446 | 175,7446 | 0,0000 |
| 33 | 170,180 | 171,4528 | 171,4528 | 0,0000 |
| 34 | 170,180 | 171,6698 | 171,6698 | 0,0000 |

Fonte: Wagner Oliveira de Araujo.

[a] Tipo de dado utilizado em Java foi o *double*; no Python, o equivalente é o *float64* do NumPy — ambos representações IEEE 754 de precisão dupla (64 bits), o que garante paridade numérica exata entre as duas implementações.

**Nota:** $\Delta = |\mathrm{Y}_{\mathrm{Python}} - \mathrm{Y}_{\mathrm{Java}}|$. Todos os valores de $\Delta$ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica *Bagging* no analito Cromo (Fe).

Tabela 12 – Paridade *Bagging* – Mn.

| Amostra | Y real | Y predito (Java)[a] | Y predito (Python) | Δ |
|---|---|---|---|---|
| 1 | 2,000 | 2,0153 | 2,0153 | 0,0000 |
| 2 | 4,000 | 3,9981 | 3,9981 | 0,0000 |
| 3 | 5,000 | 4,9809 | 4,9809 | 0,0000 |
| 4 | 2,500 | 2,5041 | 2,5041 | 0,0000 |
| 5 | 3,500 | 3,4813 | 3,4813 | 0,0000 |
| 6 | 4,500 | 4,4478 | 4,4478 | 0,0000 |
| 7 | 1,500 | 1,5056 | 1,5056 | 0,0000 |
| 8 | 3,700 | 3,6941 | 3,6941 | 0,0000 |
| 9 | 2,200 | 2,0499 | 2,0499 | 0,0000 |
| 10 | 3,200 | 3,1082 | 3,1082 | 0,0000 |
| 11 | 1,250 | 1,2605 | 1,2605 | 0,0000 |
| 12 | 1,229 | 1,0868 | 1,0868 | 0,0000 |
| 13 | 1,228 | 1,0790 | 1,0790 | 0,0000 |
| 14 | 1,050 | 1,1285 | 1,1285 | 0,0000 |
| 15 | 1,048 | 0,9638 | 0,9638 | 0,0000 |
| 16 | 2,016 | 2,1255 | 2,1255 | 0,0000 |
| 17 | 2,028 | 1,9454 | 1,9454 | 0,0000 |
| 18 | 2,010 | 1,8625 | 1,8625 | 0,0000 |
| 19 | 1,093 | 1,1769 | 1,1769 | 0,0000 |
| 20 | 1,087 | 1,0067 | 1,0067 | 0,0000 |
| 21 | 1,081 | 0,9659 | 0,9659 | 0,0000 |
| 22 | 2,297 | 2,3751 | 2,3751 | 0,0000 |
| 23 | 2,302 | 2,1683 | 2,1683 | 0,0000 |
| 24 | 2,290 | 2,1728 | 2,1728 | 0,0000 |
| 25 | 1,935 | 2,0812 | 2,0812 | 0,0000 |
| 26 | 1,963 | 1,9299 | 1,9299 | 0,0000 |
| 27 | 1,768 | 1,6882 | 1,6882 | 0,0000 |
| 28 | 1,768 | 1,6861 | 1,6861 | 0,0000 |
| 29 | 1,505 | 1,4854 | 1,4854 | 0,0000 |
| 30 | 1,513 | 1,3303 | 1,3303 | 0,0000 |
| 31 | 1,500 | 1,3175 | 1,3175 | 0,0000 |
| 32 | 3,783 | 3,9578 | 3,9578 | 0,0000 |
| 33 | 3,776 | 3,6993 | 3,6993 | 0,0000 |
| 34 | 3,776 | 3,6902 | 3,6902 | 0,0000 |

Fonte: Wagner Oliveira de Araujo.

[a] Tipo de dado utilizado em Java foi o *double*; no Python, o equivalente é o *float64* do NumPy — ambos representações IEEE 754 de precisão dupla (64 bits), o que garante paridade numérica exata entre as duas implementações.
**Nota:** $\Delta = |\mathrm{Y}_{\mathrm{Python}} - \mathrm{Y}_{\mathrm{Java}}|$. Todos os valores de $\Delta$ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica *Bagging* no analito Cromo (Mn).

Tabela 13 – Paridade *Bagging* – Ni.

| Amostra | Y real | Y predito (Java) | Y predito (Python) | Δ |
|---|---|---|---|---|
| 1 | 15,000 | 15,7904 | 15,7904 | 0,0000 |
| 2 | 30,000 | 30,4864 | 30,4864 | 0,0000 |
| 3 | 20,000 | 20,6410 | 20,6410 | 0,0000 |
| 4 | 50,000 | 50,7132 | 50,7132 | 0,0000 |
| 5 | 45,000 | 46,0191 | 46,0191 | 0,0000 |
| 6 | 60,000 | 60,3324 | 60,3324 | 0,0000 |
| 7 | 35,000 | 35,6279 | 35,6279 | 0,0000 |
| 8 | 48,000 | 48,7008 | 48,7008 | 0,0000 |
| 9 | 25,000 | 25,0248 | 25,0248 | 0,0000 |
| 10 | 38,000 | 38,1906 | 38,1906 | 0,0000 |
| 11 | 31,242 | 33,7431 | 33,7431 | 0,0000 |
| 12 | 31,434 | 33,4756 | 33,4756 | 0,0000 |
| 13 | 31,149 | 32,2768 | 32,2768 | 0,0000 |
| 14 | 52,029 | 55,5627 | 55,5627 | 0,0000 |
| 15 | 52,775 | 56,3382 | 56,3382 | 0,0000 |
| 16 | 21,809 | 23,4771 | 23,4771 | 0,0000 |
| 17 | 21,813 | 23,2773 | 23,2773 | 0,0000 |
| 18 | 25,048 | 27,0453 | 27,0453 | 0,0000 |
| 19 | 24,999 | 26,5735 | 26,5735 | 0,0000 |
| 20 | 24,999 | 26,5728 | 26,5728 | 0,0000 |

Fonte: Wagner Oliveira de Araujo.

[a] Tipo de dado utilizado em Java foi o *double*; no Python, o equivalente é o *float64* do NumPy — ambos representações IEEE 754 de precisão dupla (64 bits), o que garante paridade numérica exata entre as duas implementações.
**Nota:** $\Delta = |\mathrm{Y}_{\mathrm{Python}} - \mathrm{Y}_{\mathrm{Java}}|$. Todos os valores de $\Delta$ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica *Bagging* no analito Cromo (Ni).

Tabela 14 – Paridade *Bagging* – Mo.

| Amostra | Y real | Y predito (Java)[a] | Y predito (Python) | Δ |
|---|---|---|---|---|
| 1 | 3,000 | 3,2844 | 3,2844 | 0,0000 |
| 2 | 8,000 | 8,1148 | 8,1148 | 0,0000 |
| 3 | 5,000 | 5,2699 | 5,2699 | 0,0000 |
| 4 | 3,600 | 3,6603 | 3,6603 | 0,0000 |
| 5 | 4,000 | 4,2607 | 4,2607 | 0,0000 |
| 6 | 5,000 | 5,1603 | 5,1603 | 0,0000 |
| 7 | 9,000 | 9,0995 | 9,0995 | 0,0000 |
| 8 | 7,000 | 7,0161 | 7,0161 | 0,0000 |
| 9 | 2,800 | 2,6208 | 2,6208 | 0,0000 |
| 10 | 10,000 | 10,0238 | 10,0238 | 0,0000 |
| 11 | 2,422 | 2,5660 | 2,5660 | 0,0000 |
| 12 | 2,383 | 2,1786 | 2,1786 | 0,0000 |
| 13 | 2,382 | 2,5483 | 2,5483 | 0,0000 |
| 14 | 1,742 | 2,1182 | 2,1182 | 0,0000 |
| 15 | 1,746 | 1,9412 | 1,9412 | 0,0000 |
| 16 | 1,737 | 2,0297 | 2,0297 | 0,0000 |
| 17 | 5,547 | 5,8904 | 5,8904 | 0,0000 |
| 18 | 5,548 | 6,0116 | 6,0116 | 0,0000 |
| 19 | 6,407 | 7,2260 | 7,2260 | 0,0000 |
| 20 | 6,394 | 6,9924 | 6,9924 | 0,0000 |
| 21 | 6,394 | 6,9658 | 6,9658 | 0,0000 |

Fonte: Wagner Oliveira de Araujo.

[a] Tipo de dado utilizado em Java foi o *double*; no Python, o equivalente é o *float64* do NumPy — ambos representações IEEE 754 de precisão dupla (64 bits), o que garante paridade numérica exata entre as duas implementações.
**Nota:** $\Delta = |\mathrm{Y}_{\mathrm{Python}} - \mathrm{Y}_{\mathrm{Java}}|$. Todos os valores de $\Delta$ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica *Bagging* no analito Cromo (Mo).

Tabela 15 – Paridade *RLM* – Cr.

| Amostra | Y real | Y predito (Java)[a] | Y predito (Python) | Δ |
|---|---|---|---|---|
| 1 | 30,000 | 30,4401 | 30,4401 | 0,0 |
| 2 | 40,000 | 40,6027 | 40,6027 | 0,0 |
| 3 | 60,000 | 60,5929 | 60,5929 | 0,0 |
| 4 | 35,000 | 35,2358 | 35,2358 | 0,0 |
| 5 | 45,000 | 45,2398 | 45,2398 | 0,0 |
| 6 | 48,000 | 47,8566 | 47,8566 | 0,0 |
| 7 | 65,000 | 65,1068 | 65,1068 | 0,0 |
| 8 | 23,000 | 22,9505 | 22,9505 | 0,0 |
| 9 | 25,000 | 24,1470 | 24,1470 | 0,0 |
| 10 | 37,000 | 36,5572 | 36,5572 | 0,0 |
| 11 | 23,103 | 22,9549 | 22,9549 | 0,0 |
| 12 | 22,722 | 20,7987 | 20,7987 | 0,0 |
| 13 | 22,713 | 22,0081 | 22,0081 | 0,0 |
| 14 | 60,054 | 60,4145 | 60,4145 | 0,0 |
| 15 | 59,959 | 57,6637 | 57,6637 | 0,0 |
| 16 | 32,250 | 33,9133 | 33,9133 | 0,0 |
| 17 | 32,448 | 31,8925 | 31,8925 | 0,0 |
| 18 | 32,154 | 30,9060 | 30,9060 | 0,0 |
| 19 | 60,996 | 63,0862 | 63,0862 | 0,0 |
| 20 | 60,684 | 60,5654 | 60,5654 | 0,0 |
| 21 | 60,360 | 58,6691 | 58,6691 | 0,0 |
| 22 | 40,636 | 41,9072 | 41,9072 | 0,0 |
| 23 | 40,733 | 39,7794 | 39,7794 | 0,0 |
| 24 | 40,524 | 39,8836 | 39,8836 | 0,0 |
| 25 | 64,597 | 66,6507 | 66,6507 | 0,0 |
| 26 | 65,522 | 65,1239 | 65,1239 | 0,0 |
| 27 | 44,707 | 43,7105 | 43,7105 | 0,0 |
| 28 | 44,716 | 43,8560 | 43,8560 | 0,0 |
| 29 | 30,022 | 30,5536 | 30,5536 | 0,0 |
| 30 | 30,177 | 29,0491 | 29,0491 | 0,0 |
| 31 | 29,926 | 28,6567 | 28,6567 | 0,0 |
| 32 | 44,926 | 46,8013 | 46,8013 | 0,0 |
| 33 | 44,837 | 44,3839 | 44,3839 | 0,0 |
| 34 | 44,837 | 44,3501 | 44,3501 | 0,0 |

Fonte: Wagner Oliveira de Araujo.

[a] Tipo de dado utilizado em Java foi o *double*; no Python, o equivalente é o *float64* do NumPy — ambos representações IEEE 754 de precisão dupla (64 bits), o que garante paridade numérica exata entre as duas implementações.
**Nota:** $\Delta = |\mathrm{Y}_{\mathrm{Python}} - \mathrm{Y}_{\mathrm{Java}}|$. Todos os valores de $\Delta$ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica *Bagging* no analito Cromo (Cr).

Tabela 16 – Paridade *RLM* – Mo.

| Amostra | Y real | Y predito (Java)[a] | Y predito (Python) | Δ |
|---|---|---|---|---|
| 1 | 3,000 | 3,2312 | 3,2312 | 0,0 |
| 2 | 8,000 | 8,0690 | 8,0690 | 0,0 |
| 3 | 5,000 | 5,2252 | 5,2252 | 0,0 |
| 4 | 3,600 | 3,6276 | 3,6276 | 0,0 |
| 5 | 4,000 | 4,1362 | 4,1362 | 0,0 |
| 6 | 5,000 | 5,0582 | 5,0582 | 0,0 |
| 7 | 9,000 | 9,0103 | 9,0103 | 0,0 |
| 8 | 7,000 | 7,0129 | 7,0129 | 0,0 |
| 9 | 2,800 | 2,6673 | 2,6673 | 0,0 |
| 10 | 10,000 | 9,9628 | 9,9628 | 0,0 |
| 11 | 2,422 | 2,4751 | 2,4751 | 0,0 |
| 12 | 2,383 | 2,1994 | 2,1994 | 0,0 |
| 13 | 2,382 | 2,4692 | 2,4692 | 0,0 |
| 14 | 1,742 | 2,0321 | 2,0321 | 0,0 |
| 15 | 1,746 | 1,8651 | 1,8651 | 0,0 |
| 16 | 1,737 | 1,9493 | 1,9493 | 0,0 |
| 17 | 5,547 | 5,7680 | 5,7680 | 0,0 |
| 18 | 5,548 | 5,9010 | 5,9010 | 0,0 |
| 19 | 6,407 | 7,1323 | 7,1323 | 0,0 |
| 20 | 6,394 | 6,8709 | 6,8709 | 0,0 |
| 21 | 6,394 | 6,8308 | 6,8308 | 0,0 |

Fonte: Wagner Oliveira de Araujo.

[a] Tipo de dado utilizado em Java foi o *double*; no Python, o equivalente é o *float64* do NumPy — ambos representações IEEE 754 de precisão dupla (64 bits), o que garante paridade numérica exata entre as duas implementações.
**Nota:** $\Delta = |\mathrm{Y}_{\mathrm{Python}} - \mathrm{Y}_{\mathrm{Java}}|$. Todos os valores de $\Delta$ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica *Bagging* no analito Cromo (Mo).

Tabela 17 – Paridade *Subagging* – Cr.

| Amostra | Y real | Y predito (Java)[a] | Y predito (Python) | Δ |
|---|---|---|---|---|
| 1 | 30,000 | 30,1547 | 30,1547 | 0,0 |
| 2 | 40,000 | 39,9189 | 39,9189 | 0,0 |
| 3 | 60,000 | 59,9876 | 59,9876 | 0,0 |
| 4 | 35,000 | 34,8894 | 34,8894 | 0,0 |
| 5 | 45,000 | 44,6394 | 44,6394 | 0,0 |
| 6 | 48,000 | 47,3280 | 47,3280 | 0,0 |
| 7 | 65,000 | 64,7895 | 64,7895 | 0,0 |
| 8 | 23,000 | 22,7179 | 22,7179 | 0,0 |
| 9 | 25,000 | 23,9207 | 23,9207 | 0,0 |
| 10 | 37,000 | 36,0523 | 36,0523 | 0,0 |
| 11 | 23,103 | 22,8577 | 22,8577 | 0,0 |
| 12 | 22,722 | 20,5236 | 20,5236 | 0,0 |
| 13 | 22,713 | 21,6248 | 21,6248 | 0,0 |
| 14 | 60,054 | 60,0747 | 60,0747 | 0,0 |
| 15 | 59,959 | 57,2228 | 57,2228 | 0,0 |
| 16 | 32,250 | 33,6311 | 33,6311 | 0,0 |
| 17 | 32,448 | 31,6253 | 31,6253 | 0,0 |
| 18 | 32,154 | 30,5525 | 30,5525 | 0,0 |
| 19 | 60,996 | 62,9301 | 62,9301 | 0,0 |
| 20 | 60,684 | 60,3038 | 60,3038 | 0,0 |
| 21 | 60,360 | 58,2638 | 58,2638 | 0,0 |
| 22 | 40,636 | 41,4631 | 41,4631 | 0,0 |
| 23 | 40,733 | 39,3369 | 39,3369 | 0,0 |
| 24 | 40,524 | 39,3585 | 39,3585 | 0,0 |
| 25 | 64,597 | 66,5127 | 66,5127 | 0,0 |
| 26 | 65,522 | 65,1206 | 65,1206 | 0,0 |
| 27 | 44,707 | 43,1986 | 43,1986 | 0,0 |
| 28 | 44,716 | 43,3023 | 43,3023 | 0,0 |
| 29 | 30,022 | 30,3558 | 30,3558 | 0,0 |
| 30 | 30,177 | 28,6899 | 28,6899 | 0,0 |
| 31 | 29,926 | 28,1980 | 28,1980 | 0,0 |
| 32 | 44,926 | 46,1193 | 46,1193 | 0,0 |
| 33 | 44,837 | 43,7828 | 43,7828 | 0,0 |
| 34 | 44,837 | 43,6620 | 43,6620 | 0,0 |

Fonte: Wagner Oliveira de Araujo.

[a] Tipo de dado utilizado em Java foi o *double*; no Python, o equivalente é o *float64* do NumPy — ambos representações IEEE 754 de precisão dupla (64 bits), o que garante paridade numérica exata entre as duas implementações.
**Nota:** $\Delta = |\mathrm{Y}_{\mathrm{Python}} - \mathrm{Y}_{\mathrm{Java}}|$. Todos os valores de $\Delta$ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica *Bagging* no analito Cromo (Cr).

Tabela 18 – Paridade *RLM* – Fe.

| Amostra | Y real | Y predito (Java)[a] | Y predito (Python) | Δ |
|---|---|---|---|---|
| 1 | 200,000 | 201,3675 | 201,3675 | 0,0 |
| 2 | 170,000 | 171,6284 | 171,6284 | 0,0 |
| 3 | 160,000 | 162,8586 | 162,8586 | 0,0 |
| 4 | 160,000 | 160,3428 | 160,3428 | 0,0 |
| 5 | 150,000 | 151,4730 | 151,4730 | 0,0 |
| 6 | 130,000 | 131,2829 | 131,2829 | 0,0 |
| 7 | 140,000 | 140,9123 | 140,9123 | 0,0 |
| 8 | 170,000 | 172,1247 | 172,1247 | 0,0 |
| 9 | 200,000 | 200,0870 | 200,0870 | 0,0 |
| 10 | 160,000 | 159,7659 | 159,7659 | 0,0 |
| 11 | 226,190 | 230,8332 | 230,8332 | 0,0 |
| 12 | 222,460 | 223,5541 | 223,5541 | 0,0 |
| 13 | 222,370 | 227,3945 | 227,3945 | 0,0 |
| 14 | 187,090 | 188,8822 | 188,8822 | 0,0 |
| 15 | 186,790 | 184,4505 | 184,4505 | 0,0 |
| 16 | 185,180 | 190,9301 | 190,9301 | 0,0 |
| 17 | 186,320 | 187,3890 | 187,3890 | 0,0 |
| 18 | 184,630 | 182,9002 | 182,9002 | 0,0 |
| 19 | 189,600 | 196,1038 | 196,1038 | 0,0 |
| 20 | 188,630 | 192,7129 | 192,7129 | 0,0 |
| 21 | 187,620 | 186,7261 | 186,7261 | 0,0 |
| 22 | 201,920 | 204,5577 | 204,5577 | 0,0 |
| 23 | 202,400 | 201,9671 | 201,9671 | 0,0 |
| 24 | 201,360 | 202,1703 | 202,1703 | 0,0 |
| 25 | 130,950 | 134,1479 | 134,1479 | 0,0 |
| 26 | 132,830 | 132,1917 | 132,1917 | 0,0 |
| 27 | 177,820 | 178,5687 | 178,5687 | 0,0 |
| 28 | 177,850 | 178,9440 | 178,9440 | 0,0 |
| 29 | 217,680 | 221,3581 | 221,3581 | 0,0 |
| 30 | 218,800 | 221,6059 | 221,6059 | 0,0 |
| 31 | 216,990 | 219,0625 | 219,0625 | 0,0 |
| 32 | 170,520 | 175,9362 | 175,9362 | 0,0 |
| 33 | 170,180 | 171,7899 | 171,7899 | 0,0 |
| 34 | 170,180 | 172,1441 | 172,1441 | 0,0 |

Fonte: Wagner Oliveira de Araujo.

[a] Tipo de dado utilizado em Java foi o *double*; no Python, o equivalente é o *float64* do NumPy — ambos representações IEEE 754 de precisão dupla (64 bits), o que garante paridade numérica exata entre as duas implementações.
**Nota:** $\Delta = |Y_{\text{Python}} - Y_{\text{Java}}|$. Todos os valores de $\Delta$ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica *Bagging* no analito Cromo (Fe).

Tabela 19 – Paridade *RLM* – Ni.

| Amostra | Y real | Y predito (Java)[a] | Y predito (Python) | Δ |
|---|---|---|---|---|
| 1 | 15,000 | 15,6181 | 15,6181 | 0,0 |
| 2 | 30,000 | 30,5664 | 30,5664 | 0,0 |
| 3 | 20,000 | 20,6828 | 20,6828 | 0,0 |
| 4 | 50,000 | 50,5499 | 50,5499 | 0,0 |
| 5 | 45,000 | 45,9700 | 45,9700 | 0,0 |
| 6 | 60,000 | 60,3713 | 60,3713 | 0,0 |
| 7 | 35,000 | 35,6232 | 35,6232 | 0,0 |
| 8 | 48,000 | 48,8117 | 48,8117 | 0,0 |
| 9 | 25,000 | 25,3044 | 25,3044 | 0,0 |
| 10 | 38,000 | 38,2514 | 38,2514 | 0,0 |
| 11 | 31,242 | 33,4020 | 33,4020 | 0,0 |
| 12 | 31,434 | 33,4244 | 33,4244 | 0,0 |
| 13 | 31,149 | 32,4378 | 32,4378 | 0,0 |
| 14 | 52,029 | 55,4537 | 55,4537 | 0,0 |
| 15 | 52,775 | 56,0699 | 56,0699 | 0,0 |
| 16 | 21,809 | 23,4975 | 23,4975 | 0,0 |
| 17 | 21,813 | 23,3956 | 23,3956 | 0,0 |
| 18 | 25,048 | 26,8478 | 26,8478 | 0,0 |
| 19 | 24,999 | 26,6769 | 26,6769 | 0,0 |
| 20 | 24,999 | 26,8538 | 26,8538 | 0,0 |

Fonte: Wagner Oliveira de Araujo.

[a] Tipo de dado utilizado em Java foi o *double*; no Python, o equivalente é o *float64* do NumPy — ambos representações IEEE 754 de precisão dupla (64 bits), o que garante paridade numérica exata entre as duas implementações.
**Nota:** $\Delta = |\mathrm{Y}_{\mathrm{Python}} - \mathrm{Y}_{\mathrm{Java}}|$. Todos os valores de $\Delta$ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica *Bagging* no analito Cromo (Ni).

Tabela 20 – Paridade *RLM* – Mn.

| Amostra | Y real | Y predito (Java)[a] | Y predito (Python) | Δ |
|---|---|---|---|---|
| 1 | 2,000 | 2,0441 | 2,0441 | 0,0 |
| 2 | 4,000 | 4,0317 | 4,0317 | 0,0 |
| 3 | 5,000 | 4,9755 | 4,9755 | 0,0 |
| 4 | 2,500 | 2,5277 | 2,5277 | 0,0 |
| 5 | 3,500 | 3,5166 | 3,5166 | 0,0 |
| 6 | 4,500 | 4,4755 | 4,4755 | 0,0 |
| 7 | 1,500 | 1,5306 | 1,5306 | 0,0 |
| 8 | 3,700 | 3,7306 | 3,7306 | 0,0 |
| 9 | 2,200 | 2,0483 | 2,0483 | 0,0 |
| 10 | 3,200 | 3,1410 | 3,1410 | 0,0 |
| 11 | 1,250 | 1,3246 | 1,3246 | 0,0 |
| 12 | 1,229 | 1,1092 | 1,1092 | 0,0 |
| 13 | 1,228 | 1,1021 | 1,1021 | 0,0 |
| 14 | 1,050 | 1,1513 | 1,1513 | 0,0 |
| 15 | 1,048 | 0,9547 | 0,9547 | 0,0 |
| 16 | 2,016 | 2,1754 | 2,1754 | 0,0 |
| 17 | 2,028 | 1,9594 | 1,9594 | 0,0 |
| 18 | 2,010 | 1,8714 | 1,8714 | 0,0 |
| 19 | 1,093 | 1,1930 | 1,1930 | 0,0 |
| 20 | 1,087 | 0,9912 | 0,9912 | 0,0 |
| 21 | 1,081 | 0,9568 | 0,9568 | 0,0 |
| 22 | 2,297 | 2,4229 | 2,4229 | 0,0 |
| 23 | 2,302 | 2,1744 | 2,1744 | 0,0 |
| 24 | 2,290 | 2,1834 | 2,1834 | 0,0 |
| 25 | 1,935 | 2,1058 | 2,1058 | 0,0 |
| 26 | 1,963 | 1,9624 | 1,9624 | 0,0 |
| 27 | 1,768 | 1,7019 | 1,7019 | 0,0 |
| 28 | 1,768 | 1,6913 | 1,6913 | 0,0 |
| 29 | 1,505 | 1,5456 | 1,5456 | 0,0 |
| 30 | 1,513 | 1,3417 | 1,3417 | 0,0 |
| 31 | 1,500 | 1,3242 | 1,3242 | 0,0 |
| 32 | 3,783 | 4,0186 | 4,0186 | 0,0 |
| 33 | 3,776 | 3,7449 | 3,7449 | 0,0 |
| 34 | 3,776 | 3,7318 | 3,7318 | 0,0 |

Fonte: Wagner Oliveira de Araujo.

[a] Tipo de dado utilizado em Java foi o *double*; no Python, o equivalente é o *float64* do NumPy — ambos representações IEEE 754 de precisão dupla (64 bits), o que garante paridade numérica exata entre as duas implementações.
**Nota:** $\Delta = |\mathrm{Y}_{\mathrm{Python}} - \mathrm{Y}_{\mathrm{Java}}|$. Todos os valores de $\Delta$ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica *Bagging* no analito Cromo (Mn).

Tabela 21 – Paridade *Subagging* – Fe.

| Amostra | Y real | Y predito (Java)[a] | Y predito (Python) | Δ |
|---|---|---|---|---|
| 1 | 200,000 | 201,0091 | 201,0091 | 0,0 |
| 2 | 170,000 | 170,8332 | 170,8332 | 0,0 |
| 3 | 160,000 | 162,3268 | 162,3268 | 0,0 |
| 4 | 160,000 | 160,0403 | 160,0403 | 0,0 |
| 5 | 150,000 | 151,2045 | 151,2045 | 0,0 |
| 6 | 130,000 | 131,2211 | 131,2211 | 0,0 |
| 7 | 140,000 | 140,8559 | 140,8559 | 0,0 |
| 8 | 170,000 | 171,1367 | 171,1367 | 0,0 |
| 9 | 200,000 | 199,1951 | 199,1951 | 0,0 |
| 10 | 160,000 | 159,0988 | 159,0988 | 0,0 |
| 11 | 226,190 | 231,0943 | 231,0943 | 0,0 |
| 12 | 222,460 | 222,8628 | 222,8628 | 0,0 |
| 13 | 222,370 | 226,8653 | 226,8653 | 0,0 |
| 14 | 187,090 | 188,4710 | 188,4710 | 0,0 |
| 15 | 186,790 | 184,3402 | 184,3402 | 0,0 |
| 16 | 185,180 | 190,9941 | 190,9941 | 0,0 |
| 17 | 186,320 | 187,1093 | 187,1093 | 0,0 |
| 18 | 184,630 | 182,3256 | 182,3256 | 0,0 |
| 19 | 189,600 | 196,1556 | 196,1556 | 0,0 |
| 20 | 188,630 | 192,6410 | 192,6410 | 0,0 |
| 21 | 187,620 | 186,6622 | 186,6622 | 0,0 |
| 22 | 201,920 | 204,5022 | 204,5022 | 0,0 |
| 23 | 202,400 | 201,5124 | 201,5124 | 0,0 |
| 24 | 201,360 | 201,6347 | 201,6347 | 0,0 |
| 25 | 130,950 | 134,1539 | 134,1539 | 0,0 |
| 26 | 132,830 | 133,0960 | 133,0960 | 0,0 |
| 27 | 177,820 | 178,3030 | 178,3030 | 0,0 |
| 28 | 177,850 | 178,5385 | 178,5385 | 0,0 |
| 29 | 217,680 | 221,6976 | 221,6976 | 0,0 |
| 30 | 218,800 | 221,1559 | 221,1559 | 0,0 |
| 31 | 216,990 | 218,2779 | 218,2779 | 0,0 |
| 32 | 170,520 | 175,3388 | 175,3388 | 0,0 |
| 33 | 170,180 | 171,2162 | 171,2162 | 0,0 |
| 34 | 170,180 | 171,4580 | 171,4580 | 0,0 |

Fonte: Wagner Oliveira de Araujo.

[a] Tipo de dado utilizado em Java foi o *double*; no Python, o equivalente é o *float64* do NumPy — ambos representações IEEE 754 de precisão dupla (64 bits), o que garante paridade numérica exata entre as duas implementações.
**Nota:** $\Delta = |\mathrm{Y}_{\mathrm{Python}} - \mathrm{Y}_{\mathrm{Java}}|$. Todos os valores de $\Delta$ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica *Bagging* no analito Cromo (Fe).

Tabela 22 – Paridade *Subagging* – Mo.

| Amostra | Y real | Y predito (Java)[a] | Y predito (Python) | Δ |
|---|---|---|---|---|
| 1 | 3,000 | 3,2461 | 3,2461 | 0,0 |
| 2 | 8,000 | 8,0772 | 8,0772 | 0,0 |
| 3 | 5,000 | 5,2196 | 5,2196 | 0,0 |
| 4 | 3,600 | 3,6313 | 3,6313 | 0,0 |
| 5 | 4,000 | 4,1708 | 4,1708 | 0,0 |
| 6 | 5,000 | 5,0867 | 5,0867 | 0,0 |
| 7 | 9,000 | 9,0419 | 9,0419 | 0,0 |
| 8 | 7,000 | 7,0083 | 7,0083 | 0,0 |
| 9 | 2,800 | 2,6193 | 2,6193 | 0,0 |
| 10 | 10,000 | 9,9699 | 9,9699 | 0,0 |
| 11 | 2,422 | 2,5253 | 2,5253 | 0,0 |
| 12 | 2,383 | 2,1609 | 2,1609 | 0,0 |
| 13 | 2,382 | 2,4665 | 2,4665 | 0,0 |
| 14 | 1,742 | 2,0690 | 2,0690 | 0,0 |
| 15 | 1,746 | 1,8521 | 1,8521 | 0,0 |
| 16 | 1,737 | 1,9387 | 1,9387 | 0,0 |
| 17 | 5,547 | 5,7878 | 5,7878 | 0,0 |
| 18 | 5,548 | 5,9076 | 5,9076 | 0,0 |
| 19 | 6,407 | 7,1674 | 7,1674 | 0,0 |
| 20 | 6,394 | 6,8991 | 6,8991 | 0,0 |
| 21 | 6,394 | 6,8579 | 6,8579 | 0,0 |

Fonte: Wagner Oliveira de Araujo.

[a] Tipo de dado utilizado em Java foi o *double*; no Python, o equivalente é o *float64* do NumPy — ambos representações IEEE 754 de precisão dupla (64 bits), o que garante paridade numérica exata entre as duas implementações.
**Nota:** $\Delta = |\mathrm{Y}_{\mathrm{Python}} - \mathrm{Y}_{\mathrm{Java}}|$. Todos os valores de $\Delta$ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica *Bagging* no analito Cromo (Mo).

Tabela 23 – Paridade *Subagging* – Mn.

| Amostra | Y real | Y predito (Java)[a] | Y predito (Python) | Δ |
|---|---|---|---|---|
| 1 | 2,000 | 2,0088 | 2,0088 | 0,0 |
| 2 | 4,000 | 3,9880 | 3,9880 | 0,0 |
| 3 | 5,000 | 4,9797 | 4,9797 | 0,0 |
| 4 | 2,500 | 2,4954 | 2,4954 | 0,0 |
| 5 | 3,500 | 3,4684 | 3,4684 | 0,0 |
| 6 | 4,500 | 4,4303 | 4,4303 | 0,0 |
| 7 | 1,500 | 1,5007 | 1,5007 | 0,0 |
| 8 | 3,700 | 3,6739 | 3,6739 | 0,0 |
| 9 | 2,200 | 2,0319 | 2,0319 | 0,0 |
| 10 | 3,200 | 3,0903 | 3,0903 | 0,0 |
| 11 | 1,250 | 1,2602 | 1,2602 | 0,0 |
| 12 | 1,229 | 1,0783 | 1,0783 | 0,0 |
| 13 | 1,228 | 1,0738 | 1,0738 | 0,0 |
| 14 | 1,050 | 1,1324 | 1,1324 | 0,0 |
| 15 | 1,048 | 0,9554 | 0,9554 | 0,0 |
| 16 | 2,016 | 2,1216 | 2,1216 | 0,0 |
| 17 | 2,028 | 1,9282 | 1,9282 | 0,0 |
| 18 | 2,010 | 1,8453 | 1,8453 | 0,0 |
| 19 | 1,093 | 1,1846 | 1,1846 | 0,0 |
| 20 | 1,087 | 0,9996 | 0,9996 | 0,0 |
| 21 | 1,081 | 0,9579 | 0,9579 | 0,0 |
| 22 | 2,297 | 2,3711 | 2,3711 | 0,0 |
| 23 | 2,302 | 2,1490 | 2,1490 | 0,0 |
| 24 | 2,290 | 2,1537 | 2,1537 | 0,0 |
| 25 | 1,935 | 2,0800 | 2,0800 | 0,0 |
| 26 | 1,963 | 1,9192 | 1,9192 | 0,0 |
| 27 | 1,768 | 1,6718 | 1,6718 | 0,0 |
| 28 | 1,768 | 1,6675 | 1,6675 | 0,0 |
| 29 | 1,505 | 1,4858 | 1,4858 | 0,0 |
| 30 | 1,513 | 1,3205 | 1,3205 | 0,0 |
| 31 | 1,500 | 1,3057 | 1,3057 | 0,0 |
| 32 | 3,783 | 3,9483 | 3,9483 | 0,0 |
| 33 | 3,776 | 3,6782 | 3,6782 | 0,0 |
| 34 | 3,776 | 3,6669 | 3,6669 | 0,0 |

Fonte: Wagner Oliveira de Araujo.

[a] Tipo de dado utilizado em Java foi o *double*; no Python, o equivalente é o *float64* do NumPy — ambos representações IEEE 754 de precisão dupla (64 bits), o que garante paridade numérica exata entre as duas implementações.
**Nota:** $\Delta = |\mathrm{Y}_{\mathrm{Python}} - \mathrm{Y}_{\mathrm{Java}}|$. Todos os valores de $\Delta$ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica *Bagging* no analito Cromo (Mn).

Tabela 24 – Paridade *Subagging* – Ni.

| Amostra | Y real | Y predito (Java)[a] | Y predito (Python) | Δ |
|---|---|---|---|---|
| 1 | 15,000 | 15,7160 | 15,7160 | 0,0 |
| 2 | 30,000 | 30,4808 | 30,4808 | 0,0 |
| 3 | 20,000 | 20,5533 | 20,5533 | 0,0 |
| 4 | 50,000 | 50,6579 | 50,6579 | 0,0 |
| 5 | 45,000 | 45,9194 | 45,9194 | 0,0 |
| 6 | 60,000 | 60,2658 | 60,2658 | 0,0 |
| 7 | 35,000 | 35,6042 | 35,6042 | 0,0 |
| 8 | 48,000 | 48,6265 | 48,6265 | 0,0 |
| 9 | 25,000 | 24,9836 | 24,9836 | 0,0 |
| 10 | 38,000 | 38,1508 | 38,1508 | 0,0 |
| 11 | 31,242 | 33,6217 | 33,6217 | 0,0 |
| 12 | 31,434 | 33,2719 | 33,2719 | 0,0 |
| 13 | 31,149 | 32,1552 | 32,1552 | 0,0 |
| 14 | 52,029 | 55,5191 | 55,5191 | 0,0 |
| 15 | 52,775 | 56,1578 | 56,1578 | 0,0 |
| 16 | 21,809 | 23,3643 | 23,3643 | 0,0 |
| 17 | 21,813 | 23,1637 | 23,1637 | 0,0 |
| 18 | 25,048 | 26,9728 | 26,9728 | 0,0 |
| 19 | 24,999 | 26,4848 | 26,4848 | 0,0 |
| 20 | 24,999 | 26,4882 | 26,4882 | 0,0 |

Fonte: Wagner Oliveira de Araujo.

[a] Tipo de dado utilizado em Java foi o *double*; no Python, o equivalente é o *float64* do NumPy — ambos representações IEEE 754 de precisão dupla (64 bits), o que garante paridade numérica exata entre as duas implementações.
**Nota:** $\Delta = |\mathrm{Y}_{\mathrm{Python}} - \mathrm{Y}_{\mathrm{Java}}|$. Todos os valores de $\Delta$ são iguais a zero, indicando paridade perfeita entre as implementações Java e Python para a técnica *Bagging* no analito Cromo (Ni).

# APÊNDICE C – RESULTADO DOS TESTES

O Código 1 apresenta a saída de uma sessão do *pytest* 9.1.0 (Python 3.12.10, Windows) que executou o `test_suite_5.py`, com 92 testes: 21 unitários (leitura de matrizes TXT/CSV), 60 de caixa preta (RLM, *Bagging* e *Subagging*, com RMSE, MAE e $R^2$ para Cr, Ni e Fe) e 11 de estresse (tempo, RAM e escalabilidade). Conforme o Código 1, todos os testes passaram, sem falhas, em 75,25 segundos.

Código 1 – `Teste Consolidado`

```
============================= test session starts ==============================
platform win32 -- Python 3.12.10, pytest-9.1.0, pluggy-1.6.0
C:\Users\wagner.araujo\AppData\Local\Microsoft\WindowsApps\PythonSoftwareFoundation.Pyt⌋
↪  hon.3.12_qbz5n2kfra8p0\python.exe
cachedir: .pytest_cache
rootdir: L:\TCCI\D_Programacao\streamlit-app\tests
plugins: anyio-4.13.0
collecting ... collected 92 items

test_suite_5.py::TestUnitario::test_parse_matrix_txt_tab PASSED          [  1%]
test_suite_5.py::TestUnitario::test_parse_matrix_txt_virgula_br PASSED   [  2%]
test_suite_5.py::TestUnitario::test_parse_matrix_csv_ponto_virgula PASSED [  3%]
test_suite_5.py::TestUnitario::test_parse_matrix_csv_virgula PASSED      [  4%]
test_suite_5.py::TestUnitario::test_parse_matrix_ignora_linhas_vazias PASSED [  5%]
test_suite_5.py::TestUnitario::test_parse_vector_txt PASSED              [  6%]
test_suite_5.py::TestUnitario::test_parse_vector_csv PASSED              [  7%]
test_suite_5.py::TestUnitario::test_parse_vector_virgula_br PASSED       [  8%]
test_suite_5.py::TestUnitario::test_perform_rlm_shape PASSED             [  9%]
test_suite_5.py::TestUnitario::test_perform_rlm_sistema_exato PASSED     [ 10%]
test_suite_5.py::TestUnitario::test_perform_rlm_r2_alto PASSED           [ 11%]
test_suite_5.py::TestUnitario::test_bagging_shape PASSED                 [ 13%]
test_suite_5.py::TestUnitario::test_subagging_shape PASSED               [ 14%]
test_suite_5.py::TestUnitario::test_bagging_reprodutivel PASSED          [ 15%]
test_suite_5.py::TestUnitario::test_bagging_seeds_diferentes PASSED      [ 16%]
test_suite_5.py::TestUnitario::test_calc_metrics_perfeito PASSED         [ 17%]
test_suite_5.py::TestUnitario::test_calc_metrics_valores_conhecidos PASSED [ 18%]
test_suite_5.py::TestUnitario::test_calc_metrics_r2_negativo PASSED      [ 19%]
test_suite_5.py::TestUnitario::test_calc_metrics_retorna_floats PASSED   [ 20%]
test_suite_5.py::TestUnitario::test_cv_retorna_media_e_std PASSED        [ 21%]
test_suite_5.py::TestUnitario::test_cv_subagging_fracao PASSED           [ 22%]
test_suite_5.py::TestCaixaPreta::test_rlm_rmse[Mn] PASSED                [ 23%]
test_suite_5.py::TestCaixaPreta::test_rlm_mae[Mn] PASSED                 [ 25%]
test_suite_5.py::TestCaixaPreta::test_rlm_r2[Mn] PASSED                  [ 26%]
test_suite_5.py::TestCaixaPreta::test_bagging_rmse[Mn] PASSED            [ 27%]
test_suite_5.py::TestCaixaPreta::test_bagging_mae[Mn] PASSED             [ 28%]
test_suite_5.py::TestCaixaPreta::test_bagging_r2[Mn] PASSED              [ 29%]
test_suite_5.py::TestCaixaPreta::test_bagging_m_otimo[Mn] PASSED         [ 30%]
test_suite_5.py::TestCaixaPreta::test_subagging_rmse[Mn] PASSED          [ 31%]
test_suite_5.py::TestCaixaPreta::test_subagging_mae[Mn] PASSED           [ 32%]
test_suite_5.py::TestCaixaPreta::test_subagging_r2[Mn] PASSED            [ 33%]
test_suite_5.py::TestCaixaPreta::test_subagging_k_m_otimos[Mn] PASSED    [ 34%]
test_suite_5.py::TestCaixaPreta::test_estrutura_resultado[Mn] PASSED     [ 35%]
test_suite_5.py::TestCaixaPreta::test_rlm_rmse[Mo] PASSED                [ 36%]
test_suite_5.py::TestCaixaPreta::test_rlm_mae[Mo] PASSED                 [ 38%]
test_suite_5.py::TestCaixaPreta::test_rlm_r2[Mo] PASSED                  [ 39%]
test_suite_5.py::TestCaixaPreta::test_bagging_rmse[Mo] PASSED            [ 40%]
test_suite_5.py::TestCaixaPreta::test_bagging_mae[Mo] PASSED             [ 41%]
test_suite_5.py::TestCaixaPreta::test_bagging_r2[Mo] PASSED              [ 42%]
```

```
test_suite_5.py::TestCaixaPreta::test_bagging_m_otimo[Mo] PASSED         [ 43%]
test_suite_5.py::TestCaixaPreta::test_subagging_rmse[Mo] PASSED          [ 44%]
test_suite_5.py::TestCaixaPreta::test_subagging_mae[Mo] PASSED           [ 45%]
test_suite_5.py::TestCaixaPreta::test_subagging_r2[Mo] PASSED            [ 46%]
test_suite_5.py::TestCaixaPreta::test_subagging_k_m_otimos[Mo] PASSED    [ 47%]
test_suite_5.py::TestCaixaPreta::test_estrutura_resultado[Mo] PASSED     [ 48%]
test_suite_5.py::TestCaixaPreta::test_rlm_rmse[Cr] PASSED                [ 50%]
test_suite_5.py::TestCaixaPreta::test_rlm_mae[Cr] PASSED                 [ 51%]
test_suite_5.py::TestCaixaPreta::test_rlm_r2[Cr] PASSED                  [ 52%]
test_suite_5.py::TestCaixaPreta::test_bagging_rmse[Cr] PASSED            [ 53%]
test_suite_5.py::TestCaixaPreta::test_bagging_mae[Cr] PASSED             [ 54%]
test_suite_5.py::TestCaixaPreta::test_bagging_r2[Cr] PASSED              [ 55%]
test_suite_5.py::TestCaixaPreta::test_bagging_m_otimo[Cr] PASSED         [ 56%]
test_suite_5.py::TestCaixaPreta::test_subagging_rmse[Cr] PASSED          [ 57%]
test_suite_5.py::TestCaixaPreta::test_subagging_mae[Cr] PASSED           [ 58%]
test_suite_5.py::TestCaixaPreta::test_subagging_r2[Cr] PASSED            [ 59%]
test_suite_5.py::TestCaixaPreta::test_subagging_k_m_otimos[Cr] PASSED    [ 60%]
test_suite_5.py::TestCaixaPreta::test_estrutura_resultado[Cr] PASSED     [ 61%]
test_suite_5.py::TestCaixaPreta::test_rlm_rmse[Ni] PASSED                [ 63%]
test_suite_5.py::TestCaixaPreta::test_rlm_mae[Ni] PASSED                 [ 64%]
test_suite_5.py::TestCaixaPreta::test_rlm_r2[Ni] PASSED                  [ 65%]
test_suite_5.py::TestCaixaPreta::test_bagging_rmse[Ni] PASSED            [ 66%]
test_suite_5.py::TestCaixaPreta::test_bagging_mae[Ni] PASSED             [ 67%]
test_suite_5.py::TestCaixaPreta::test_bagging_r2[Ni] PASSED              [ 68%]
test_suite_5.py::TestCaixaPreta::test_bagging_m_otimo[Ni] PASSED         [ 69%]
test_suite_5.py::TestCaixaPreta::test_subagging_rmse[Ni] PASSED          [ 70%]
test_suite_5.py::TestCaixaPreta::test_subagging_mae[Ni] PASSED           [ 71%]
test_suite_5.py::TestCaixaPreta::test_subagging_r2[Ni] PASSED            [ 72%]
test_suite_5.py::TestCaixaPreta::test_subagging_k_m_otimos[Ni] PASSED    [ 73%]
test_suite_5.py::TestCaixaPreta::test_estrutura_resultado[Ni] PASSED     [ 75%]
test_suite_5.py::TestCaixaPreta::test_rlm_rmse[Fe] PASSED                [ 76%]
test_suite_5.py::TestCaixaPreta::test_rlm_mae[Fe] PASSED                 [ 77%]
test_suite_5.py::TestCaixaPreta::test_rlm_r2[Fe] PASSED                  [ 78%]
test_suite_5.py::TestCaixaPreta::test_bagging_rmse[Fe] PASSED            [ 79%]
test_suite_5.py::TestCaixaPreta::test_bagging_mae[Fe] PASSED             [ 80%]
test_suite_5.py::TestCaixaPreta::test_bagging_r2[Fe] PASSED              [ 81%]
test_suite_5.py::TestCaixaPreta::test_bagging_m_otimo[Fe] PASSED         [ 82%]
test_suite_5.py::TestCaixaPreta::test_subagging_rmse[Fe] PASSED          [ 83%]
test_suite_5.py::TestCaixaPreta::test_subagging_mae[Fe] PASSED           [ 84%]
test_suite_5.py::TestCaixaPreta::test_subagging_r2[Fe] PASSED            [ 85%]
test_suite_5.py::TestCaixaPreta::test_subagging_k_m_otimos[Fe] PASSED    [ 86%]
test_suite_5.py::TestCaixaPreta::test_estrutura_resultado[Fe] PASSED     [ 88%]
test_suite_5.py::TestStress::test_rlm_tempo_matriz_grande PASSED         [ 89%]
test_suite_5.py::TestStress::test_bagging_tempo_10bags PASSED            [ 90%]
test_suite_5.py::TestStress::test_rlm_tempo_stress PASSED                [ 91%]
test_suite_5.py::TestStress::test_ram_rlm_matriz_grande PASSED           [ 92%]
test_suite_5.py::TestStress::test_ram_bagging_matriz_grande PASSED       [ 93%]
test_suite_5.py::TestStress::test_ram_stress_registra_limite PASSED      [ 94%]
test_suite_5.py::TestStress::test_bagging_escalabilidade_bags[5] PASSED  [ 95%]
test_suite_5.py::TestStress::test_bagging_escalabilidade_bags[10] PASSED [ 96%]
test_suite_5.py::TestStress::test_bagging_escalabilidade_bags[25] PASSED [ 97%]
test_suite_5.py::TestStress::test_bagging_escalabilidade_bags[50] PASSED [ 98%]
test_suite_5.py::TestStress::test_parse_matrix_arquivo_grande PASSED     [100%]

======================== 92 passed in 75.25s (0:01:15) ========================
```