

INSTITUTO FEDERAL
Goiás
Câmpus Anápolis

Jamily Costa Ribeiro

Emprego de NL2SQL com LLMs para responder a consultas sobre Currículos Lattes e atuações acadêmicas de servidores do IFG

Anápolis - GO

2026

Jamily Costa Ribeiro

Emprego de NL2SQL com LLMs para responder a consultas sobre Currículos Lattes e atuações acadêmicas de servidores do IFG

Monografia apresentada ao curso de Bacharelado em Ciência da Computação, como requisito para obtenção do grau final na disciplina de Trabalho de Conclusão de Curso.

Instituto Federal de Educação, Ciência e Tecnologia de Goiás - Câmpus Anápolis

Orientador: Prof. Dr. Sergio Daniel Carvalho Canuto

Anápolis - GO

2026

Dados Internacionais de Catalogação na Publicação (CIP)

R484e Ribeiro, Jamily Costa

Emprego de NL2SQL com LLMs para responder a consultas sobre Currículos *Lattes* e atuações acadêmicas de servidores do IFG. / Jamily Costa Ribeiro. – Anápolis: IFG, 2026.
56 f. il. color.

Orientador: Prof. Dr. Sergio Daniel Carvalho Canuto

Trabalho de Conclusão de Curso – Instituto Federal de Educação, Ciência e Tecnologia de Goiás, Campus Anápolis – Bacharelado em Ciência da Computação, 2026.

1. NL2SQL. 2. Modelos de linguagem de grande escala. 3. Bancos de dados relacionais. 4. Linguagem natural. 5. Dados acadêmicos.
I. Canuto, Sergio Daniel Carvalho (orient.).
II. Título.

CDD 006.35

Ficha catalográfica elaborada pelo bibliotecário Matheus Rocha Piacenti CRB1/02992
IFG Campus Anápolis

TERMO DE AUTORIZAÇÃO PARA DISPONIBILIZAÇÃO NO REPOSITÓRIO DIGITAL DO IFG - ReDi IFG

Com base no disposto na Lei Federal nº 9.610/98, AUTORIZO o Instituto Federal de Educação, Ciência e Tecnologia de Goiás, a disponibilizar gratuitamente o documento no Repositório Digital (ReDi IFG), sem ressarcimento de direitos autorais, conforme permissão assinada abaixo, em formato digital para fins de leitura, download e impressão, a título de divulgação da produção técnico-científica no IFG.

Identificação da Produção Técnico-Científica

[ ] Tese	[ ] Artigo Científico
[ ] Dissertação	[ ] Capítulo de Livro
[ ] Monografia – Especialização	[ ] Livro
[X] TCC - Graduação	[ ] Trabalho Apresentado em Evento
[ ] Produto Técnico e Educacional - Tipo: _____	

Nome Completo do Autor: Jamily Costa Ribeiro
Matrícula: 20221060140024
Título do Trabalho: Emprego de NL2SQL com LLMs para responder a consultas sobre Currículos Lattes e atuações acadêmicas de servidores do IFG

Autorização - Marque uma das opções

1. ( ) Autorizo disponibilizar meu trabalho no Repositório Digital do IFG (acesso aberto);
2. (X) Autorizo disponibilizar meu trabalho no Repositório Digital do IFG somente após a data 01/04/2027 (Embargo);
3. ( ) Não autorizo disponibilizar meu trabalho no Repositório Digital do IFG (acesso restrito).

Ao indicar a opção **2 ou 3**, marque a justificativa:

( ) O documento está sujeito a registro de patente.
(X) O documento pode vir a ser publicado como livro, capítulo de livro ou artigo.
( ) Outra justificativa: _____

DECLARAÇÃO DE DISTRIBUIÇÃO NÃO-EXCLUSIVA

O/A referido/a autor/a declara que:

i. o documento é seu trabalho original, detém os direitos autorais da produção técnico-científica e não infringe os direitos de qualquer outra pessoa ou entidade;
ii. obteve autorização de quaisquer materiais inclusos no documento do qual não detém os direitos de autor/a, para conceder ao Instituto Federal de Educação, Ciência e Tecnologia de Goiás os direitos requeridos e que este material cujos direitos autorais são de terceiros, estão claramente identificados e reconhecidos no texto ou conteúdo do documento entregue;
iii. cumpriu quaisquer obrigações exigidas por contrato ou acordo, caso o documento entregue seja baseado em trabalho financiado ou apoiado por outra instituição que não o Instituto Federal de Educação, Ciência e Tecnologia de Goiás.

Anápolis, 25/03/2026.

gov.br
Documento assinado digitalmente
JAMILY COSTA RIBEIRO
Data: 25/03/2026 15:35:23-0300
Verifique em https://validar.iti.gov.br

_____
Assinatura do Autor e/ou Detentor dos Direitos Autorais

ATA DE DEFESA DE TRABALHO DE CONCLUSÃO DE CURSO

Na presente data realizou-se a sessão pública de defesa do Trabalho de Conclusão de Curso intitulado **Emprego de NL2SQL com LLMs para responder a consultas sobre Currículos Lattes e atuações acadêmicas de servidores do IFG**, sob orientação de Sergio Daniel Carvalho Canuto , apresentado pela aluna **Jamily Costa Ribeiro (20221060140024)** do Curso **Bacharelado em Ciência da Computação (Câmpus Anápolis)**. Os trabalhos foram iniciados às **11:00** do dia **02/03/2026** pelo Professor presidente da banca examinadora, constituída pelos seguintes membros:

- **Sergio Daniel Carvalho Canuto** (Presidente)
- **Daniel Xavier de Sousa** (Examinador Interno)
- **Eduardo Noronha de Andrade Freitas** (Examinador Externo)

A banca examinadora, tendo terminado a apresentação do conteúdo do Trabalho de Conclusão de Curso, passou à arguição da candidata. Em seguida, os examinadores reuniram-se para avaliação e deram o parecer final sobre o trabalho apresentado pela aluna, tendo sido atribuído o seguinte resultado:

[X] Aprovado [ ] Reprovado Nota : 10,0

Observação / Apreciações:

Proclamados os resultados pelo presidente da banca examinadora, foram encerrados os trabalhos e, para constar, eu **Sergio Daniel Carvalho Canuto** lavrei a presente ata que assino juntamente com os demais membros da banca examinadora.

Documento assinado eletronicamente por:

- **Daniel Xavier de Sousa**, em **18/03/2026 20:51:03** com chave **52961f08232511f18e5a005056a537a4**.
- **Eduardo Noronha de Andrade Freitas**, em **19/03/2026 05:58:16** com chave **c502e9c6237111f19259005056a537a4**.
- **Sergio Daniel Carvalho Canuto**, em **18/03/2026 18:33:43** com chave **235dd46e231211f183ab005056a537a4**.

Este documento foi emitido pelo SUAP. Para comprovar sua autenticidade, faça a leitura do QrCode ao lado ou acesse https://suap.ifg.edu.br/comum/autenticar_documento/ e informe os dados a seguir.

Tipo de Documento: Ata de Projeto Final

Data da Emissão: 19/03/2026

Código de Autenticação: 68445f

Lista de ilustrações

Figura 1 – Processo NL2SQL 14
Figura 2 – Plataforma Jacarandá: Diagrama Entidade-Relacionamento (DER) . . 28
Figura 3 – Distribuição dos pares ⟨pergunta, SQL, resposta⟩ da coleção **PMG** . . 30
Figura 4 – Geração, tradução e avaliação da coleção PMG 30
Figura 5 – Distribuição dos pares ⟨pergunta, resposta⟩ da coleção **PS** 31
Figura 6 – Geração, tradução e avaliação da coleção PS 32
Figura 7 – Taxa de falhas de execução por método na Coleção PMG (%) 41
Figura 8 – Boxplot da distribuição do tempo de execução das consultas preditas por método na Coleção PMG (*outliers* acima de 10000ms foram removidos para melhor visualização). 43
Figura 9 – Taxa de falhas de execução por método na Coleção PS-Derivada (%). . 46
Figura 10 – Boxplot da distribuição do tempo de execução das consultas preditas por método na Coleção PS-Derivada (*outliers* acima de 2500ms foram removidos para melhor visualização) 47
Figura 11 – Projeção t-SNE da distribuição de perguntas 48
Figura 12 – Top 15 termos mais discriminantes para perguntas inválidas 48

Lista de tabelas

Tabela 1 – Métodos NL2SQL existentes 22
Tabela 2 – Métodos de geração e avaliação utilizados nos trabalhos 26
Tabela 3 – Acurácia de Execução, custo computacional e tempo de resposta médio de modelos da Família GPT na coleção PMG 38
Tabela 4 – Acurácia de Execução, custo computacional e tempo de resposta médio de modelos da Família GPT na coleção PS 39
Tabela 5 – Comparativo da composição das coleções PS e PS-Derivada 39
Tabela 6 – Resultados das métricas de avaliação dos métodos na coleção PMG . . 40
Tabela 7 – Taxa de Falhas de Execução das consultas preditas pelos métodos na coleção PMG 41
Tabela 8 – Resultados das métricas de avaliação dos métodos na coleção PS-Derivada. 44
Tabela 9 – Taxa de Falhas de Execução das consultas preditas pelos métodos na coleção PS-Derivada. 45

Lista de abreviaturas e siglas

BI	*Business Intelligence* (Inteligência de Negócios)
EM	*Exact Match Accuracy* (Acurácia de Correspondência Exata)
ETL	*Extract, Transform, Load* (Extrair, Transformar, Carregar)
EX	*Execution Accuracy* (Acurácia de Execução)
ICL	*In-Context Learning* (Aprendizado em Contexto)
IFG	Instituto Federal de Educação, Ciência e Tecnologia de Goiás
KDD	*Knowledge Discovery in Databases* (Descoberta de Conhecimento em Bases de Dados)
LCS	*Longest Common Subsequence* (Maior Subsequência Comum)
LLM	*Large Language Model* (Modelo de Linguagem de Grande Escala)
ML	*Machine Learning* (Aprendizado de Máquina)
MCTS	*Monte Carlo Tree Search* (Busca em Árvore de Monte Carlo)
NL	*Natural Language* (Linguagem Natural)
NL2SQL	*Natural Language to SQL* (Tradução de Linguagem Natural para SQL)
OOB	*Out-of-Bag* (Fora da Bolsa)
PLN	Processamento de Linguagem Natural
ROUGE	*Recall-Oriented Understudy for Gisting Evaluation* (Estudo Orientado à Recordação para Avaliação de Conteúdo)
SFT	*Supervised Fine-Tuning* (Ajuste Fino Supervisionado)
SGBD	Sistema de Gerenciamento de Banco de Dados
SQL	*Structured Query Language* (Linguagem de Consulta Estruturada)
TF-IDF	*Term Frequency-Inverse Document Frequency* (Frequência do Termo – Inverso da Frequência nos Documentos)
t-SNE	*t-distributed Stochastic Neighbor Embedding* (Incorporação estocástica de vizinho t-distribuída)
VES	*Valid Efficiency Score* (Pontuação de Eficiência Válida)

Agradecimentos

Em primeiro lugar, agradeço a Deus pela minha vida, por abrir as portas para que eu concluísse esta graduação e por me permitir superar os obstáculos encontrados ao longo da realização deste trabalho.

Agradeço aos meus pais, Genilson e Irineide, por nunca medirem esforços para que eu realizasse o sonho de cursar o ensino superior e por sempre me apoiarem — inclusive em orações — mesmo à distância. Minha gratidão à minha querida irmã, Giselle, que sempre ofereceu palavras de força e apoio. À minha amiga de infância, Rayssa, e ao meu namorado, Allefy, que, mesmo distantes fisicamente, sempre souberam ouvir e compartilhar as dificuldades e alegrias desta fase tão importante.

Sou grata aos amigos que o Bacharelado em Ciência da Computação me proporcionou; vocês foram fundamentais para a minha formação e para que eu me sentisse acolhida em uma nova cidade. Em especial, agradeço ao meu amigo Ricardo, com quem tive a liberdade de dividir conquistas e desafios desde o primeiro semestre da graduação.

Ao meu orientador, professor Sergio, que me auxiliou não apenas no desenvolvimento desta pesquisa, mas também me guiou na escolha deste tema. Agradeço pela excelente orientação, pela paciência e por sempre transmitir a tranquilidade necessária para a conclusão deste ciclo.

Agradeço a todos os professores do curso de Ciência da Computação por, além de contribuírem com minha formação acadêmica e profissional, auxiliarem no meu desenvolvimento pessoal.

Meu muito obrigada a todos!

Resumo

O avanço dos Modelos de Linguagem de Grande Escala (LLMs) tem impulsionado o surgimento de novas abordagens para a interação com bases de dados por meio de linguagem natural, sobretudo a tarefa de tradução de consultas em linguagem natural para SQL (NL2SQL). Este trabalho investiga e compara estratégias de NL2SQL aplicadas a dados acadêmicos institucionais da Plataforma Jacarandá, desenvolvida pelo Instituto Federal de Goiás. De caráter exploratório e experimental, a pesquisa apoia-se em revisão bibliográfica e em avaliações comparativas de técnicas de *prompting* e métodos da literatura. Como contribuições, apresenta a (i) sistematização de um protocolo de avaliação de resultados; (ii) duas coleções de teste fundamentadas no esquema relacional da plataforma – uma curada manualmente e outra sintética; e (iii) uma análise crítica do desempenho das abordagens avaliadas. Os resultados destacam a superioridade da estratégia *Few-Shot*, que atingiu acurácia de execução de até 72,1%, e a elevada robustez técnica do método C3SQL, com uma taxa de falhas sintáticas residual de apenas 1,0% na base manual. O trabalho evidencia tanto o potencial quanto as limitações do uso de LLMs em soluções NL2SQL para dados acadêmicos, oferecendo subsídios técnicos e conceituais para futuras implementações institucionais.

Palavras-chave: NL2SQL, Modelos de Linguagem de Grande Escala, Bancos de Dados Relacionais, Linguagem Natural, Dados Acadêmicos.

Abstract

The advancement of Large Language Models (LLMs) has driven the emergence of new approaches for interacting with databases through natural language, particularly the task of translating natural language queries into SQL (NL2SQL). This work investigates and compares NL2SQL strategies applied to institutional academic data from the Jacarandá Platform, developed by the Federal Institute of Goiás (IFG). Characterized as exploratory and experimental, the research is based on a literature review and comparative evaluations of prompting techniques and existing methods from the literature. Its contributions include: (i) the systematization of a result evaluation protocol; (ii) two test collections based on the platform's relational schema — one manually curated and one synthetic; and (iii) a critical analysis of the evaluated approaches performance. The results highlight the superiority of the *Few-Shot* strategy, which reached an execution accuracy of up to 72.1%, and the high technical robustness of the C3SQL method, with a residual syntactic failure rate of only 1.0% on the manual collection. The study demonstrates both the potential and limitations of using LLMs in NL2SQL solutions for academic data, offering technical and conceptual subsidies for future institutional implementations.

Keywords: NL2SQL, Large Language Models, Relational Databases, Natural Language, Academic Data.

Sumário

1 INTRODUÇÃO 13

2 JUSTIFICATIVA 16

3 OBJETIVO 17
3.1 Objetivo Geral 17
3.2 Objetivos Específicos 17

4 TRABALHOS RELACIONADOS 18
4.1 Estratégias NL2SQL 18
4.1.1 Pré-processamento 18
4.1.2 Tradução NL2SQL 19
4.1.3 Pós-processamento 20
4.2 Estratégias de Geração de Dados 23
4.2.1 Anotação Humana 23
4.2.2 Geração Sintética 23
4.2.3 Variação e Ambiguidade 24
4.3 Estratégias de Avaliação de Resultados 25

5 METODOLOGIA 27
5.1 Seleção e Pré-Processamento de Dados 27
5.1.1 Plataforma Jacarandá: Banco de Dados Relacional 27
5.1.2 Coleção de Dados Manualmente Gerada 29
5.1.3 Coleção de Dados Sintética 29
5.2 Mineração de Dados 31
5.2.1 Preparação do Contexto Semântico 32
5.2.2 Estratégias de Tradução e Parametrização 33
5.3 Avaliação e Interpretação do Conhecimento 34

6 RESULTADOS E DISCUSSÕES 37
6.1 NL2SQL nos Dados Gerados Manualmente 38
6.2 NL2SQL nos Dados Sintéticos 43
6.3 É Possível Identificar Perguntas Difíceis? 46

7 CONCLUSÕES E TRABALHOS FUTUROS 50
7.1 Objetivos Alcançados 50
7.2 Principais Resultados 50

7.3 Trabalhos Futuros 51

REFERÊNCIAS 52

A APÊNDICE 56
A.1 Prompt Geração de Pares <pergunta, resposta>Sintéticos 56
A.2 Prompt Zero-Shot 57
A.3 Prompt Few-Shot 58

1 Introdução

O avanço dos Modelos de Linguagem de Grande Escala (LLMs) tem provado sua eficácia no tratamento de linguagem natural em diversas aplicações. A capacidade desses modelos de capturar padrões sintáticos e semânticos complexos permite que eles interpretem e gerem respostas coerentes a partir de consultas em linguagem natural (NL), apresentando robustez e adaptabilidade superiores às técnicas tradicionais de Processamento de Linguagem Natural (PLN). Por essa razão, é notório o crescimento recente da adoção desses modelos para aplicação em diversas tarefas (MISHRA et al., 2024; LIANG et al., 2024; LIANG et al., 2025). Tal cenário é impulsionado pelo aumento do poder computacional, disponibilidade de dados e praticidade de aplicações baseadas na resolução de problemas formulados com perguntas em linguagem natural.

Um dos desafios existentes em muitas organizações acadêmicas e corporativas é a extração de informações relevantes de bancos de dados relacionais: a necessidade de formular consultas SQL corretas e eficientes torna-se um obstáculo para usuários sem conhecimento técnico. É neste contexto que surge a abordagem NL2SQL, ou Text-to-SQL, cujo objetivo central é "democratizar" o acesso a dados, reduzindo as barreiras de uso de sistemas de gerenciamento de bancos de dados (SGBDs) relacionais. Assim, ao permitir que o usuário simplesmente expresse sua necessidade em linguagem natural, o sistema traduz automaticamente essa intenção para uma consulta SQL válida, promovendo autonomia e produtividade.

Nesse contexto, define-se o Esquema Relacional como a representação lógica de um banco de dados como uma coleção de relações (tabelas). Estruturado em linhas (tuplas) e colunas (atributos), ele utiliza chaves primárias para identificação única e chaves estrangeiras para integridade referencial, mapeando entidades e relacionamentos do modelo conceitual (ER) (ELMASRI; NAVATHE, 2018).

Complementarmente, o SQL (*Structured Query Language*) é a linguagem declarativa padrão utilizada para interagir com esses sistemas. Por meio dela, é possível realizar operações de definição, manipulação e, principalmente, consulta aos dados. Contudo, a rigidez sintática do SQL exige que o usuário conheça precisamente o esquema relacional e as palavras-chave da linguagem, o que motiva o desenvolvimento de interfaces que utilizam linguagem natural.

A proposta de associar NL2SQL a LLMs, como detalhado em estudos recentes (LI et al., 2024; LIU et al., 2025; SHI et al., 2025; MOHAMMADJAFARI; MAIDA; GOTTUMUKKALA, 2025; HONG et al., 2025), potencializa ainda mais essa funcionalidade. Os LLMs, com seu entendimento semântico profundo, podem interpretar consultas ambíguas,

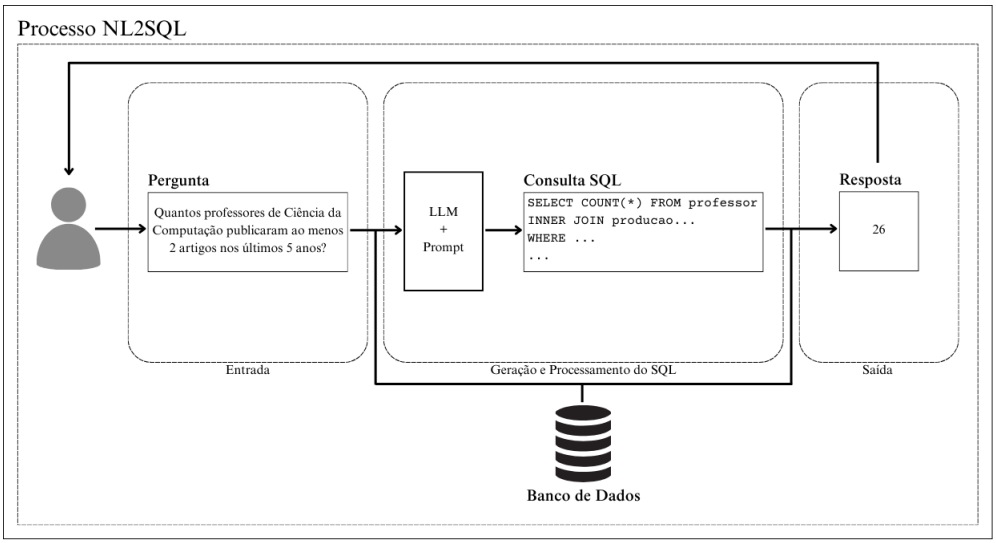
corrigir possíveis imprecisões do usuário e gerar instruções SQL mais precisas, mesmo quando lidam com esquemas complexos ou com vocabulário técnico específico. Isso não só melhora a qualidade e a exatidão das consultas, mas também amplia o escopo de domínios em que NL2SQL pode ser aplicado, adaptando-se a diferentes contextos e temas de bases de dados.

Nesse contexto, o presente trabalho tem como objetivo investigar e analisar diferentes estratégias de tradução de perguntas em linguagem natural para consultas SQL (NL2SQL), aplicadas aos dados da versão inicial do banco de dados da Plataforma Jacarandá. Essa plataforma consiste em um software desenvolvido pela Assessoria de Planejamento e Desenvolvimento Institucional (APDI) do Instituto Federal de Educação, Ciência e Tecnologia de Goiás (IFG), com o propósito de atender demandas administrativas e acadêmicas da instituição.

A pesquisa conduzida possui caráter exploratório e experimental, concentrando-se na revisão da literatura e na avaliação de diferentes abordagens e estratégias de NL2SQL, como estratégias de *prompt* e métodos propostos em trabalhos correlatos. Os experimentos realizados visam compreender o comportamento, as limitações e o potencial dessas abordagens no contexto de dados acadêmicos institucionais.

A Figura 1 descreve um exemplo de processo de interação do usuário com as soluções avaliadas:

Figura 1 – Processo NL2SQL



Como ilustrado na imagem, a interação do usuário inicia-se com a formulação de uma pergunta em linguagem natural, a qual é processada por um LLM para a geração automática da consulta SQL correspondente. Após a execução da consulta no banco de dados, obtém-se o resultado final. Essa saída pode ser avaliada de forma quantitativa ao verificar se seu valor corresponde com o esperado com base nos dados disponíveis. De maneira análoga, a consulta SQL gerada pelo modelo pode ser analisada sob uma

perspectiva qualitativa, considerando a fidelidade semântica entre a pergunta original e a estrutura lógica do SQL produzido. Dessa forma, torna-se possível validar tanto a exatidão da resposta quanto a coerência da tradução da intenção do usuário para o comando SQL.

As principais contribuições deste trabalho residem na sistematização de um arcabouço de avaliação voltado ao domínio institucional acadêmico, especificamente focado em dados obtidos de currículos Lattes e informações sobre a produtividade de servidores do IFG. Destaca-se a construção de duas coleções de dados para a validação de tarefas NL2SQL: uma base padrão curada manualmente e uma base sintética, ambas fundamentadas na primeira versão do esquema relacional da Plataforma Jacarandá. Além disso, o estudo fornece uma análise comparativa entre diferentes estratégias de *prompting* e métodos da literatura, oferecendo subsídios técnicos para futuras extensões nos sistemas acadêmicos. Os resultados obtidos demonstram a eficácia dessas abordagens, com a estratégia *Few-Shot* atingindo acurácia de execução de até 72,1% e o método C3SQL apresentando elevada robustez técnica, com uma taxa de falha sintática residual de apenas 1,0% na coleção manual.

Para o cumprimento desses propósitos, este trabalho está organizado conforme a seguinte estrutura: o Capítulo 2 apresenta a **Justificativa**, seguida pela definição dos **Objetivos** (Capítulo 3), situando a relevância da pesquisa. O Capítulo 4 detalha os **Trabalhos Relacionados**, revisando o estado da arte em estratégias NL2SQL sob a ótica de modelos de linguagem. Em seguida, o Capítulo 5 descreve a **Metodologia** aplicada, incluindo o processo de extração de dados da plataforma, a construção das coleções de teste e os protocolos de avaliação. Os **Resultados e Discussões** são apresentados no Capítulo 6, onde os desempenhos das abordagens são analisados de forma crítica à luz das métricas de acurácia e robustez. Por fim, o Capítulo 7 sintetiza as principais **Conclusões** e elenca sugestões de **Trabalhos Futuros**.

2 Justificativa

A elaboração manual de consultas SQL requer conhecimento especializado da linguagem, da estrutura interna do banco de dados e das práticas de otimização — aspectos que constituem barreiras significativas para usuários sem formação técnica em sistemas de bancos de dados relacionais. Nesse cenário, a abordagem NL2SQL mostra-se promissora, pois permite que a necessidade de informação seja expressa em linguagem natural, transferindo para o sistema a responsabilidade de traduzi-la em instruções estruturadas.

Contudo, existe o desafio de gerar corretamente as instruções SQL, visto que ambiguidade ou subespecificação da consulta em linguagem natural (NL), além de possíveis incoerências na base de dados, podem levar a resultados incorretos ou à falha total da consulta. No entanto, uma vez que se alcance uma tradução fidedigna, isto é, um SQL sintaticamente válido e semanticamente alinhado à intenção do usuário, a resposta extraída do banco torna-se precisa e confiável, livre das imprecisões tipicamente associadas às interfaces manuais.

Outro ponto crítico refere-se à avaliação das estratégias NL2SQL. Para que seja possível treinar, validar e comparar diferentes modelos e abordagens, é indispensável a existência de coleções de dados compostas por pares de perguntas em linguagem natural e consultas SQL correspondentes ou respostas reais prévias. Essas coleções funcionam como referência para mensurar a qualidade da tradução e garantir que o modelo seja capaz de generalizar para diferentes contextos de consulta. A literatura oferece diversos conjuntos de dados em domínios como saúde, finanças e ciência, mas ainda são escassos os recursos voltados ao domínio acadêmico.

Nesse sentido, destaca-se a ausência de bases de dados públicas que contemplem informações ligadas aos Currículos Lattes e, em particular, à atuação acadêmica de docentes e pesquisadores em instituições de ensino superior. Essa lacuna impõe um desafio adicional: além de desenvolver a estratégia NL2SQL em si, torna-se necessário criar ou adaptar conjuntos de dados que reflitam as particularidades desse domínio. Tal aspecto reforça a originalidade e a relevância da presente pesquisa.

Assim, justifica-se investigar essa abordagem no domínio dos Currículos Lattes e das atuações acadêmicas de servidores do IFG, informações reunidas na Plataforma Jacarandá. A adoção dessa técnica visa oferecer consultas mais acessíveis e resultados robustos, fortalecendo tanto a gestão acadêmica quanto o suporte a pesquisas institucionais, ampliando o valor dos dados disponíveis para essa comunidade.

3 Objetivo

3.1 Objetivo Geral

Avaliar estratégias baseado em Modelos de Linguagem de Grande Escala (LLMs) para a interpretação de consultas em linguagem natural sobre os Currículos Lattes e as atuações acadêmicas dos servidores do IFG, traduzindo-as em instruções SQL corretas e eficientes, de modo a fornecer respostas precisas e acessíveis.

3.2 Objetivos Específicos

- Investigar, analisar e comparar diferentes estratégias existentes para a tarefa de NL2SQL;
- Avaliar o desempenho de distintos Modelos de Linguagem (LLMs) quanto a geração correta e eficiente de comandos SQL;
- Construir duas coleções de dados para validação do modelo e dos métodos NL2SQL adotados:
    1. uma coleção gerada manualmente, composta por pares de perguntas em linguagem natural, consultas SQL esperadas e respectivas respostas;
    2. uma coleção sintética, mais ampla e densa, gerada a partir de dados reais extraídos da primeira versão do banco de dados da **Plataforma Jacarandá**, contendo pares de perguntas e seus valores esperados.
- Aplicar métricas de avaliação adequadas para medir a acurácia, a eficiência, o alinhamento estrutural e a robustez das consultas geradas.

4 Trabalhos Relacionados

Nesta seção são apresentados e discutidos trabalhos que abordam a tarefa NL2SQL, ou Text-to-SQL, considerando três eixos principais: (i) estratégias NL2SQL, que descrevem abordagens e arquiteturas utilizadas para traduzir perguntas em linguagem natural para consultas SQL; (ii) estratégias de geração de dados, fundamentais para a criação de coleções de perguntas-consulta-resposta que permitem treinar e avaliar modelos LLM; (iii) estratégias de avaliação de resultados, que envolvem métricas e métodos utilizados para mensurar a acurácia e a eficiência das consultas geradas.

A análise desses trabalhos tem como objetivo situar a proposta desta pesquisa no contexto do estado da arte, além de permitir a identificação de possíveis adaptações a serem aplicadas em cada um dos eixos abordados. Em particular, busca-se compreender como diferentes soluções enfrentam os principais desafios destacados no Capítulo 2 — tais como a ambiguidade presente na linguagem natural e a complexidade das consultas SQL. Ademais, a ausência de bases de referência específicas para o setor acadêmico, especialmente no que se refere a currículos e produções vinculadas ao Lattes, configura-se como um aspecto inédito que este trabalho pretende explorar, fundamentando-se nas análises e aprendizados extraídos do estudo prévio da literatura.

4.1 Estratégias NL2SQL

A tarefa de tradução de linguagem natural (NL) para consultas SQL é composta por um conjunto de estratégias que abrangem diferentes etapas do processo, desde a preparação do contexto até a correção final da consulta. De acordo com LIU et al., essas estratégias podem ser agrupadas em três grandes categorias: **pré-processamento**, **tradução NL2SQL** e **pós-processamento**.

4.1.1 Pré-processamento

O pré-processamento atua como uma etapa fundamental de preparação e enriquecimento dos dados de entrada, visando atenuar a ambiguidade inerente à linguagem natural e fornecer o contexto semântico necessário para que o modelo realize a tradução para SQL com maior precisão. De acordo com a taxonomia proposta por LIU et al., essa etapa pode ser consolidada em três subestratégias principais:

- **Vinculação de Esquemas (*Schema Linking*):** Considerada uma das etapas mais críticas, consiste em identificar e mapear referências na pergunta para elementos

específicos do banco de dados, como tabelas e colunas. Enquanto técnicas tradicionais baseiam-se em casamento de *strings* e métricas de similaridade (GUO et al., 2019), abordagens contemporâneas utilizam redes neurais profundas (ZHANG et al., 2024) ou aprendizado em contexto (*In-Context Learning* - ICL) com modelos de linguagem de grande escala (LLMs) (POURREZA; RAFIEI, 2023; DONG et al., 2023; POURREZA; RAFIEI, 2024; QU et al., 2024; TALAEI et al., 2024; WANG et al., 2025) para resolver ambiguidades semânticas complexas e mapeamentos indiretos.

- **Recuperação de Conteúdo do Banco de Dados:** Para auxiliar na formulação precisa de filtros e restrições (cláusulas `WHERE`), o pré-processamento envolve a consulta de instâncias reais de dados nas células do banco. A inserção de valores de exemplo no *prompt* (POURREZA et al., 2024; LI et al., 2024; LI et al., 2024; QIN et al., 2025; XIE et al., 2025) permite que o modelo compreenda o formato dos dados e distinga entre colunas com domínios semanticamente próximos, reduzindo erros de alinhamento de valores.

- **Integração de Conhecimento Externo:** A aquisição de informações adicionais e conhecimento de domínio (CHANG; FOSLER-LUSSIER, 2023; ZHANG et al., 2023; ZHANG et al., 2024; REN et al., 2024; FAN et al., 2024; XIE et al., 2024; LI et al., 2026) desempenha um papel crucial na interpretação de intenções do usuário que não estão explicitamente descritas no esquema. Essa estratégia visa prover o contexto necessário sobre regras de negócio e terminologias específicas, preenchendo a lacuna entre o vocabulário do usuário e a estrutura técnica do banco de dados.

4.1.2 Tradução NL2SQL

O núcleo do processo de NL2SQL reside na etapa de tradução, que compreende a transformação de intenções expressas em linguagem natural em representações lógicas estruturadas e, por fim, na consulta SQL executável. Com o advento dos Modelos de Linguagem de Grande Escala (LLMs), o paradigma de tradução migrou de arquiteturas puramente neurais baseadas em codificadores-decodificadores para abordagens fundamentadas em engenharia de *prompts* e aprendizado em contexto (*In-Context Learning* - ICL).

Nesse contexto, a elaboração de *prompts* específicos para a tarefa busca guiar os modelos na otimização do mapeamento semântico, com o intuito de elevar a precisão na geração de consultas. As principais estratégias de *prompting* documentadas na literatura recente incluem:

- **Zero-Shot:** Nesta técnica, o LLM realiza a tradução sem a exposição prévia a exemplos específicos da base de dados alvo, baseando-se exclusivamente em seu

conhecimento pré-treinado e nas instruções fornecidas. Trabalhos como o C3SQL (DONG et al., 2023) exploram essa abordagem utilizando *self-consistency* para a vinculação de esquemas e geração de candidatos. De forma análoga, o método ODIS (CHANG; FOSLER-LUSSIER, 2023) enriquece o *prompt* com informações contextuais para maximizar a acurácia das predições sem a necessidade de exemplares.

- **Few-Shot:** Esta estratégia fundamenta-se no fornecimento de um pequeno conjunto de pares pergunta-SQL para orientar o modelo quanto à estrutura esperada. O método DIN-SQL (POURREZA; RAFIEI, 2023) destaca-se ao combinar essa técnica com a decomposição de tarefas, enquanto o DAIL-SQL (GAO et al., 2024) introduz uma seleção dinâmica de k exemplos mais semanticamente similares à pergunta de entrada, otimizando a relevância do contexto fornecido ao modelo.

- **Cadeia de Pensamento (*Chain-of-Thought* - CoT):** Visando reduzir falhas em consultas que exigem raciocínio multietapa, os *prompts* CoT orientam o modelo a decompor o problema em passos lógicos antes da geração do código final. Abordagens avançadas como o CHESS (TALAEI et al., 2024) estruturam essa estratégia em um framework multiagente, onde especialistas (Recuperador, Seletor, Gerador e Testador) colaboram de forma iterativa. Complementarmente, o Alpha-SQL (LI et al., 2025) integra o raciocínio de LLMs à Busca em Árvore de Monte Carlo (MCTS), permitindo que um agente autônomo planeje e selecione dinamicamente módulos de vinculação e geração com base no *feedback* de execução.

Além das estratégias baseadas em *prompt*, existem métodos que optam pelo Ajuste Fino Supervisionado (SFT), como o CodeS (LI et al., 2024) e o FinSQL (ZHANG et al., 2024). Tais abordagens visam especializar o modelo na sintaxe SQL e no domínio específico dos dados, reduzindo a dependência de contextos extensos no momento da inferência.

Mais detalhes sobre a arquitetura e as variações de *prompt* selecionadas para este trabalho são apresentados na Seção 5.2.2.

4.1.3 Pós-processamento

Após a geração da consulta, muitos trabalhos adotam etapas de pós-processamento para refinar o resultado final, buscando assegurar a correção sintática, a consistência lógica e a eficiência de execução. Como as LLMs podem gerar alucinações ou erros de sintaxe SQL, diferentes estratégias são empregadas para validar e otimizar a saída, sendo as quatro principais detalhadas a seguir:

- **Auto-correção e Refinamento:** Esta estratégia busca identificar e reparar erros sintáticos ou de mapeamento detectados após a primeira tentativa de geração. O

foco recai sobre a correção de predicados, como nomes de colunas inexistentes ou valores mal formatados. Diversos métodos interpretam mensagens de erro e realizam um refinamento iterativo da consulta (POURREZA; RAFIEI, 2023; TALAEI et al., 2024; LI et al., 2025). Porém, embora essa estratégia busque corrigir erros de sintaxe, eles frequentemente ignoram erros semânticos que podem impactar diretamente na resposta final.

- **Consistência e Votação (*Self-consistency*):** Para atenuar a variabilidade das respostas, essa abordagem amostra diversos caminhos de raciocínio (múltiplas consultas SQL candidatas) para a mesma pergunta. O sistema seleciona a resposta que apresenta maior consenso entre as execuções, o que demonstra aumentar significativamente a robustez do modelo frente a ambiguidades (DONG et al., 2023; GAO et al., 2024; LI et al., 2026). No entanto, isso pode aumentar significativamente o custo e o tempo de resposta.

- **Decodificação Guiada por Execução:** O resultado da execução de uma consulta fornece um *feedback* crítico sobre a validade da tradução. Métodos que aplicam estratégias guiadas pela execução (TALAEI et al., 2024; LI et al., 2025) utilizam o retorno do interpretador SQL (seja uma mensagem de erro ou um conjunto de resultados vazio/inesperado) como sinal para ajustar a lógica da consulta, garantindo que o código final seja funcional e recupere os dados pretendidos. O que, apesar de otimizar a consulta final, acarreta no aumento do tempo de geração e do custo computacional.

- **Re-ranqueamento (*Reranking*):** Em cenários complexos ou de multidomínio, são aplicadas técnicas de reclassificação N-Best (FAN et al., 2024). Nessas situações, o modelo é encarregado de gerar uma lista de candidatos potenciais e um módulo de ranqueamento (frequentemente um classificador auxiliar) avalia qual das estruturas SQL melhor preserva a semântica da pergunta em linguagem natural, selecionando a de maior pontuação.

Em resumo, observa-se que os avanços recentes em NL2SQL estão fortemente associados ao uso de LLMs e à sofisticação da engenharia de *prompt*. Entretanto, o sucesso da tradução não depende apenas da etapa de geração, mas da integração entre pré-processamento, tradução e pós-processamento, conforme apresentado pelos principais trabalhos da literatura (Tabela 1).

No caso da **Plataforma Jacarandá**, a vinculação adequada dos esquemas acadêmicos, a definição de *prompts* especializados e a adoção de mecanismos de correção automática de consultas representam passos fundamentais para lidar com a ambiguidade e a complexidade das perguntas em linguagem natural. Os detalhes técnicos das estratégias avaliadas neste trabalho são apresentados na Seção 5.2.

Tabela 1 – Métodos NL2SQL existentes

Método	**Pré-Processamento**			**Tradução**	**Pós-Processamento**			
	SchL	DB-Ret	AddInfo	*Prompt*	Corr	Consist	Ex-G	*N*-BR
OpenSearch-SQL (2025)	✗	✗	✗	Few-Shot CoT	✗	✗	✗	
CHASE-SQL (2024)	✗	✗	✗	CoT	✗	✗	✗	
ROUTE (2025)	✗	✗	✗	Zero-Shot	✗	✗	✗	
Alpha-SQL (2025)	✗	✗	✗	Zero-Shot CoT	✗	✗	✗	
CHESS (2024)	✗	✗	✗	Few-Shot CoT	✗	✗	✗	
CodeS | SFT CodeS (2024)	✗	✗		Few-Shot			✗	
FinSQL (2024)	✗		✗	Few-Shot CoT	✗	✗		
DTS-SQL (2024)	✗			Few-Shot CoT				
TA-SQL (2024)	✗			Zero-Shot				
SuperSQL (2024)	✗	✗	✗	Few-Shot		✗		
PET-SQL (2026)	✗		✗	Few-Shot		✗		
CoE-SQL (2024)			✗	CoT	✗			
PURPLE (2024)	✗		✗	Zero-Shot	✗	✗	✗	
MetaSQL (2024)	✗		✗	Few-Shot				✗
DEA-SQL (2024)	✗		✗	Few-Shot CoT	✗			
DIN-SQL (2023)	✗		✗	Few-Shot CoT	✗			
DAIL-SQL (2024)			✗	Few-Shot		✗		
C3SQL (2023)	✗			Zero-Shot		✗		
ACT-SQL (2023)	✗		✗	Few-Shot CoT				
ODIS (2023)			✗	Zero-Shot				
MAC-SQL (2025)	✗			Few-Shot CoT	✗		✗	

SchL: Vinculação de Esquema (*Schema Linking*); **DB-Ret**: Recuperação de Conteúdo do Banco de Dados (*DB Content Retrieval*); **AddInfo**: Integração de Inforação Adicional (*Additional Information Acquisition*); **Corr**: Correção (*Correction*); **Consist**: Consistência (*Consistency*); **Ex-G**: Execução Guiada (*Execution-Guided*); ***N*-BR**: Re-ranqueamento (*N-best Rerankers*).

4.2 Estratégias de Geração de Dados

A avaliação de uma estratégia NL2SQL, bem como do modelo selecionado para tal, depende da disponibilidade de uma base de dados composta por pares de perguntas em linguagem natural e suas consultas SQL correspondentes ou seus valores finais esperados. A criação dessas coleções é, portanto, um elemento central no avanço da área, visto que impacta diretamente a capacidade de generalização e a robustez dos modelos. A literatura apresenta diferentes estratégias de geração de dados, que podem ser agrupadas em três grandes categorias: (i) anotação humana, (ii) geração sintética e (iii) variação baseada em ambiguidades.

4.2.1 Anotação Humana

A anotação manual é a estratégia mais direta e precisa para construção de coleções NL2SQL. Nela, especialistas de um domínio específico elaboram perguntas em linguagem natural, enquanto engenheiros de software ou especialistas em bancos de dados produzem as consultas SQL correspondentes. Esse método, embora trabalhoso, garante alta qualidade, especialmente em cenários onde é necessária precisão semântica.

O estudo-base desta pesquisa (LIU et al., 2025) destaca a anotação humana como um dos métodos empregados. Bases de dados como a BookSQL e a BULL, voltadas ao setor financeiro (KUMAR et al., 2024; ZHANG et al., 2024), foram construídas com a participação de especialistas do domínio para garantir relevância e consistência. Da mesma forma, o MIMICSQL (WANG; SHI; REDDY, 2020) explorou registros médicos eletrônicos, enquanto o ScienceBenchmark (ZHANG et al., 2023) foi voltado a bancos de dados científicos complexos, combinando elaboração manual inicial com posterior expansão automática.

Essa abordagem garante precisão e adequação contextual, mas demanda alto custo humano e carece de escalabilidade frente a métodos automáticos.

4.2.2 Geração Sintética

Para superar as limitações de custo e escala da anotação manual, diversos trabalhos exploram a geração automática de dados sintéticos. Nessa abordagem, utilizam-se modelos computacionais para criar pares de pergunta-consulta a partir de regras pré-definidas, modelos semânticos ou grandes modelos de linguagem.

No caso do MIMICSQL (WANG; SHI; REDDY, 2020), os autores categorizaram perguntas em dois grupos principais: *recuperação direta*, voltadas a informações pontuais, e *raciocínio*, que exigem junção de múltiplas tabelas. A partir dessas categorias, construíram modelos de perguntas e de consultas SQL genéricos para gerar um conjunto sintético

ampliado. Já o ScienceBenchmark (ZHANG et al., 2023) utilizou um processo em quatro etapas: extração de modelos de SQL a partir de Árvores de Sintaxe Abstrata (AST), geração de novas consultas, uso de um LLM (`GPT-3`) para criar perguntas em linguagem natural a partir das consultas geradas na etapa anterior e posterior filtragem humana.

Mais recentemente, o modelo Text-to-SQL SENSE (YANG et al., 2024) explorou dados sintéticos de forma diferenciada, distinguindo entre dados "fortes", produzidos por modelos robustos como o `GPT-4`, e dados "fracos", gerados por modelos menores de código aberto (*open-source*). Os autores introduziram intencionalmente inconsistências com os dados fracos, permitindo que o modelo aprendesse a lidar com erros e reduzisse alucinações em consultas, enquanto a introdução dos dados fortes tinha o objetivo de melhorar a sua generalização de domínio.

A vantagem da geração sintética é a escalabilidade: é possível criar bases amplas e diversificadas com menor esforço humano. Contudo, essa estratégia traz riscos de redundância, perda de naturalidade das perguntas e introdução de vieses artificiais nos modelos treinados.

4.2.3 Variação e Ambiguidade

Uma terceira vertente busca enriquecer os dados por meio da introdução de ambiguidades e variações linguísticas. O *benchmark* AmbiQT (BHASKAR et al., 2023), por exemplo, gerou mais de 3000 exemplos a partir do SPIDER (YU et al., 2018), nos quais cada pergunta pode ter duas consultas SQL corretas. Para isso, os autores aplicaram geração de sinônimos com ChatGPT e perturbações baseadas em regras. Essa estratégia permite testar a robustez dos modelos frente a ambiguidades lexicais e estruturais, desafiando sua capacidade de interpretar corretamente a linguagem natural.

Os pontos positivos dessa abordagem incluem maior diversidade e realismo linguístico, já que reflete situações ambíguas comuns na comunicação humana. Entretanto, o ponto negativo é a elevação da complexidade na avaliação dos resultados, pois múltiplas respostas podem ser igualmente corretas.

De modo geral, observa-se um equilíbrio entre precisão e custo na escolha da estratégia de geração de dados. Enquanto a anotação humana assegura qualidade, a geração sintética garante escalabilidade, e a variação baseada em ambiguidades adiciona realismo. Assim, a tendência na literatura recente tem sido a combinação de algumas dessas abordagens, buscando aproveitar os pontos fortes de cada uma.

No âmbito desta pesquisa, que visa responder a perguntas em linguagem natural sobre as informações presentes no banco de dados da **Plataforma Jacarandá**, a ausência de bases de referência específicas para o domínio acadêmico representa um desafio adicional. Dessa forma, a construção de um conjunto de dados adequado poderá se beneficiar

da integração de estratégias: iniciar com anotação manual (para garantir qualidade), expandir com geração sintética (para aumentar a cobertura) e, posteriormente, aplicar variações linguísticas para aproximar o modelo de cenários reais de uso. O detalhamento da abordagem adotada nesta pesquisa encontra-se nas Subseções 5.1.2 e 5.1.3.

4.3 Estratégias de Avaliação de Resultados

A avaliação de sistemas NL2SQL requer métricas capazes de mensurar tanto a qualidade estrutural das consultas geradas quanto sua efetividade prática ao serem executadas. Na literatura, observam-se métricas que variam desde comparações sintáticas entre a consulta de referência e a predita, até indicadores de precisão semântica e de eficiência computacional.

O estudo-base desta pesquisa (LIU et al., 2025) apresenta a *Execution Accuracy* (EX), sendo esta uma métrica bastante consolidada e amplamente utilizada. A EX mede a proporção de consultas preditas que retornam o mesmo resultado que a consulta de referência ao serem executadas no banco de dados. Por sua simplicidade e objetividade, aparece em praticamente todos os trabalhos da área, servindo como uma visão geral do desempenho do tradutor NL2SQL. Contudo, seu ponto fraco está em não distinguir consultas estruturalmente incorretas que, por coincidência, retornam o mesmo resultado.

Outra métrica considerada é a *Exact Match Accuracy* (EM), que verifica a equivalência estrutural entre a consulta gerada e a consulta de referência. Diferentemente da EX, a EM avalia se o modelo conseguiu reproduzir a estrutura correta do SQL. Embora menos comum, foi aplicada em bases como BookSQL e MIMICSQL. Associada a ela, a métrica *ROUGE-L*, tradicionalmente empregada em tarefas de sumarização, também foi explorada nesses trabalhos para medir sobreposição de subsequências entre consultas. Apesar de oferecer *insights* sobre a similaridade sintática, ambas podem falhar em refletir a equivalência semântica, isto é, consultas diferentes que retornam o mesmo resultado podem ser penalizadas indevidamente.

Visando unir acurácia e eficiência computacional, foi proposta a *Valid Efficiency Score* (VES), também apresentada em LIU et al.. Essa métrica avalia não apenas a correção dos resultados, mas também aspectos relacionados ao desempenho computacional, como tempo de execução e consumo de recursos. Embora ainda pouco utilizada em trabalhos correlatos, apresenta grande potencial para cenários práticos, nos quais a eficiência da consulta é tão importante quanto sua correção.

De forma geral, percebe-se que cada métrica enfatiza um aspecto distinto: a EX privilegia a corretude do resultado, a EM e a ROUGE-L o alinhamento estrutural, e a VES a combinação entre acurácia e eficiência. Assim, diferentes trabalhos optam por combiná-las a fim de obter uma avaliação mais abrangente.

No contexto deste trabalho, a adoção da VES, em conjunto com métricas como EX e ROUGE-L, permitirá análises mais completas sobre a eficácia das diferentes estratégias NL2SQL e modelos de LLM avaliados. Cabe ressaltar que a métrica de Correspondência Exata (*Exact Match Accuracy* — EM) não será utilizada nesta pesquisa por ser considerada excessivamente rigorosa, penalizando consultas que apresentam diferenças estruturais simples, mas que mantêm a equivalência semântica e funcional. Além disso, nota-se que a EM não tem sido amplamente adotada nos trabalhos mais recentes da literatura, que priorizam o resultado da execução em detrimento da conformidade literal ao código de referência. Os detalhes formais das métricas selecionadas são descritos na Seção 5.3.

A Tabela 2 sintetiza os principais trabalhos discutidos, evidenciando as estratégias empregadas na geração de coleções de dados, bem como as métricas utilizadas para a avaliação dos resultados. Essa sistematização facilita a compreensão das abordagens existentes e ressalta a relevância do presente trabalho, ao propor e avaliar uma solução adaptada ao contexto dos Currículos Lattes e atuações acadêmicas dos servidores do IFG.

Tabela 2 – Métodos de geração e avaliação utilizados nos trabalhos

Trabalho Citado	**Métodos de Geração**			**Métodos de Avaliação**			
	G1	G2	G3	EM	EX	VES	ROUGE-L
LIU et al.	✗	✗	✗	✗	✗	✗	
KUMAR et al.	✗			✗	✗		✗
ZHANG et al. 2024	✗				✗		
ZHANG et al. 2023	✗	✗			✗		
WANG; SHI; REDDY	✗	✗		✗	✗		✗
YANG et al.		✗			✗		
BHASKAR et al.			✗		✗		

G1: Geração de Dados por Especialistas (anotação humana); **G2**: Geração de Dados Sintéticos; **G3**: Geração de Sinônimos; **EM**: *Exact Match Accuracy* (Acurácia de Correspondência Exata); **EX**: *Execution Accuracy* (Acurácia de Execução); **VES**: *Valid Efficiency Score* (Pontuação de Eficiência Válida); **ROUGE-L**: *Longest Common Subsequence* (Maior Subsequência Comum).

5 Metodologia

A metodologia adotada neste trabalho fundamenta-se no processo de Descoberta de Conhecimento em Bases de Dados (KDD - *Knowledge Discovery in Databases*), conforme proposto por FAYYAD; PIATETSKY-SHAPIRO; SMYTH (1996). Essa escolha justifica-se pela necessidade de estruturar, de forma sistemática, o fluxo experimental necessário para a preparação de bases de dados acadêmicas e a subsequente avaliação de estratégias NL2SQL apoiadas em Modelos de Linguagem de Grande Escala (LLMs).

Neste estudo, o processo KDD é aplicado como o arcabouço metodológico que orienta as fases de seleção, preparação e transformação dos dados institucionais, fornecendo a base necessária para a execução dos experimentos. A etapa central de "mineração" é aqui representada pelo processo de inferência dos LLMs na tarefa de tradução de texto para SQL, o que possibilita um procedimento de análise e validação das consultas geradas frente aos objetivos propostos.

O procedimento metodológico desta pesquisa está organizado nas etapas detalhadas a seguir.

5.1 Seleção e Pré-Processamento de Dados

A primeira etapa do processo de KDD consiste na seleção dos dados, fase em que são identificadas as fontes relevantes, estabelecidos os critérios de inclusão e exclusão, e realizadas as coletas necessárias. Em seguida, aplica-se o pré-processamento, que compreende a limpeza dos dados, o tratamento de valores ausentes, ruídos e inconsistências, além de eventuais processos de normalização. Posteriormente, efetua-se a transformação dos dados para adequá-los ao formato exigido pelas etapas subsequentes, englobando operações como agregação, redução de dimensionalidade e codificação de atributos.

Para esta pesquisa, a base de dados selecionada provém da plataforma institucional **Jacarandá**. O pré-processamento abrangeu desde a organização do banco relacional até a construção de coleções compostas por pares de perguntas em linguagem natural, consultas SQL correspondentes e as respectivas respostas esperadas. Esse processo assegurou a consistência e a representatividade dos dados utilizados para avaliar as estratégias NL2SQL sob investigação.

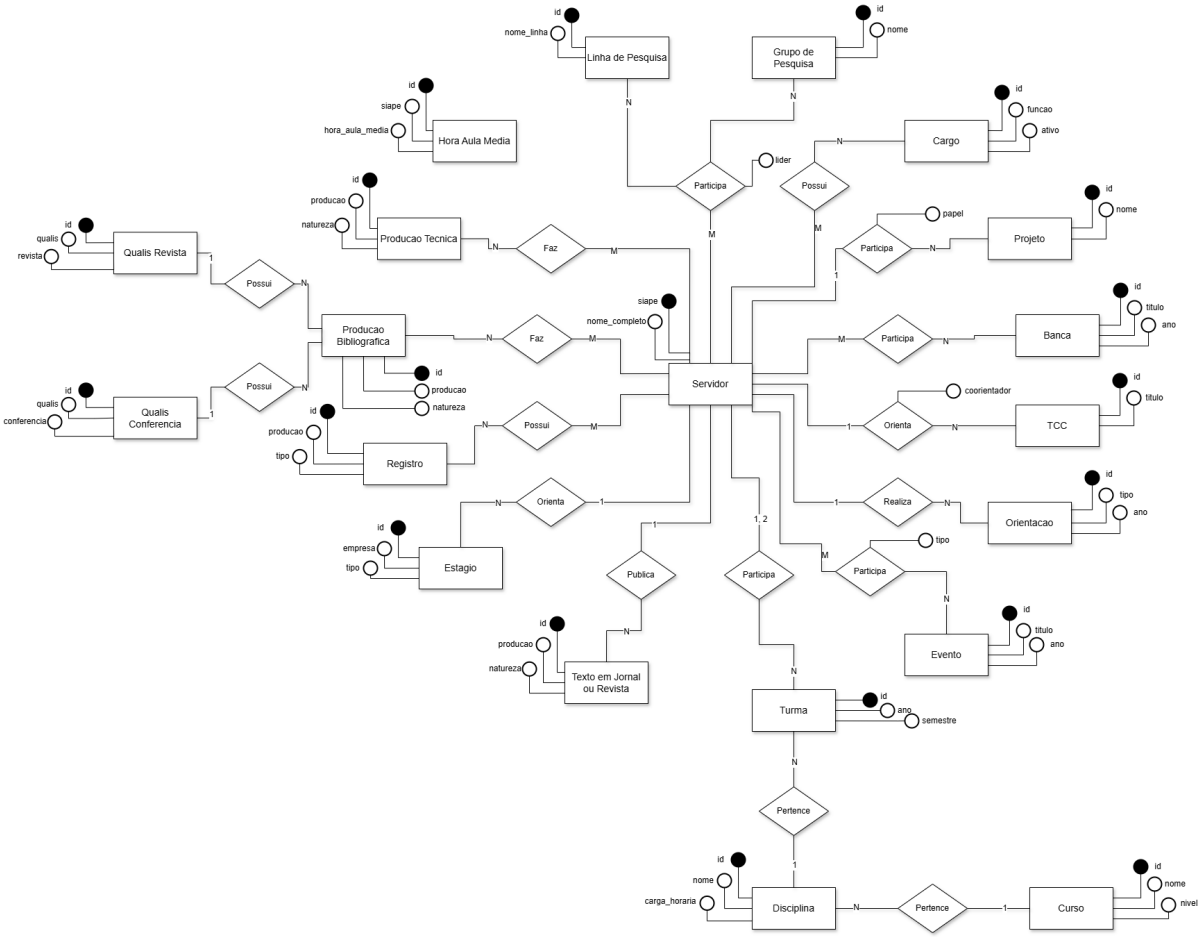
5.1.1 Plataforma Jacarandá: Banco de Dados Relacional

A **Plataforma Jacarandá** centraliza informações sobre os currículos e as atividades acadêmicas dos servidores do IFG em um banco de dados relacional. Este repositório

constitui a principal fonte de dados da pesquisa, servindo de base para a geração das coleções de dados (manual e sintética), para a formulação das consultas e para a posterior avaliação das inferências produzidas pelos modelos.

A Figura 2 apresenta o modelo conceitual do banco de dados da plataforma, representado por meio de um Diagrama Entidade-Relacionamento (DER) especificando suas principais entidades, relacionamentos e atributos.

Figura 2 – Plataforma Jacarandá: Diagrama Entidade-Relacionamento (DER)



Os dados da plataforma são oriundos de duas fontes principais: (i) registros institucionais internos sobre atividades e produtividade acadêmica dos servidores, e (ii) informações extraídas dos Currículos Lattes (CNPq). A integração dessas fontes é realizada por rotinas de Extração, Transformação e Carregamento (ETL), resultando em um banco de dados consolidado em PostgreSQL. Embora existam estudos prévios sobre bases relacionadas ao Currículo Lattes no IFG, como propostas de sistemas de recomendação (SANTOS et al., 2025), esta pesquisa configura-se, conforme a literatura consultada, como a primeira investigação a aplicar técnicas de NL2SQL neste contexto específico.

Visando o alinhamento com o estado da arte, uma versão secundária do banco de dados foi transposta para o SGBD SQLite, seguindo o padrão adotado pelos principais

benchmarks de domínio geral da área, como Spider (LEI et al., 2024) e BIRD (LI et al., 2023). Essa conversão garantiu a compatibilidade da base da Plataforma Jacarandá com os métodos de geração e avaliação estabelecidos em trabalhos correlatos. Complementarmente, foi realizada a normalização das colunas textuais, que consistiu na remoção de caracteres acentuados e na conversão dos textos para caixa alta, assegurando maior robustez e consistência durante o processo de casamento de dados e inferência dos modelos.

5.1.2 Coleção de Dados Manualmente Gerada

Uma das funcionalidades centrais da **Plataforma Jacarandá** é a automatização do cálculo de pontuações relacionadas às diferentes atuações dos servidores, permitindo sua participação em editais institucionais. Para isso, o sistema disponibiliza relatórios organizados em tópicos e subtópicos, acessíveis aos usuários cadastrados. Esses relatórios serviram como principal fonte de inspiração para a construção de uma coleção de dados com anotação humana, especificamente adaptada ao cenário de avaliação NL2SQL.

O processo de construção seguiu as seguintes etapas: (i) extração dos subtópicos presentes nos principais editais da instituição, (ii) organização desses subtópicos em categorias associadas aos seus respectivos tópicos, (iii) elaboração de perguntas em linguagem natural representativas para cada tópico, (iv) escrita manual das consultas SQL correspondentes e (v) execução das consultas sobre um *backup* da versão inicial da base de dados da Plataforma Jacarandá para obtenção das respostas esperadas.

A coleção final, denominada **Perguntas Manualmente Geradas (PMG)**, resultou em 100 pares ⟨pergunta, SQL, resposta⟩. Essa coleção contempla seis categorias principais de perguntas, conforme descrito e exemplificado na Figura 3.

Essa coleção serviu como um *benchmark* inicial, construído com maior rigor humano, a fim de testar a capacidade do modelo em compreender consultas institucionais reais. Posteriormente, ela foi submetida ao módulo NL2SQL desenvolvido, e seus resultados são discutidos no Capítulo 6. Em linhas gerais, o fluxo de geração da coleção, aplicação da estratégia NL2SQL e avaliação dos resultados são resumidos na Figura 4.

5.1.3 Coleção de Dados Sintética

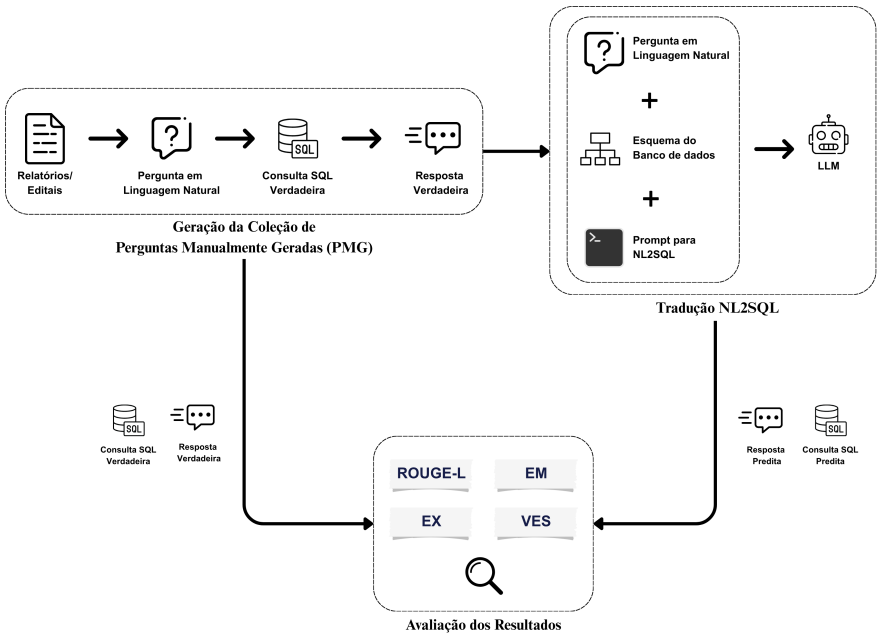
Além da coleção manual, foi elaborado um conjunto de dados sintético com o objetivo de ampliar a cobertura de perguntas possíveis sobre o banco de dados e avaliar a capacidade de generalização do modelo em diferentes domínios. Para isso, utilizou-se a página de *Business Intelligence* (BI) da Plataforma Jacarandá, que disponibiliza gráficos com indicadores relacionados à carga horária, número de servidores efetivos e temporários, participações em atividades de ensino, pesquisa, extensão e gestão, além de produções.

Com base nesses gráficos, foram desenvolvidas sete consultas para obter informações

Figura 3 – Distribuição dos pares ⟨pergunta, SQL, resposta⟩ da coleção **PMG**

Sigla	Descrição (quantidade)	Exemplo de Pergunta	Exemplo de SQL	Exemplo de Resposta
PMG-A	Tempo de serviço e formação de um servidor (5)	Qual é o maior grau acadêmico obtido pelo servidor Daniel Xavier?	**SELECT** titulacao **FROM** servidor **WHERE LOWER**(nome_completo) **LIKE LOWER**('Daniel Xavier%');	DOUTORADO
PMG-B	Atuações em atividades de ensino (12)	Quantos projetos de ensino cadastrados no IFG, nos últimos cinco anos, foram de autoria ou coordenação do servidor Sérgio Daniel Carvalho?	**SELECT COUNT**(*) **AS** quantidade **FROM** servidor **INNER JOIN** servidor_proj **ON** servidor.siape = servidor_proj.siape **INNER JOIN** proj **ON** servidor_proj.proj_id = proj.id **WHERE** (proj.data_termino >= **CURRENT_DATE** - **INTERVAL** '5 years' **OR** proj.data_termino **IS NULL**) **AND** proj.tipo_projeto = 'ENSINO' **AND** (servidor_proj.papel = 'COORDENADOR' **OR** servidor_proj.papel = 'AUTOR') **AND LOWER**(servidor.nome_completo) **LIKE LOWER**('Sergio Daniel Carvalho%');	0
PMG-C	Atuações em atividades de pesquisa (26)	Quantos projetos de pesquisa cadastrados no IFG foram de autoria ou coordenação do servidor Sérgio Daniel Carvalho nos últimos cinco anos?	**SELECT COUNT**(*) **AS** quantidade **FROM** servidor **INNER JOIN** servidor_proj **ON** servidor.siape = servidor_proj.siape **INNER JOIN** proj **ON** servidor_proj.proj_id = proj.id **WHERE LOWER**(servidor.nome_completo) **LIKE LOWER**('Sergio Daniel Carvalho%') **AND** (proj.data_termino >= **CURRENT_DATE** - **INTERVAL** '5 years' **OR** proj.data_termino **IS NULL**) **AND** proj.tipo_projeto = 'PESQUISA' **AND** (servidor_proj.papel = 'COORDENADOR' **OR** servidor_proj.papel = 'AUTOR');	5
PMG-D	Atuações em atividades de extensão (10)	Quantas organizações de eventos no IFG o servidor de siape 1324561 fez nos últimos 5 anos?	**SELECT COUNT**(*) **AS** quantidade **FROM** servidor **INNER JOIN** participacao_prodtec **ON** servidor.siape = participacao_prodtec.siape **INNER JOIN** prodtec **ON** participacao_prodtec.prodtec_id = prodtec.id **WHERE** servidor.pk_siape = 1324561 **AND** prodtec.ano >= **EXTRACT**(**YEAR FROM CURRENT_DATE**) - 5 **AND** prodtec.natureza = 'ORGANIZACAO';	0
PMG-E	Produções intelectuais (43)	Qual foi a quantidade de capítulos de livros publicados pelos servidores do campus Aparecida de Goiânia nos últimos cinco anos?	**SELECT COUNT**(*) **AS** quantidade **FROM** servidor **INNER JOIN** participacao_prodbib **ON** servidor.siape = participacao_prodbib.siape **INNER JOIN** prodbib **ON** participacao_prodbib.prodbib_id = prodbib.id **WHERE** servidor.sigla_campus = 'APA' AND **CAST**(prodbib.ano AS **INTEGER**) >= **EXTRACT**(**YEAR FROM CURRENT_DATE**) - 5 **AND** prodbib.tipo = 'CAPÍTULO DE LIVRO';	134
PMG-F	Atuações em atividades de gestão (4)	Quantas vezes o servidor Sérgio Daniel Carvalho exerceu função ou cargo de direção (CD, FG ou FCC) no IFG nos últimos cinco anos?	**SELECT COUNT**(*) **AS** quantidade **FROM** servidor **INNER JOIN** cargo **ON** servidor.siape = cargo.siape **WHERE LOWER**(servidor.nome_completo) **LIKE LOWER**('Sergio Daniel Carvalho%') **AND** (cargo.data_saida >= **CURRENT_DATE OR** cargo.data_saida **IS NULL**) **AND** cargo.funcao = 'CARGO DE DIRECAO';	0

Figura 4 – Geração, tradução e avaliação da coleção PMG



representativas a partir do *backup* da base. Cada consulta gerou uma tabela agregada, contendo entre cinco e oito colunas informativas. A menor tabela resultou em 133 linhas e a maior em 5016. Em comum, todas possuíam uma coluna principal de contagem (ex.: número de servidores, número de participações), geralmente agrupada por campus e área de atuação. Algumas tabelas também incluíram agrupamentos adicionais por semestre/ano ou por gênero dos servidores (feminino ou masculino).

Essas tabelas representativas foram então submetidas ao modelo `gpt-4.1-mini`, em partes de 30 a 60 linhas cada, a depender de seu tamanho total. Para cada divisão, foi

elaborado um *prompt* contendo: (i) instruções para a geração de perguntas, (ii) explicação do significado de siglas utilizadas, (iii) breve descrição da tabela fornecida e (iv) especificação do formato de saída, restringindo-o a pares ⟨pergunta, resposta⟩. Como resposta, o modelo gerou cerca de 10 pares por divisão, sendo que cada resposta correspondia a um valor único (numérico ou textual) presente em uma única coluna. O *prompt* usado para geração dos pares é descrito no Apêndice A.1.

Após um processo de limpeza manual — necessário para remover parte das perguntas redundantes, mal formuladas ou inconsistentes — consolidou-se a coleção final denominada **Perguntas Sintéticas (PS)**, composta por 800 pares ⟨pergunta, resposta⟩, distribuídos nas classes descritas na Figura 5.

Figura 5 – Distribuição dos pares ⟨pergunta, resposta⟩ da coleção **PS**

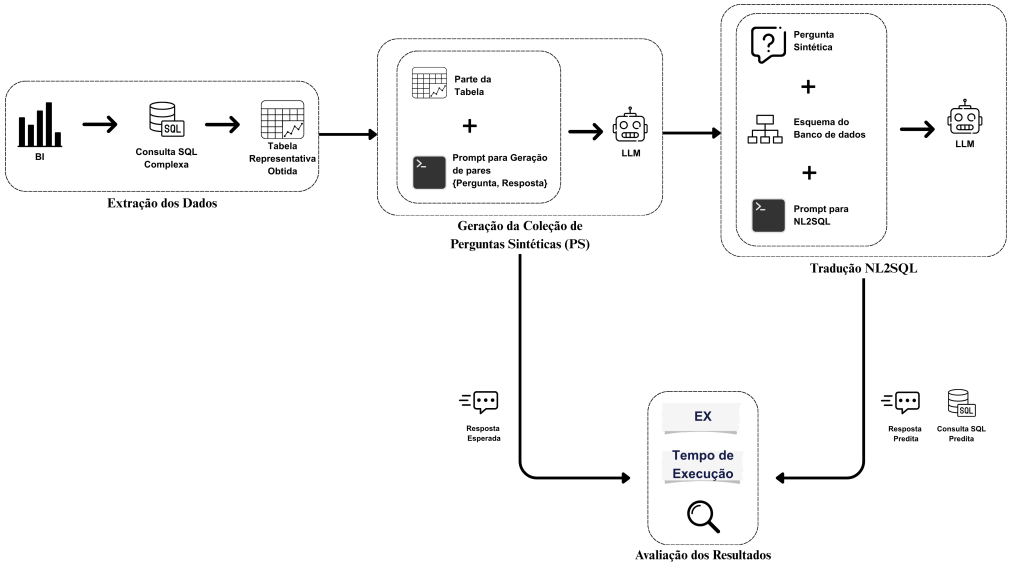
Sigla	Descrição (quantidade)	Exemplo de Pergunta	Exemplo de Resposta
PS-A	Carga horária média de servidores (200)	Em que ano o Campus Anápolis registrou a maior média de horas-aula para Engenharia de Transportes?	2020
PS-B	Quantidade de servidores efetivos e temporários (165)	Qual é a quantidade de servidores efetivos no Campus Goiânia na área de Biologia Geral no segundo semestre de 2022?	7
PS-C	Atuações em atividades de ensino (70)	Qual a área de atuação com maior quantidade de participações no Campus Cidade de Goiás em Ministração de Disciplinas por semestre no Ensino Médio Integrado, nos últimos cinco anos?	ARTES
PS-D	Atuações em atividades de extensão (90)	Qual o total de participações masculinas em Organização de Eventos no Campus Itumbiara na área de Matemática, nos últimos cinco anos?	3
PS-E	Atuações em atividades de gestão (20)	Qual é o gênero predominante na ocupação de cargos de direção na área de Engenharia Civil no Campus Anápolis, nos últimos cinco anos?	FEMININO
PS-F	Atuações em atividades de pesquisa (115)	Quantas participações foram registradas no Campus Itumbiara na área de Sociologia para Orientação de Trabalho de Iniciação Científica e Tecnológica no gênero masculino, nos últimos cinco anos?	1
PS-G	Produções intelectuais (140)	Quantas produções do tipo CAPÍTULO DE LIVRO foram feitas por servidoras do Campus Jataí na área LETRAS em 2020?	6

Esse conjunto sintético complementa a coleção manual, permitindo a avaliação do módulo NL2SQL em cenários com maior volume de dados e variedade de perguntas. O processo de construção da coleção é sintetizado na Figura 6 e seus resultados são apresentados e discutidos no Capítulo 6.

5.2 Mineração de Dados

A etapa de mineração constitui o núcleo do processo de KDD, sendo o momento em que as capacidades dos Modelos de Linguagem de Grande Escala (LLMs) serão aplicadas para a extração de padrões e a resolução da tarefa proposta. No escopo desta pesquisa, a mineração é definida pelo processo de tradução de texto para SQL, onde perguntas em linguagem natural são convertidas em instruções estruturadas. O objetivo central é avaliar

Figura 6 – Geração, tradução e avaliação da coleção PS



diferentes abordagens para maximizar a acurácia semântica e a validade sintática das consultas, considerando as particularidades dos dados de referência.

Para formalizar o experimento, considere: seja q uma pergunta em linguagem natural e S a descrição do esquema relacional (tabelas, colunas, chaves e relacionamentos) do Jacarandá. O processo busca obter uma função de tradução que resulte em uma consulta $SQL(q, S)$ capaz de retornar a resposta correta. Para isso, a mineração foi estruturada em duas fases: a preparação do contexto $C(S)$ e a execução das estratégias de tradução.

5.2.1 Preparação do Contexto Semântico

Os dados de entrada para as estratégias avaliadas compreendem as coleções manual e sintética, ambas integradas ao esquema SQLite. Antes da inferência, o esquema S é consolidado em um contexto $C(S)$, que disponibiliza ao modelo o conjunto de metadados essenciais, incluindo nomes de tabelas, colunas, tipos de dados, chaves e, em cenários específicos, amostras de valores reais das instâncias. A partir desse contexto, o método realiza a vinculação de esquema (*schema linking*), processo fundamental para identificar os elementos relacionais pertinentes à pergunta em linguagem natural e assegurar um mapeamento preciso entre a intenção do usuário e a estrutura do banco de dados.

Adicionalmente, o contexto é enriquecido com diretrizes específicas para o tratamento de particularidades da língua portuguesa. Foram inseridas instruções para a remoção de acentos e cedilhas, bem como para a padronização de caixa (*case sensitivity*) nos atributos textuais. Tais medidas visam mitigar divergências e evitar falhas de correspondência de *strings* durante a predição e a execução das consultas, garantindo maior robustez ao processo de recuperação de dados.

5.2.2 Estratégias de Tradução e Parametrização

A seleção das estratégias de tradução para este trabalho pautou-se em critérios de relevância na literatura, aplicabilidade ao domínio institucional e, primordialmente, viabilidade de reprodução técnica. Diante da vasta gama de métodos existentes, optou-se por focar em abordagens que apresentaram condições adequadas de reprodutibilidade experimental, garantindo maior confiabilidade e comparabilidade nos resultados obtidos.

Nesse sentido, foram desconsiderados métodos que não disponibilizavam repositórios públicos ou que eram voltados a problemas distintos do escopo desta pesquisa, como abordagens que exigem *fine-tuning* extensivo ou técnicas especializadas exclusivamente em interações conversacionais. Além disso, a exclusão de certas propostas recentes justificou-se por limitações técnicas impeditivas, tais como dependências não documentadas, incompatibilidades com versões atuais de APIs de modelos de linguagem e rigidez do código quanto ao SGBD ou à coleção de dados padrão.

Dessa forma, foram selecionadas quatro estratégias representativas do estado da arte e de técnicas de engenharia de *prompt*, cada uma configurada com parâmetros específicos de temperatura e amostragem para garantir a consistência dos testes:

- **Zero-Shot Prompting:** Utilizada como linha de base (baseline), esta técnica explora o conhecimento prévio do LLM sem o fornecimento de exemplos. Foi utilizado um modelo LLM pré-definido com temperatura configurada em 1, visando permitir a exploração da criatividade do modelo na interpretação do esquema. O *prompt* estruturado para esta etapa encontra-se no Apêndice A.2.

- **Few-Shot Prompting:** Esta abordagem fornece ao modelo um contexto enriquecido com seis pares de exemplos selecionados para cobrir a diversidade semântica da base Jacarandá. A estrutura dos exemplares foi inspirada no método DIN-SQL (POURREZA; RAFIEI, 2023), em que cada exemplo não se limita ao par pergunta-SQL, mas inclui um estágio intermediário de vinculação. Assim, os exemplos são apresentados no formato: (i) pergunta em linguagem natural; (ii) *schema_links*, consistindo em um mapeamento explícito das tabelas e colunas relevantes para a pergunta (ex: `{"tabela1": ["coluna1", "coluna2"]}`); e (iii) a consulta SQL correspondente. Essa organização visa guiar o raciocínio do modelo na identificação dos elementos do esquema antes da geração do código. A temperatura foi mantida em 1 para garantir paridade com a abordagem *Zero-Shot*, e a estrutura completa do *prompt* está disponível no Apêndice A.3.

- **ODIS (Zero-Shot):** Trata-se de um método da literatura que foca na inserção de informações adicionais no contexto. Foi utilizada a versão Zero-Shot do método, com uma adaptação personalizada no *prompt*: a introdução de instruções explícitas para

a normalização de atributos textuais (remoção de acentos e padronização de caixa), garantindo que a lógica do ODIS fosse aplicada respeitando as particularidades ortográficas dos dados dos servidores.

- **C3SQL:** Este método implementa um fluxo de pré-processamento, seguido de em etapas de seleção (tabelas e colunas) e geração. Utilizou-se o mesmo LLM para todas as fases, seguindo a parametrização recomendada: temperatura 0.7 e 10 amostras ($n = 10$) para as etapas de seleção; e temperatura 1 com 20 amostras ($n = 20$) para a geração de consultas candidatas. Além das instruções de normalização de texto incorporadas ao *prompt*, foi aplicada uma restrição de tempo de execução (*timeout*) na etapa de *self-consistency*, visando evitar o travamento do *pipeline* por consultas excessivamente onerosas ao banco de dados.

5.3 Avaliação e Interpretação do Conhecimento

Uma vez que os resultados são obtidos, torna-se importante avaliá-los e interpretá-los. Nesse processo, as métricas de avaliação desempenham papel fundamental na análise do desempenho da solução NL2SQL. Neste trabalho, foram selecionadas métricas amplamente utilizadas no contexto de tradução de linguagem natural para SQL, de modo a mensurar tanto a correção sintática quanto a aderência semântica e a eficiência das consultas geradas.

Para formalizar a avaliação, definem-se as seguintes variáveis: N representa o tamanho do conjunto de dados; V_i corresponde ao conjunto de resultados obtidos a partir da consulta SQL da verdade fundamental (consulta esperada) Y_i; e $\hat{V}_i$ refere-se ao conjunto de resultados retornados pela consulta SQL predita $\hat{Y}_i$, gerada pela solução NL2SQL.

Exact Match Accuracy (EM) (YU et al., 2018): a Acurácia de Correspondência Exata é baseada na Acurácia de Correspondência de Componentes (CM) e mede se todos os componentes SQL da consulta SQL prevista correspondem à consulta SQL verdadeira, isto é, $\mathcal{C} = C_k$. Pode ser calculada da seguinte forma:

$$EM = \frac{\sum_{i=1}^{N} \mathbf{1}\left(\bigwedge_{C_k \in \mathcal{C}} Y_i^{C_k} = \hat{Y}_i^{C_k}\right)}{N} \tag{5.1}$$

Já a **Component-Match Accuracy (CM)** mede a correspondência exata de diferentes componentes (cláusulas) SQL. O cálculo pode ser formalizado da seguinte maneira:

$$CM^C = \frac{\sum_{i=1}^{N} \mathbf{1}\left(Y_i^C = \hat{Y}_i^C\right)}{N} \tag{5.2}$$

onde Y_i^C é o componente da consulta SQL Y_i, sendo que alguns (por exemplo, `WHERE`) não consideram restrições de ordem.

Execution Accuracy (EX) (YU et al., 2018): a Acurácia de Execução avalia o desempenho do sistema NL2SQL comparando se os conjuntos de resultados da execução

das consultas SQL verdadeiras e das consultas SQL preditas são idênticos. A função retorna 1 se a condição interna for satisfeita, e 0 caso contrário.

$$EX = \frac{\sum_{i=1}^{N} \mathbf{1}(V_i = \hat{V}_i)}{N} \tag{5.3}$$

Valid Efficiency Score (VES) (LI et al., 2023): A Pontuação de Eficiência Válida avalia a eficiência na execução de consultas SQL consideradas válidas. Uma consulta é definida como válida quando é executada com sucesso, sem erros, e retorna resultados significativos. Essa métrica combina dois aspectos essenciais: a acurácia de obtenção de resultados corretos e a eficiência de execução da consulta SQL. O cálculo é dado por:

$$VES = \frac{\sum_{i=1}^{N} \mathbf{1}(V_i = \hat{V}_i) \cdot \mathbf{R}(Y_i, \hat{Y}_i)}{N}, \quad \mathbf{R}(Y_i, \hat{Y}_i) = \sqrt{\frac{\mathbf{E}(Y_i)}{\mathbf{E}(\hat{Y}_i)}} \tag{5.4}$$

onde $\mathbf{R}(.)$ representa a eficiência relativa de execução da consulta SQL prevista em relação à consulta SQL de referência. Essa medida busca reduzir a influência de variações ocasionais no ambiente de execução, realizando uma normalização por meio da radiciação. Já $\mathbf{E}(.)$ expressa a eficiência de uma consulta SQL específica, podendo ser associada, por exemplo, ao tempo de execução ou ao consumo de recursos computacionais.

ROUGE-L (LIN, 2004): O ROUGE-L é uma métrica baseada na *maior subsequência comum* (*Longest Common Subsequence – LCS*). Nesse sentido, para a avaliação de técnicas NL2SQL, essa métrica pode ser usada para avaliar a similaridade entre a consulta SQL prevista e a consulta SQL de referência (esperada). Diferentemente de outras métricas que avaliam coincidências exatas de palavras, o ROUGE-L considera a ordem das palavras, valorizando sequências que preservam a estrutura original.

Uma subsequência comum mais longa indica maior similaridade entre as consultas. A partir do LCS, são calculadas as métricas de **revocação** (*recall*, R) e **precisão** (*precision*, P), definidas como:

$$R = \frac{\text{LCS}(Y, \hat{Y})}{|Y|}, \quad P = \frac{\text{LCS}(Y, \hat{Y})}{|\hat{Y}|}$$

onde: Y é a sequência de tokens da consulta SQL de referência, $\hat{Y}$ é a sequência de tokens da consulta SQL prevista e $\text{LCS}(Y, \hat{Y})$ é o tamanho da maior subsequência comum entre ambas.

A **pontuação F1** (ou *F1-Score*) combina precisão e revocação em uma única métrica harmônica, sendo calculada por:

$$F_1 = \frac{2 \cdot P \cdot R}{P + R}$$

Esse procedimento permite capturar não apenas a presença dos elementos corretos, mas também a preservação da sua ordem, tornando a métrica mais sensível à estrutura da consulta.

Com essa abordagem metodológica, pretende-se testar na prática como as soluções de tradução de texto para SQL se comportam com os dados reais do IFG. Dessa forma, o estudo não apenas analisa a teoria, mas entrega dados concretos e orientações que possam subsidiar trabalhos futuros.

6 Resultados e Discussões

Nesta seção são apresentados os experimentos realizados para avaliar o desempenho das estratégias de conversão de linguagem natural para SQL (NL2SQL) adotadas neste trabalho.

Inicialmente, optou-se pela técnica de *prompt engineering* do tipo *zero-shot*. Nesse cenário, o modelo de linguagem de grande porte (LLM) foi solicitado a realizar a conversão de texto em consultas SQL sem receber exemplos prévios ou demonstrações da tarefa. Para isso, foram fornecidas aos modelos testados instruções específicas, acompanhadas da estrutura do banco de dados da **Plataforma Jacarandá**, incluindo os nomes das tabelas, atributos, tipos de dados e alguns valores representativos.

As perguntas foram submetidas aos modelos individualmente, considerando dois conjuntos distintos: (i) uma coleção de dados de perguntas elaboradas manualmente e (ii) uma coleção de dados sintética, gerada de forma automática por um LLM e uma entrada de dados. Os modelos de linguagem foram então avaliados considerando três aspectos principais: acurácia das respostas obtidas em relação as reais (EX), custo computacional de entrada e saída de dados e tempo de resposta médio do LLM.

As tabelas Tabela 3 e Tabela 4 apresentam os resultados obtidos para a Coleção de Perguntas Manualmente Geradas (PMG) e para a Coleção de Perguntas Sintéticas (PS), respectivamente.

Os resultados apresentados nas tabelas indicam que o `GPT-5` obteve o desempenho máximo em acurácia de execução (EX), alcançando 54% na coleção PMG e 40,1% na PS. Contudo, esse desempenho está atrelado a um alto custo computacional e a uma latência elevada, com tempo médio de resposta de 41 segundos, possivelmente devido a sua configuração padrão que faz o uso intensivo de recursos de raciocínio (*reasoning effort*).

Para os experimentos subsequentes, optou-se pelo modelo `GPT-4.1-Mini` como *backend* único. Esta decisão baseia-se no equilíbrio entre acurácia, custo e tempo de resposta. O modelo apresentou desempenho estável em dados reais (47% na PMG), mantendo-se significativamente superior aos modelos de entrada, como o `GPT-3.5-Turbo` e o `GPT-4o-Mini`, que demonstraram fragilidades na coleção sintética (PS), com acurácias abaixo de 9%.

A seguir, são apresentados os resultados dos métodos avaliados sobre a coleção manual (PMG) e sobre uma subcoleção da base sintética, denominada **PS-Derivada**. A criação desta coleção derivada justifica-se pelo fato de a base sintética original (PS) ser composta apenas por pares de pergunta e valor esperado, carecendo de consultas SQL de

Tabela 3 – Acurácia de Execução, custo computacional e tempo de resposta médio de modelos da Família GPT na coleção PMG

Coleção	Modelo							
	5.1	**5**	**5-mini**	**4.1**	**4.1-mini**	**4o**	**4o-mini**	**3.5-turbo**
PMG-A	20,0	**60,0**	40,0	20,0	40,0	20,0	40,0	40,0
PMG-B	33,3	41,7	33,3	33,3	33,3	33,3	41,7	**50,0**
PMG-C	46,2	**53,8**	42,3	46,2	**53,8**	42,3	34,6	42,3
PMG-D	**80,0**	**80,0**	**80,0**	**80,0**	70,0	**80,0**	50,0	50,0
PMG-E	39,5	48,8	48,8	44,1	39,5	**53,5**	18,6	9,3
PMG-F	**75,0**	**75,0**	**75,0**	**75,0**	**75,0**	50,0	**75,0**	**75,0**
TOTAL	45,0	**54,0**	49,0	47,0	47,0	49,0	32,0	31,0
Entrada	1,25	1,25	0,25	2,00	0,40	2,50	**0,15**	8,00
Saída	10,00	10,00	2,00	8,00	1,60	10,00	**0,60**	6,00
Tempo	2,3	41	29	1,7	2,1	2,3	2,5	**1,6**

PMG: Perguntas Manualmente Geradas; **PMG-A**: Tempo de serviço e formação do servidor; **PMG-B**: Atuações em atividades de ensino; **PMG-C**: Atuações em atividades de pesquisa; **PMG-D**: Atuações em atividades de extensão; **PMG-E**: Produções intelectuais; **PMG-F**: Atuações em atividades de gestão; **EX**: *Execution Accuracy* (Acurácia de Execução); **Entrada**: Custo em dólar ($) por 1M de *tokens*; **Saída**: Custo em dólar ($) por 1M de *tokens*; **Tempo**: Tempo de resposta médio para cada pergunta em segundos.

referência para o cálculo de métricas de similaridade estrutural e eficiência.

A PS-Derivada foi construída a partir de um critério de filtragem rigoroso: foram selecionadas apenas as perguntas em que ao menos um dos oito modelos avaliados na análise preliminar gerou uma consulta SQL correta. Para os casos em que múltiplos modelos obtiveram sucesso para a mesma pergunta, optou-se pelo SQL que apresentou o menor tempo de execução, visando estabelecer um referencial de eficiência. Esse processo permitiu não apenas obter as consultas de referência necessárias, mas também reduzir problemas de desatualização temporal nos dados e filtrar eventuais perguntas sintéticas mal formuladas. Todo o conjunto resultante foi submetido a uma revisão manual para assegurar a integridade dos pares.

Dessa forma, os experimentos utilizam o `gpt-4.1-mini` como *backend* para mensurar: a acurácia das respostas (EX), a eficiência de execução (VES) e a similaridade estrutural das consultas ($ROUGE - L$). A composição detalhada das coleções sintéticas por categoria é apresentada na Tabela 5.

6.1 NL2SQL nos Dados Gerados Manualmente

Nesta seção, analisam-se os resultados obtidos na coleção de Perguntas Manualmente Geradas (PMG), comparando o desempenho das quatro estratégias de tradução selecionadas, conforme consolidado na Tabela 6.

Ao observar os resultados agregados (TOTAL), a estratégia **Few-Shot** apresentou

Tabela 4 – Acurácia de Execução, custo computacional e tempo de resposta médio de modelos da Família GPT na coleção PS

Coleção	**Modelo**							
	5.1	**5**	**5-mini**	**4.1**	**4.1-mini**	**4o**	**4o-mini**	**3.5-turbo**
PS-A	57,0	67,0	**71,0**	36,0	60,5	50,0	22,5	27,5
PS-B	38,2	**64,2**	59,4	40,0	26,1	33,3	5,5	6,7
PS-C	1,4	**5,7**	**5,7**	4,3	1,4	1,4	1,4	0,0
PS-D	1,1	**14,4**	6,7	2,2	2,2	2,2	1,1	0,0
PS-E	0,0	**15,0**	5,0	0,0	0,0	0,0	0,0	0,0
PS-F	3,5	**7,8**	4,3	6,1	0,9	6,1	0,0	0,9
PS-G	15,0	**37,1**	25,0	26,4	3,6	10,7	0,7	0,0
TOTAL	25,5	**40,1**	36,4	23,4	21,6	22,5	7,1	8,4
Entrada	1,25	1,25	0,25	2,00	0,40	2,50	**0,15**	8,00
Saída	10,00	10,00	2,00	8,00	1,60	10,00	**0,60**	6,00
Tempo	2,3	41	29	1,7	2,1	2,3	2,5	**1,6**

PS: Perguntas Sintéticas; **PS-A**: Carga horária média de servidores; **PS-B**: Quantidade de servidores efetivos e temporários; **PS-C**: Atuações em atividades de ensino; **PS-D**: Atuações em atividades de extensão; **PS-E**: Atuações em atividades de gestão; **PS-F**: Atuações em atividades de pesquisa; **PS-G**: Produções intelectuais; **EX**: *Execution Accuracy* (Acurácia de Execução); **Entrada**: Custo em dólar ($) por 1M de *tokens*; **Saída**: Custo em dólar ($) por 1M de *tokens*; **Tempo**: Tempo de resposta médio para cada pergunta em segundos.

Tabela 5 – Comparativo da composição das coleções PS e PS-Derivada

COLEÇÃO PS (Original)	**COLEÇÃO PS-DERIVADA**
PS: Perguntas Sintéticas (800)	PS: Perguntas Sintéticas (420)
PS-A: Carga horária média (200)	PS-A: Carga horária média (165)
PS-B: Servidores efetivos/temporários (165)	PS-B: Servidores efetivos/temporários (135)
PS-C: Atividades de ensino (70)	PS-C: Atividades de ensino (65)
PS-D: Atividades de extensão (90)	PS-D: Atividades de extensão (20)
PS-E: Atividades de gestão (20)	PS-E: Atividades de gestão (15)
PS-F: Atividades de pesquisa (115)	PS-F: Atividades de pesquisa (10)
PS-G: Produções intelectuais (140)	PS-G: Produções intelectuais (10)

o melhor desempenho geral, consolidando-se com a maior Acurácia de Execução (EX) de 55,0%, além de atingir o índice mais elevado de eficiência com um VES de 87,1 e similaridade estrutural ($ROUGE - L$) de 0,51. Esse comportamento evidencia que o fornecimento de exemplares que espelham a complexidade da base permite ao modelo realizar um mapeamento mais preciso do que a simples descrição do esquema (*Zero-Shot*).

A análise qualitativa das consultas incorretas revelou uma lacuna semântica significativa, indicando que as falhas não se limitaram a inconsistências na estrutura sintática do SQL, mas concentraram-se no processamento de atributos textuais. Mesmo com a aplicação de diretrizes de normalização de acentos e *case* no contexto, os métodos frequentemente falharam na construção de filtros (cláusulas `WHERE`). Observou-se, primordialmente, o uso de comparações absolutas em cenários que exigiriam buscas parciais, negligenciando o uso

Tabela 6 – Resultados das métricas de avaliação dos métodos na coleção PMG

Coleção	Métrica	Método			
		Zero-Shot	**Few-Shot (k=6)**	**ODIS (*zero-shot*)**	**C3SQL**
PMG-A	EX	**60,0**	40,0	40,0	20,0
	VES	**61,4**	39,5	42,3	21,6
	ROUGE-L (F1)	0,65	0,63	**0,67**	0,52
PMG-B	EX	41,7	**50,0**	25,0	33,3
	VES	71,5	**94,5**	56,5	29,4
	ROUGE-L (F1)	0,39	**0,55**	0,43	0,42
PMG-C	EX	57,7	53,8	**65,4**	57,7
	VES	58,8	**73,0**	64,8	63,7
	ROUGE-L (F1)	0,43	0,47	0,48	**0,51**
PMG-D	EX	70,0	70,0	50,0	**80,0**
	VES	62,7	**117,9**	79,1	98,3
	ROUGE-L (F1)	0,36	0,41	0,38	**0,44**
PMG-E	EX	41,9	**51,1**	39,5	44,1
	VES	55,0	**92,3**	59,9	88,3
	ROUGE-L (F1)	0,48	**0,55**	0,47	0,44
PMG-F	EX	75,0	**100,0**	**100,0**	**100,0**
	VES	70,9	84,2	**103,9**	87,2
	ROUGE-L (F1)	0,34	0,37	**0,38**	**0,38**
TOTAL	EX	51,0	**55,0**	48,0	51,0
	VES	59,7	**87,1**	63,6	72,4
	ROUGE-L (F1)	0,45	**0,51**	0,47	0,46

PMG: Perguntas Manualmente Geradas; **PMG-A**: Tempo de serviço e formação do servidor; **PMG-B**: Atuações em atividades de ensino; **PMG-C**: Atuações em atividades de pesquisa; **PMG-D**: Atuações em atividades de extensão; **PMG-E**: Produções intelectuais; **PMG-F**: Atuações em atividades de gestão; **EX**: *Execution Accuracy* (Acurácia de Execução); **VES**: *Valid Efficiency Score* (Pontuação de Eficiência Válida). **ROUGE-L**: *Longest Common Subsequence* (Maior Subsequência Comum).

do operador `LIKE`. Essas falhas de correspondência impedem a recuperação correta dos registros e impactam negativamente a EX, ainda que os modelos preservem um índice de $ROUGE-L$ moderado devido à proximidade estrutural com a consulta de referência.

O método **C3SQL** obteve uma acurácia total de 51,0%, figurando em um patamar competitivo, especialmente na categoria PMG-D, onde alcançou o melhor resultado isolado com 80,0% de EX. No entanto, uma investigação aprofundada nos dados de inferência revelou um aspecto crítico sobre o mecanismo de *self-consistency* do método. Ao avaliar as 20 consultas candidatas geradas pelo C3SQL antes da fase de votação final, observou-se que em diversos casos o modelo gerou a consulta correta entre as candidatas, mas o algoritmo de seleção falhou ao não elegê-la como a saída final. Estima-se que, com uma estratégia de seleção (ou *ranking*) mais criteriosa, o C3SQL poderia ter obtido um incremento de 4% na acurácia total, atingindo os 55,0% de EX. Esse achado sugere que, para dados institucionais complexos, o desafio futuro reside não apenas na capacidade de geração dos modelos, mas

no refinamento dos critérios de seleção de consenso (*Self-Correction/Consistence*).

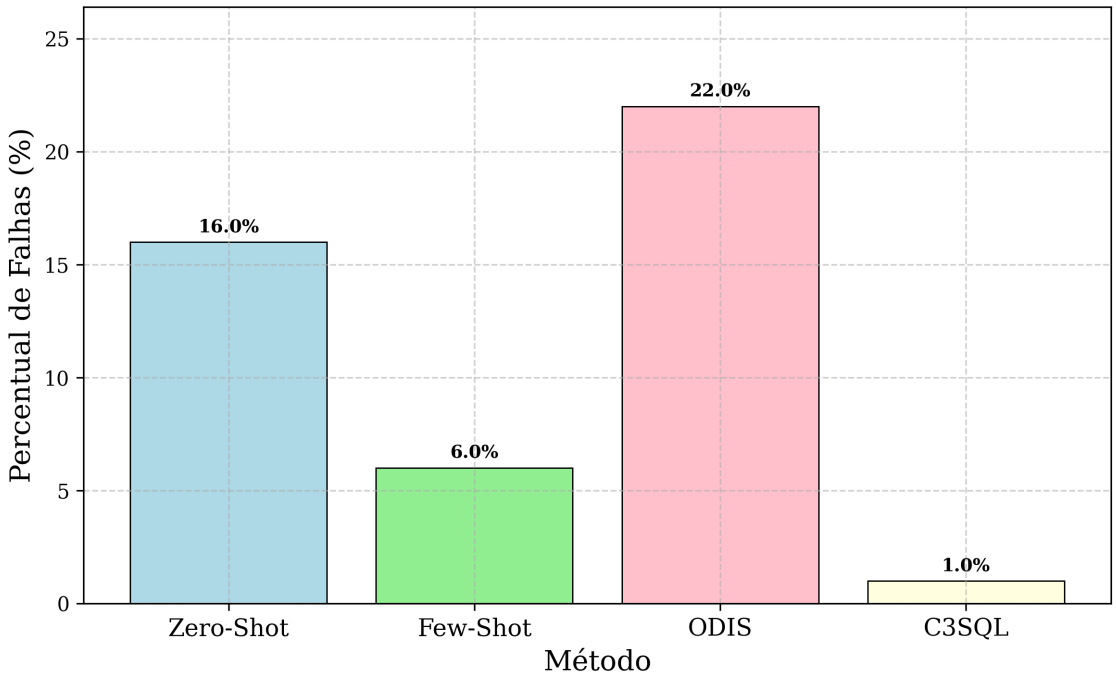
Além da avaliação de acurácia, é fundamental investigar a robustez das estratégias frente às restrições do SGBD SQLite. Uma consulta é considerada "falha" quando apresenta erros sintáticos ou estruturais que impedem sua execução, impossibilitando a recuperação de qualquer informação. A Tabela 7 e a Figura 7 detalham o percentual de falhas observado em cada método na coleção PMG.

Tabela 7 – Taxa de Falhas de Execução das consultas preditas pelos métodos na coleção PMG

Coleção	**Método**			
	Zero-Shot	**Few-Shot (k=6)**	**ODIS (*zero-shot*)**	**C3SQL**
PMG-A	**0,0**	**0,0**	**0,0**	**0,0**
PMG-B	**0,0**	16,7	8,3	**0,0**
PMG-C	11,5	7,7	7,7	**0,0**
PMG-D	10,0	10,0	30,0	**0,0**
PMG-E	25,6	**2,3**	37,2	**2,3**
PMG-F	25,0	**0,0**	**0,0**	**0,0**
TOTAL	16,0	6,0	22,0	**1,0**

PMG: Perguntas Manualmente Geradas; **PMG-A**: Tempo de serviço e formação do servidor; **PMG-B**: Atuações em atividades de ensino; **PMG-C**: Atuações em atividades de pesquisa; **PMG-D**: Atuações em atividades de extensão; **PMG-E**: Produções intelectuais; **PMG-F**: Atuações em atividades de gestão; **Taxa de Falha**: Percentual de consultas preditas com erros de execução.

Figura 7 – Taxa de falhas de execução por método na Coleção PMG (%)



Os dados revelam que o método **ODIS** apresentou a maior fragilidade sintática, com um índice total de 22,0% de falhas. Esse comportamento foi acentuado na categoria

PMG-E, onde a taxa de erro atingiu 37,2%. A análise qualitativa das predições do ODIS indica que a ausência de uma etapa dedicada de vinculação de esquema (*schema linking*) pode induzir o modelo a alucinar colunas inexistentes ou a realizar tentativas de junção (`JOIN`) sem incluir as tabelas intermediárias necessárias. Além disso, observou-se o uso de *tokens* ou comandos não suportados pela sintaxe do SQLite, confirmando que a mera inserção de conhecimento externo sem filtragem de contexto prejudica a validade sintática.

As estratégias **Zero-Shot** e **Few-Shot** apresentaram comportamentos similares, com taxas de falha de 16,0% e 6,0%, respectivamente. Em ambos os casos, as falhas decorreram majoritariamente da referência a atributos ausentes nas tabelas selecionadas, erros na lógica de junção de múltiplas tabelas e aplicação de funções ou comandos técnicos não reconhecidos pelo interpretador SQLite. Nota-se que o fornecimento de exemplos no Few-Shot reduziu significativamente essas ocorrências em comparação ao Zero-Shot, servindo como um guia de conformidade sintática para o modelo.

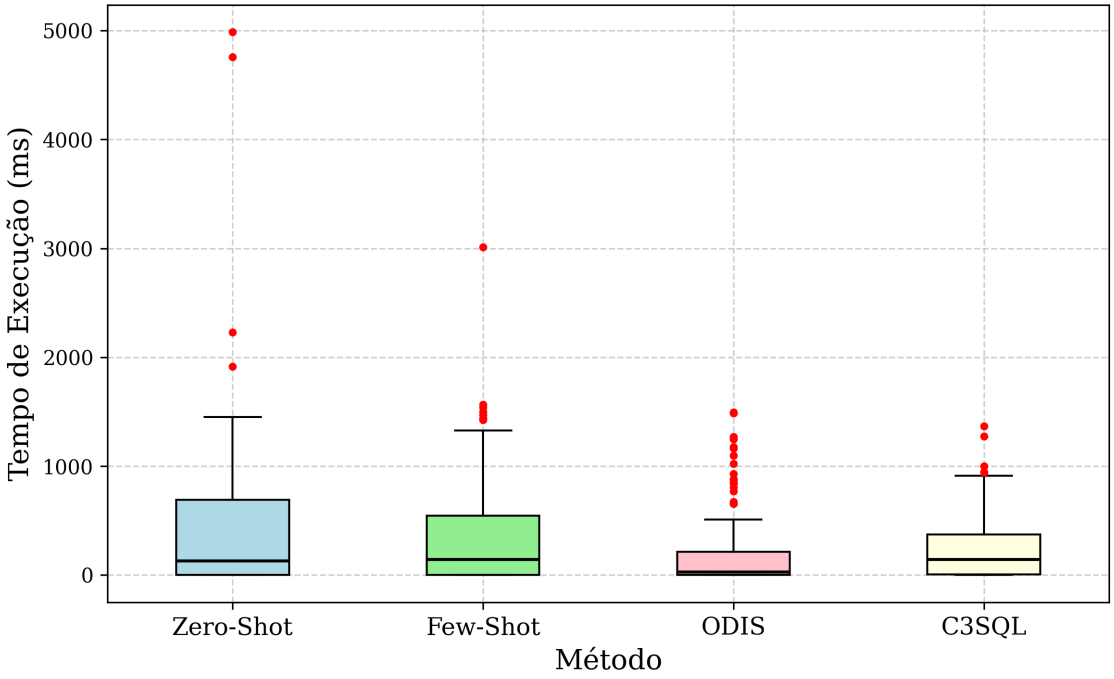
Por outro lado, o método **C3SQL** demonstrou ser o mais robusto, com uma taxa de falha residual de apenas 1,0%. É importante ressaltar que todas as consultas produzidas pelo C3SQL foram sintaticamente corretas e executáveis em sua essência. O índice de falha reportado corresponde exclusivamente a situações em que todas as candidatas geradas ultrapassaram o limite de tempo (*timeout*) estabelecido para a execução. Esse resultado evidencia o sucesso da etapa de pré-processamento do C3SQL, que realiza uma seleção criteriosa de tabelas e colunas (*schema linking*) antes da geração final, eliminando ruídos que levam a erros de sintaxe. A falha, neste caso, atua como um mecanismo de segurança do pipeline para evitar consultas excessivamente custosas, e não como uma limitação de tradução do modelo.

Em termos de eficiência computacional das consultas produzidas, a Figura 8 apresenta a distribuição do tempo de execução das consultas preditas por cada método.

A análise da distribuição dos tempos de execução revela a existência de disparidades entre as estratégias avaliadas. Os métodos **Zero-Shot** e **Few-Shot** demonstram uma variabilidade elevada, caracterizada por intervalos interquartis amplos e a presença frequente de outliers que superam os 1.500 ms. No caso específico do Zero-Shot, registram-se picos de até 5.000 ms, o que sugere que a ausência de guias estruturais ou exemplos pode levar à produção de códigos menos otimizados ou com junções (*joins*) excessivamente onerosas ao banco de dados.

Em contrapartida, embora o **ODIS** apresente a menor mediana e dispersão, tal resultado deve ser interpretado com cautela, visto que a alta taxa de falhas do método restringe essa métrica ao subconjunto de consultas mais triviais que obtiveram sucesso, não indicando necessariamente uma capacidade de otimização em cenários complexos. Por fim, o **C3SQL** destaca-se pela consistência e estabilidade, com a vasta maioria de suas consultas executadas em menos de 500 ms. Esse desempenho corrobora a eficácia de suas

Figura 8 – Boxplot da distribuição do tempo de execução das consultas preditas por método na Coleção PMG (*outliers* acima de 10000ms foram removidos para melhor visualização).



etapas de pré-processamento e seleção de esquema, que garantem não apenas a validade sintática, mas também a construção de estruturas lógicas mais assertivas.

6.2 NL2SQL nos Dados Sintéticos

Para a análise da coleção sintética, o foco recai sobre o comportamento dos modelos em um volume maior de dados e em como a complexidade das perguntas geradas automaticamente desafia os métodos. Os resultados consolidados na Tabela 8 permitem observar que a tendência de superioridade de certas estratégias se mantém, embora novos desafios técnicos tenham surgido.

Assim como observado na coleção manual, a estratégia **Few-Shot** obteve o melhor desempenho absoluto, atingindo uma Acurácia de Execução (EX) de 72,1% e uma eficiência (VES) de 83,1. A robustez do método é evidenciada principalmente nas categorias PS-A e PS-B, com acurácias de 87,3% e 84,4%, respectivamente. Esses valores indicam que, mesmo em uma base de dados mais densa, o fornecimento de exemplares com *schema links* permite ao modelo navegar com precisão por tabelas que envolvem esses dados.

A análise qualitativa das predições incorretas nas estratégias **Zero-Shot**, **Few-Shot** e **ODIS** revelou dois padrões principais de erro. Primeiramente, confirmou-se a dificuldade recorrente na filtragem de atributos textuais e, adicionalmente, identificou-se

Tabela 8 – Resultados das métricas de avaliação dos métodos na coleção PS-Derivada.

Coleção	Métrica	Método			
		Zero-Shot	**Few-Shot (k=6)**	**ODIS (*zero-shot*)**	**C3SQL**
PS-A	EX	72,1	**87,3**	39,4	4,8
	VES	77,1	**93,1**	39,5	4,6
	ROUGE-L (F1)	**0,66**	**0,66**	0,63	0,52
PS-B	EX	32,6	**84,4**	12,6	3,0
	VES	35,1	**106,9**	11,1	3,3
	ROUGE-L (F1)	0,52	**0,58**	0,48	0,38
PS-C	EX	20,0	**30,0**	0,0	10,0
	VES	22,7	**43,2**	0,0	5,0
	ROUGE-L (F1)	0,53	0,54	**0,55**	0,44
PS-D	EX	**33,3**	20,0	20,0	20,0
	VES	**34,1**	30,8	15,3	19,7
	ROUGE-L (F1)	**0,60**	0,56	0,55	0,46
PS-E	EX	10,0	**20,0**	10,0	0,0
	VES	10,2	**20,5**	10,0	0,0
	ROUGE-L (F1)	0,55	**0,60**	0,48	0,37
PS-F	EX	5,0	**35,0**	10,0	25,0
	VES	4,6	**47,1**	10,0	23,4
	ROUGE-L (F1)	**0,62**	**0,62**	**0,62**	0,49
PS-G	EX	12,3	**46,2**	6,2	0,0
	VES	16,0	**47,3**	12,6	0,0
	ROUGE-L (F1)	**0,57**	**0,57**	0,55	0,45
TOTAL	EX	42,9	**72,1**	21,9	5,0
	VES	46,2	**83,1**	22,3	4,8
	ROUGE-L (F1)	0,59	**0,61**	0,56	0,45

PS: Perguntas Sintéticas; **PS-A**: Carga horária média de servidores; **PS-B**: Quantidade de servidores efetivos e temporários; **PS-C**: Atuações em atividades de ensino; **PS-D**: Atuações em atividades de extensão; **PS-E**: Atuações em atividades de gestão; **PS-F**: Atuações em atividades de pesquisa; **PS-G**: Produções intelectuais; **EX**: *Execution Accuracy* (Acurácia de Execução); **VES**: *Valid Efficiency Score* (Pontuação de Eficiência Válida). **ROUGE-L**: *Longest Common Subsequence* (Maior Subsequência Comum).

uma falha estrutural específica: a ausência de um `SELECT` externo para isolar apenas a informação solicitada pela pergunta. Em diversas instâncias, o modelo gerou consultas que, embora logicamente coerentes, retornavam colunas ou linhas adicionais além do valor exato esperado para a resposta. Como a métrica de *EX* exige a correspondência exata entre o resultado da execução e o gabarito, essas variações de escopo levaram à classificação de consultas funcionais como incorretas.

O método **C3SQL** apresentou o desempenho mais baixo nesta coleção, com apenas 5,0% de acurácia total. Entretanto, uma auditoria nos logs de geração revelou que o problema reside majoritariamente na etapa final de seleção por autoconsistência (*self-consistency*), semelhante ao que ocorreu na coleção PMG. Ao analisar as 20 consultas

candidatas geradas para cada pergunta antes da votação, constatou-se que o modelo produziu o SQL correto em diversas iterações, mas estas não foram selecionadas pelo algoritmo de consenso. Verificou-se que, caso a seleção fosse otimizada para identificar esses candidatos corretos, o C3SQL apresentaria um ganho de +15,48% na acurácia, elevando seu resultado final para 20,48%.

De forma análoga aos resultados observados na coleção manual, a análise sintática das SQLs preditas revelam que a validade das consultas é impactada diretamente pela eficácia da etapa de vinculação de esquema (*schema linking*). A Tabela 9 e a Figura 9 detalham o percentual de falhas de execução para cada método.

Tabela 9 – Taxa de Falhas de Execução das consultas preditas pelos métodos na coleção PS-Derivada.

Coleção	**Método**			
	Zero-Shot	**Few-Shot (k-6)**	**ODIS (*zero-shot*)**	**C3SQL**
PS-A	3,6	**1,8**	3,0	3,6
PS-B	1,5	**0,0**	21,5	1,5
PS-C	30,0	10,0	30,0	**0,0**
PS-D	**6,7**	13,3	13,3	**6,7**
PS-E	10,0	**0,0**	30,0	10,0
PS-F	20,0	10,0	**0,0**	**0,0**
PS-G	56,9	10,7	61,5	**4,6**
TOTAL	12,9	3,6	19,5	**3,3**

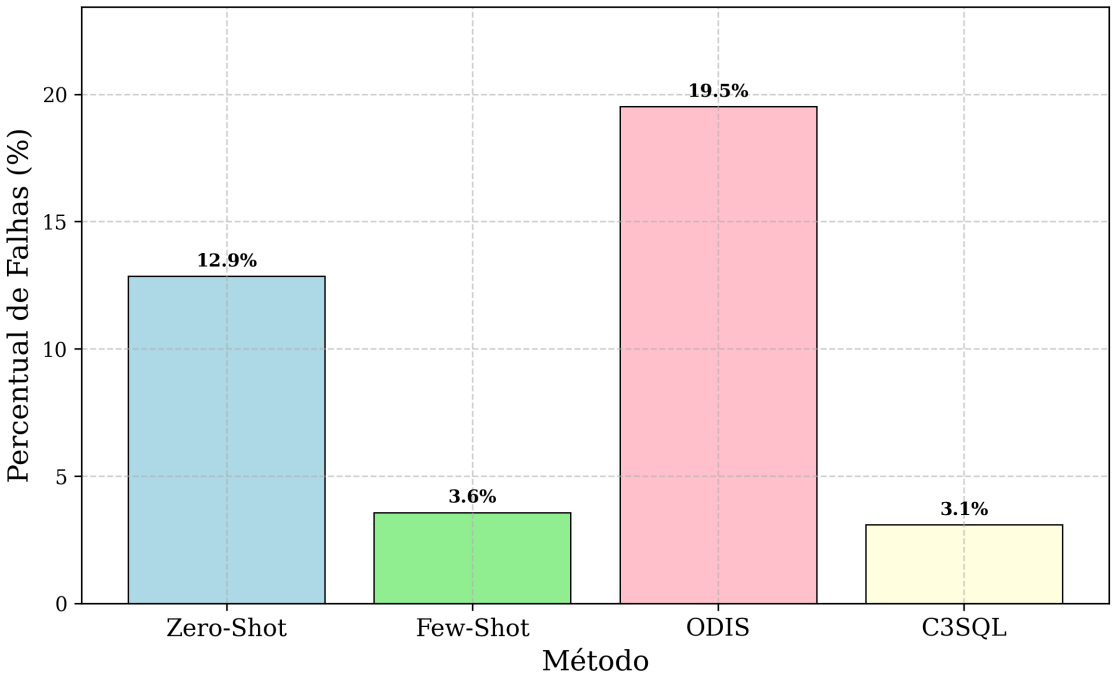
PS: Perguntas Sintéticas; **PS-A**: Carga horária média de servidores; **PS-B**: Quantidade de servidores efetivos e temporários; **PS-C**: Atuações em atividades de ensino; **PS-D**: Atuações em atividades de extensão; **PS-E**: Atuações em atividades de gestão; **PS-F**: Atuações em atividades de pesquisa; **PS-G**: Produções intelectuais; **Taxa de Falha**: Percentual de consultas preditas com erros de execução.

Os dados demonstram que o método **ODIS** permanece como a estratégia mais suscetível a erros estruturais, apresentando uma taxa total de falhas de 19,5%. O desempenho é particularmente crítico na categoria PS-G, onde a taxa de falha atingiu 61,5%. A investigação qualitativa aponta novamente que os erros de sintaxe decorrem da ausência de um mecanismo de filtragem de metadados. Além disso, registrou-se a persistência do uso de *tokens* e funções não suportados pelo interpretador SQLite.

As estratégias **Zero-Shot** e **Few-Shot** apresentaram taxas de falha de 12,9% e 3,6%, respectivamente. Nota-se que o fornecimento de exemplares no Few-Shot reduziu drasticamente a incidência de erros sintáticos, mesmo na categoria desafiadora PS-G, onde o método falhou em apenas 10,7% das vezes, contra 56,9% do Zero-Shot. As falhas remanescentes em ambos os métodos concentram-se no uso de atributos ausentes nas tabelas selecionadas e na aplicação de funções que divergem do padrão SQLite.

Por outro lado, o método **C3SQL** manteve sua característica de alta robustez técnica, apresentando uma taxa de falha residual de 3,3%. A análise dos logs de execução

Figura 9 – Taxa de falhas de execução por método na Coleção PS-Derivada (%).



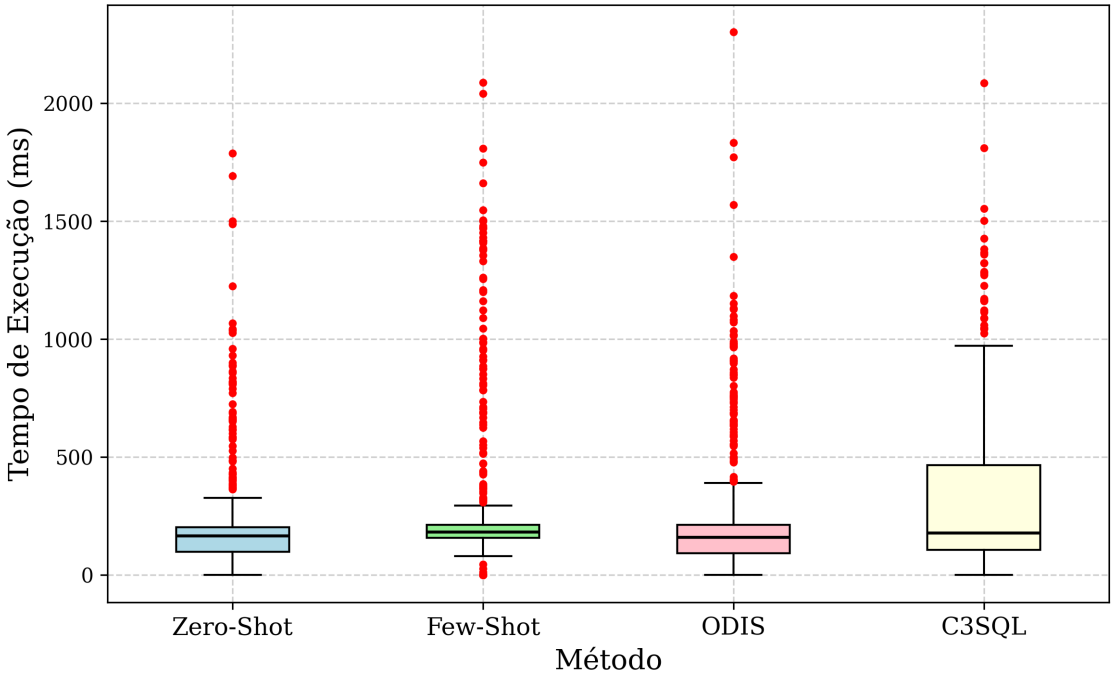
confirma que, assim como na coleção PMG, o C3SQL gerou consultas sintaticamente válidas em sua totalidade. As falhas contabilizadas referem-se estritamente ao mecanismo de autoconsistência, em casos que nenhuma das consultas candidatas foi selecionada por ultrapassarem o limite de tempo (*timeout*) estabelecido para o *pipeline*. Esse comportamento reforça que o pré-processamento do C3SQL é eficaz em garantir a correção do código, mas pode resultar em estruturas lógicas complexas que exigem alto custo computacional, especialmente em categorias como PS-D e PS-G.

A análise da distribuição dos tempos de execução na coleção PS-Derivada (Figura 10) revela que, enquanto as estratégias **Zero-Shot** e **Few-Shot** apresentam medianas de tempo reduzidas, elas exibem uma alta incidência de *outliers* que superam os 1.000 ms, sugerindo que a geração direta sem filtros de refinamento pode resultar em planos de execução subotimizados. O método **ODIS**, apesar de registrar a menor mediana e dispersão, possui resultados tecnicamente enviesados por sua elevada taxa de falhas em consultas complexas, refletindo apenas a eficiência em tarefas triviais que obtiveram sucesso na execução. Em contraste, o **C3SQL** apresenta uma mediana e um intervalo interquartil superiores, mas mantém uma melhor estabilidade operacional.

6.3 É Possível Identificar Perguntas Difíceis?

Esta seção investiga se as falhas das estratégias NL2SQL seguem padrões identificáveis. Ao compreender a natureza das "perguntas difíceis" – aquelas que resultaram

Figura 10 – Boxplot da distribuição do tempo de execução das consultas preditas por método na Coleção PS-Derivada (*outliers* acima de 2500ms foram removidos para melhor visualização)



em uma Acurácia de Execução (EX) igual a zero – é possível traçar diretrizes para o aprimoramento de sistemas futuros.

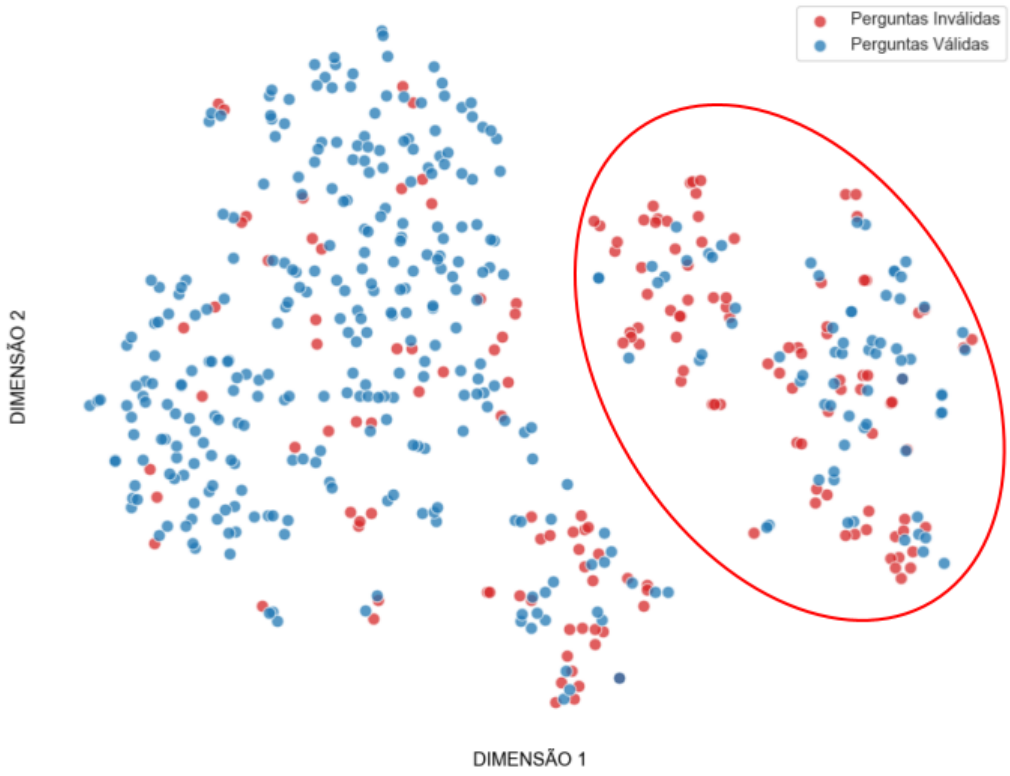
Esta análise foi realizada sobre o conjunto unificado das coleções PMG e PS-Derivada, totalizando 520 instâncias, utilizando as predições do método de melhor desempenho (Few-Shot). Do total avaliado, 358 perguntas (68,8%) foram classificadas como válidas (corretas), enquanto 162 (31,2%) foram invalidadas por erros semânticos ou sintáticos.

Para investigar se as falhas seguem padrões previsíveis, as sentenças foram convertidas em vetores numéricos via TF-IDF e mapeadas em um espaço bidimensional através do algoritmo de redução de dimensionalidade t-SNE. A Figura 11 demonstra a distribuição espacial das questões, onde os pontos azuis representam acertos e os vermelhos, as falhas.

A análise revela uma concentração nítida de perguntas inválidas em uma região específica (destacada em vermelho), indicando que as falhas não são aleatórias. Esse agrupamento sugere que o sistema possui limitações sistemáticas em determinadas estruturas de linguagem ou domínios de busca.

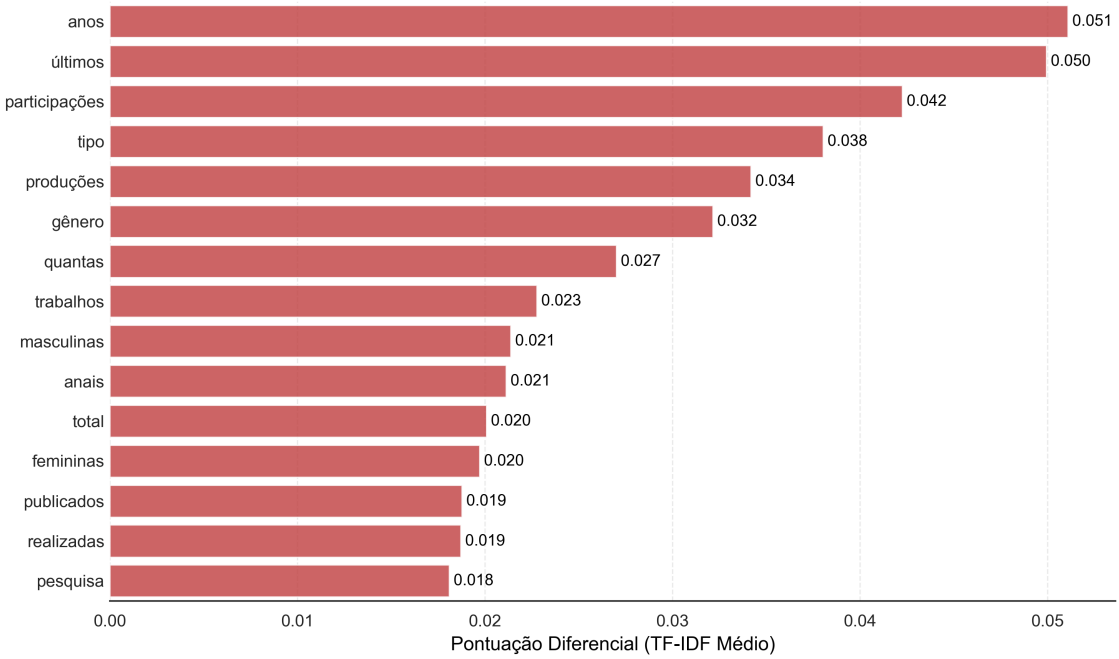
Para compreender o que torna uma pergunta "difícil", aplicou-se uma análise de importância de atributos baseada na pontuação diferencial de TF-IDF. Diferente de uma contagem simples de frequência, este método seleciona termos que são típicos em perguntas inválidas e raros nas válidas. O cálculo consiste na subtração da importância

Figura 11 – Projeção t-SNE da distribuição de perguntas



média de cada termo no grupo de acertos da sua importância média no grupo de falhas (Média $_{\text{inválidas}}$ − Média $_{\text{válidas}}$). Essa abordagem isola palavras com alto poder discriminativo, penalizando termos genéricos do domínio ou *stopwords* que aparecem em ambos os cenários. Os resultados são apresentados na Figura 12.

Figura 12 – Top 15 termos mais discriminantes para perguntas inválidas



Os dados mostram que os termos “anos” e “últimos” são os indicadores mais fortes de que uma pergunta resultará em erro. Essa dificuldade reside na complexidade de traduzir termos relativos ao tempo para consultas SQL “dinâmicas”. Construir uma lógica temporal que envolva cálculos de datas sobre múltiplas colunas e tabelas associadas representa um desafio técnico superior para os modelos, que frequentemente falham ao mapear essas expressões para as funções específicas do SQLite.

No universo de 162 falhas, 69 perguntas (42,6%) continham esse trio de palavras, sendo que 60 delas geraram SQLs executáveis, mas com resultados incorretos. Isso confirma que o problema não é a sintaxe, mas a incapacidade do modelo em resolver a lógica semântica de intervalos temporais dinâmicos no contexto do IFG.

Em suma, a resposta à pergunta proposta é afirmativa: é possível identificar padrões em perguntas difíceis. O agrupamento no t-SNE e a identificação de termos temporais discriminativos provam que o erro é estatisticamente localizável. Isso aponta um caminho claro: o desenvolvimento de camadas de pré-processamento que convertam expressões temporais em datas fixas ou parâmetros explícitos antes da geração do SQL, eliminando a ambiguidade que causa a maioria das falhas.

7 Conclusões e Trabalhos Futuros

Esta pesquisa investigou a aplicação de Modelos de Linguagem de Grande Escala (LLMs) na tarefa de tradução de linguagem natural para SQL (NL2SQL), focando no domínio específico dos currículos Lattes e atuações acadêmicas de servidores do IFG. Ao finalizar este trabalho, observa-se que a integração de inteligência artificial generativa com bases de dados institucionais não apenas é viável, mas oferece um caminho promissor para democratizar o acesso à informação acadêmica em bancos de dados relacionais.

7.1 Objetivos Alcançados

Os objetivos propostos inicialmente (Capítulo 3) foram plenamente satisfeitos. A investigação comparativa de estratégias NL2SQL foi realizada através da análise de quatro abordagens distintas: Zero-Shot, Few-Shot, ODIS e C3SQL. Para sustentar essa análise, foram construídas e validadas duas coleções de dados inéditas: a PMG (manualmente gerada) e a PS (sintética e densa), fornecendo um *benchmark* robusto para o contexto da Plataforma Jacarandá.

Além disso, avaliou-se o desempenho de diversos modelos da família GPT, permitindo a seleção do `gpt-4.1-mini` como um *backend* que equilibra acurácia e viabilidade financeira. A aplicação de métricas multidimensionais (EX, VES e $ROUGE-L$) permitiu uma visão holística que transcende a simples verificação da correção sintática, alcançando também a eficiência e a robustez das consultas geradas.

7.2 Principais Resultados

Os experimentos demonstraram que a estratégia **Few-Shot** ($k = 6$) com o uso de *schema links* é a mais eficaz para o domínio, atingindo uma acurácia de execução (EX) de 55,0% na coleção PMG e 72,1% na coleção PS-Derivada. Esse resultado sublinha a importância de fornecer exemplos contextuais para guiar o modelo em esquemas relacionais complexos.

Por outro lado, o método C3SQL destacou-se pela robustez técnica, apresentando a menor taxa de falhas sintáticas (apenas 1,0% na PMG), embora seu desempenho total tenha sido limitado pelo mecanismo de autoconsistência para algumas instâncias. Por fim, a análise via t-SNE e TF-IDF revelou um "gargalo temporal": perguntas envolvendo termos de características temporais representam o maior desafio semântico, frequentemente levando a erros em perguntas complexas que exigem cálculos dinâmicos de datas.

7.3 Trabalhos Futuros

Apesar dos avanços alcançados, o campo de NL2SQL para dados institucionais acadêmicos permanece fértil para explorações. Como desdobramentos desta pesquisa, sugerem-se as seguintes frentes de trabalho:

- **Modelos *Open-Source*:** Testar o desempenho de LLMs abertos (como Llama ou Mistral), avaliando se modelos menores e passíveis de hospedagem local conseguem manter a precisão observada nos modelos proprietários, garantindo maior soberania de dados à instituição.
- **Comitê de Técnicas:** Implementar e avaliar um método de comitê ou conjunto (*ensemble*), que combine as forças de diferentes estratégias (ex: a robustez do C3SQL com a precisão semântica do *Few-Shot*) para decidir a consulta final com base em métricas de consenso.
- **Ajuste Fino (*Fine-tuning*):** Verificar se o treinamento específico do modelo com os dados da Plataforma Jacarandá e esquemas de bancos de dados acadêmicos pode superar as limitações das técnicas de *prompt engineering*, especialmente na redução de alucinações de esquema.
- **Pré-processamento:** Desenvolver módulos dedicados à vinculação de esquema (*schema linking*) para garantir que o modelo identifique corretamente as entidades antes da geração. Sugere-se a exploração de representações do esquema baseadas em grafos, visando otimizar a identificação de relacionamentos e caminhos de junção complexos entre as tabelas da Plataforma Jacarandá. Adicionalmente, implementar camadas que lidem com o tratamento de expressões temporais, visando mitigar a principal fonte de erro semântico identificada nesta pesquisa.
- **Pós-processamento:** Investigar o aprimoramento de mecanismos de *self-correction* e *self-consistency*. Dado que o estudo revelou um potencial de ganho de acurácia em casos de seleção mais precisa de consultas candidatas, o desenvolvimento de critérios de *ranking* ou validação sintática pós-geração apresenta-se como um caminho crítico para elevar a confiabilidade do sistema final.

Referências

BHASKAR, A. et al. Benchmarking and improving text-to-SQL generation under ambiguity. In: BOUAMOR, H.; PINO, J.; BALI, K. (Ed.). *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Singapore: Association for Computational Linguistics, 2023. p. 7053–7074. Disponível em: <https://aclanthology.org/2023.emnlp-main.436/>. Citado 2 vezes nas páginas 24 e 26.

CHANG, S.; FOSLER-LUSSIER, E. Selective demonstrations for cross-domain text-to-SQL. In: BOUAMOR, H.; PINO, J.; BALI, K. (Ed.). *Findings of the Association for Computational Linguistics: EMNLP 2023*. Singapore: Association for Computational Linguistics, 2023. p. 14174–14189. Disponível em: <https://aclanthology.org/2023.findings-emnlp.944/>. Citado 3 vezes nas páginas 19, 20 e 22.

DONG, X. et al. *C3: Zero-shot Text-to-SQL with ChatGPT*. 2023. Disponível em: <https://arxiv.org/abs/2307.07306>. Citado 4 vezes nas páginas 19, 20, 21 e 22.

ELMASRI, R.; NAVATHE, S. B. *Sistemas de Banco de Dados*. 7ª. ed. São Paulo: Pearson Education, 2018. ISBN 9788543025001. Citado na página 13.

FAN, Y. et al. Metasql: A generate-then-rank framework for natural language to sql translation. In: *2024 IEEE 40th International Conference on Data Engineering (ICDE)*. [S.l.: s.n.], 2024. p. 1765–1778. Citado 3 vezes nas páginas 19, 21 e 22.

FAYYAD, U.; PIATETSKY-SHAPIRO, G.; SMYTH, P. The kdd process for extracting useful knowledge from volumes of data. *Commun. ACM*, Association for Computing Machinery, New York, NY, USA, v. 39, n. 11, p. 27–34, nov. 1996. ISSN 0001-0782. Disponível em: <https://doi.org/10.1145/240455.240464>. Citado na página 27.

GAO, D. et al. Text-to-sql empowered by large language models: A benchmark evaluation. *Proc. VLDB Endow.*, VLDB Endowment, v. 17, n. 5, p. 1132–1145, jan. 2024. ISSN 2150-8097. Disponível em: <https://doi.org/10.14778/3641204.3641221>. Citado 3 vezes nas páginas 20, 21 e 22.

GUO, J. et al. Towards complex text-to-SQL in cross-domain database with intermediate representation. In: KORHONEN, A.; TRAUM, D.; MÀRQUEZ, L. (Ed.). *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*. Florence, Italy: Association for Computational Linguistics, 2019. p. 4524–4535. Disponível em: <https://aclanthology.org/P19-1444/>. Citado na página 19.

HONG, Z. et al. Next-Generation Database Interfaces: A Survey of LLM-Based Text-to-SQL . *IEEE Transactions on Knowledge & Data Engineering*, IEEE Computer Society, Los Alamitos, CA, USA, v. 37, n. 12, p. 7328–7345, dez. 2025. ISSN 1558-2191. Disponível em: <https://doi.ieeecomputersociety.org/10.1109/TKDE.2025.3609486>. Citado na página 13.

KUMAR, R. et al. BookSQL: A large scale text-to-SQL dataset for accounting domain. In: DUH, K.; GOMEZ, H.; BETHARD, S. (Ed.). *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational*

Linguistics: Human Language Technologies (Volume 1: Long Papers). Mexico City, Mexico: Association for Computational Linguistics, 2024. p. 497–516. Disponível em: <https://aclanthology.org/2024.naacl-long.28/>. Citado 2 vezes nas páginas 23 e 26.

LEI, F. et al. Spider 2.0: Evaluating language models on real-world enterprise text-to-sql workflows. *arXiv preprint arXiv:2411.07763*, 2024. Citado na página 29.

LI, B. et al. The dawn of natural language to sql: Are we fully ready? *Proc. VLDB Endow.*, VLDB Endowment, v. 17, n. 11, p. 3318–3331, jul. 2024. ISSN 2150-8097. Disponível em: <https://doi.org/10.14778/3681954.3682003>. Citado 3 vezes nas páginas 13, 19 e 22.

LI, B. et al. *Alpha-SQL: Zero-Shot Text-to-SQL using Monte Carlo Tree Search*. 2025. Disponível em: <https://arxiv.org/abs/2502.17248>. Citado 3 vezes nas páginas 20, 21 e 22.

LI, H. et al. Codes: Towards building open-source language models for text-to-sql. *Proc. ACM Manag. Data*, Association for Computing Machinery, New York, NY, USA, v. 2, n. 3, maio 2024. Disponível em: <https://doi.org/10.1145/3654930>. Citado 3 vezes nas páginas 19, 20 e 22.

LI, J. et al. Can llm already serve as a database interface? a big bench for large-scale database grounded text-to-sqls. In: *Proceedings of the 37th International Conference on Neural Information Processing Systems*. Red Hook, NY, USA: Curran Associates Inc., 2023. (NIPS '23). Citado 2 vezes nas páginas 29 e 35.

LI, Z. et al. Pet-sql: A prompt-enhanced two-round refinement of text-to-sql with cross-consistency. In: *Database Systems for Advanced Applications: 30th International Conference, DASFAA 2025, Singapore, Singapore, May 26–29, 2025, Proceedings, Part II*. Berlin, Heidelberg: Springer-Verlag, 2026. p. 193–208. ISBN 978-981-95-3829-4. Disponível em: <https://doi.org/10.1007/978-981-95-3830-0_13>. Citado 3 vezes nas páginas 19, 21 e 22.

LIANG, W. et al. *The Widespread Adoption of Large Language Model-Assisted Writing Across Society*. 2025. Disponível em: <https://arxiv.org/abs/2502.09747>. Citado na página 13.

LIANG, W. et al. *Mapping the Increasing Use of LLMs in Scientific Papers*. 2024. Disponível em: <https://arxiv.org/abs/2404.01268>. Citado na página 13.

LIN, C.-Y. ROUGE: A package for automatic evaluation of summaries. In: *Text Summarization Branches Out*. Barcelona, Spain: Association for Computational Linguistics, 2004. p. 74–81. Disponível em: <https://aclanthology.org/W04-1013/>. Citado na página 35.

LIU, X. et al. *A Survey of Text-to-SQL in the Era of LLMs: Where are we, and where are we going?* 2025. Disponível em: <https://arxiv.org/abs/2408.05109>. Citado 5 vezes nas páginas 13, 18, 23, 25 e 26.

MISHRA, T. et al. Use of large language models as artificial intelligence tools in academic research and publishing among global clinical researchers. *Scientific Reports*, v. 14, n. 31672, 2024. Disponível em: <https://www.nature.com/articles/s41598-024-81370-6>. Citado na página 13.

MOHAMMADJAFARI, A.; MAIDA, A. S.; GOTTUMUKKALA, R. *From Natural Language to SQL: Review of LLM-based Text-to-SQL Systems*. 2025. Disponível em: <https://arxiv.org/abs/2410.01066>. Citado na página 13.

POURREZA, M. et al. *CHASE-SQL: Multi-Path Reasoning and Preference Optimized Candidate Selection in Text-to-SQL*. 2024. Disponível em: <https://arxiv.org/abs/2410.01943>. Citado 2 vezes nas páginas 19 e 22.

POURREZA, M.; RAFIEI, D. Din-sql: decomposed in-context learning of text-to-sql with self-correction. In: *Proceedings of the 37th International Conference on Neural Information Processing Systems*. Red Hook, NY, USA: Curran Associates Inc., 2023. (NIPS '23). Citado 5 vezes nas páginas 19, 20, 21, 22 e 33.

POURREZA, M.; RAFIEI, D. DTS-SQL: Decomposed text-to-SQL with small large language models. In: AL-ONAIZAN, Y.; BANSAL, M.; CHEN, Y.-N. (Ed.). *Findings of the Association for Computational Linguistics: EMNLP 2024*. Miami, Florida, USA: Association for Computational Linguistics, 2024. p. 8212–8220. Disponível em: <https://aclanthology.org/2024.findings-emnlp.481/>. Citado 2 vezes nas páginas 19 e 22.

QIN, Y. et al. *ROUTE: Robust Multitask Tuning and Collaboration for Text-to-SQL*. 2025. Disponível em: <https://arxiv.org/abs/2412.10138>. Citado 2 vezes nas páginas 19 e 22.

QU, G. et al. Before generation, align it! a novel and effective strategy for mitigating hallucinations in text-to-SQL generation. In: KU, L.-W.; MARTINS, A.; SRIKUMAR, V. (Ed.). *Findings of the Association for Computational Linguistics: ACL 2024*. Bangkok, Thailand: Association for Computational Linguistics, 2024. p. 5456–5471. Disponível em: <https://aclanthology.org/2024.findings-acl.324/>. Citado 2 vezes nas páginas 19 e 22.

REN, T. et al. PURPLE: Making a Large Language Model a Better SQL Writer . In: *2024 IEEE 40th International Conference on Data Engineering (ICDE)*. Los Alamitos, CA, USA: IEEE Computer Society, 2024. p. 15–28. Disponível em: <https://doi.ieeecomputersociety.org/10.1109/ICDE60146.2024.00009>. Citado 2 vezes nas páginas 19 e 22.

SANTOS, J. V. F. dos et al. Nova base de dados brasileira para sistemas de recomendação de artigos científicos. In: . Brazil: Brazilian Symposium on Databases, 2025. Citado na página 28.

SHI, L. et al. A survey on employing large language models for text-to-sql tasks. *ACM Comput. Surv.*, Association for Computing Machinery, New York, NY, USA, v. 58, n. 2, set. 2025. ISSN 0360-0300. Disponível em: <https://doi.org/10.1145/3737873>. Citado na página 13.

TALAEI, S. et al. *CHESS: Contextual Harnessing for Efficient SQL Synthesis*. 2024. Disponível em: <https://arxiv.org/abs/2405.16755>. Citado 4 vezes nas páginas 19, 20, 21 e 22.

WANG, B. et al. MAC-SQL: A multi-agent collaborative framework for text-to-SQL. In: RAMBOW, O. et al. (Ed.). *Proceedings of the 31st International Conference on Computational Linguistics*. Abu Dhabi, UAE: Association for Computational Linguistics, 2025. p. 540–557. Disponível em: <https://aclanthology.org/2025.coling-main.36/>. Citado 2 vezes nas páginas 19 e 22.

WANG, P.; SHI, T.; REDDY, C. K. Text-to-sql generation for question answering on electronic medical records. In: *Proceedings of The Web Conference 2020*. New York, NY, USA: Association for Computing Machinery, 2020. (WWW '20), p. 350–361. ISBN 9781450370233. Disponível em: <https://doi.org/10.1145/3366423.3380120>. Citado 2 vezes nas páginas 23 e 26.

XIE, X. et al. Opensearch-sql: Enhancing text-to-sql with dynamic few-shot and consistency alignment. *Proc. ACM Manag. Data*, Association for Computing Machinery, New York, NY, USA, v. 3, n. 3, jun. 2025. Disponível em: <https://doi.org/10.1145/3725331>. Citado 2 vezes nas páginas 19 e 22.

XIE, Y. et al. *Decomposition for Enhancing Attention: Improving LLM-based Text-to-SQL through Workflow Paradigm*. 2024. Disponível em: <https://arxiv.org/abs/2402.10671>. Citado 2 vezes nas páginas 19 e 22.

YANG, J. et al. Synthesizing text-to-SQL data from weak and strong LLMs. In: KU, L.-W.; MARTINS, A.; SRIKUMAR, V. (Ed.). *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Bangkok, Thailand: Association for Computational Linguistics, 2024. p. 7864–7875. Disponível em: <https://aclanthology.org/2024.acl-long.425/>. Citado 2 vezes nas páginas 24 e 26.

YU, T. et al. Spider: A large-scale human-labeled dataset for complex and cross-domain semantic parsing and text-to-SQL task. In: RILOFF, E. et al. (Ed.). *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*. Brussels, Belgium: Association for Computational Linguistics, 2018. p. 3911–3921. Disponível em: <https://aclanthology.org/D18-1425/>. Citado 2 vezes nas páginas 24 e 34.

ZHANG, C. et al. Finsql: Model-agnostic llms-based text-to-sql framework for financial analysis. In: *Companion of the 2024 International Conference on Management of Data*. New York, NY, USA: Association for Computing Machinery, 2024. (SIGMOD '24), p. 93–105. ISBN 9798400704222. Disponível em: <https://doi.org/10.1145/3626246.3653375>. Citado 5 vezes nas páginas 19, 20, 22, 23 e 26.

ZHANG, H. et al. ACT-SQL: In-context learning for text-to-SQL with automatically-generated chain-of-thought. In: BOUAMOR, H.; PINO, J.; BALI, K. (Ed.). *Findings of the Association for Computational Linguistics: EMNLP 2023*. Singapore: Association for Computational Linguistics, 2023. p. 3501–3532. Disponível em: <https://aclanthology.org/2023.findings-emnlp.227/>. Citado 2 vezes nas páginas 19 e 22.

ZHANG, H. et al. CoE-SQL: In-context learning for multi-turn text-to-SQL with chain-of-editions. In: DUH, K.; GOMEZ, H.; BETHARD, S. (Ed.). *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*. Mexico City, Mexico: Association for Computational Linguistics, 2024. p. 6487–6508. Disponível em: <https://aclanthology.org/2024.naacl-long.361/>. Citado 2 vezes nas páginas 19 e 22.

ZHANG, Y. et al. Sciencebenchmark: A complex real-world benchmark for evaluating natural language to sql systems. *Proc. VLDB Endow.*, VLDB Endowment, v. 17, n. 4, p. 685–698, dez. 2023. ISSN 2150-8097. Disponível em: <https://doi.org/10.14778/3636218.3636225>. Citado 3 vezes nas páginas 23, 24 e 26.

A Apêndice

A.1 Prompt Geração de Pares <pergunta, resposta>Sintéticos

Você é um assistente especializado em gerar perguntas em linguagem natural com suas respectivas respostas a partir de um conjunto de dados.
Dada a descrição e a tabela abaixo, gere exatamente 10 pares de perguntas e respostas que possam ser respondidas exclusivamente com uma palavra, número ou valor presente em uma das colunas.
As perguntas devem ser diversas, baseadas nos dados da tabela e devem abordar todas as colunas (como valores, nomes ou quantidades) para a construção da pergunta. As respostas devem ser diretas, compostas apenas por uma palavra, número ou valor extraído exatamente da tabela, sem complementos, interpretações ou reformulações.

Regras:

1. As perguntas devem ser claras e desenvolvidas abordando os valores presentes nas colunas.

2. As respostas devem ser uma única palavra, número ou valor, exatamente como aparece na tabela (ex.: “18,00” ou “HISTORIA”).

3. É obrigatório variar os tipos de perguntas: sobre maior/menor valor, quantidades, valores ou classes específicas, etc.

4. Use preferencialmente o nome do câmpus correspondente ao invés de sua sigla, conforme descrito abaixo:

   - ANA: Campus Anápolis
   - GYN: Campus Goiânia
   [demais campus...]

5. A saída deve conter apenas os pares de pergunta e resposta, sem explicações adicionais, sem comentários e sem markdown.

6. Cada pergunta deve ser imediatamente seguida de sua respectiva resposta.

7. O formato de cada par deve ser exatamente:
   pergunta, resposta,
   ... (e assim por diante)

Descrição:
[DESCRIÇÃO TEXTUAL DA TABELA]

Tabela:
[TABELA DE DADOS]

Saída: {Seus pares pergunta-resposta aqui}

A.2 Prompt Zero-Shot

Você é um assistente especializado em conversão de linguagem natural para SQL. Seu trabalho é transformar uma pergunta escrita em português em um comando SQL correto, otimizado e seguro. Considere sempre a estrutura do banco de dados fornecida.

Instruções:

1. Gere a consulta SQL no formato do SGBD SQLite.
2. Use apenas as colunas e tabelas existentes na estrutura do banco de dados abaixo.
3. Use alias quando útil para melhorar a legibilidade.
4. Sempre escreva SQL em caixa alta (UPPER CASE).
5. Não use SELECT *, selecione apenas a coluna relevante.
6. Use JOINs apenas quando necessário.
7. Sempre inclua WHERE, GROUP BY, ORDER BY, HAVING e LIMIT quando a pergunta indicar.
8. Se houver ambiguidade, faça suposições razoáveis com base nos nomes das tabelas e colunas.
9. Fique atento aos tipos dos atributos e faça conversões se necessário.
10. Quando necessário, use o LIKE e '%' para verificar trechos em atributos de texto.
11. Priorize converter os textos para minúsculo (LOWER()) antes de comparar.
12. Não utilize acentos ou cedilha nos atributos textuais.
13. Responda com apenas o código SQL, sem explicações, sem markdown, sem quebras de linha e sem tabulação (\n ou \t).

Estrutura do Banco de Dados:

Tabela: servidor
nome_completo (VARCHAR(300))
pk_siape (INT) — PRIMARY KEY
categoria (TEXT) (ex: 'DOCENTE', 'TECNICO_ADMINISTRATIVO')

[demais tabelas e colunas...]

Entrada: "<pergunta em NL>"

Saída: {Seu SQL aqui}

A.3 Prompt Few-Shot

Você é um assistente especializado em conversão de linguagem natural para SQL. Seu trabalho é transformar uma pergunta escrita em português em um comando SQL correto, otimizado e seguro. Considere sempre a estrutura do banco de dados fornecida.

Instruções:

1. Gere a consulta SQL no formato do SGBD SQLite.

2. Use apenas as colunas e tabelas existentes na estrutura do banco de dados abaixo.

3. Siga os passos conforme descritos nos exemplos fornecidos: passo 1 - leitura da pergunta; passo 2 - seleção de tabelas e colunas correspondentes; passo 3 - geração do SQL final.

4. Use alias quando útil para melhorar a legibilidade.

5. Sempre escreva SQL em caixa alta (UPPER CASE).

6. Não use SELECT *, selecione apenas as colunas relevantes.

7. Use JOINs apenas quando necessário.

8. Sempre inclua WHERE, GROUP BY, ORDER BY, HAVING e LIMIT quando a pergunta indicar.

9. Fique atento aos tipos dos atributos e faça conversões se necessário.

10. Quando necessário, use o LIKE e '%' para verificar trechos em atributos de texto.

11. Priorize converter os textos para minúsculo (LOWER()) antes de comparar.

12. Remova todos os acentos e cedilhas ao utilizar textos literais nos SQLs.

13. Responda com apenas com o schema_links e código SQL, sem explicações, sem markdown, sem quebras de linha e sem tabulação (\n ou \t).

14. Em última instância, se houver ambiguidade, faça suposições razoáveis com base nos nomes das tabelas e colunas.

Estrutura do Banco de Dados:

Tabela: servidor
nome_completo (VARCHAR(300))
pk_siape (INT) — PRIMARY KEY
categoria (TEXT) (ex: 'DOCENTE', 'TECNICO_ADMINISTRATIVO')

[demais tabelas e colunas...]

Exemplos:

- Exemplo 1

Pergunta: "Quantos artigos completos foram publicados por servidores do Campus Itumbiara, nos últimos cinco anos, em revistas com classificação qualis A1 ou A2?"

schema_links: {
"servidor": ["pk_siape", ...],
"servidor_prodbibliografica": ["fk_siape", "fk_producao"],
"producao_bibliografica": ["pk", "fk_revista", "tipo", ...],

“qualis_revista”: [“pk”, “qualis”],
}

Resposta: SELECT COUNT(*) ...

[demais exemplos...]

Entrada: “<pergunta em NL>”

Saída: {Seu SQL aqui}