4 RESULTADOS E DISCUSSÕES

Esta seção apresenta os resultados e discute as técnicas de *bootstrap*, *bagging* e *subagging* aplicadas à regressão linear múltipla. Ela avalia o erro médio quadrático de predição (RMSEP) e compara os tempos de execução dos algoritmos RLM, RLM-*bagging* e RLM-*subagging*.

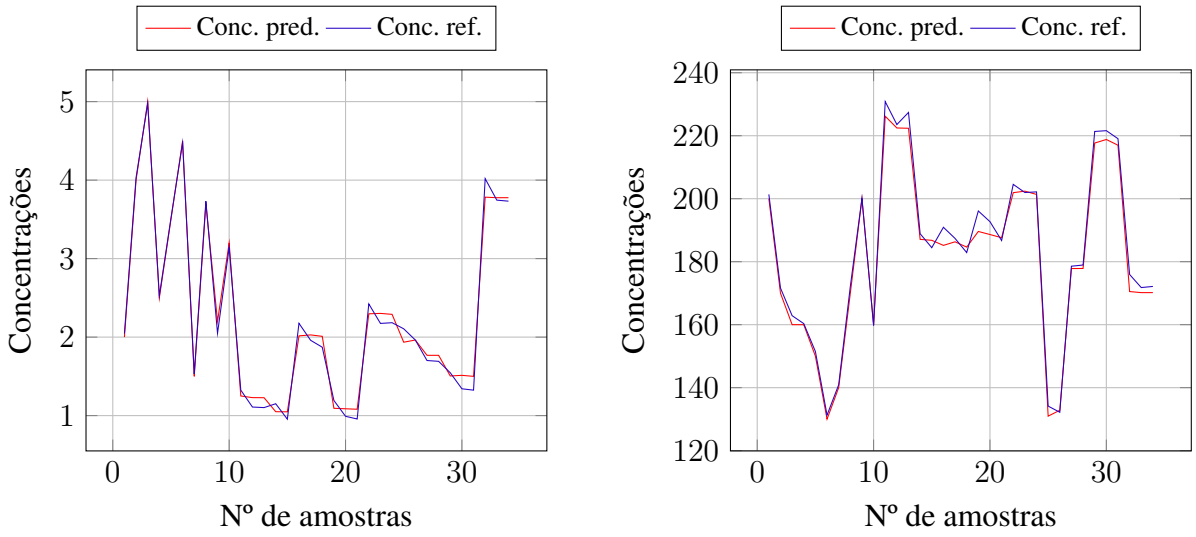
Tabela 6 – RMSEP com RLM para as amostras de aço-ligas.

RMSEP	Mn	Mo	Cr	Ni	Fe
RLM	0,1051	0,2633	1,0798	1,6043	2,7513

Fonte: elaborado pelo autor.

A Tabela 6 mostra o RMSEP obtido com a RLM para todas as amostras de aço-ligas.

Figura 5 – RMSEP com RLM para Mn e Fe.



(a) RMSEP com RLM para Mn.

(b) RMSEP com RLM para Fe.

Fonte: elaborado pelo autor.

A Figura 5 exibe o comportamento do RMSEP para os elementos Mn e Fe. A Figura 5a detalha o RMSEP do manganês (Mn) e a Figura 5b, o do ferro (Fe). O sinal azul representa a concentração esperada do Mn e do Fe e sinal vermelho a concentração predita obtida com a RLM. Pode ser visto na Tabela 6 que o Mn apresenta o menor RMSEP entre os três métodos, com destaque para o RLM-*subagging* (0,0974). Por outro lado, o Fe apresenta o maior RMSEP, com o valor mais elevado obtido pela RLM (2,7513). De forma geral, o RLM-*subagging* apresentou desempenho superior ou equivalente ao RLM e ao RLM-*bagging* para a maioria dos elementos analisados.

A escolha dos elementos ferro e manganês para esta análise baseia-se em fundamentos científicos bem estabelecidos na metalurgia. O ferro é o elemento matriz que define a própria natureza do material, uma vez que sem ferro não existe aço. O manganês, por sua vez, é o

único elemento de liga historicamente considerado essencial para a produção de qualquer aço comercial, atuando como desoxidante e modificador fundamental das propriedades mecânicas. Os demais elementos (Cr, Mo, Ni) são importantes para propriedades específicas, mas não são fundamentais para a definição básica e produção do aço como o ferro e o manganês. Acredita-se que o comportamento destas duas amostras são suficientes para ilustrar o comportamento geral esperado para as outras amostras.

4.1 APLICAÇÃO DA TÉCNICA *BOOTSTRAP* NA CALIBRAÇÃO POR RLM

A técnica de reamostragem *bootstrap* foi aplicada como abordagem independente na calibração multivariada dos dados espectrométricos das amostras de aço-liga, utilizando a Regressão Linear Múltipla (RLM) como modelo base. Diferentemente das estratégias *ensemble*, como *bagging* e *subbagging*, o *bootstrap* opera com reamostragens com reposição, permitindo a construção de múltiplos modelos calibrados sobre subconjuntos variados do conjunto de treinamento.

Os resultados obtidos com o RLM-*bootstrap* indicaram desempenho variável entre os diferentes analitos avaliados. Para os elementos Cromo (Cr) e Ferro (Fe), a abordagem apresentou melhorias na acurácia preditiva em comparação com a RLM clássica, demonstrando a eficácia da reamostragem na redução da variância do modelo. Para Manganês (Mn), Molibdênio (Mo) e Níquel (Ni), o RLM-*bootstrap* apresentou desempenho semelhante ao da RLM clássica, sem ganhos expressivos de precisão.

Em termos de eficiência computacional, o RLM-*bootstrap* apresentou tempo de execução moderado, posicionando-se entre as abordagens mais complexas (*bagging*) e as mais simples (RLM clássica e *subbagging*). Essa característica reforça seu potencial como alternativa viável em cenários que demandam equilíbrio entre acurácia e custo computacional.

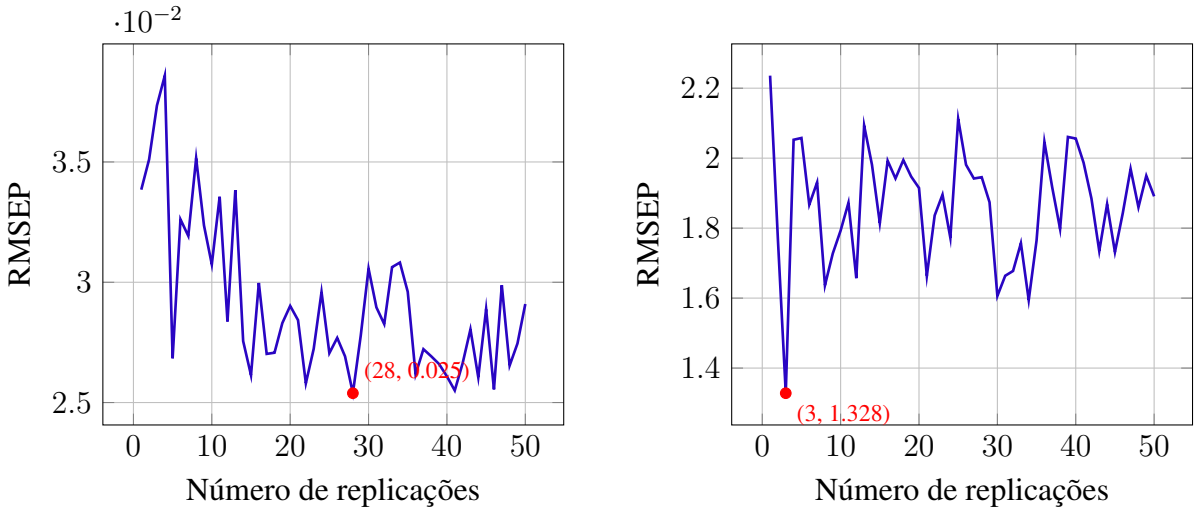
A inclusão do RLM-*bootstrap* no estudo contribui para uma compreensão mais ampla das técnicas de reamostragem aplicadas à calibração multivariada. Os resultados obtidos sugerem que, em contextos específicos, o *bootstrap* pode oferecer vantagens na estabilização de predições, especialmente quando se busca maior robustez estatística na modelagem sem incorrer em alto custo computacional.

4.2 *BAGGING*

Os resultados obtidos com a técnica *bagging* foram produzidos com a implementação do Algoritmo 2. Contudo, como visto na Subseção 2.7.1 da Seção 2.7, o algoritmo RLM-*bagging* depende do parâmetro m que define o número de replicações *bootstrap*.

Foi conduzido um experimento para avaliar a sensibilidade do *bagging* em função do número de replicações, variando de 1 a 50. O procedimento experimental implementou o RLM-*bagging* com um algoritmo iterativo que modifica sistematicamente o número de replicações utilizadas.

Figura 6 – RMSEP em função do número de replicações *bootstrap* para RLM-*bagging*.



(a) RMSEP em função do número de replicação para o Mn.

(b) RMSEP em função do número de replicação para o Fe.

Fonte: elaborado pelo autor.

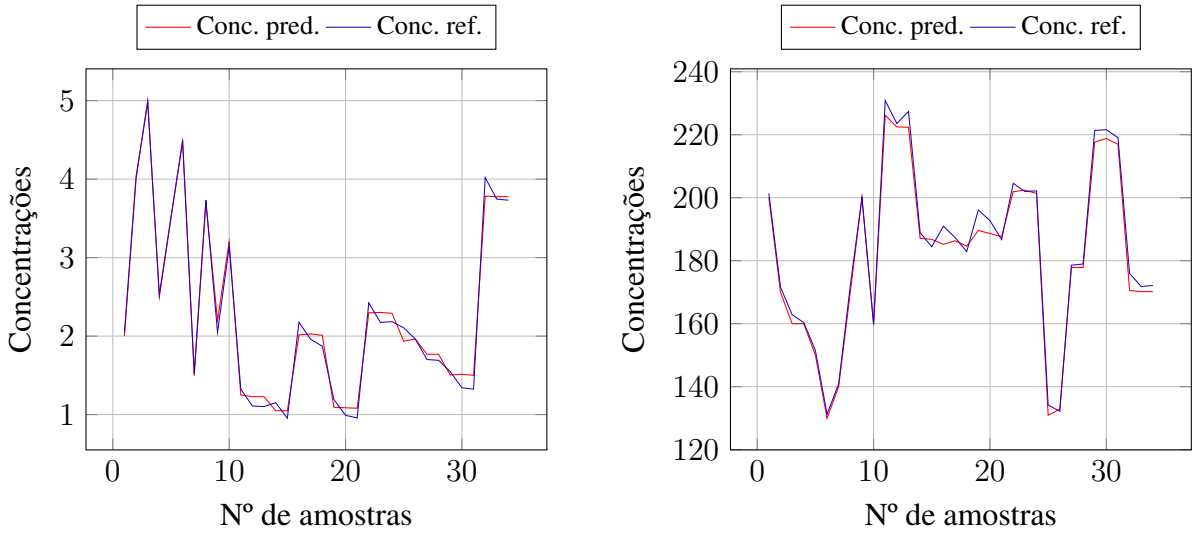
A Figura 6 mostra o RMSEP da RLM em função das replicações *bootstrap*. A Figura 6a mostra o comportamento do RLM-*bagging* para o Mn e a Figura 6b mostra o RMSEP do RLM-*bagging* para o Fe. Para o Manganês, observa-se comportamento mais estável após $(15 - 20)$ replicações, os valores do RMSEP tendem a se estabilizar em torno de $(0,026 - 0,030)$ e apresenta menor variabilidade absoluta. Para o Ferro, verifica-se maior oscilação ao longo de todas as replicações, os valores oscilam entre $(1,3 - 2,2)$ sem clara estabilização, apresentando maior variabilidade tanto absoluta quanto relativa. Existe considerável variabilidade para ambos os elementos, mas: o Ferro evidenciou a maior amplitude de variação entre os métodos, com desempenho variando de 34% a 41%, indicando sensibilidade elevada à técnica utilizada. O Manganês apresenta tendência de estabilização após aproximadamente 20 replicações. O Ferro mantém oscilações mesmo com 50 replicações. Isso sugere que o *bagging* para Fe pode precisar de mais replicações ou que a predição do Fe é inerentemente mais difícil que a do Mn.

A Figura 7 mostra o comportamento do RMSEP com RLM-*bagging*. A Figura 7a mostra o RMSEP com RLM-*bagging* do Mn e a Figura 7b mostra o RMSEP com RLM-*bagging* do Fe.

Observa-se desempenho variável do RLM-*bagging* em relação aos resultados da técnica RLM mostrados na Tabela 6. O RLM-*bagging* apresentou melhorias para Mn (redução de 5,4%) e Fe (redução de 3,3%), enquanto demonstrou desempenho inferior para Mo (aumento de 30,8%), Cr (aumento de 12,4%) e Ni (aumento de 4,3%). Os valores de RMSEP obtidos com o RLM-*bagging* foram $(0{,}0994)$ para o Mn e $(2{,}6597)$ para o Fe, conforme apresentado na Tabela 7.

A Tabela 7 mostra a comparação do erro do RLM-*bagging* em relação ao erro da RLM. O RLM-*bagging* apresentou melhorias apenas para Mn (redução de 5,42%) e Fe (redução de 3,33%), enquanto para Mo, Cr e Ni o erro aumentou em 30,76%, 12,44% e 4,32%, respectiva-

Figura 7 – RMSEP para o Mn e Fe com RLM-*bagging*.



(a) Predição do Mn com RLM-*bagging*.

(b) Predição do Fe com RLM-*bagging*.

Fonte: elaborado pelo autor.

Tabela 7 – RMSEP da RLM-*bagging*, para cada elemento de aço-ligas.

RMSEP	Mn	Mo	Cr	Ni	Fe
RLM	0,1051	0,2633	1,0798	1,6043	2,7513
RLM-*bagging*	0,0994[*17]	0,3443[*17]	1,2141[*17]	1,6736[*17]	2,6597[*17]

[*] Números de *bootstrap* utilizados.

Fonte: elaborado pelo autor.

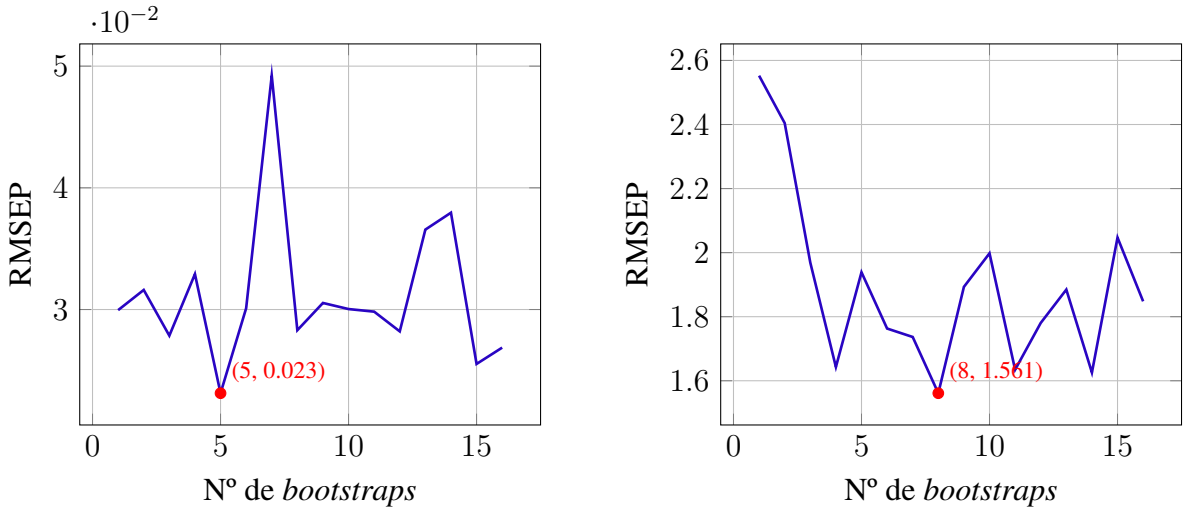
mente. Em média, o erro do RLM-*bagging* foi 7,75% maior do que o da RLM sem reamostragem. Esses resultados indicam que a aplicação do *bagging* não resultou em uma melhoria consistente no desempenho preditivo do modelo de regressão linear múltipla para este conjunto de dados.

4.3 *SUBAGGING*

A seção *Subagging* apresenta os resultados obtidos por meio da aplicação da Regressão Linear Múltipla (RLM) sobre subconjuntos gerados via *bootstrap*, de forma semelhante ao *bagging*, porém sem reposição de amostras. O algoritmo *subagging* exige a definição de um parâmetro adicional, além do número de replicações. Enquanto no *bagging* o tamanho das amostras *bootstrap* permanece constante e igual ao conjunto original, no *subagging* esse tamanho é variável. Para analisar a sensibilidade do *subagging*, o estudo conduz um experimento com 16 amostras *bootstrap*, cujos resultados são apresentados na Figura 8.

Observa-se nas Figuras 8a e 8b que o *subagging* apresenta sensibilidade ao número de amostras *bootstrap* utilizadas no algoritmo. Para a predição do Mn, o número ideal de amostras *bootstrap* é 5, resultando em RMSEP de 0,023. Para a predição do Fe, o número ideal de amostras *bootstrap* também é 8, com RMSEP de 1,561, observando-se uma ligeira piora acima

Figura 8 – RMSEP em função das replicações *bootstrap* para RLM-*subagging*.



(a) Erros encontrados para cada replicação do Mn variando a quantidade de amostras *bootstrap*.

(b) Erros encontrados para cada replicação do Fe variando a quantidade de amostras *bootstrap*.

Fonte: elaborado pelo autor.

desse valor.

Tabela 8 – RMSEP da RLM e RLM-*subagging* para as amostras de aço-ligas.

RMSEP	Mn	Mo	Cr	Ni	Fe
RLM	0,1051	0,2633	1,0798	1,6043	2,7513
RLM-*subagging*	$0{,}0974^{*5}$	$0{,}2821^{*16}$	$1{,}1616^{*12}$	$1{,}6003^{*10}$	$2{,}7302^{*8}$

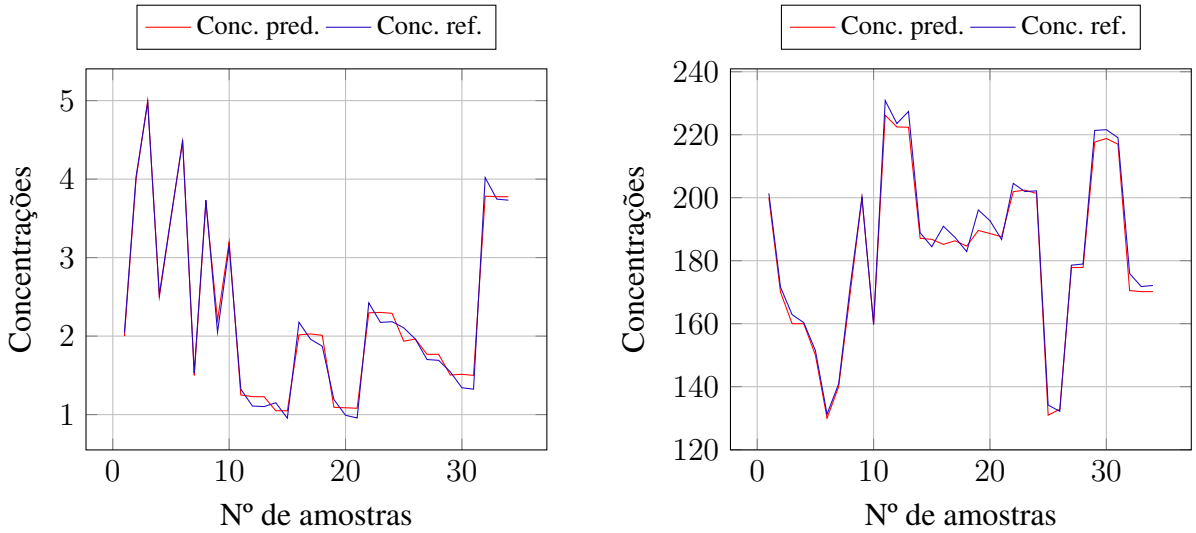
* números de *bootstrap* utilizadas.

Fonte: elaborado pelo autor.

A Tabela 8 mostra o erro do RLM-*subagging* comparado com o erro da RLM tradicional. O RLM-*subagging* apresentou melhorias para três dos cinco analitos testados: Mn (redução de 7,33%), Ni (redução de 0,25%) e Fe (redução de 0,77%). Para Mo e Cr, houve aumento do erro de 7,14% e 7,58%, respectivamente. Em média, considerando todos os analitos, o RLM-*subagging* apresentou desempenho praticamente equivalente ao da RLM tradicional, com variação média de apenas 1,27% no RMSEP.

A Figura 9 mostra o comportamento do RMSEP com RLM-*subagging*. Nas Figuras 9a e 9b, é possível observar as predições dos elementos Mn e Fe.

Figura 9 – RMSEP do Mn e Fe com *subagging*.



(a) RMSEP do Mn com RLM-*subagging*.

(b) RMSEP do Fe com RLM-*subagging*.

Fonte: elaborado pelo autor.

Tabela 9 – Comparação do RMSEP das técnicas para 50% e 80% de calibração.

Técnica/Proporção		Mn	Mo	Cr	Ni	Fe
RLM	50%	0,2029	1,5651	0,7215	28,4381	3,2962
	80%	0,1119	0,2546	1,0978	1,5865	2,5795
RLM-*bagging*	50%	0,1742	0,7338	1,4512	28,1847	5,9944
	80%	0,1142	0,3337	1,1661	1,3281	2,5367
RLM-*subagging*	50%	0,2205	0,5944	1,8984	28,0398	7,2990
	80%	0,1108	0,2809	1,1807	1,3724	2,4871

Fonte: elaborado pelo autor.

Em geral, a utilização da proporção de calibração de 80% resultou em desempenho superior (menor RMSEP) para a grande maioria dos casos analisados. Para RLM-*bagging* e RLM-*subagging*, a proporção de 80% foi superior em todos os cinco elementos. Para a RLM clássica, a proporção de 80% foi melhor em quatro dos cinco elementos (Mn, Mo, Ni e Fe), sendo a única exceção o Cr, onde 50% de calibração produziu menor RMSEP (0,7215 contra 1,0978). Um conjunto de dados de treinamento maior, como esperado teoricamente, contribui para modelos mais robustos e com melhor capacidade de generalização.

Quanto ao melhor desempenho absoluto por elemento, o RLM-*subagging* com 80% de calibração obteve o menor RMSEP para Mn (0,1108) e Fe (2,4871), a RLM com 80% obteve o menor erro para Mo (0,2546), o RLM-*bagging* com 80% para Ni (1,3281), e a RLM com 50% para Cr (0,7215).

A técnica que atingiu o menor RMSEP varia conforme o elemento, destacando que não há uma solução única para todos os casos:

Tabela 10 – RMSEP Mínimo e a Configuração de Desempenho Superior.

Elemento	**Menor RMSEP**	**Técnica de Desempenho Superior**	**Proporção**
Mn	0,1108	RLM	80%
Mo	0,2546	RLM	80%
Cr	**0,7215**	RLM-*subagging*	50%
Ni	1,3281	RLM	80%
Fe	**2,4871**	RLM-*subagging*	80%

Fonte: elaborado pelo autor.

a) RLM (Clássico): Obteve a melhor performance para Mo ($0{,}2546$ com 80% de calibração) e Cr ($0{,}7215$ com 50% de calibração). Para estes elementos, a relação preditiva é relativamente simples e linear, não requerendo a complexidade adicional dos métodos de *ensemble*.

b) RLM-*bagging*: Demonstrou superioridade para Ni, atingindo $1{,}3281$ com 80% de calibração, superando a RLM ($1{,}5865$) e o RLM-*subagging* ($1{,}3724$).

c) RLM-*subagging*: Obteve o melhor desempenho para Mn ($0{,}1108$ com 80% de calibração) e Fe ($2{,}4871$ com 80% de calibração). Estes resultados indicam que estes elementos se beneficiam da agregação de modelos com subamostragem para reduzir a variância das predições.

As técnicas de ensemble (RLM-*bagging* e RLM-*subagging*) são construídas através da agregação de m modelos individuais, gerados por *bootstrap*. O RMSEP final é determinado pela média das previsões desses m modelos. O desafio na aplicação destas técnicas é otimizar o parâmetro $m \in \{5, 10, 20, 50\}$ para encontrar o ponto onde a redução da variância é maximizada sem desperdiçar recursos computacionais.

Os menores RMSEP reportados na Tabela 9 para as técnicas de *ensemble* são resultados diretos da otimização de m dentro do conjunto testado:

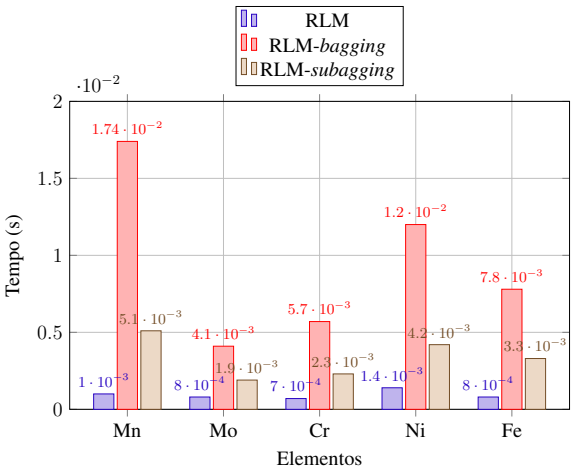
a) Para Mn e Fe, onde o RLM-*subagging* foi o vencedor absoluto, os valores ótimos de m foram $m = 5$ e $m = 8$, respectivamente. Estes valores relativamente baixos sugerem que poucos modelos agregados já foram suficientes para estabilizar e reduzir o erro preditivo, superando a performance do RLM clássico. Para Ni, o RLM-*bagging* com $m = 17$ obteve o menor RMSEP ($1{,}3281$).

b) Para Mo e Cr, nenhuma técnica de *ensemble* superou a RLM clássica, independentemente do valor de m utilizado. Isso indica que, para estes elementos, a agregação de modelos introduz mais variância do que reduz, e a relação preditiva linear simples é mais adequada.

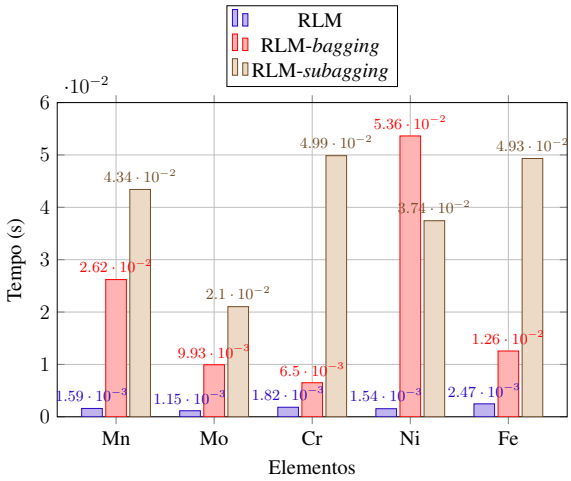
Em síntese, a análise demonstra que a escolha ideal do modelo não é apenas uma questão da técnica, mas também da proporção de calibração e, criticamente, da otimização do número de replicações (m) nas abordagens de *ensemble* para cada elemento químico.

Figura 10 – Tempo de execução dos algoritmos RLM, RLM-*bagging* e RLM-*subagging*.

(a) 50% das amostras



(b) 80% das amostras



Fonte: elaborado pelo autor.

A análise dos tempos de execução apresentados na Figura 10 revela diferenças significativas entre os três algoritmos avaliados: RLM clássico, RLM-*bagging* e RLM-*subagging*. Os experimentos foram conduzidos utilizando 50% e 80% das amostras disponíveis para cada elemento químico analisado (Mn, Mo, Cr, Ni e Fe).

A comparação entre os dois cenários revela comportamentos distintos de crescimento temporal conforme o aumento do tamanho do conjunto de treinamento. Para o RLM clássico, o aumento médio foi de aproximadamente 2,0 vezes, com variação considerável entre elementos (1,1× para Ni até 3,1× para Fe). O RLM-*bagging* apresentou um aumento médio de cerca de 2,2 vezes, com comportamento igualmente heterogêneo entre os analitos.

O comportamento mais acentuado foi observado no RLM-*subagging*, que apresentou um aumento médio de aproximadamente 13,0 vezes no tempo de execução ao passar de 50% para 80% das amostras, com variações entre 8,5× (Mn) e 21,7× (Cr). Este crescimento expressivo reflete a sensibilidade do algoritmo de subamostragem ao tamanho do conjunto de treinamento, uma vez que os parâmetros ótimos m^* e k^* requerem um número substancialmente maior de iterações para conjuntos maiores.

Em termos absolutos, com 80% das amostras, o RLM-*bagging* mostrou-se em média 1,7 vezes mais rápido que o RLM-*subagging*, invertendo a relação de eficiência computacional observada no cenário com 50% das amostras. Esse resultado indica que a vantagem temporal do RLM-*subagging* não se mantém com o aumento do tamanho amostral, devendo ser considerada na escolha da técnica em aplicações com conjuntos de dados maiores.

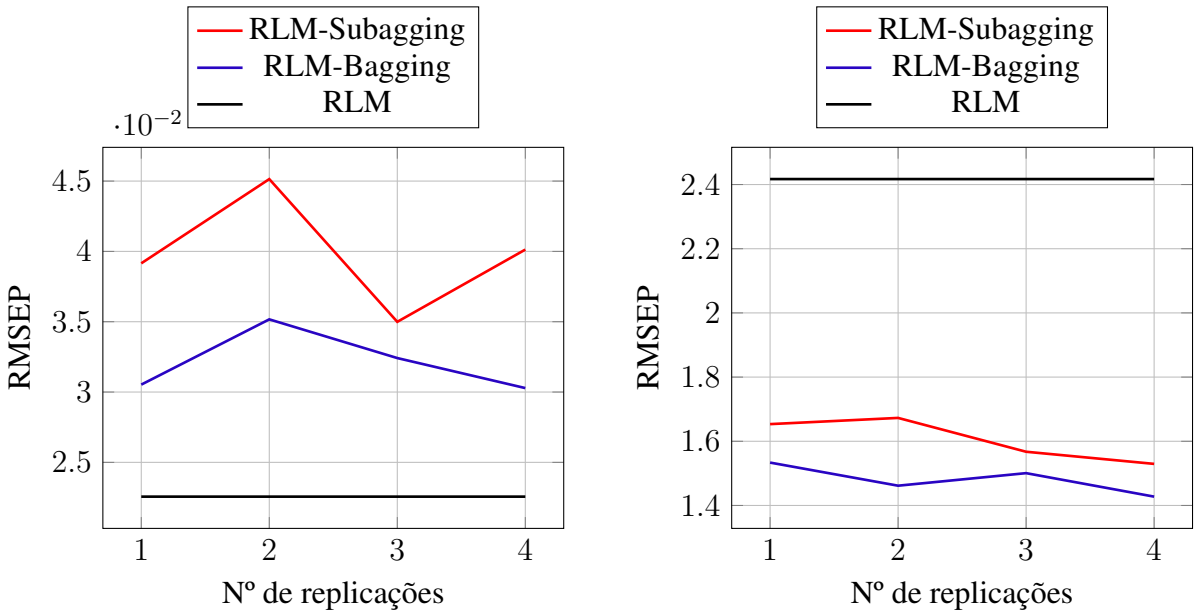
4.4 *BAGGIN* × *SUBAGGING*

Os valores de RMSEP apresentados na (Tabela 11) diferem dos reportados na (Tabela 7) porque esta última apresenta resultados com número fixo de *bootstraps* sem otimização, enquanto a (Tabela 11) adota parâmetros otimizados por validação cruzada 5-*fold* e incorpora as três técnicas comparativamente com métricas ampliadas.

Com a implementação do *bagging* e do *subagging*, observou-se melhora das predições obtidas com a RLM para alguns analitos específicos. O RLM-*bagging* apresentou melhor desempenho para Mo e Fe, enquanto o RLM-*subagging* mostrou-se superior apenas para Cr. Contudo, para Mn e Ni, a RLM clássica manteve os menores valores de RMSEP, indicando que as técnicas ensemble nem sempre garantem melhoria. Dessa forma, é importante comparar o desempenho do RLM-*bagging* e RLM-*subagging* considerando as características específicas de cada analito.

Análises específicas da técnica RLM-*bagging* demonstraram melhorias significativas para determinados analitos, particularmente Mo e Fe, enquanto o RLM-*subagging* apresentou desempenho superior apenas para Cr. Os percentuais de melhoria variam consideravelmente entre analitos, conforme os resultados apresentados nas Tabelas 7 e 8. Para avaliar comparativamente o desempenho dessas técnicas, foi feita uma predição com o RLM-*bagging* e RLM-*subagging*, utilizando o mesmo conjunto de amostras *bootstrap*, no intuito de comparar os erros de predição das duas técnicas apresentadas na Figura 11.

Figura 11 – RMSEP para todas as técnicas



(a) RMSEP obtido com as três técnicas aplicadas ao Mn.

(b) RMSEP obtido com as três técnicas aplicadas ao Fe.

Fonte: elaborado pelo autor.

A RLM clássica gera uma única predição, enquanto tanto o RLM-*bagging* quanto o RLM-*subagging* utilizam múltiplas reamostragens para produzir predições agregadas. Na análise

comparativa, o RLM-*subagging* foi avaliado com diferentes quantidades de amostras *bootstrap*, gerando um conjunto de 16 predições, sendo uma para cada quantidade de *bootstrap* testada. A Tabela 11 apresenta os resultados dessa comparação direta entre as técnicas, utilizando o mesmo conjunto de dados de validação. Observa-se que a RLM clássica mantém desempenho superior para Mn, Mo e Ni, enquanto o RLM-*subagging* apresenta melhor resultado apenas para Cr em relação ao RLM-*bagging*. Os resultados desta comparação são também apresentados nas Figuras 11a e 11b.

Tabela 11 – Desempenho comparativo das técnicas de calibração multivariada para elementos químicos em aço-liga.

Elemento	Técnica	RMSEP	MAE	R^2	Tempo	Parâmetros
Mn	RLM	0,1051	0,0887	0,9907	2,4 ms	—
	RLM-*bagging*	0,1072	0,0908	0,9903	68,2 ms	$m^* = 30$
	RLM-*subagging**	**0,0966**	**0,0805**	**0,9922**	17,1 ms	$k^* = 80\%, m^* = 10$
Mo	RLM*	**0,2633**	**0,1952**	**0,9882**	2,4 ms	—
	RLM-*bagging*	0,3388	0,2722	0,9805	67,5 ms	$m^* = 30$
	RLM-*subagging*	0,2879	0,2201	0,9859	46,8 ms	$k^* = 80\%, m^* = 30$
Cr	RLM*	**1,0798**	**0,8654**	**0,9938**	2,5 ms	—
	RLM-*bagging*	1,2089	0,9830	0,9922	44,5 ms	$m^* = 20$
	RLM-*subagging*	1,1294	0,9010	0,9932	46,8 ms	$k^* = 80\%, m^* = 30$
Ni	RLM	1,6043	1,3256	0,9837	2,3 ms	—
	RLM-*subagging**	**1,6003**	**1,2409**	**0,9838**	10,6 ms	$k^* = 60\%, m^* = 10$
	RLM-*bagging*	1,7085	1,4122	0,9815	66,6 ms	$m^* = 30$
Fe	RLM	2,7513	2,1865	0,9892	13,5 ms	—
	RLM-*bagging**	**2,6406**	**2,0246**	**0,9900**	97,2 ms	$m^* = 30$
	RLM-*subagging*	2,6509	2,0578	0,9900	41,2 ms	$k^* = 80\%, m^* = 30$

* Melhor desempenho em RMSEP. Parâmetros m^* (número de replicações *bootstrap*) e k^* (fração de subamostra) otimizados por validação cruzada 5-*fold* aplicada exclusivamente ao conjunto de calibração (*seed* = 42). O conjunto de teste foi utilizado uma única vez para avaliação final.

Fonte: elaborado pelo autor.

Os resultados comparativos entre as três técnicas avaliadas para todos os analitos são apresentados na Tabela 11. Diferentemente da análise anterior, os parâmetros m^* e k^* de cada método foram determinados por validação cruzada 5-*fold* aplicada exclusivamente ao conjunto de calibração, garantindo que o conjunto de teste não influenciasse a seleção dos hiperparâmetros e assegurando a comparabilidade entre os métodos.

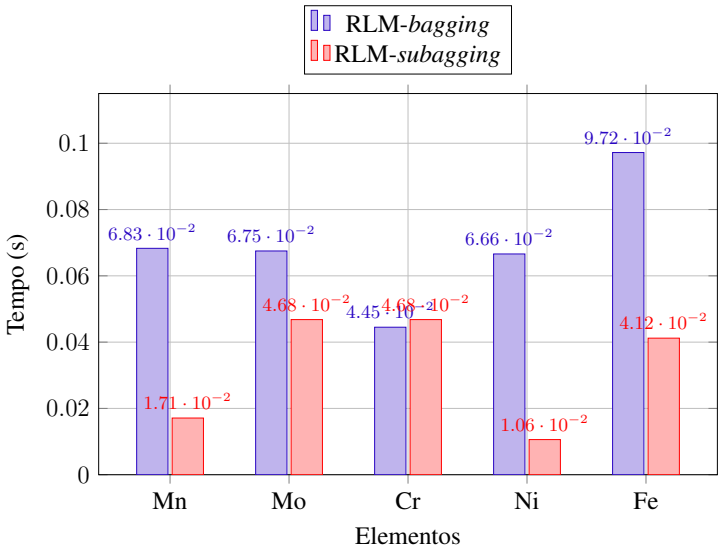
Os resultados revelam que não existe uma técnica universalmente superior para todos os analitos. Para o Manganês (Mn), o RLM-*subagging* ($k^* = 80\%$, $m^* = 10$) apresentou o menor RMSEP (0,0966), representando uma redução de 8,1% em relação à RLM clássica, além de ser 4,0 vezes mais rápido que o RLM-*bagging*. Para o Ferro (Fe), o RLM-*bagging* ($m^* = 30$) obteve o melhor desempenho (RMSEP = 2,6406), com melhoria de 4,0% sobre a RLM clássica. Para o Níquel (Ni), o RLM-*subagging* ($k^* = 60\%$, $m^* = 10$) apresentou resultado marginalmente superior (RMSEP = 1,6003), com diferença de 0,25% em relação à RLM clássica e tempo de

execução 6,3 vezes menor que o RLM-*bagging*.

Em contrapartida, para o Molibdênio (Mo) e o Cromo (Cr), a RLM clássica demonstrou desempenho superior (RMSEP de 0,2633 e 1,0798, respectivamente), indicando que a complexidade adicional introduzida pelas estratégias de *ensemble* não resultou em melhorias significativas de precisão para esses analitos. Esses resultados sugerem que a relação preditiva para Mo e Cr é suficientemente linear, não se beneficiando da agregação de modelos.

A análise do custo computacional evidencia que o RLM-*subagging* configura-se como alternativa balanceada entre precisão e eficiência, sendo consistentemente mais rápido que o RLM-*bagging* para todos os elementos avaliados. Observa-se ainda que o parâmetro $k^* = 80\%$ revelou-se ótimo para o *subagging* em quatro dos cinco elementos, sugerindo que subamostras maiores favorecem a estabilidade do modelo neste contexto específico de dados espectrométricos de aço-ligas.

Figura 12 – Tempo de execução dos algoritmos RLM-*bagging* e RLM-*subagging* com parâmetros otimizados por validação cruzada 5-*fold*.



Fonte: elaborado pelo autor.

A Figura 12 apresenta os tempos de execução dos algoritmos RLM-*bagging* e RLM-*subagging* para cada elemento, utilizando os parâmetros m^* e k^* determinados por validação cruzada 5-*fold*. Diferentemente da análise anterior, os parâmetros agora variam por elemento — refletindo configurações objetivamente otimizadas —, o que torna a comparação de tempos diretamente atrelada ao custo real de cada configuração de melhor desempenho preditivo.

Em quatro dos cinco elementos avaliados (Mn, Mo, Ni e Fe), o RLM-*subagging* mostrou-se mais rápido que o RLM-*bagging*. Em média, o RLM-*subagging* é aproximadamente 3,0 vezes mais rápido, representando uma redução de 66,7% no tempo de execução. As maiores diferenças ocorreram para o Ni (6,3 vezes mais rápido, com $k^* = 60\%$ e $m^* = 10$) e para o Mn (4,0 vezes mais rápido, com $k^* = 80\%$ e $m^* = 10$). Para Mo e Fe, as reduções foram de 1,4 e 2,4 vezes, respectivamente. Essa eficiência decorre da amostragem sem reposição, que emprega

subconjuntos de tamanho reduzido ($k^* \leq 80\%$), resultando em operações matriciais mais ágeis e menor redundância nos dados processados a cada iteração.

O Cromo (Cr) constitui o único caso em que o RLM-*subagging* apresentou tempo marginalmente superior ao RLM-*bagging* (46,8 ms contra 44,5 ms, diferença de apenas 2,3 ms). Esse comportamento é explicado pelos parâmetros ótimos obtidos pela validação cruzada: o RLM-*bagging* utilizou $m^* = 20$ replicações, enquanto o RLM-*subagging* requereu $m^* = 30$ replicações com $k^* = 80\%$ para atingir o menor *Root-Mean-Square Error of Prediction in Cross-Validation* (RMSEP-CV). O maior número de iterações compensou o benefício da subamostragem, resultando em custo computacional equivalente para este analito específico.

O desempenho superior das técnicas de ensemble para Fe e Cr pode ser atribuído à complexidade espectral desses elementos. O Fe, como elemento matriz, apresenta espectro de alta densidade com potencial de autoabsorção, enquanto o Cr sofre sobreposições com linhas do Fe e Ni. Essas características introduzem não-linearidades e instabilidade no modelo base, condições nas quais a agregação de múltiplos modelos é teoricamente vantajosa. Para Mn e Mo, cujas linhas analíticas apresentam menor interferência matricial, a relação espectral-concentração é suficientemente bem capturada pela RLM clássica.

Em relação à RLM clássica, ambas as técnicas de *ensemble* apresentam custo computacional significativamente superior, com o RLM-*bagging* sendo em média 21,9 vezes mais lento e o RLM-*subagging* até 19,4 vezes mais lento (para o Mo). Ainda assim, para aplicações em que a acurácia preditiva justifica o custo computacional adicional — como na determinação de Mn e Fe em aço-ligas — o RLM-*subagging* configura-se como alternativa equilibrada entre precisão e eficiência, sendo preferível ao RLM-*bagging* na maioria dos cenários avaliados.